Universität Bonn

Mitschrift zur Vorlesung

Algorithmische Grundlagen des maschinellen Lernens

gehalten von

Prof. Dr. Anne Driemel

geTEXed von

Daniel Emse

Sommer 2026

Anmerkungen und Korrekturen

Falls du Anmerkungen/Korrekturen hast, melde dich bei mir (`daniel.emse@uni-bonn.de`).

Inhaltsverzeichnis

Vorlesung **1**

0 Einführung **2**
0.1 Binäre Klassifikation 2
0.1.1 Lernen von Schwellenwertfunktionen 4
0.1.2 PAC-Lernbarkeit 5
0.1.3 Lernen von Intervallen 5

Anhang **A**

Liste der Definitionen **B**

Liste der Aussagen **C**

Liste der Algorithmen **D**

Liste der Abkürzungen **E**

Index **F**

Vorlesung

Kapitel 0

Einführung

[14.04.2026, Vorlesung 1]

0.1 Binäre Klassifikation

Beispiel 0.1.

- SPAM oder noSPAM für E-Mails
- Hund oder kein Hund für Fotos

Wir haben also immer die **Labels** *positiv* oder *negativ* für solche **Instanzen**.

Definition 0.2: Merkmalsraum

Ein *Merkmalsraum* X ist eine Menge, die eindeutig alle zu untersuchenden Instanzen eines Problems darstellt.

Beispiel 0.3.

- Für die SPAM-Klassifikation könnten wir beispielsweise folgendermaßen klassifizieren:
  1. X ist die Menge aller Strings in UTF-8 Unicode-Codierung
  2. X ist eine Menge von Vektoren, also $X \subseteq \mathbb{Z}^d_{\geq 0}$, wobei ein Vektor aus X angibt, ob und wie häufig bestimmte Wörter in der E-Mail vorkommen. Dabei sind beispielsweise Wörter wie *price*, *winner* oder ähnliches Teile des *bag of words*, und ihnen ist ein Index $\in \{1, \dots, d\}$ zugeordnet. Der entsprechende Vektor zählt also diese Häufigkeiten
- Für die Image-Klassifikation könnten wir beispielsweise folgendermaßen klassifizieren:
  1. X ist die Menge aller Bilder in RGB-Pixeldarstellung mit fester Auflösung, fester Größe und fester Farbtiefe (beispielsweise 1 Megapixel, 24 bit Farbtiefe führen zu $|X| = \left(2^{24}\right)^{10^6}$, das ist tatsächlich sehr groß)
  2. X ist eine Menge von Vektoren, also $X \subseteq \mathbb{Z}^d_{\geq 0}$, wobei ein Vektor aus X angibt, ob und wie häufig bestimmte *SIFT descriptors* vorkommen

Letztendlich suchen wir eine *Hypothese* $h : X \to \{1, -1\}$, sodass

$$h(x) = \begin{cases} 1 & x \text{ ist SPAM/Hund/}\dots \\ -1 & \text{sonst.} \end{cases}$$

Definition 0.4: Hypothesenklasse

Eine *Hypothesenklasse* $\mathcal{H}$ ist eine Menge von Funktionen $X \to \{1, -1\}$.

Beispiel 0.5. Wir betrachten einige Beispiele für $\mathcal{H}$.

- Es könnte $\mathcal{H} = \{f : X \to \{1, -1\}\}$ sein, also einfach *alle* solche Funktionen beinhalten.

  Nachteil: Wir haben zu wenig Struktur.
- Sei $X = \mathbb{R}$ und $\mathcal{H} = \{h_a \mid a \in \mathbb{R}\}$, wobei

$$h_a(x) = \begin{cases} 1 & x \geq a \\ -1 & x < a. \end{cases}$$

- Sei X die Menge aller Bilder und $\mathcal{H}$ die Menge aller Hypothesen h_w, die einem neuronalen Netz mit fester Architektur und einem Gewichtsvektor w entsprichen.

Wie wählen wir nun also unsere Hypothesen aus? Was macht eine gute Hypothese aus?

Definition 0.6: Grundwahrheit

Die *Grundwahrheit* f ist eine Funktion $f : X \to \{1, -1\}$. Wenn dieses f existiert, weist f jedem $x \in X$ das korrekte Label zu.

Wir nehmen an, dass so ein f existiert.

Ziel: Finde eine Hypothese h, die f möglichst nahe kommt.

Wir nehmen an, dass m Datenpunkte (*Instanzen*) aus einer Wahrscheinlichkeitsverteilung $\mathcal{D}$ über X gezogen werden. Diese nennen wir *Sample*.

Definition 0.7: Diskrete Wahrscheinlichkeitsverteilung

Eine *diskrete Wahrscheinlichkeitsverteilung* $\mathcal{D}$ über X ist definiet über ein *Wahrscheinlichkeitsmaß* $\mathbb{P} : X \to [0, 1]$, wobei $\mathbb{P}(x) \neq 0$ nur für abzählbar viele Punkte gelten soll und

$$\sum_{x \in X} \mathbb{P}(x) = 1$$

gelten soll.

Beispiel 0.8. Sei $X = \mathbb{R}$ und $\mathbb{P}(x) = \begin{cases} \frac{1}{100} & x \in \{1, \ldots, 100\} \\ 0 & \text{sonst} \end{cases} = \mathbb{1}_{\{1,\ldots,100\}}(x)$.

Definition 0.9: Tatsächlicher Fehler

Der *tatsächliche Fehler* $\mathrm{err}_{\mathcal{D},f}(h)$ einer Hypothese h hinsichtlich Verteilung $\mathcal{D}$ über Merkmalsraum X und Grundwahrheit f ist

$$\mathrm{err}_{\mathcal{D},f}(h) := \mathbb{P}_{x \sim \mathcal{D}}[h(x) \neq f(x)].$$

Beispiel 0.10. Es sei $f(x) = h_{30}$ und $h(x) = h_{50}$. Dann ist

$$\mathrm{err}_{\mathcal{D},f}(h) = \frac{|\{30, \ldots, 49\}|}{|\{1, \ldots, 100\}|} = \frac{20}{100} = \frac{1}{5}.$$

Problem 0.11: Lernproblem

Input: m Datenpunkte $x_1, \ldots, x_m$, die *unabhängig und identisch verteilt (independent and identically distributed, iid)* aus $\mathcal{D}$ gezogen sind, und $y_1 = f(x_1), \ldots, y_m = f(x_m)$ (die *korrekten* Labels). Sei $S = \{(x_1, y_1), \ldots, (x_m, y_m)\}$ die Menge der Samples also gegeben
Output: Hypothese $h_S \in \mathcal{H}$
Objective: $\mathrm{err}_{\mathcal{D},f}(h_S)$ möglichst klein

Definition 0.12: Trainingsfehler

Der *Trainingsfehler* $\mathrm{err}_S(h)$ einer Hypothese $h \in \mathcal{H}$ hinsichtlich einer Trainingsmenge S ist

$$\mathrm{err}_S(h) := \frac{1}{m}|\{h(x_i) \neq y_i\}|.$$

[14.04.2026, Vorlesung 1]
[16.04.2026, Vorlesung 2]

0.1.1 Lernen von Schwellenwertfunktionen

Sei im Folgenden $X = \mathbb{R}$ unser Merkmalsraum.

In diesem Beispiel und auch im Folgenden vereinfachen wir uns das Leben durch die Annahme, dass die Grundwahrheit *realisierbar* ist. Das heißt, dass $f \in \mathcal{H}$. Wir werden unsere Theorie später verallgemeinern, dass sie auch ohne diese Annahme auskommt. Wir nehmen also an, dass es ein $a \in \mathbb{R}$ gibt, sodass die Grundwahrheit $f : X \to \{-1, 1\}$ gegeben ist durch

$$f(x) = \begin{cases} 1 & x \geq a \\ -1 & \text{sonst.} \end{cases}$$

Wir nehmen an, dass uns m Datenpunkte mit korrekten Labels gegeben sind: Seien $x_1, \ldots, x_m$ Datenpunkte, die iid aus $\mathcal{D}$ gezogen sind. Außerdem seien $y_i = f(x_i)$ die zugehörigen, korrekten Labels. Die Menge aller Samples bezeichnen wir mit $S = \{(x_1, y_1), \ldots, (x_m, y_m)\}$.

Ein einfacher Lernalgorithmus wählt nun das größte a', sodass $h_{a'}$ die Menge S korrekt klassifiziert. Das heißt, wir setzen a' auf den Wert des kleinsten x_i mit $y_i = 1$, wenn es ein solches gibt. Anderenfalls $a' = \infty$.

Satz 0.13: Abschätzung tatsächlicher Fehler des einfachen Lernalgorithmus

Sei $h_{a'}$ die vom einfachen Lernalgorithmus berechnete Hypothese, der als Eingabe eine Menge von Samples von m Datenpunkten mit korrekten Labels gemäß f erhält, die iid aus $\mathcal{D}$ gezogen werden. Dann gilt für alle $\varepsilon > 0$, dass

$$\mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_{a'}) > \varepsilon] \leq e^{-\varepsilon m}.$$

Beweis. Weil unser Lernalgorithmus unter allen Hypothesen, die S korrekt klassifizieren, die Hypothese $h_{a'}$ mit dem größten a' wählt, wird auf jeden Fall gelten, dass $a' \geq a$. Falsch klassifiziert werden alle Punkte im Bereich $[a, a')$. Somit gilt nun für jede Verteilung $\mathcal{D}$

$$\mathrm{err}_{\mathcal{D},f}(h_{a'}) = \mathbb{P}_{x\sim\mathcal{D}}[x \in (a, a']].$$

Sei nun $a'' \geq a$ die kleinste Zahl, sodass $\mathbb{P}_{x\sim D}[x \in (a, a'')] \geq \varepsilon$. Es könnte sein, dass a'' nicht existiert, weil $\mathbb{P}_{x\sim\mathcal{D}}[x \in [a, \infty)] < \varepsilon$. Dann ist aber die Wahrscheinlichkeit, dass der Fehler $\mathrm{err}_{\mathcal{D},f}(h_{a'})$ den Wert ε überschreitet, gleich null, und die Aussage des Satzes gilt trivialerweise.

Es bleibt zu zeigen, dass die Aussage des Satzes auch dann gilt, wenn $\mathcal{D}$ dergestalt ist, dass $\mathbb{P}_{x\sim D}[x \in [a,\infty)] \geq \varepsilon$ und somit a'' wohldefiniert ist. Damit muss auch gelten $\mathbb{P}_{x\sim D}[x \in (a,a'']] \leq \varepsilon$. Der Fehler von $h_{a'}$ wird also höchstens ε sein, falls $a' \leq a''$. Dies geschieht, wenn es mindestens ein i gibt, sodass $x_i \in [a,a'']$. Sei $\mathcal{E}_i$ das Ereignis, dass $x_i \in [a,a'']$. Es gilt $\mathbb{P}[\mathcal{E}_i] = \mathbb{P}_{x_i\sim\mathcal{D}}[x_i \in [a,a'']] \geq \varepsilon$. Damit *nicht* $a' \leq a''$ gilt, darf keines der Ereignisse $\mathcal{E}_i$ eintreten. Wir interessieren uns also für $\bigcap_i \overline{\mathcal{E}_i}$. Weil $x_1,\ldots,x_m$ unabhängige Züge aus $\mathcal{D}$ sind, gilt nun auch

$$\mathbb{P}\left[\bigcap_i \overline{\mathcal{E}_i}\right] = \prod_i \mathbb{P}[\overline{\mathcal{E}_i}] \leq (1-\varepsilon)^m.$$

Mit $1-x \leq e^{-x}$ für alle $x \in \mathbb{R}$ folgt die Behauptung. □

0.1.2 PAC-Lernbarkeit

Satz 0.13 sagt uns nun insbesondere, dass wenn wir $m = \frac{1}{\varepsilon}\ln\left(\frac{1}{\delta}\right)$ wählen, die Wahrscheinlichkeit, dass der tatsächliche Fehler unserer gefundenen Hypothese größer als ε ist, kleiner als δ wird.

Diese Aussage gilt für alle $\varepsilon > 0$ und alle $\delta > 0$. Wenn die Anzahl der Samples also nur groß genug ist, werden wir mit großer Wahrscheinlichkeit nur einen sehr kleinen Fehler haben. Die Hypothesenklassen, für die dies gilt, heißen *probably approximately correct (PAC)-lernbar*:

Definition 0.14: PAC-Lernbarkeit

Eine Hypothesenklasse $\mathcal{H}$ heißt *PAC-lernbar* (im realisierbaren Sinn), wenn es eine Funktion $m_{\mathcal{H}}$ und einen Lernalgorithmus $\mathcal{A}$ gibt, sodass A für alle $\varepsilon,\delta > 0$ jede Verteilung $\mathcal{D}$ und alle $f \in \mathcal{H}$, gegeben ein Sample S von Größe mindestens $m_{\mathcal{H}}(\varepsilon,\delta)$ von Datenpunkten mit korrekten Labels, eine Hypothese $h_S \in \mathcal{H}$ berechnet, sodass

$$\mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_S) < \varepsilon] \geq 1-\delta.$$

PAC-Lernbarkeit nach dieser Definition impliziert nicht unbedingt, dass das Lernproblem effizient lösbar ist. Man spricht von *effizienter PAC-Lernbarkeit*, wenn die Laufzeit von $\mathcal{A}$ polynomiell ist und außerdem gilt, dass $m_{\mathcal{H}}(\varepsilon,\delta)$ polynomiell in $\frac{1}{\varepsilon}$ und $\frac{1}{\delta}$ beschränkt ist.

PAC steht für *probably approximately correct*. Dabei bedeutet *probably* in diesem Fall, dass die Wahrscheinlichkeit mindestens $1-\delta$ ist, und *approximately correct* bezieht sich darauf, dass $\mathrm{err}_{\mathcal{D},f}(h_S) < \varepsilon$.

Nicht jede Hypothesenklasse ist PAC-lernbar. Zum Beispiel ist die Klasse aller Hypothesen $\mathbb{N} \to \{-1,1\}$ nicht PAC-lernbar, was wir noch beweisen werden.

0.1.3 Lernen von Intervallen

Wir betrachten als weiteres Beispiel nun die Klasse der Intervallfunktionen. Weiterhin sei $X = \mathbb{R}$, aber $\mathcal{H}$ sei nun die Menge der Funktionen der Form$h_{a',b'} : \mathbb{R} \to \{-1,1\}$ mit

$$h_{a',b'} = \begin{cases} 1 & x \in [a',b'] \\ -1 & \text{sonst.} \end{cases}$$

Wir betrachten weiterhin den realisierbaren Fall. Das heißt, es gibt eine Grundwahrheit $f \in \mathcal{H}$, die alle Datenpunkte richtig klassifiziert. Diese hat die Form

$$f(x) = \begin{cases} 1 & x \in [a,b] \\ -1 & \text{sonst.} \end{cases}$$

Gegeben ist wieder eine Menge $S = \{(x_1, y_1), \ldots, (x_m, y_m)\}$ von Datenpunkten mit korrekten Labels. Unser Lernalgorithmus wählt das kleinste Intervall $[a', b']$, das S korrekt klassifiziert. Das heißt, wir setzen a' auf den Wert des kleinsten x_i mit $y_i = 1$ und b' auf den Wert des größten x_i mit $y_i = 1$.

Den Fall, dass es kein i mit $y_i = 1$ gibt, schieben wir ab in die Übung und ignorieren ihn.

Satz 0.15: Abschätzung tatsächlicher Fehler Intervalllernen

Für alle $\varepsilon > 0$ gilt

$$\mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_{a',b'}) > \varepsilon] \leq 2e^{-\frac{\varepsilon m}{2}}.$$

Lemma 0.16: Union Bound

Es seien $\mathcal{E}_1, \ldots, \mathcal{E}_n$ (nicht notwendigerweise disjunkte) Ereignisse. Dann gilt

$$\mathbb{P}\left[\bigcup_{i=1}^{n} \mathcal{E}_i\right] \leq \sum_{i=1}^{n} \mathbb{P}[\mathcal{E}_i].$$

Beweis. Induktives Anwenden von $\mathbb{P}[A \cup B] = \mathbb{P}[A] + \mathbb{P}[B] - \mathbb{P}[A \cap B] \leq \mathbb{P}[A] + \mathbb{P}[B]$. □

Beweis von Satz 0.15. Weil unser Lernalgorithmus das kleinste Intervall wählt, welches S korrekt klassifiziert, wird auf jeden Fall gelten, dass $a' \geq a$ und $b' \leq b$. Falsch klassifiziert werden alle Punkte im Bereich $[a, a') \cup (b', b]$. Somit gilt nun für jede Verteilung $\mathcal{D}$

$$\mathrm{err}_{\mathcal{D},f}(h_{a',b'}) = \mathbb{P}_{x\sim\mathcal{D}}[x \in [a, a') \cup (b', b]].$$

Analog zu oben betrachten wir den Fall, dass $\mathbb{P}_{x\sim\mathcal{D}}[x \in [a, b]] < \varepsilon$. In diesem Fall ist die Wahrscheinlichkeit, dass der Fehler $\mathrm{err}_{\mathcal{D},f}(h_{a',b'})$ den Wert ε überschreitet, wieder gleich null, und die Aussage des Satzes gilt trivialerweise.

Es bleibt zu zeigen, dass die Aussage des Satzes auch dann gilt, wenn $\mathcal{D}$ dergestalt ist, dass $\mathbb{P}_{x\sim D}[x \in [a, b]] \geq \varepsilon$. Sei nun, ähnlich wie oben, $a'' \in [a, b]$ die kleinste Zahl, sodass $\mathbb{P}_{x\sim D}[x \in [a, a'']] \geq \frac{\varepsilon}{2}$. Analog sei $b'' \in [a, b]$ die größte Zahl, sodass $\mathbb{P}_{x\sim\mathcal{D}}[x \in [b'', b]] \geq \frac{\varepsilon}{2}$. Damit $\mathrm{err}_{\mathcal{D},f}(h_{a',b'}) \leq \varepsilon$, ist es nun hinreichend, dass $a' \leq a''$ und $b' \geq b''$. Dies geschieht, wenn es mindestens ein i und mindestens ein j gibt, sodass $x_i \in [a, a'']$ und $x_j \in [b'', b]$ wobei i und j nicht verschieden sein müssen. Für jedes i gilt

$$\mathbb{P}[x_i \in [a, a'']] \geq \frac{\varepsilon}{2} \quad \text{und} \quad \mathbb{P}[x_i \in [b'', b]] \geq \frac{\varepsilon}{2}.$$

Sei $\mathcal{E}_a$ das Ereignis, dass $x_1, \ldots, x_m \notin [a, a'']$ und sei $\mathcal{E}_b$ das Ereignis, dass $x_1, \ldots, x_m \notin [b'', b]$. Weil $x_1, \ldots, x_m$ unabhängige Züge aus $\mathcal{D}$ sind, gilt nun auch

$$\mathbb{P}[\mathcal{E}_a] \leq \left(1 - \frac{\varepsilon}{2}\right)^m \quad \text{und} \quad \mathbb{P}[\mathcal{E}_b] \leq \left(1 - \frac{\varepsilon}{2}\right)^m$$

und mit Lemma 0.16 folgt

$$\mathbb{P}[\mathcal{E}_a \cup \mathcal{E}_b] \leq 2\left(1 - \frac{\varepsilon}{2}\right)^m.$$

Die Behauptung folgt wieder mit $1 - x \leq e^{-x}$. □

Aus dem Satz können wir folgern, dass auch die Klasse der Intervalle PAC-lernbar ist. Setzen wir etwa $m = \frac{2}{\varepsilon'} \ln\left(\frac{2}{\delta}\right)$, dann folgt aus Satz 0.15, dass $\mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_S) \leq \varepsilon'] \geq 1 - \delta$, wobei wir ε' und δ als Parameter wählen können. Es gilt für jedes $\varepsilon' < \varepsilon$, dass

$$\mathbb{P}[\mathrm{err}_{D,f}(h_S) < \varepsilon] \geq \mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_S) \leq \varepsilon'].$$

Wählen wir also beispielsweise $m_{\mathcal{H}}(\varepsilon, \delta) = \frac{4}{\varepsilon} \ln\left(\frac{2}{\delta}\right)$, dann folgt $\mathbb{P}[\text{err}_{\mathcal{D},f}(h_S) < \varepsilon] \geq 1 - \delta$. Die Klasse der Intervalle ist also PAC-lernbar.

[16.04.2026, Vorlesung 2]
[21.04.2026, Vorlesung 3]

Anhang

Liste der Definitionen

0.2 Merkmalsraum 2
0.4 Hypothesenklasse 2
0.6 Grundwahrheit 3
0.7 Diskrete Wahrscheinlichkeitsverteilung 3
0.9 Tatsächlicher Fehler 3
0.11 Lernproblem 4
0.12 Trainingsfehler 4
0.14 PAC-Lernbarkeit 5

Liste der Aussagen

0.13 Abschätzung tatsächlicher Fehler des einfachen Lernalgorithmus 4
0.15 Abschätzung tatsächlicher Fehler Intervalllernen 6
0.16 Union Bound 6

Liste der Algorithmen

Liste der Abkürzungen

iid unabhängig und identisch verteilt (independent and identically distributed) 4

PAC probably approximately correct . . . . . 5 ff., B

Index

bag of words, 2

Fehler
    tatsächlicher -, 3
    Trainings-, 4

Grundwahrheit, 3

Hypothese, 2
Hypothesenklasse, 2

iid, 4
Instanz, 2

Label, 2

Merkmalsraum, 2

PAC, 5–7, B
PAC-Lernbarkeit, 5
    effiziente -, 5

realisierbar, 4

Sample, 3, 4

tatsächlicher Fehler, 3
Trainingsfehler, 4

Wahrscheinlichkeitsmaß, 3
Wahrscheinlichkeitsverteilung, 3
    diskrete -, 3