Universität Bonn

Mitschrift zur Vorlesung

Algorithmische Grundlagen des maschinellen Lernens

gehalten von

Prof. Dr. Anne Driemel

geTEXed von

Daniel Emse

Sommer 2026

Anmerkungen und Korrekturen

Falls du Anmerkungen/Korrekturen hast, melde dich bei mir (`daniel.emse@uni-bonn.de`).

Inhaltsverzeichnis

Vorlesung **1**

0 Einführung **2**
0.1 Binäre Klassifikation 2

Anhang **A**

Liste der Definitionen **B**

Liste der Aussagen **C**

Liste der Algorithmen **D**

Index **E**

Vorlesung

Kapitel 0

Einführung

[14.04.2026, Vorlesung 1]

0.1 Binäre Klassifikation

Beispiel 0.1.

- SPAM oder noSPAM für E-Mails
- Hund oder kein Hund für Fotos

Wir haben also immer die **Labels** *positiv* oder *negativ* für solche **Instanzen**.

Definition 0.2: Merkmalsraum

Ein *Merkmalsraum* X ist eine Menge, die eindeutig alle zu untersuchenden Instanzen eines Problems darstellt.

Beispiel 0.3.

- Für die SPAM-Klassifikation könnten wir beispielsweise folgendermaßen klassifizieren:
  1. X ist die Menge aller Strings in UTF-8 Unicode-Codierung
  2. X ist eine Menge von Vektoren, also $X \subseteq \mathbb{Z}^d_{\geq 0}$, wobei ein Vektor aus X angibt, ob und wie häufig bestimmte Wörter in der E-Mail vorkommen. Dabei sind beispielsweise Wörter wie *price*, *winner* oder ähnliches Teile des *bag of words*, und ihnen ist ein Index $\in \{1, \dots, d\}$ zugeordnet. Der entsprechende Vektor zählt also diese Häufigkeiten
- Für die Image-Klassifikation könnten wir beispielsweise folgendermaßen klassifizieren:
  1. X ist die Menge aller Bilder in RGB-Pixeldarstellung mit fester Auflösung, fester Größe und fester Farbtiefe (beispielsweise 1 Megapixel, 24 bit Farbtiefe führen zu $|X| = \left(2^{24}\right)^{10^6}$, das ist tatsächlich sehr groß)
  2. X ist eine Menge von Vektoren, also $X \subseteq \mathbb{Z}^d_{\geq 0}$, wobei ein Vektor aus X angibt, ob und wie häufig bestimmte *SIFT descriptors* vorkommen

Letztendlich suchen wir eine *Hypothese* $h : X \to \{1, -1\}$, sodass

$$h(x) = \begin{cases} 1 & x \text{ ist SPAM/Hund/}\dots \\ -1 & \text{sonst.} \end{cases}$$

Definition 0.4: Hypothesenklasse

Eine *Hypothesenklasse* $\mathcal{H}$ ist eine Menge von Funktionen $X \to \{1, -1\}$.

Beispiel 0.5. Wir betrachten einige Beispiele für $\mathcal{H}$.

- Es könnte $\mathcal{H} = \{f : X \to \{1, -1\}\}$ sein, also einfach *alle* solche Funktionen beinhalten.
  Nachteil: Wir haben zu wenig Struktur.
- Sei $X = \mathbb{R}$ und $\mathcal{H} = \{h_a \mid a \in \mathbb{R}\}$, wobei

$$h_a(x) = \begin{cases} 1 & x \geq a \\ -1 & x < a. \end{cases}$$

- Sei X die Menge aller Bilder und $\mathcal{H}$ die Menge aller Hypothesen h_w, die einem neuronalen Netz mit fester Architektur und einem Gewichtsvektor w entsprichen.

Wie wählen wir nun also unsere Hypothesen aus? Was macht eine gute Hypothese aus?

Definition 0.6: Grundwahrheit

Die *Grundwahrheit* f ist eine Funktion $f : X \to \{1, -1\}$. Wenn dieses f existiert, weist f jedem $x \in X$ das korrekte Label zu.

Wir nehmen an, dass so ein f existiert.

Ziel: Finde eine Hypothese h, die f möglichst nahe kommt.

Wir nehmen an, dass m Datenpunkte (*Instanzen*) aus einer Wahrscheinlichkeitsverteilung $\mathcal{D}$ über X gezogen werden. Diese nennen wir *Sample*.

Definition 0.7: Diskrete Wahrscheinlichkeitsverteilung

Eine *diskrete Wahrscheinlichkeitsverteilung* $\mathcal{D}$ über X ist definiet über ein *Wahrscheinlichkeitsmaß* $\mathbb{P} : X \to [0, 1]$, wobei $\mathbb{P}(x) \neq 0$ nur für abzählbar viele Punkte gelten soll und

$$\sum_{x \in X} \mathbb{P}(x) = 1$$

gelten soll.

Beispiel 0.8. Sei $X = \mathbb{R}$ und $\mathbb{P}(x) = \begin{cases} \frac{1}{100} & x \in \{1, \ldots, 100\} \\ 0 & \text{sonst} \end{cases} = \mathbb{1}_{\{1,\ldots,100\}}(x)$.

Definition 0.9: Tatsächlicher Fehler

Der *tatsächliche Fehler* $\mathrm{err}_{\mathcal{D},f}(h)$ einer Hypothese h hinsichtlich Verteilung $\mathcal{D}$ über Merkmalsraum X und Grundwahrheit f ist

$$\mathrm{err}_{\mathcal{D},f}(h) := \mathbb{P}_{x \sim \mathcal{D}}[h(x) \neq f(x)].$$

Beispiel 0.10. Es sei $f(x) = h_{30}$ und $h(x) = h_{50}$. Dann ist

$$\mathrm{err}_{\mathcal{D},f}(h) = \frac{|\{30, \ldots, 49\}|}{|\{1, \ldots, 100\}|} = \frac{20}{100} = \frac{1}{5}.$$

Problem 0.11: Lernproblem

Input: m Datenpunkte $x_1, \ldots, x_m$, die unabhängig und identisch verteilt (*iid*) aus $\mathcal{D}$ gezogen sind, und $y_1 = f(x_1), \ldots, y_m = f(x_m)$ (die *korrekten* Labels). Sei $\mathcal{S} = \{(x_1, y_1), \ldots, (x_m, y_m)\}$ die Menge der Samples also gegeben
Output: Hypothese $h_{\mathcal{S}} \in \mathcal{H}$
Objective: $\mathrm{err}_{\mathcal{D},f}(h_{\mathcal{S}})$ möglichst klein

Definition 0.12: Trainingsfehler

Der *Trainingsfehler* $\mathrm{err}_{\mathcal{S}}(h)$ einer Hypothese $h \in \mathcal{H}$ hinsichtlich einer Trainingsmenge $\mathcal{S}$ ist

$$\mathrm{err}_{\mathcal{S}}(h) := \frac{1}{m}|\{h(x_i) \neq y_i\}|.$$

[14.04.2026, Vorlesung 1]
[16.04.2026, Vorlesung 2]

[16.04.2026, Vorlesung 2]
[21.04.2026, Vorlesung 3]

Anhang

Liste der Definitionen

0.2 Merkmalsraum 2
0.4 Hypothesenklasse 2
0.6 Grundwahrheit 3
0.7 Diskrete Wahrscheinlichkeitsverteilung 3
0.9 Tatsächlicher Fehler 3
0.11 Lernproblem 3
0.12 Trainingsfehler 4

Liste der Aussagen

Liste der Algorithmen

Index

bag of words, 2

Fehler
    tatsächlicher -, 3
    Trainings-, 4

Grundwahrheit, 3

Hypothese, 2
Hypothesenklasse, 2

iid, 3
Instanz, 2

Label, 2

Merkmalsraum, 2

Sample, 3

tatsächlicher Fehler, 3
Trainingsfehler, 4

Wahrscheinlichkeitsmaß, 3
Wahrscheinlichkeitsverteilung, 3
    diskrete -, 3