Universität Bonn

Mitschrift zur Vorlesung

Algorithmische Grundlagen des maschinellen Lernens

gehalten von

Prof. Dr. Anne Driemel

geTEXed von

Daniel Emse

Sommer 2026

Anmerkungen und Korrekturen

Falls du Anmerkungen/Korrekturen hast, melde dich bei mir (`daniel.emse@uni-bonn.de`).

Inhaltsverzeichnis

Vorlesung **1**

0 Einführung **2**
0.1 Binäre Klassifikation 2

1 PAC-Lernbarkeit **5**
1.1 Lernen von Schwellenwertfunktionen 5
1.2 PAC-Lernbarkeit 6
1.3 Lernen von Intervallen 6

2 Endliche Hypothesenklassen, Wachstumsfunktion und VC-Dimension **8**
2.1 Endliche Hypothesenklassen, Wachstumsfunktion 8
2.2 Subexponentielles Wachstum impliziert PAC-Lernbarkeit 9
2.3 Schranke über die VC-Dimension 9
2.3.1 Mengensysteme und deren VC-Dimension 10
2.3.2 Wachstum von endlichen Mengensystemen 11
2.3.3 Unendliche Mengensysteme 12

Anhang **A**

Liste der Definitionen **B**

Liste der Aussagen **C**

Liste der Algorithmen **D**

Liste der Abkürzungen **E**

Index **F**

Vorlesung

Kapitel 0

Einführung

[14.04.2026, Vorlesung 1]

0.1 Binäre Klassifikation

Beispiel 0.1.

- SPAM oder noSPAM für E-Mails
- Hund oder kein Hund für Fotos

Wir haben also immer die **Labels** *positiv* oder *negativ* für solche **Instanzen**.

Definition 0.2: Merkmalsraum

Ein *Merkmalsraum* $\mathcal{X}$ ist eine Menge, die eindeutig alle zu untersuchenden Instanzen eines Problems darstellt.

Beispiel 0.3.

- Für die SPAM-Klassifikation könnten wir beispielsweise folgendermaßen klassifizieren:
  1. $\mathcal{X}$ ist die Menge aller Strings in UTF-8 Unicode-Codierung
  2. $\mathcal{X}$ ist eine Menge von Vektoren, also $\mathcal{X} \subseteq \mathbb{Z}^d_{\geq 0}$, wobei ein Vektor aus $\mathcal{X}$ angibt, ob und wie häufig bestimmte Wörter in der E-Mail vorkommen. Dabei sind beispielsweise Wörter wie *price*, *winner* oder ähnliches Teile des *bag of words*, und ihnen ist ein Index $\in \{1, \dots, d\}$ zugeordnet. Der entsprechende Vektor zählt also diese Häufigkeiten
- Für die Image-Klassifikation könnten wir beispielsweise folgendermaßen klassifizieren:
  1. $\mathcal{X}$ ist die Menge aller Bilder in RGB-Pixeldarstellung mit fester Auflösung, fester Größe und fester Farbtiefe (beispielsweise 1 Megapixel, 24 bit Farbtiefe führen zu $|\mathcal{X}| = (2^{24})^{10^6}$, das ist tatsächlich sehr groß)
  2. $\mathcal{X}$ ist eine Menge von Vektoren, also $\mathcal{X} \subseteq \mathbb{Z}^d_{\geq 0}$, wobei ein Vektor aus $\mathcal{X}$ angibt, ob und wie häufig bestimmte *SIFT descriptors* vorkommen

Letztendlich suchen wir eine *Hypothese* $h : \mathcal{X} \to \{1, -1\}$, sodass

$$h(x) = \begin{cases} 1 & x \text{ ist SPAM/Hund/} \dots \\ -1 & \text{sonst.} \end{cases}$$

Definition 0.4: Hypothesenklasse

Eine *Hypothesenklasse* $\mathcal{H}$ ist eine Menge von Funktionen $\mathcal{X} \to \{1, -1\}$.

Beispiel 0.5. Wir betrachten einige Beispiele für $\mathcal{H}$.

- Es könnte $\mathcal{H} = \{f : \mathcal{X} \to \{1, -1\}\}$ sein, also einfach *alle* solche Funktionen beinhalten.

  Nachteil: Wir haben zu wenig Struktur.
- Sei $\mathcal{X} = \mathbb{R}$ und $\mathcal{H} = \{h_a \mid a \in \mathbb{R}\}$, wobei

$$h_a(x) = \begin{cases} 1 & x \geq a \\ -1 & x < a. \end{cases}$$

- Sei $\mathcal{X}$ die Menge aller Bilder und $\mathcal{H}$ die Menge aller Hypothesen h_w, die einem neuronalen Netz mit fester Architektur und einem Gewichtsvektor w entsprichen.

Wie wählen wir nun also unsere Hypothesen aus? Was macht eine gute Hypothese aus?

Definition 0.6: Grundwahrheit

Die *Grundwahrheit* f ist eine Funktion $f : \mathcal{X} \to \{1, -1\}$. Wenn dieses f existiert, weist f jedem $x \in \mathcal{X}$ das korrekte Label zu.

Wir nehmen an, dass so ein f existiert.

Ziel: Finde eine Hypothese h, die f möglichst nahe kommt.

Wir nehmen an, dass m Datenpunkte (*Instanzen*) aus einer Wahrscheinlichkeitsverteilung $\mathcal{D}$ über $\mathcal{X}$ gezogen werden. Diese nennen wir *Sample*.

Definition 0.7: Diskrete Wahrscheinlichkeitsverteilung

Eine *diskrete Wahrscheinlichkeitsverteilung* $\mathcal{D}$ über $\mathcal{X}$ ist definiet über ein *Wahrscheinlichkeitsmaß* $\mathbb{P} : \mathcal{X} \to [0, 1]$, wobei $\mathbb{P}(x) \neq 0$ nur für abzählbar viele Punkte gelten soll und

$$\sum_{x \in \mathcal{X}} \mathbb{P}(x) = 1$$

gelten soll.

Beispiel 0.8. Sei $\mathcal{X} = \mathbb{R}$ und $\mathbb{P}(x) = \begin{cases} \frac{1}{100} & x \in \{1, \ldots, 100\} \\ 0 & \text{sonst} \end{cases} = \mathbb{1}_{\{1,\ldots,100\}}(x)$.

Definition 0.9: Tatsächlicher Fehler

Der *tatsächliche Fehler* $\mathrm{err}_{\mathcal{D},f}(h)$ einer Hypothese h hinsichtlich Verteilung $\mathcal{D}$ über Merkmalsraum $\mathcal{X}$ und Grundwahrheit f ist

$$\mathrm{err}_{\mathcal{D},f}(h) := \mathbb{P}_{x \sim \mathcal{D}}[h(x) \neq f(x)].$$

Beispiel 0.10. Es sei $f(x) = h_{30}$ und $h(x) = h_{50}$. Dann ist

$$\mathrm{err}_{\mathcal{D},f}(h) = \frac{|\{30, \ldots, 49\}|}{|\{1, \ldots, 100\}|} = \frac{20}{100} = \frac{1}{5}.$$

Problem 0.11: Lernproblem

Input: m Datenpunkte $x_1, \ldots, x_m$, die *unabhängig und identisch verteilt (independent and identically distributed, iid)* aus $\mathcal{D}$ gezogen sind, und $y_1 = f(x_1), \ldots, y_m = f(x_m)$ (die *korrekten* Labels). Sei $S = \{(x_1, y_1), \ldots, (x_m, y_m)\}$ die Menge der Samples also gegeben
Output: Hypothese $h_S \in \mathcal{H}$
Objective: $\mathrm{err}_{\mathcal{D},f}(h_S)$ möglichst klein

Definition 0.12: Trainingsfehler

Der *Trainingsfehler* $\mathrm{err}_S(h)$ einer Hypothese $h \in \mathcal{H}$ hinsichtlich einer Trainingsmenge S ist

$$\mathrm{err}_S(h) \coloneqq \frac{1}{m}|\{h(x_i) \neq y_i\}|.$$

[14.04.2026, Vorlesung 1]
[16.04.2026, Vorlesung 2]

Kapitel 1

PAC-Lernbarkeit

1.1 Lernen von Schwellenwertfunktionen

Sei im Folgenden $\mathcal{X} = \mathbb{R}$ unser Merkmalsraum.

In diesem Beispiel und auch im Folgenden vereinfachen wir uns das Leben durch die Annahme, dass die Grundwahrheit *realisierbar* ist. Das heißt, dass $f \in \mathcal{H}$. Wir werden unsere Theorie später verallgemeinern, dass sie auch ohne diese Annahme auskommt. Wir nehmen also an, dass es ein $a \in \mathbb{R}$ gibt, sodass die Grundwahrheit $f : \mathcal{X} \to \{-1, 1\}$ gegeben ist durch

$$f(x) = \begin{cases} 1 & x \geq a \\ -1 & \text{sonst.} \end{cases}$$

Wir nehmen an, dass uns m Datenpunkte mit korrekten Labels gegeben sind: Seien $x_1, \ldots, x_m$ Datenpunkte, die iid aus $\mathcal{D}$ gezogen sind. Außerdem seien $y_i = f(x_i)$ die zugehörigen, korrekten Labels. Die Menge aller Samples bezeichnen wir mit $S = \{(x_1, y_1), \ldots, (x_m, y_m)\}$.

Ein einfacher Lernalgorithmus wählt nun das größte a', sodass $h_{a'}$ die Menge S korrekt klassifiziert. Das heißt, wir setzen a' auf den Wert des kleinsten x_i mit $y_i = 1$, wenn es ein solches gibt. Anderenfalls $a' = \infty$.

Satz 1.1: Abschätzung tatsächlicher Fehler der Schwellenwertfunktionen

Sei $h_{a'}$ die vom einfachen Lernalgorithmus berechnete Hypothese, der als Eingabe eine Menge von Samples von m Datenpunkten mit korrekten Labels gemäß f erhält, die iid aus $\mathcal{D}$ gezogen werden. Dann gilt für alle $\varepsilon > 0$, dass

$$\mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_{a'}) > \varepsilon] \leq e^{-\varepsilon m}.$$

Beweis. Weil unser Lernalgorithmus unter allen Hypothesen, die S korrekt klassifizieren, die Hypothese $h_{a'}$ mit dem größten a' wählt, wird auf jeden Fall gelten, dass $a' \geq a$. Falsch klassifiziert werden alle Punkte im Bereich $[a, a')$. Somit gilt nun für jede Verteilung $\mathcal{D}$

$$\mathrm{err}_{\mathcal{D},f}(h_{a'}) = \mathbb{P}_{x\sim\mathcal{D}}[x \in (a, a']].$$

Sei nun $a'' \geq a$ die kleinste Zahl, sodass $\mathbb{P}_{x\sim D}[x \in (a, a'')] \geq \varepsilon$. Es könnte sein, dass a'' nicht existiert, weil $\mathbb{P}_{x\sim\mathcal{D}}[x \in [a, \infty)] < \varepsilon$. Dann ist aber die Wahrscheinlichkeit, dass der Fehler $\mathrm{err}_{\mathcal{D},f}(h_{a'})$ den Wert ε überschreitet, gleich null, und die Aussage des Satzes gilt trivialerweise.

Es bleibt zu zeigen, dass die Aussage des Satzes auch dann gilt, wenn $\mathcal{D}$ dergestalt ist, dass $\mathbb{P}_{x\sim D}[x \in [a, \infty)] \geq \varepsilon$ und somit a'' wohldefiniert ist. Damit muss auch gelten $\mathbb{P}_{x\sim D}[x \in (a, a'']] \leq \varepsilon$. Der Fehler von $h_{a'}$ wird also höchstens ε sein, falls $a' \leq a''$. Dies geschieht, wenn es mindestens ein i gibt, sodass $x_i \in [a, a'']$. Sei $\mathcal{E}_i$ das Ereignis, dass $x_i \in [a, a'']$. Es gilt $\mathbb{P}[\mathcal{E}_i] = \mathbb{P}_{x_i\sim\mathcal{D}}[x_i \in [a, a'']] \geq \varepsilon$. Damit *nicht* $a' \leq a''$ gilt, darf keines der Ereignisse $\mathcal{E}_i$ eintreten. Wir interessieren

uns also für $\bigcap_i \overline{\mathcal{E}_i}$. Weil $x_1, \ldots, x_m$ unabhängige Züge aus $\mathcal{D}$ sind, gilt nun auch

$$\mathbb{P}\left[\bigcap_i \overline{\mathcal{E}_i}\right] = \prod_i \mathbb{P}[\overline{\mathcal{E}_i}] \leq (1-\varepsilon)^m.$$

Mit $1 - x \leq e^{-x}$ für alle $x \in \mathbb{R}$ folgt die Behauptung. □

1.2 PAC-Lernbarkeit

Satz 1.1 sagt uns nun insbesondere, dass wenn wir $m = \frac{1}{\varepsilon} \ln\left(\frac{1}{\delta}\right)$ wählen, die Wahrscheinlichkeit, dass der tatsächliche Fehler unserer gefundenen Hypothese größer als ε ist, kleiner als δ wird. Diese Aussage gilt für alle $\varepsilon > 0$ und alle $\delta > 0$. Wenn die Anzahl der Samples also nur groß genug ist, werden wir mit großer Wahrscheinlichkeit nur einen sehr kleinen Fehler haben. Die Hypothesenklassen, für die dies gilt, heißen *PAC-lernbar*:

Definition 1.2: PAC-Lernbarkeit

Eine Hypothesenklasse $\mathcal{H}$ heißt *PAC-lernbar* (im realisierbaren Sinn), wenn es eine Funktion $m_{\mathcal{H}}$ und einen Lernalgorithmus $\mathcal{A}$ gibt, sodass A für alle $\varepsilon, \delta > 0$ jede Verteilung $\mathcal{D}$ und alle $f \in \mathcal{H}$, gegeben ein Sample S von Größe mindestens $m_{\mathcal{H}}(\varepsilon, \delta)$ von Datenpunkten mit korrekten Labels, eine Hypothese $h_S \in \mathcal{H}$ berechnet, sodass

$$\mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_S) < \varepsilon] \geq 1 - \delta.$$

PAC-Lernbarkeit nach dieser Definition impliziert nicht unbedingt, dass das Lernproblem effizient lösbar ist. Man spricht von *effizienter PAC-Lernbarkeit*, wenn die Laufzeit von $\mathcal{A}$ polynomiell ist und außerdem gilt, dass $m_{\mathcal{H}}(\varepsilon, \delta)$ polynomiell in $\frac{1}{\varepsilon}$ und $\frac{1}{\delta}$ beschränkt ist.

PAC steht für *probably approximately correct*. Dabei bedeutet *probably* in diesem Fall, dass die Wahrscheinlichkeit mindestens $1 - \delta$ ist, und *approximately correct* bezieht sich darauf, dass $\mathrm{err}_{\mathcal{D},f}(h_S) < \varepsilon$.

Nicht jede Hypothesenklasse ist PAC-lernbar. Zum Beispiel ist die Klasse aller Hypothesen $\mathbb{N} \to \{-1, 1\}$ nicht PAC-lernbar, was wir noch beweisen werden.

1.3 Lernen von Intervallen

Wir betrachten als weiteres Beispiel nun die Klasse der Intervallfunktionen. Weiterhin sei $\mathcal{X} = \mathbb{R}$, aber $\mathcal{H}$ sei nun die Menge der Funktionen der Form $h_{a',b'} : \mathbb{R} \to \{-1, 1\}$ mit

$$h_{a',b'} = \begin{cases} 1 & x \in [a', b'] \\ -1 & \text{sonst.} \end{cases}$$

Wir betrachten weiterhin den realisierbaren Fall. Das heißt, es gibt eine Grundwahrheit $f \in \mathcal{H}$, die alle Datenpunkte richtig klassifiziert. Diese hat die Form

$$f(x) = \begin{cases} 1 & x \in [a, b] \\ -1 & \text{sonst.} \end{cases}$$

Gegeben ist wieder eine Menge $S = \{(x_1, y_1), \ldots, (x_m, y_m)\}$ von Datenpunkten mit korrekten Labels. Unser Lernalgorithmus wählt das kleinste Intervall $[a', b']$, das S korrekt klassifiziert. Das heißt, wir setzen a' auf den Wert des kleinsten x_i mit $y_i = 1$ und b' auf den Wert des größten x_i mit $y_i = 1$. Den Fall, dass es kein i mit $y_i = 1$ gibt, schieben wir ab in die Übung und ignorieren ihn.

Satz 1.3: Abschätzung tatsächlicher Fehler Intervalllernen

Für alle $\varepsilon > 0$ gilt

$$\mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_{a',b'}) > \varepsilon] \leq 2e^{-\frac{\varepsilon m}{2}}.$$

Lemma 1.4: Union Bound

Es seien $\mathcal{E}_1, \ldots, \mathcal{E}_n$ (nicht notwendigerweise disjunkte) Ereignisse. Dann gilt

$$\mathbb{P}\left[\bigcup_{i=1}^{n} \mathcal{E}_i\right] \leq \sum_{i=1}^{n} \mathbb{P}[\mathcal{E}_i].$$

Beweis. Induktives Anwenden von $\mathbb{P}[A \cup B] = \mathbb{P}[A] + \mathbb{P}[B] - \mathbb{P}[A \cap B] \leq \mathbb{P}[A] + \mathbb{P}[B]$. □

Beweis von Satz 1.3. Weil unser Lernalgorithmus das kleinste Intervall wählt, welches S korrekt klassifiziert, wird auf jeden Fall gelten, dass $a' \geq a$ und $b' \leq b$. Falsch klassifiziert werden alle Punkte im Bereich $[a, a') \cup (b', b]$. Somit gilt nun für jede Verteilung $\mathcal{D}$

$$\mathrm{err}_{\mathcal{D},f}(h_{a',b'}) = \mathbb{P}_{x\sim\mathcal{D}}[x \in [a, a') \cup (b', b]].$$

Analog zu oben betrachten wir den Fall, dass $\mathbb{P}_{x\sim\mathcal{D}}[x \in [a, b]] < \varepsilon$. In diesem Fall ist die Wahrscheinlichkeit, dass der Fehler $\mathrm{err}_{\mathcal{D},f}(h_{a',b'})$ den Wert ε überschreitet, wieder gleich null, und die Aussage des Satzes gilt trivialerweise.

Es bleibt zu zeigen, dass die Aussage des Satzes auch dann gilt, wenn $\mathcal{D}$ dergestalt ist, dass $\mathbb{P}_{x\sim D}[x \in [a, b]] \geq \varepsilon$. Sei nun, ähnlich wie oben, $a'' \in [a, b]$ die kleinste Zahl, sodass $\mathbb{P}_{x\sim D}[x \in [a, a'']] \geq \frac{\varepsilon}{2}$. Analog sei $b'' \in [a, b]$ die größte Zahl, sodass $\mathbb{P}_{x\sim\mathcal{D}}[x \in [b'', b]] \geq \frac{\varepsilon}{2}$. Damit $\mathrm{err}_{\mathcal{D},f}(h_{a',b'}) \leq \varepsilon$, ist es nun hinreichend, dass $a' \leq a''$ und $b' \geq b''$. Dies geschieht, wenn es mindestens ein i und mindestens ein j gibt, sodass $x_i \in [a, a'']$ und $x_j \in [b'', b]$ wobei i und j nicht verschieden sein müssen. Für jedes i gilt

$$\mathbb{P}[x_i \in [a, a'']] \geq \frac{\varepsilon}{2} \quad \text{und} \quad \mathbb{P}[x_i \in [b'', b]] \geq \frac{\varepsilon}{2}.$$

Sei $\mathcal{E}_a$ das Ereignis, dass $x_1, \ldots, x_m \notin [a, a'']$ und sei $\mathcal{E}_b$ das Ereignis, dass $x_1, \ldots, x_m \notin [b'', b]$. Weil $x_1, \ldots, x_m$ unabhängige Züge aus $\mathcal{D}$ sind, gilt nun auch

$$\mathbb{P}[\mathcal{E}_a] \leq \left(1 - \frac{\varepsilon}{2}\right)^m \quad \text{und} \quad \mathbb{P}[\mathcal{E}_b] \leq \left(1 - \frac{\varepsilon}{2}\right)^m$$

und mit Lemma 1.4 folgt

$$\mathbb{P}[\mathcal{E}_a \cup \mathcal{E}_b] \leq 2\left(1 - \frac{\varepsilon}{2}\right)^m.$$

Die Behauptung folgt wieder mit $1 - x \leq e^{-x}$. □

Aus dem Satz können wir folgern, dass auch die Klasse der Intervalle PAC-lernbar ist. Setzen wir etwa $m = \frac{2}{\varepsilon'} \ln\left(\frac{2}{\delta}\right)$, dann folgt aus Satz 1.3, dass $\mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_S) \leq \varepsilon'] \geq 1 - \delta$, wobei wir ε' und δ als Parameter wählen können. Es gilt für jedes $\varepsilon' < \varepsilon$, dass

$$\mathbb{P}[\mathrm{err}_{D,f}(h_S) < \varepsilon] \geq \mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_S) \leq \varepsilon'].$$

Wählen wir also beispielsweise $m_{\mathcal{H}}(\varepsilon, \delta) = \frac{4}{\varepsilon} \ln\left(\frac{2}{\delta}\right)$, dann folgt $\mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_S) < \varepsilon] \geq 1 - \delta$. Die Klasse der Intervalle ist also PAC-lernbar.

[16.04.2026, Vorlesung 2]
[21.04.2026, Vorlesung 3]

Kapitel 2

Endliche Hypothesenklassen, Wachstumsfunktion und VC-Dimension

2.1 Endliche Hypothesenklassen, Wachstumsfunktion

Wir betrachten den Fall, dass $\mathcal{H}$ endlich ist.

Satz 2.1: Tatsächlicher Fehler bei endlicher Hypothesenklasse

Wenn $m \geq \frac{1}{\varepsilon} \ln\left(\frac{|\mathcal{H}|}{\delta}\right)$, *dann gilt mit Wahrscheinlichkeit mindestens* $1-\delta$, *dass alle* $h \in \mathcal{H}$ *mit* $\mathrm{err}_S(h) = 0$ *auch* $\mathrm{err}_{\mathcal{D},f}(h) < \varepsilon$ *erfüllen.*

Beweis. Sei $h \in \mathcal{H}$ fest mit $\mathrm{err}_{\mathcal{D},f}(h) \geq \varepsilon$. Dann gilt, da S iid mittels $\mathcal{D}$ gezogen wird, und mit der Voraussetzung $\mathbb{P}[h(x_i) \neq y_i] \geq \varepsilon$

$$\mathbb{P}\left[\mathrm{err}_S(h) = 0\right] = \mathbb{P}[h(x_1) = y_1, \ldots, h(x_m) = y_m] = \prod_{i=1}^{m} \mathbb{P}[h(x_i) = y_i] \leq (1-\varepsilon)^m \leq e^{-\varepsilon m}.$$

Für jede Hypothese definiere $\mathcal{E}_h$ als das Ereignis, dass $\mathrm{err}_S(h) = 0$ ist. Dann ist

$$\mathbb{P}[\exists h \in \mathcal{H} : \mathrm{err}_S(h) = 0 \text{ und } \mathrm{err}_{\mathcal{D},f}(h) \geq \varepsilon] = \mathbb{P}\left[\bigcup_{\substack{h \in \mathcal{H} \\ \mathrm{err}_{\mathcal{D},f}(h) \geq \varepsilon}} \mathcal{E}_h\right]$$

$$\leq \sum_{\substack{h \in \mathcal{H} \\ \mathrm{err}_{\mathcal{D},f}(h) \geq \varepsilon}} \mathbb{P}[\mathrm{err}_S(h) = 0] \leq |\mathcal{H}| e^{-\varepsilon m} \leq \delta,$$

also exakt, was wir zeigen wollten. □

Definition 2.2: Wachstumsfunktion

Gegeben $A \subseteq \mathcal{X}$, sei $\mathcal{H}|_A$ die Menge aller Hypothesen $h \in \mathcal{H}$ mit Definitionsbereich eingeschränkt auf A, also

$$\mathcal{H}|_A = \{h|_A \mid h \in \mathcal{H}\}.$$

Die *Wachstumsfunktion* von $\mathcal{H}$ ist definiert als

$$\Pi_{\mathcal{H}}(m) := \max_{\substack{A \subseteq \mathcal{X} \\ |A| = m}} |\mathcal{H}|_A|.$$

Es gilt immer $\Pi_{\mathcal{H}}(m) \leq 2^m$, es ist aber oft wesentlich kleiner.

Beispiel 2.3. Sei $\mathcal{X} = \mathbb{R}$ und $\mathcal{H}$ die Klasse der Schwellenwertfunktionen $h_a(x) = \begin{cases} 1 & x \geq a \\ -1 & \text{sonst.} \end{cases}$

Für $A = \{2, 3, 4\}$ ist

$$\mathcal{H}|_A = \left\{ x \mapsto -1 \forall x \in A x \mapsto 1 \forall x \in A, x \mapsto \begin{cases} 1 & x = 4 \\ -1 & x \in \{2, 3\} \end{cases}, x \mapsto \begin{cases} 1 & x \in \{3, 4\} \\ -1 & x = 2 \end{cases} \right\}$$

und damit ist $|\mathcal{H}|_A| = 4 \ll 2^3$. Allgemein ist für $|A| = m$ für Schwellenwertfunktionen immer $|\mathcal{H}|_A| = m + 1$.

2.2 Subexponentielles Wachstum impliziert PAC-Lernbarkeit

Satz 2.4: PAC-lernbar wenn Wachstumsfunktion subexponentiell

Es seien $\varepsilon, \delta > 0$ fest, und

$$m \geq \max\left\{ \frac{8}{\varepsilon}, \frac{2}{\varepsilon} \log_2 \left(\frac{2\Pi_{\mathcal{H}}(2m)}{\delta} \right) \right\}.$$

Betrachte eine Sample-Menge S von m Datenpunkten mit korrekten Labels gemäß der Grundwahrheit f, die iid aus $\mathcal{D}$ gezogen werden. Dann gilt mit Wahrscheinlichkeit $\geq 1-\delta$, dass alle $h \in \mathcal{H}$ mit $\text{err}_S(h) = 0$ auch $\text{err}_{\mathcal{D},f}(h) < \varepsilon$ erfüllen.

Der Beweis folgt später. Wir fragen uns erstmal, wann die Ungleichung

$$m \geq \frac{2}{\varepsilon} \log_2 \left(\frac{2\Pi_{\mathcal{H}}(2m)}{\delta} \right) = \frac{2}{\varepsilon} \log_2(\Pi_{\mathcal{H}}(2m)) + \frac{2}{\varepsilon} \log_2 \left(\frac{2}{\delta} \right) \tag{2.1}$$

erfüllt ist. Es ist (2.1) äquivalent zu

$$\frac{m - \frac{2}{\varepsilon} \log_2 \left(\frac{2}{\delta} \right)}{\log_2(\Pi_{\mathcal{H}}(2m))} \geq \frac{2}{\varepsilon}.$$

Wir testen ein paar Schranken aus.

(a) Wenn $\Pi_{\mathcal{H}}(2m) = 2^{2m}$, dann ist $\log_2(\Pi_{\mathcal{H}}(2m)) = 2m$ und die Ungleichung kann nicht für alle $\varepsilon, \delta > 0$ erfüllt werden.

(b) Gilt $\log_2(\Pi_{\mathcal{H}}(2m)) \in o(m)$, so müssen wir m nur hinreichend groß wählen, um diese Schranke zu erfüllen.

Beispiel 2.5. Bei den Schwellenwertfunktionen ist $\Pi_{\mathcal{H}}(2m) = 2m + 1$. Dann gilt für alle $\delta > 0$

$$\frac{m - \frac{2}{\varepsilon} \log_2 \left(\frac{2}{\delta} \right)}{\log_2(2m + 1)} \xrightarrow{m \to \infty} \infty.$$

Damit erhalten wir (mit dem Beweis von Satz 2.4 als Black Box) PAC-Lernbarkeit für Hypothesenklassen, die die angesprochenen Ungleichungen erfüllen.

2.3 Schranke über die VC-Dimension

Über die Vapnik-Chervonenkis (VC)-Dimension werden wir die Wachstumsfunktion beschränken (in mehr Details in der nächsten Vorlesung):

Lemma 2.6: Sneak Peak: Wachstumslemma

Wenn $\mathcal{H}$ VC-Dimension d hat, so gilt

$$\Pi_{\mathcal{H}}(m) \leq \left(\frac{em}{d}\right)^d$$

Damit motivieren wir folgenden Satz:

Satz 2.7: PAC-Lernbarkeit mit VC-Dimension

Sei $\mathcal{H}$ eine Hypothesenklasse mit VC-Dimension $d < \infty$. Seien $1 \geq \varepsilon > 0$, $\delta > 0$ und sei

$$m \geq \max\left\{\frac{4}{\varepsilon}\log_2\left(\frac{2}{\delta}\right), \frac{8d}{\varepsilon}\log_2\left(\frac{16}{\varepsilon}\right)\right\}. \tag{2.2}$$

Betrachte eine Sample-Menge S von m Datenpunkten mit korrekten Labels gemäß der Grundwahrheit f, die iid aus $\mathcal{D}$ gezogen werden. Dann gilt mit Wahrscheinlichkeit $\geq 1-\delta$, dass alle $h \in \mathcal{H}$ mit $\mathrm{err}_S(h) = 0$ auch $\mathrm{err}_{\mathcal{D},f}(h) < \varepsilon$ erfüllen.

Beweis. Es genügt zu zeigen, dass (2.2) bereits (2.1) impliziert (wenn wir später Satz 2.4 später gezeigt haben).

Zunächst, da $d \geq 1$ und $\varepsilon \leq 1$, gilt

$$m \geq \frac{8d}{\varepsilon}\log_2\left(\frac{16}{\varepsilon}\right) \geq \frac{8}{\varepsilon}.$$

Weiterhin gilt

$$\frac{m - \frac{2}{\varepsilon}\log_2\left(\frac{2}{\delta}\right)}{\log_2(\Pi_{\mathcal{H}}(2m))} \geq \frac{m}{2d\log_2\left(\frac{2em}{d}\right)} \geq \frac{\frac{8d}{\varepsilon}\log_2\left(\frac{16}{\varepsilon}\right)}{2d\log_2\left(\frac{2e}{d}\cdot\frac{8d}{\varepsilon}\log_2\left(\frac{16}{\varepsilon}\right)\right)} \geq \frac{4}{\varepsilon}\frac{\log_2\left(\frac{16}{\varepsilon}\right)}{\log_2\left(\frac{16e}{\varepsilon}\cdot\log_2\left(\frac{16e}{\varepsilon}\right)\right)} \geq \frac{2}{\varepsilon},$$

da der Nenner monoton fallend in ε und im Intervall $(0,1)$ mindestens $\frac{1}{2}$ ist. □

[21.04.2026, Vorlesung 3]
[23.04.2026, Vorlesung 4]

Heute fragen wir uns, welche Struktur einer Hypothesenklasse $\mathcal{H}$ zu subexponentiellem Wachstum führt.

2.3.1 Mengensysteme und deren VC-Dimension

Definition 2.8: Mengensystem, Aufspalten, Abspalten

Sei $\mathcal{X}$ eine beliebige Menge und $\mathcal{R} \subseteq \mathcal{P}(\mathcal{X})$. Dann nennen wir $\mathcal{R}$ ein *Mengensystem mit Grundmenge* $\mathcal{X}$.
Eine Menge $A' \subseteq \mathcal{X}$ wird *durch* $\mathcal{R}$ von einer Menge A *abgespalten*, wenn $r \in \mathcal{R}$ existiert, sodass $A' = r \cap A$.
Eine Menge $A \subseteq \mathcal{X}$ wird *durch* $\mathcal{R}$ *aufgespalten* (engl. *Shattering*), wenn jede Teilmenge $A' \subseteq A$ von A durch $\mathcal{R}$ abgespalten wird.

Definition 2.9: VC-Dimension

Die *Vapnik-Chervonenkis (VC)-Dimension* von $\mathcal{R}$ ist die Anzahl der Elemente der größten aufgespaltenen Menge. Wir schreiben dafür $\dim(\mathcal{R})$.
Wir setzen $\dim(\mathcal{R}) := \infty$, wenn für jedes $n_0 \in \mathbb{N}$ eine aufgespaltene Menge mit n_0 Elementen existiert, und $\dim(\mathcal{R}) := 0$, wenn keine solche Menge existiert.

Beispiel 2.10.

1. Für $\mathcal{X} = \mathbb{R}^2$ und $\mathcal{R}$ die Menge aller achsenparalleler Rechtecke. Betrachte $A \subseteq \mathcal{X}$. Es ist $\dim(\mathcal{R}) \geq 4$. Wenn wir mindestens fünf Punkte haben, so ist einer dieser Punkte in keiner Koordinate „extrem“ bzw. „maximal“, und wir können also nie ein Rechteck um alle Punkte außer diesen Mittelpunkt bauen. Also ist $\dim(\mathcal{R}) = 4$.
2. Für $\mathcal{X} = \mathbb{R}^2$ und $\mathcal{R}$ die Menge aller konvexen Polygone. Dann ist für jedes n_0 die Menge der n_0 Punkte, die ein regelmäßiges n_0-Eck bilden, aufspaltbar. Also ist $\dim(\mathcal{R}) = \infty$.

2.3.2 Wachstum von endlichen Mengensystemen

Beispiel 2.11. Sei $\mathcal{X} = \{1, \ldots, m\}$ und sei $\mathcal{R}$ das Mengensystem, das alle Teilmengen von maximaler Größe k enthält. Dann ist $\dim(\mathcal{R}) = k$ und

$$|\mathcal{R}| = \sum_{i=0}^{k} \binom{m}{i} = \sum_{i=0}^{k} \left(\frac{m}{k}\right)^i \frac{k^i}{i!} \leq \left(\frac{m}{k}\right)^k \sum_{i=0}^{k} \frac{k^i}{i!} \leq \left(\frac{em}{k}\right)^k.$$

mit

$$\binom{m}{i} = \frac{m!}{(m-i)!i!} \leq \frac{m^i k^i}{i!k^i} \leq \left(\frac{m}{k}\right)^i \frac{k^i}{i!}$$

und der Reihendarstellung von exp

$$e^x = \sum_{i=0}^{\infty} \frac{x^i}{i!}.$$

Damit wächst $|\mathcal{R}|$ subexponentiell in m für konstante k.

Lemma 2.12: Größe von Mengensystemen

Es gilt für jedes Mengensystem $\mathcal{R}$ mit m-elementiger Grundmenge $\mathcal{X}$ und VC-Dimension d, dass

$$|\mathcal{R}| \leq \sum_{i=0}^{d} \binom{m}{i}.$$

Beweis. Wir machen Induktion über m.

IA: $m = 0$. Dann ist $|\mathcal{R}| \leq 1$ und $d = 0$ und es gilt

$$\sum_{i=0}^{d} \binom{0}{i} = \binom{0}{0} = 1.$$

IS: $m > 0$. Sei $\mathcal{R}$ ein Mengensystem mit Grundmenge $\mathcal{X}$ mit $|\mathcal{X}| = m$ und VC-Dimension d. Angenommen, $d = 0$. Dann ist $|\mathcal{R}| \leq 1$ und die Aussage ist erfüllt, da $\binom{m}{i} \geq \binom{1}{0} = 1$.

Sei also auch $d > 0$. Sei $x \in \mathcal{X}$ fest. Sei $\mathcal{R}_1 := \{r \setminus \{x\} \mid r \in \mathcal{R}\}$ und sei $\dim(\mathcal{R}_1) = d_1 \leq d$. Nach Induktionsvoraussetzung folgt

$$|\mathcal{R}_1| \leq \sum_{i=0}^{d_1} \binom{m-1}{i} \leq \sum_{i=0}^{d} \binom{m-1}{i}.$$

Definiere $\mathcal{R}_2 := \{r \setminus \{x\} \mid r \cup \{x\} \in \mathcal{R} \text{ und } r \setminus \{x\} \in \mathcal{R}\}$. Es gilt also $|\mathcal{R}| = |\mathcal{R}_1| + |\mathcal{R}_2|$. Dieses $\mathcal{R}_2$ dient dazu, es auszugleichen, dass in $\mathcal{R}_1$ durch Beschränkung von $\mathcal{R}$ auf $\mathcal{X} \setminus \{x\}$ zwei verschiedene Mengen identisch werden können. Diese Mengen werden in $\mathcal{R}_2$ quasi doppelt gezählt und somit ausgeglichen.

Beispiel. Für $\mathcal{X} = \{1,2,3\}, x = 1$ und $\mathcal{R} = \{\{1,2\},\{2\},\{1,3\}\}$, dann ist $\mathcal{R}_1 = \{\{2\},\{3\}\}$ und $\mathcal{R}_2 = \{\{2\}\}$.

Sei $d_2 = \dim(\mathcal{R}_2)$. Wir behaupten, dass $d_2 \leq d-1$: Angenommen, $d_2 \geq d$. Dann gibt es $A \subseteq \mathcal{X} \setminus \{x\}$ mit $|A| = d$, sodass A durch $\mathcal{R}_2$ aufgespalten wird. Dann wird aber $A \cup \{x\}$ nach Definition von $\mathcal{R}_2$ durch $\mathcal{R}_1$ aufgespalten, und die VC-Dimension von $\mathcal{R}$ wäre somit mindestens $d_2 + 1 > d$. Widerspruch!

Somit gilt nach Induktionsvoraussetzung

$$|\mathcal{R}_2| \leq \sum_{i=0}^{d_2} \binom{m-1}{i} \leq \sum_{i=0}^{d-1} \binom{m-1}{i}.$$

Nun gilt mit $\binom{a}{b} = \binom{a-1}{b} + \binom{a-1}{b-1}$

$$\begin{aligned}|\mathcal{R}| = |\mathcal{R}_1| + |\mathcal{R}_2| &\leq \sum_{i=0}^{d} \binom{m-1}{i} + \sum_{i=0}^{d-1} \binom{m-1}{i} = \sum_{i=0}^{d} \binom{m-1}{i} + \sum_{i=1}^{d} \binom{m-1}{i-1} \\ &= \binom{m-1}{0} + \sum_{i=1}^{d} \binom{m-1}{i} + \binom{m-1}{i-1} = \binom{m}{0} + \sum_{i=1}^{d} \binom{m}{i} = \sum_{i=0}^{d} \binom{m}{i},\end{aligned}$$

was wir zeigen wollten. □

2.3.3 Unendliche Mengensysteme

Definition 2.13: Untersystem

Sei $\mathcal{R}$ ein Mengensystem mit Grundmenge $\mathcal{X}$. Jede Menge $A \subseteq \mathcal{X}$ bestimmt ein *Untersystem* von $\mathcal{R}$ wie folgt:

$$\mathcal{R}|_A = \{r \cap A \mid r \in \mathcal{R}\}$$

Es gilt $\dim(\mathcal{R}|_A) \leq \dim(\mathcal{R})$.

Wir betrachten nun das Wachstumslemma (Sneak Peak war Lemma 2.6).

Lemma 2.14: Wachstumslemma

Sei $\mathcal{R}$ ein Mengensystem mit Grundmenge $\mathcal{X}$ und VC-Dimension d. Für jedes $n \in \mathbb{N}$ gilt

$$\Pi_{\mathcal{R}}(m) := \max_{\substack{A \subseteq \mathcal{X} \\ |A| = m}} |\mathcal{R}|_A| \leq \left(\frac{em}{d}\right)^d.$$

Wir nennen Π die Wachstumsfunktion *von $\mathcal{R}$.*

Beweis. Für jedes $A \subseteq \mathcal{X}$ mit $|A| = m$ gilt

$$|\mathcal{R}|_A| \leq \sum_{i=0}^{d} \binom{m}{i} \leq \left(\frac{em}{d}\right)^d$$

nach Lemma 2.12 und der Rechnung aus Beispiel 2.11. Es solft somit direkt $\Pi_{\mathcal{R}}(m) \leq (\frac{em}{d})^d$. □

Nun folgt mit $\mathcal{R} \coloneqq \{r_h \mid h \in \mathcal{H}\}$, wobei $r_h \coloneqq \{x \in \mathcal{X} \mid h(x) = 1\}$, auch direkt $\Pi_{\mathcal{H}}(m) = \Pi_{\mathcal{R}}(m)$ und damit Lemma 2.6.

[23.04.2026, Vorlesung 4]
[28.04.2026, Vorlesung 5]

Anhang

Liste der Definitionen

0.2 Merkmalsraum 2
0.4 Hypothesenklasse 2
0.6 Grundwahrheit 3
0.7 Diskrete Wahrscheinlichkeitsverteilung 3
0.9 Tatsächlicher Fehler 3
0.11 Lernproblem 4
0.12 Trainingsfehler 4
1.2 PAC-Lernbarkeit 6
2.2 Wachstumsfunktion 8
2.8 Mengensystem, Aufspalten, Abspalten 10
2.9 VC-Dimension 11
2.13 Untersystem 12

Liste der Aussagen

1.1 Abschätzung tatsächlicher Fehler der Schwellenwertfunktionen 5
1.3 Abschätzung tatsächlicher Fehler Intervalllernen 7
1.4 Union Bound 7
2.1 Tatsächlicher Fehler bei endlicher Hypothesenklasse 8
2.4 PAC-lernbar wenn Wachstumsfunktion subexponentiell 9
2.6 Sneak Peak: Wachstumslemma 10
2.7 PAC-Lernbarkeit mit VC-Dimension 10
2.12 Größe von Mengensystemen 11
2.14 Wachstumslemma 12

Liste der Algorithmen

Liste der Abkürzungen

iid unabhängig und identisch verteilt (independent and identically distributed) . . . 4 f., 8 ff.

PAC probably approximately correct . . . . . 5 ff., 9 f., B f.

VC Vapnik-Chervonenkis . . . . . 8–12, B f.

Index

Abspaltung (Menge), 10
Aufspaltung (Menge), 10

bag of words, 2

Fehler
    tatsächlicher -, 3
    Trainings-, 4

Grundwahrheit, 3

Hypothese, 2
Hypothesenklasse, 2

iid, 4, 5, 8–10
Instanz, 2

Label, 2

Mengensystem, 10
    Abspaltung, 10
    Aufspaltung, 10
    Untersystem, 12

Merkmalsraum, 2

PAC, 5–7, 9, 10, B, C
PAC-Lernbarkeit, 6
    effiziente -, 6

realisierbar, 5

Sample, 3, 4

tatsächlicher Fehler, 3
Trainingsfehler, 4

Untersystem, 12

VC, 8–12, B, C
VC-Dimension, 11

Wachstumfsunktion, 12
Wachstumsfunktion, 8
Wahrscheinlichkeitsmaß, 3
Wahrscheinlichkeitsverteilung, 3
    diskrete -, 3