Universität Bonn

Mitschrift zur Vorlesung

Algorithmische Grundlagen des maschinellen Lernens

gehalten von

Prof. Dr. Anne Driemel

geTEXed von

Daniel Emse

Sommer 2026

Anmerkungen und Korrekturen

Falls du Anmerkungen/Korrekturen hast, melde dich bei mir (`daniel.emse@uni-bonn.de`).

Inhaltsverzeichnis

Vorlesung **1**

1 Einführung **2**
1.1 Binäre Klassifikation 2

2 PAC-Lernbarkeit **5**
2.1 Lernen von Schwellenwertfunktionen 5
2.2 PAC-Lernbarkeit 6
2.3 Lernen von Intervallen 6

3 Endliche Hypothesenklassen, Wachstumsfunktion und VC-Dimension **8**
3.1 Endliche Hypothesenklassen, Wachstumsfunktion 8
3.2 Subexponentielles Wachstum impliziert PAC-Lernbarkeit 9
3.3 Schranke über die VC-Dimension 9

4 Mengensysteme und deren VC-Dimension **11**
4.1 Wachstum von endlichen Mengensystemen 11
4.2 Unendliche Mengensysteme 13

5 Lineare Klassifikation und ihre VC-Dimension **14**
5.1 VC-Dimension von Halbräumen 14
5.2 Homogene Halbräume 17

6 PAC-Lernbarkeit und ε-Netze **18**

7 Boosting **21**
7.1 Einführendes Beispiel 21
7.2 Problemstellung 21
7.3 Idee für einen Algorithmus 22
7.4 AdaBoost 22

8 VC-Dimensionen von Kompositionen **25**

9 Entscheidungsbäume **26**
9.1 Hypothesenklasse 26
9.2 VC-Dimension 27
9.3 Lernalgorithmen 27
9.3.1 Greedy-Algorithmus 27

Anhang **A**

Liste der Definitionen **B**

Liste der Aussagen **C**

Liste der Algorithmen **D**

Liste der Abkürzungen **E**

Index **F**

Vorlesung

Kapitel 1

Einführung

[14.04.2026, Vorlesung 1]

1.1 Binäre Klassifikation

Beispiel 1.1.

- SPAM oder noSPAM für E-Mails
- Hund oder kein Hund für Fotos

Wir haben also immer die **Labels** *positiv* oder *negativ* für solche **Instanzen**.

Definition 1.2: Merkmalsraum

Ein *Merkmalsraum* $\mathcal{X}$ ist eine Menge, die eindeutig alle zu untersuchenden Instanzen eines Problems darstellt.

Beispiel 1.3.

- Für die SPAM-Klassifikation könnten wir beispielsweise folgendermaßen klassifizieren:
  1. $\mathcal{X}$ ist die Menge aller Strings in UTF-8 Unicode-Codierung
  2. $\mathcal{X}$ ist eine Menge von Vektoren, also $\mathcal{X} \subseteq \mathbb{Z}^d_{\geq 0}$, wobei ein Vektor aus $\mathcal{X}$ angibt, ob und wie häufig bestimmte Wörter in der E-Mail vorkommen. Dabei sind beispielsweise Wörter wie *price*, *winner* oder ähnliches Teile des *bag of words*, und ihnen ist ein Index $\in \{1, \dots, d\}$ zugeordnet. Der entsprechende Vektor zählt also diese Häufigkeiten
- Für die Image-Klassifikation könnten wir beispielsweise folgendermaßen klassifizieren:
  1. $\mathcal{X}$ ist die Menge aller Bilder in RGB-Pixeldarstellung mit fester Auflösung, fester Größe und fester Farbtiefe (beispielsweise 1 Megapixel, 24 bit Farbtiefe führen zu $|\mathcal{X}| = (2^{24})^{10^6}$, das ist tatsächlich sehr groß)
  2. $\mathcal{X}$ ist eine Menge von Vektoren, also $\mathcal{X} \subseteq \mathbb{Z}^d_{\geq 0}$, wobei ein Vektor aus $\mathcal{X}$ angibt, ob und wie häufig bestimmte *SIFT descriptors* vorkommen

Letztendlich suchen wir eine *Hypothese* $h \colon \mathcal{X} \to \{1, -1\}$, sodass

$$h(x) = \begin{cases} 1 & x \text{ ist SPAM/Hund/} \dots \\ -1 & \text{sonst.} \end{cases}$$

Definition 1.4: Hypothesenklasse

Eine *Hypothesenklasse* $\mathcal{H}$ ist eine Menge von Funktionen $\mathcal{X} \to \{1, -1\}$.

Beispiel 1.5. Wir betrachten einige Beispiele für $\mathcal{H}$.

- Es könnte $\mathcal{H} = \{f \colon \mathcal{X} \to \{1, -1\}\}$ sein, also einfach *alle* solche Funktionen beinhalten.

  Nachteil: Wir haben zu wenig Struktur.
- Sei $\mathcal{X} = \mathbb{R}$ und $\mathcal{H} = \{h_a \mid a \in \mathbb{R}\}$, wobei

$$h_a(x) = \begin{cases} 1 & x \geq a \\ -1 & x < a. \end{cases}$$

- Sei $\mathcal{X}$ die Menge aller Bilder und $\mathcal{H}$ die Menge aller Hypothesen h_w, die einem neuronalen Netz mit fester Architektur und einem Gewichtsvektor w entsprichen.

Wie wählen wir nun also unsere Hypothesen aus? Was macht eine gute Hypothese aus?

Definition 1.6: Grundwahrheit

Die *Grundwahrheit* f ist eine Funktion $f \colon \mathcal{X} \to \{1, -1\}$. Wenn dieses f existiert, weist f jedem $x \in \mathcal{X}$ das korrekte Label zu.

Wir nehmen an, dass so ein f existiert.

Ziel: Finde eine Hypothese h, die f möglichst nahe kommt.

Wir nehmen an, dass m Datenpunkte (*Instanzen*) aus einer Wahrscheinlichkeitsverteilung $\mathcal{D}$ über $\mathcal{X}$ gezogen werden. Diese nennen wir *Sample*.

Definition 1.7: Diskrete Wahrscheinlichkeitsverteilung

Eine *diskrete Wahrscheinlichkeitsverteilung* $\mathcal{D}$ über $\mathcal{X}$ ist definiet über ein *Wahrscheinlichkeitsmaß* $\mathbb{P} \colon \mathcal{X} \to [0, 1]$, wobei $\mathbb{P}(x) \neq 0$ nur für abzählbar viele Punkte gelten soll und

$$\sum_{x \in \mathcal{X}} \mathbb{P}(x) = 1$$

gelten soll.

Beispiel 1.8. Sei $\mathcal{X} = \mathbb{R}$ und $\mathbb{P}(x) = \begin{cases} \frac{1}{100} & x \in \{1, \ldots, 100\} \\ 0 & \text{sonst} \end{cases} = \mathbb{1}_{\{1,\ldots,100\}}(x).$

Definition 1.9: Tatsächlicher Fehler

Der *tatsächliche Fehler* $\mathrm{err}_{\mathcal{D},f}(h)$ einer Hypothese h hinsichtlich Verteilung $\mathcal{D}$ über Merkmalsraum $\mathcal{X}$ und Grundwahrheit f ist

$$\mathrm{err}_{\mathcal{D},f}(h) \coloneqq \mathbb{P}_{x \sim \mathcal{D}}[h(x) \neq f(x)].$$

Beispiel 1.10. Es sei $f(x) = h_{30}$ und $h(x) = h_{50}$. Dann ist

$$\mathrm{err}_{\mathcal{D},f}(h) = \frac{|\{30, \ldots, 49\}|}{|\{1, \ldots, 100\}|} = \frac{20}{100} = \frac{1}{5}.$$

Problem 1.11: Lernproblem

Input: m Datenpunkte $x_1, \ldots, x_m$, die *unabhängig und identisch verteilt (independent and identically distributed, iid)* aus $\mathcal{D}$ gezogen sind, und $y_1 = f(x_1), \ldots, y_m = f(x_m)$ (die *korrekten* Labels). Sei $S = \{(x_1, y_1), \ldots, (x_m, y_m)\}$ die Menge der Samples also gegeben
Output: Hypothese $h_S \in \mathcal{H}$
Objective: $\mathrm{err}_{\mathcal{D},f}(h_S)$ möglichst klein

Definition 1.12: Trainingsfehler

Der *Trainingsfehler* $\mathrm{err}_S(h)$ einer Hypothese $h \in \mathcal{H}$ hinsichtlich einer Trainingsmenge S ist

$$\mathrm{err}_S(h) \coloneqq \frac{1}{m}|\{h(x_i) \neq y_i\}|.$$

[14.04.2026, Vorlesung 1]
[16.04.2026, Vorlesung 2]

Kapitel 2

PAC-Lernbarkeit

2.1 Lernen von Schwellenwertfunktionen

Sei im Folgenden $\mathcal{X} = \mathbb{R}$ unser Merkmalsraum.

In diesem Beispiel und auch im Folgenden vereinfachen wir uns das Leben durch die Annahme, dass die Grundwahrheit *realisierbar* ist. Das heißt, dass $f \in \mathcal{H}$. Wir werden unsere Theorie später verallgemeinern, dass sie auch ohne diese Annahme auskommt. Wir nehmen also an, dass es ein $a \in \mathbb{R}$ gibt, sodass die Grundwahrheit $f\colon \mathcal{X} \to \{-1, 1\}$ gegeben ist durch

$$f(x) = \begin{cases} 1 & x \geq a \\ -1 & \text{sonst.} \end{cases}$$

Wir nehmen an, dass uns m Datenpunkte mit korrekten Labels gegeben sind: Seien $x_1, \ldots, x_m$ Datenpunkte, die iid aus $\mathcal{D}$ gezogen sind. Außerdem seien $y_i = f(x_i)$ die zugehörigen, korrekten Labels. Die Menge aller Samples bezeichnen wir mit $S = \{(x_1, y_1), \ldots, (x_m, y_m)\}$.

Ein einfacher Lernalgorithmus wählt nun das größte a', sodass $h_{a'}$ die Menge S korrekt klassifiziert. Das heißt, wir setzen a' auf den Wert des kleinsten x_i mit $y_i = 1$, wenn es ein solches gibt. Anderenfalls $a' = \infty$.

Satz 2.1: Abschätzung tatsächlicher Fehler der Schwellenwertfunktionen

Sei $h_{a'}$ die vom einfachen Lernalgorithmus berechnete Hypothese, der als Eingabe eine Menge von Samples von m Datenpunkten mit korrekten Labels gemäß f erhält, die iid aus $\mathcal{D}$ gezogen werden. Dann gilt für alle $\varepsilon > 0$, dass

$$\mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_{a'}) > \varepsilon] \leq e^{-\varepsilon m}.$$

Beweis. Weil unser Lernalgorithmus unter allen Hypothesen, die S korrekt klassifizieren, die Hypothese $h_{a'}$ mit dem größten a' wählt, wird auf jeden Fall gelten, dass $a' \geq a$. Falsch klassifiziert werden alle Punkte im Bereich $[a, a')$. Somit gilt nun für jede Verteilung $\mathcal{D}$

$$\mathrm{err}_{\mathcal{D},f}(h_{a'}) = \mathbb{P}_{x\sim\mathcal{D}}[x \in (a, a']].$$

Sei nun $a'' \geq a$ die kleinste Zahl, sodass $\mathbb{P}_{x\sim D}[x \in (a, a'')] \geq \varepsilon$. Es könnte sein, dass a'' nicht existiert, weil $\mathbb{P}_{x\sim\mathcal{D}}[x \in [a, \infty)] < \varepsilon$. Dann ist aber die Wahrscheinlichkeit, dass der Fehler $\mathrm{err}_{\mathcal{D},f}(h_{a'})$ den Wert ε überschreitet, gleich null, und die Aussage des Satzes gilt trivialerweise.

Es bleibt zu zeigen, dass die Aussage des Satzes auch dann gilt, wenn $\mathcal{D}$ dergestalt ist, dass $\mathbb{P}_{x\sim D}[x \in [a, \infty)] \geq \varepsilon$ und somit a'' wohldefiniert ist. Damit muss auch gelten $\mathbb{P}_{x\sim D}[x \in (a, a'']] \leq \varepsilon$. Der Fehler von $h_{a'}$ wird also höchstens ε sein, falls $a' \leq a''$. Dies geschieht, wenn es mindestens ein i gibt, sodass $x_i \in [a, a'']$. Sei $\mathcal{E}_i$ das Ereignis, dass $x_i \in [a, a'']$. Es gilt $\mathbb{P}[\mathcal{E}_i] = \mathbb{P}_{x_i\sim\mathcal{D}}[x_i \in [a, a'']] \geq \varepsilon$. Damit *nicht* $a' \leq a''$ gilt, darf keines der Ereignisse $\mathcal{E}_i$ eintreten. Wir interessieren

uns also für $\bigcap_i \overline{\mathcal{E}_i}$. Weil $x_1, \ldots, x_m$ unabhängige Züge aus $\mathcal{D}$ sind, gilt nun auch

$$\mathbb{P}\left[\bigcap_i \overline{\mathcal{E}_i}\right] = \prod_i \mathbb{P}[\overline{\mathcal{E}_i}] \leq (1-\varepsilon)^m.$$

Mit $1 - x \leq e^{-x}$ für alle $x \in \mathbb{R}$ folgt die Behauptung. □

2.2 PAC-Lernbarkeit

Satz 2.1 sagt uns nun insbesondere, dass wenn wir $m = \frac{1}{\varepsilon} \ln\left(\frac{1}{\delta}\right)$ wählen, die Wahrscheinlichkeit, dass der tatsächliche Fehler unserer gefundenen Hypothese größer als ε ist, kleiner als δ wird. Diese Aussage gilt für alle $\varepsilon > 0$ und alle $\delta > 0$. Wenn die Anzahl der Samples also nur groß genug ist, werden wir mit großer Wahrscheinlichkeit nur einen sehr kleinen Fehler haben. Die Hypothesenklassen, für die dies gilt, heißen *PAC-lernbar*:

Definition 2.2: PAC-Lernbarkeit

Eine Hypothesenklasse $\mathcal{H}$ heißt *PAC-lernbar* (im realisierbaren Sinn), wenn es eine Funktion $m_{\mathcal{H}}$ und einen Lernalgorithmus $\mathcal{A}$ gibt, sodass A für alle $\varepsilon, \delta > 0$ jede Verteilung $\mathcal{D}$ und alle $f \in \mathcal{H}$, gegeben ein Sample S von Größe mindestens $m_{\mathcal{H}}(\varepsilon, \delta)$ von Datenpunkten mit korrekten Labels, eine Hypothese $h_S \in \mathcal{H}$ berechnet, sodass

$$\mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_S) < \varepsilon] \geq 1 - \delta.$$

PAC-Lernbarkeit nach dieser Definition impliziert nicht unbedingt, dass das Lernproblem effizient lösbar ist. Man spricht von *effizienter PAC-Lernbarkeit*, wenn die Laufzeit von $\mathcal{A}$ polynomiell ist und außerdem gilt, dass $m_{\mathcal{H}}(\varepsilon, \delta)$ polynomiell in $\frac{1}{\varepsilon}$ und $\frac{1}{\delta}$ beschränkt ist.

PAC steht für *probably approximately correct*. Dabei bedeutet *probably* in diesem Fall, dass die Wahrscheinlichkeit mindestens $1 - \delta$ ist, und *approximately correct* bezieht sich darauf, dass $\mathrm{err}_{\mathcal{D},f}(h_S) < \varepsilon$.

Nicht jede Hypothesenklasse ist PAC-lernbar. Zum Beispiel ist die Klasse aller Hypothesen $\mathbb{N} \to \{-1, 1\}$ nicht PAC-lernbar, was wir noch beweisen werden.

2.3 Lernen von Intervallen

Wir betrachten als weiteres Beispiel nun die Klasse der Intervallfunktionen. Weiterhin sei $\mathcal{X} = \mathbb{R}$, aber $\mathcal{H}$ sei nun die Menge der Funktionen der Form $h_{a',b'} : \mathbb{R} \to \{-1, 1\}$ mit

$$h_{a',b'} = \begin{cases} 1 & x \in [a', b'] \\ -1 & \text{sonst.} \end{cases}$$

Wir betrachten weiterhin den realisierbaren Fall. Das heißt, es gibt eine Grundwahrheit $f \in \mathcal{H}$, die alle Datenpunkte richtig klassifiziert. Diese hat die Form

$$f(x) = \begin{cases} 1 & x \in [a, b] \\ -1 & \text{sonst.} \end{cases}$$

Gegeben ist wieder eine Menge $S = \{(x_1, y_1), \ldots, (x_m, y_m)\}$ von Datenpunkten mit korrekten Labels. Unser Lernalgorithmus wählt das kleinste Intervall $[a', b']$, das S korrekt klassifiziert. Das heißt, wir setzen a' auf den Wert des kleinsten x_i mit $y_i = 1$ und b' auf den Wert des größten x_i mit $y_i = 1$. Den Fall, dass es kein i mit $y_i = 1$ gibt, schieben wir ab in die Übung und ignorieren ihn.

Satz 2.3: Abschätzung tatsächlicher Fehler Intervalllernen

Für alle $\varepsilon > 0$ gilt

$$\mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_{a',b'}) > \varepsilon] \leq 2e^{-\frac{\varepsilon m}{2}}.$$

Lemma 2.4: Union Bound

Es seien $\mathcal{E}_1, \ldots, \mathcal{E}_n$ (nicht notwendigerweise disjunkte) Ereignisse. Dann gilt

$$\mathbb{P}\left[\bigcup_{i=1}^{n} \mathcal{E}_i\right] \leq \sum_{i=1}^{n} \mathbb{P}[\mathcal{E}_i].$$

Beweis. Induktives Anwenden von $\mathbb{P}[A \cup B] = \mathbb{P}[A] + \mathbb{P}[B] - \mathbb{P}[A \cap B] \leq \mathbb{P}[A] + \mathbb{P}[B]$. □

Beweis von Satz 2.3. Weil unser Lernalgorithmus das kleinste Intervall wählt, welches S korrekt klassifiziert, wird auf jeden Fall gelten, dass $a' \geq a$ und $b' \leq b$. Falsch klassifiziert werden alle Punkte im Bereich $[a, a') \cup (b', b]$. Somit gilt nun für jede Verteilung $\mathcal{D}$

$$\mathrm{err}_{\mathcal{D},f}(h_{a',b'}) = \mathbb{P}_{x\sim\mathcal{D}}[x \in [a, a') \cup (b', b]].$$

Analog zu oben betrachten wir den Fall, dass $\mathbb{P}_{x\sim\mathcal{D}}[x \in [a, b]] < \varepsilon$. In diesem Fall ist die Wahrscheinlichkeit, dass der Fehler $\mathrm{err}_{\mathcal{D},f}(h_{a',b'})$ den Wert ε überschreitet, wieder gleich null, und die Aussage des Satzes gilt trivialerweise.

Es bleibt zu zeigen, dass die Aussage des Satzes auch dann gilt, wenn $\mathcal{D}$ dergestalt ist, dass $\mathbb{P}_{x\sim D}[x \in [a, b]] \geq \varepsilon$. Sei nun, ähnlich wie oben, $a'' \in [a, b]$ die kleinste Zahl, sodass $\mathbb{P}_{x\sim D}[x \in [a, a'']] \geq \frac{\varepsilon}{2}$. Analog sei $b'' \in [a, b]$ die größte Zahl, sodass $\mathbb{P}_{x\sim\mathcal{D}}[x \in [b'', b]] \geq \frac{\varepsilon}{2}$. Damit $\mathrm{err}_{\mathcal{D},f}(h_{a',b'}) \leq \varepsilon$, ist es nun hinreichend, dass $a' \leq a''$ und $b' \geq b''$. Dies geschieht, wenn es mindestens ein i und mindestens ein j gibt, sodass $x_i \in [a, a'']$ und $x_j \in [b'', b]$ wobei i und j nicht verschieden sein müssen. Für jedes i gilt

$$\mathbb{P}[x_i \in [a, a'']] \geq \frac{\varepsilon}{2} \quad \text{und} \quad \mathbb{P}[x_i \in [b'', b]] \geq \frac{\varepsilon}{2}.$$

Sei $\mathcal{E}_a$ das Ereignis, dass $x_1, \ldots, x_m \notin [a, a'']$ und sei $\mathcal{E}_b$ das Ereignis, dass $x_1, \ldots, x_m \notin [b'', b]$. Weil $x_1, \ldots, x_m$ unabhängige Züge aus $\mathcal{D}$ sind, gilt nun auch

$$\mathbb{P}[\mathcal{E}_a] \leq \left(1 - \frac{\varepsilon}{2}\right)^m \quad \text{und} \quad \mathbb{P}[\mathcal{E}_b] \leq \left(1 - \frac{\varepsilon}{2}\right)^m$$

und mit Lemma 2.4 folgt

$$\mathbb{P}[\mathcal{E}_a \cup \mathcal{E}_b] \leq 2\left(1 - \frac{\varepsilon}{2}\right)^m.$$

Die Behauptung folgt wieder mit $1 - x \leq e^{-x}$. □

Aus dem Satz können wir folgern, dass auch die Klasse der Intervalle PAC-lernbar ist. Setzen wir etwa $m = \frac{2}{\varepsilon'} \ln\left(\frac{2}{\delta}\right)$, dann folgt aus Satz 2.3, dass $\mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_S) \leq \varepsilon'] \geq 1 - \delta$, wobei wir ε' und δ als Parameter wählen können. Es gilt für jedes $\varepsilon' < \varepsilon$, dass

$$\mathbb{P}[\mathrm{err}_{D,f}(h_S) < \varepsilon] \geq \mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_S) \leq \varepsilon'].$$

Wählen wir also beispielsweise $m_{\mathcal{H}}(\varepsilon, \delta) = \frac{4}{\varepsilon} \ln\left(\frac{2}{\delta}\right)$, dann folgt $\mathbb{P}[\mathrm{err}_{\mathcal{D},f}(h_S) < \varepsilon] \geq 1 - \delta$. Die Klasse der Intervalle ist also PAC-lernbar.

[16.04.2026, Vorlesung 2]
[21.04.2026, Vorlesung 3]

Kapitel 3

Endliche Hypothesenklassen, Wachstumsfunktion und VC-Dimension

3.1 Endliche Hypothesenklassen, Wachstumsfunktion

Wir betrachten den Fall, dass $\mathcal{H}$ endlich ist.

Satz 3.1: Tatsächlicher Fehler bei endlicher Hypothesenklasse

Wenn $m \geq \frac{1}{\varepsilon} \ln\left(\frac{|\mathcal{H}|}{\delta}\right)$, *dann gilt mit Wahrscheinlichkeit mindestens* $1-\delta$, *dass alle* $h \in \mathcal{H}$ *mit* $\operatorname{err}_S(h) = 0$ *auch* $\operatorname{err}_{\mathcal{D},f}(h) < \varepsilon$ *erfüllen.*

Beweis. Sei $h \in \mathcal{H}$ fest mit $\operatorname{err}_{\mathcal{D},f}(h) \geq \varepsilon$. Dann gilt, da S iid mittels $\mathcal{D}$ gezogen wird, und mit der Voraussetzung $\mathbb{P}[h(x_i) \neq y_i] \geq \varepsilon$

$$\mathbb{P}\left[\operatorname{err}_S(h) = 0\right] = \mathbb{P}[h(x_1) = y_1, \ldots, h(x_m) = y_m] = \prod_{i=1}^{m} \mathbb{P}[h(x_i) = y_i] \leq (1-\varepsilon)^m \leq e^{-\varepsilon m}.$$

Für jede Hypothese definiere $\mathcal{E}_h$ als das Ereignis, dass $\operatorname{err}_S(h) = 0$ ist. Dann ist

$$\mathbb{P}[\exists h \in \mathcal{H} \colon \operatorname{err}_S(h) = 0 \text{ und } \operatorname{err}_{\mathcal{D},f}(h) \geq \varepsilon] = \mathbb{P}\left[\bigcup_{\substack{h \in \mathcal{H} \\ \operatorname{err}_{\mathcal{D},f}(h) \geq \varepsilon}} \mathcal{E}_h\right]$$

$$\leq \sum_{\substack{h \in \mathcal{H} \\ \operatorname{err}_{\mathcal{D},f}(h) \geq \varepsilon}} \mathbb{P}[\operatorname{err}_S(h) = 0] \leq |\mathcal{H}| e^{-\varepsilon m} \leq \delta,$$

also exakt, was wir zeigen wollten. □

Definition 3.2: Wachstumsfunktion

Gegeben $A \subseteq \mathcal{X}$, sei $\mathcal{H}|_A$ die Menge aller Hypothesen $h \in \mathcal{H}$ mit Definitionsbereich eingeschränkt auf A, also

$$\mathcal{H}|_A = \{h|_A \mid h \in \mathcal{H}\}.$$

Die *Wachstumsfunktion* von $\mathcal{H}$ ist definiert als

$$\Pi_{\mathcal{H}}(m) \coloneqq \max_{\substack{A \subseteq \mathcal{X} \\ |A| = m}} |\mathcal{H}|_A|.$$

Es gilt immer $\Pi_{\mathcal{H}}(m) \leq 2^m$, es ist aber oft wesentlich kleiner.

Beispiel 3.3. Sei $\mathcal{X} = \mathbb{R}$ und $\mathcal{H}$ die Klasse der Schwellenwertfunktionen $h_a(x) = \begin{cases} 1 & x \geq a \\ -1 & \text{sonst.} \end{cases}$

Für $A = \{2, 3, 4\}$ ist

$$\mathcal{H}|_A = \left\{ x \mapsto -1 \forall x \in A x \mapsto 1 \forall x \in A, x \mapsto \begin{cases} 1 & x = 4 \\ -1 & x \in \{2, 3\} \end{cases}, x \mapsto \begin{cases} 1 & x \in \{3, 4\} \\ -1 & x = 2 \end{cases} \right\}$$

und damit ist $|\mathcal{H}|_A| = 4 \ll 2^3$. Allgemein ist für $|A| = m$ für Schwellenwertfunktionen immer $|\mathcal{H}|_A| = m + 1$.

3.2 Subexponentielles Wachstum impliziert PAC-Lernbarkeit

Satz 3.4: PAC-lernbar wenn Wachstumsfunktion subexponentiell

Es seien $\varepsilon, \delta > 0$ fest, und

$$m \geq \max\left\{ \frac{8}{\varepsilon}, \frac{2}{\varepsilon} \log_2 \left(\frac{2\Pi_{\mathcal{H}}(2m)}{\delta} \right) \right\}. \tag{3.1}$$

Betrachte eine Sample-Menge S von m Datenpunkten mit korrekten Labels gemäß der Grundwahrheit f, die iid aus $\mathcal{D}$ gezogen werden. Dann gilt mit Wahrscheinlichkeit $\geq 1-\delta$, dass alle $h \in \mathcal{H}$ mit $\mathrm{err}_S(h) = 0$ auch $\mathrm{err}_{\mathcal{D},f}(h) < \varepsilon$ erfüllen.

Der Beweis folgt später. Wir fragen uns erstmal, wann die Ungleichung

$$m \geq \frac{2}{\varepsilon} \log_2 \left(\frac{2\Pi_{\mathcal{H}}(2m)}{\delta} \right) = \frac{2}{\varepsilon} \log_2(\Pi_{\mathcal{H}}(2m)) + \frac{2}{\varepsilon} \log_2 \left(\frac{2}{\delta} \right) \tag{3.2}$$

erfüllt ist. Es ist (3.2) äquivalent zu

$$\frac{m - \frac{2}{\varepsilon} \log_2 \left(\frac{2}{\delta} \right)}{\log_2(\Pi_{\mathcal{H}}(2m))} \geq \frac{2}{\varepsilon}.$$

Wir testen ein paar Schranken aus.

(a) Wenn $\Pi_{\mathcal{H}}(2m) = 2^{2m}$, dann ist $\log_2(\Pi_{\mathcal{H}}(2m)) = 2m$ und die Ungleichung kann nicht für alle $\varepsilon, \delta > 0$ erfüllt werden.

(b) Gilt $\log_2(\Pi_{\mathcal{H}}(2m)) \in o(m)$, so müssen wir m nur hinreichend groß wählen, um diese Schranke zu erfüllen.

Beispiel 3.5. Bei den Schwellenwertfunktionen ist $\Pi_{\mathcal{H}}(2m) = 2m + 1$. Dann gilt für alle $\delta > 0$

$$\frac{m - \frac{2}{\varepsilon} \log_2 \left(\frac{2}{\delta} \right)}{\log_2(2m + 1)} \xrightarrow{m \to \infty} \infty.$$

Damit erhalten wir (mit dem Beweis von Satz 3.4 als Black Box) PAC-Lernbarkeit für Hypothesenklassen, die die angesprochenen Ungleichungen erfüllen.

3.3 Schranke über die VC-Dimension

Über die Vapnik-Chervonenkis (VC)-Dimension werden wir die Wachstumsfunktion beschränken (in mehr Details in der nächsten Vorlesung):

Lemma 3.6: Sneak Peak: Wachstumslemma

Wenn $\mathcal{H}$ VC-Dimension d hat, so gilt

$$\Pi_{\mathcal{H}}(m) \leq \left(\frac{em}{d}\right)^d$$

Damit motivieren wir folgenden Satz:

Satz 3.7: PAC-Lernbarkeit mit VC-Dimension

Sei $\mathcal{H}$ eine Hypothesenklasse mit VC-Dimension $d < \infty$. Seien $1 \geq \varepsilon > 0$, $\delta > 0$ und sei

$$m \geq \max\left\{\frac{4}{\varepsilon}\log_2\left(\frac{2}{\delta}\right), \frac{8d}{\varepsilon}\log_2\left(\frac{16}{\varepsilon}\right)\right\}. \tag{3.3}$$

Betrachte eine Sample-Menge S von m Datenpunkten mit korrekten Labels gemäß der Grundwahrheit f, die iid aus $\mathcal{D}$ gezogen werden. Dann gilt mit Wahrscheinlichkeit $\geq 1-\delta$, dass alle $h \in \mathcal{H}$ mit $\mathrm{err}_S(h) = 0$ auch $\mathrm{err}_{\mathcal{D},f}(h) < \varepsilon$ erfüllen.

Beweis. Es genügt zu zeigen, dass (3.3) bereits (3.2) impliziert (wenn wir später Satz 3.4 später gezeigt haben).

Zunächst, da $d \geq 1$ und $\varepsilon \leq 1$, gilt

$$m \geq \frac{8d}{\varepsilon}\log_2\left(\frac{16}{\varepsilon}\right) \geq \frac{8}{\varepsilon}.$$

Weiterhin gilt

$$\frac{m - \frac{2}{\varepsilon}\log_2\left(\frac{2}{\delta}\right)}{\log_2(\Pi_{\mathcal{H}}(2m))} \geq \frac{m}{2d\log_2\left(\frac{2em}{d}\right)} \geq \frac{\frac{8d}{\varepsilon}\log_2\left(\frac{16}{\varepsilon}\right)}{2d\log_2\left(\frac{2e}{d}\cdot\frac{8d}{\varepsilon}\log_2\left(\frac{16}{\varepsilon}\right)\right)} \geq \frac{4}{\varepsilon}\frac{\log_2\left(\frac{16}{\varepsilon}\right)}{\log_2\left(\frac{16e}{\varepsilon}\cdot\log_2\left(\frac{16e}{\varepsilon}\right)\right)} \geq \frac{2}{\varepsilon},$$

da der Nenner monoton fallend in ε und im Intervall $(0,1)$ mindestens $\frac{1}{2}$ ist. □

[21.04.2026, Vorlesung 3]
[23.04.2026, Vorlesung 4]

Kapitel 4

Mengensysteme und deren VC-Dimension

Heute fragen wir uns, welche Struktur einer Hypothesenklasse $\mathcal{H}$ zu subexponentiellem Wachstum führt.

Definition 4.1: Mengensystem, Aufspalten, Abspalten

Sei $\mathcal{X}$ eine beliebige Menge und $\mathcal{R} \subseteq \mathcal{P}(\mathcal{X})$. Dann nennen wir $\mathcal{R}$ ein *Mengensystem mit Grundmenge* $\mathcal{X}$.
Eine Menge $A' \subseteq \mathcal{X}$ wird *durch* $\mathcal{R}$ von einer Menge A *abgespalten*, wenn $r \in \mathcal{R}$ existiert, sodass $A' = r \cap A$.
Eine Menge $A \subseteq \mathcal{X}$ wird *durch* $\mathcal{R}$ *aufgespalten* (engl. *Shattering*), wenn jede Teilmenge $A' \subseteq A$ von A durch $\mathcal{R}$ abgespalten wird.

Definition 4.2: VC-Dimension

Die *Vapnik-Chervonenkis (VC)-Dimension* von $\mathcal{R}$ ist die Anzahl der Elemente der größten aufgespaltenen Menge. Wir schreiben dafür $\dim(\mathcal{R})$.
Wir setzen $\dim(\mathcal{R}) := \infty$, wenn für jedes $n_0 \in \mathbb{N}$ eine aufgespaltene Menge mit n_0 Elementen existiert, und $\dim(\mathcal{R}) := 0$, wenn keine solche Menge existiert.

Beispiel 4.3.

1. Für $\mathcal{X} = \mathbb{R}^2$ und $\mathcal{R}$ die Menge aller achsenparalleler Rechtecke. Betrachte $A \subseteq \mathcal{X}$. Es ist $\dim(\mathcal{R}) \geq 4$. Wenn wir mindestens fünf Punkte haben, so ist einer dieser Punkte in keiner Koordinate „extrem“ bzw. „maximal“, und wir können also nie ein Rechteck um alle Punkte außer diesen Mittelpunkt bauen. Also ist $\dim(\mathcal{R}) = 4$.
2. Für $\mathcal{X} = \mathbb{R}^2$ und $\mathcal{R}$ die Menge aller konvexen Polygone. Dann ist für jedes n_0 die Menge der n_0 Punkte, die ein regelmäßiges n_0-Eck bilden, aufspaltbar. Also ist $\dim(\mathcal{R}) = \infty$.

4.1 Wachstum von endlichen Mengensystemen

Beispiel 4.4. Sei $\mathcal{X} = \{1, \dots, m\}$ und sei $\mathcal{R}$ das Mengensystem, das alle Teilmengen von maximaler Größe k enthält. Dann ist $\dim(\mathcal{R}) = k$ und

$$|\mathcal{R}| = \sum_{i=0}^{k} \binom{m}{i} = \sum_{i=0}^{k} \left(\frac{m}{k}\right)^i \frac{k^i}{i!} \leq \left(\frac{m}{k}\right)^k \sum_{i=0}^{k} \frac{k^i}{i!} \leq \left(\frac{em}{k}\right)^k.$$

mit

$$\binom{m}{i} = \frac{m!}{(m-i)!i!} \leq \frac{m^i k^i}{i!k^i} \leq \left(\frac{m}{k}\right)^i \frac{k^i}{i!}$$

und der Reihendarstellung von exp

$$e^x = \sum_{i=0}^{\infty} \frac{x^i}{i!}.$$

Damit wächst $|\mathcal{R}|$ subexponentiell in m für konstante k.

Lemma 4.5: Größe von Mengensystemen

Es gilt für jedes Mengensystem $\mathcal{R}$ mit m-elementiger Grundmenge $\mathcal{X}$ und VC-Dimension d, dass

$$|\mathcal{R}| \leq \sum_{i=0}^{d} \binom{m}{i}.$$

Beweis. Wir machen Induktion über m.

IA: $m = 0$**.** Dann ist $|\mathcal{R}| \leq 1$ und $d = 0$ und es gilt

$$\sum_{i=0}^{d} \binom{0}{i} = \binom{0}{0} = 1.$$

IS: $m > 0$**.** Sei $\mathcal{R}$ ein Mengensystem mit Grundmenge $\mathcal{X}$ mit $|\mathcal{X}| = m$ und VC-Dimension d. Angenommen, $d = 0$. Dann ist $|\mathcal{R}| \leq 1$ und die Aussage ist erfüllt, da $\binom{m}{i} \geq \binom{1}{0} = 1$.

Sei also auch $d > 0$. Sei $x \in \mathcal{X}$ fest. Sei $\mathcal{R}_1 \coloneqq \{r \setminus \{x\} \mid r \in \mathcal{R}\}$ und sei $\dim(\mathcal{R}_1) = d_1 \leq d$. Nach Induktionsvoraussetzung folgt

$$|\mathcal{R}_1| \leq \sum_{i=0}^{d_1} \binom{m-1}{i} \leq \sum_{i=0}^{d} \binom{m-1}{i}.$$

Definiere $\mathcal{R}_2 \coloneqq \{r \setminus \{x\} \mid r \cup \{x\} \in \mathcal{R} \text{ und } r \setminus \{x\} \in \mathcal{R}\}$. Es gilt also $|\mathcal{R}| = |\mathcal{R}_1| + |\mathcal{R}_2|$. Dieses $\mathcal{R}_2$ dient dazu, es auszugleichen, dass in $\mathcal{R}_1$ durch Beschränkung von $\mathcal{R}$ auf $\mathcal{X} \setminus \{x\}$ zwei verschiedene Mengen identisch werden können. Diese Mengen werden in $\mathcal{R}_2$ quasi doppelt gezählt und somit ausgeglichen.

Beispiel. Für $\mathcal{X} = \{1, 2, 3\}, x = 1$ und $\mathcal{R} = \{\{1, 2\}, \{2\}, \{1, 3\}\}$, dann ist $\mathcal{R}_1 = \{\{2\}, \{3\}\}$ und $\mathcal{R}_2 = \{\{2\}\}$.

Sei $d_2 = \dim(\mathcal{R}_2)$. Wir behaupten, dass $d_2 \leq d - 1$: Angenommen, $d_2 \geq d$. Dann gibt es $A \subseteq \mathcal{X} \setminus \{x\}$ mit $|A| = d$, sodass A durch $\mathcal{R}_2$ aufgespalten wird. Dann wird aber $A \cup \{x\}$ nach Definition von $\mathcal{R}_2$ durch $\mathcal{R}_1$ aufgespalten, und die VC-Dimension von $\mathcal{R}$ wäre somit mindestens $d_2 + 1 > d$. Widerspruch!

Somit gilt nach Induktionsvoraussetzung

$$|\mathcal{R}_2| \leq \sum_{i=0}^{d_2} \binom{m-1}{i} \leq \sum_{i=0}^{d-1} \binom{m-1}{i}.$$

Nun gilt mit $\binom{a}{b} = \binom{a-1}{b} + \binom{a-1}{b-1}$

$$\begin{aligned} |\mathcal{R}| = |\mathcal{R}_1| + |\mathcal{R}_2| &\leq \sum_{i=0}^{d} \binom{m-1}{i} + \sum_{i=0}^{d-1} \binom{m-1}{i} = \sum_{i=0}^{d} \binom{m-1}{i} + \sum_{i=1}^{d} \binom{m-1}{i-1} \\ &= \binom{m-1}{0} + \sum_{i=1}^{d} \binom{m-1}{i} + \binom{m-1}{i-1} = \binom{m}{0} + \sum_{i=1}^{d} \binom{m}{i} = \sum_{i=0}^{d} \binom{m}{i}, \end{aligned}$$

was wir zeigen wollten. □

4.2 Unendliche Mengensysteme

Definition 4.6: Untersystem

Sei $\mathcal{R}$ ein Mengensystem mit Grundmenge $\mathcal{X}$. Jede Menge $A \subseteq \mathcal{X}$ bestimmt ein *Untersystem* von $\mathcal{R}$ wie folgt:

$$\mathcal{R}|_A = \{r \cap A \mid r \in \mathcal{R}\}$$

Es gilt $\dim(\mathcal{R}|_A) \leq \dim(\mathcal{R})$.

Wir betrachten nun das Wachstumslemma (Sneak Peak war Lemma 3.6).

Lemma 4.7: Wachstumslemma

Sei $\mathcal{R}$ ein Mengensystem mit Grundmenge $\mathcal{X}$ und VC-Dimension d. Für jedes $n \in \mathbb{N}$ gilt

$$\Pi_{\mathcal{R}}(m) \coloneqq \max_{\substack{A \subseteq \mathcal{X} \\ |A|=m}} |\mathcal{R}|_A| \leq \left(\frac{em}{d}\right)^d.$$

Wir nennen Π die Wachstumsfunktion *von $\mathcal{R}$.*

Beweis. Für jedes $A \subseteq \mathcal{X}$ mit $|A| = m$ gilt

$$|\mathcal{R}|_A| \leq \sum_{i=0}^{d} \binom{m}{i} \leq \left(\frac{em}{d}\right)^d$$

nach Lemma 4.5 und der Rechnung aus Beispiel 4.4. Es solft somit direkt $\Pi_{\mathcal{R}}(m) \leq (\frac{em}{d})^d$. □

Nun folgt mit $\mathcal{R} \coloneqq \{r_h \mid h \in \mathcal{H}\}$, wobei $r_h \coloneqq \{x \in \mathcal{X} \mid h(x) = 1\}$, auch direkt $\Pi_{\mathcal{H}}(m) = \Pi_{\mathcal{R}}(m)$ und damit Lemma 3.6.

[23.04.2026, Vorlesung 4]
[28.04.2026, Vorlesung 5]

Kapitel 5

Lineare Klassifikation und ihre VC-Dimension

Sei die Hypothesenklasse $\mathcal{H}$ die Menge der Funktionen der Form

$$h_{a,b}\colon \mathbb{R}^d \to \{-1,1\}$$
$$x \mapsto \begin{cases} 1 & \langle a,x\rangle \geq b \\ -1 & \text{sonst.} \end{cases}$$

Äquivalent als Mengensystem $\mathcal{R}$ mit den Mengen

$$r_{a,b} = \{x \in \mathbb{R}^d \mid \langle a,x\rangle \geq b\}.$$

Dabei definiert $r_{a,b}$ einen Halbraum, beschränkt durch eine Hyperebene

$$\ell = \{x \in \mathbb{R}^d \mid \langle a,x\rangle = b\}.$$

5.1 VC-Dimension von Halbräumen

Definition 5.1: Affinkombination, affine Abhängigkeit

Eine Linearkombination

$$\sum_{i=1}^{n} \alpha_i p^i \quad \text{für } p_1,\dots,p_n \in \mathbb{R}^d, \alpha_1,\dots,\alpha_n \in \mathbb{R}$$

ist eine *Affinkombination*, wenn

$$\sum_{i=1}^{n} \alpha_i = 1$$

gilt.
Die Menge $\{p_1,\dots,p_n\} \subseteq \mathbb{R}^d$ ist *affin abhängig*, wenn es ein $i \in \{1,\dots,n\}$ gibt, sodass

$$p_i = \sum_{\substack{j=1 \\ j\neq i}}^{n} \beta_i p_j \quad \text{mit} \quad \sum_{\substack{j=1 \\ j\neq i}}^{n} \beta_i = 1.$$

Lemma 5.2: $d+2$ Punkte sind affin abhängig

Jede Menge von $d+2$ Punkten in $\mathbb{R}^d$ sind affin abhängig.

Beweis. Sei $A = \{p_1,\dots,p_{d+2}\} \subseteq \mathbb{R}^d$. Definiere $q_i \coloneqq p_i - p_{d+2}$ für alle i.

Da jede Menge von $d+1$ Punkten im $\mathbb{R}^d$ linear abhängig ist, gibt es ein $r \in \{1, \ldots, d+1\}$, sodass

$$q_r = \sum_{\substack{i=1 \\ i \neq r}}^{d+1} \beta_i q_i$$

gilt. OBdA sei $r = d+1$. Dann ist also

$$q_r = \sum_{i=1}^{d} \beta_i q_i,$$

und somit gilt

$$p_{d+1} = q_{d+1} + p_{d+2} = \left(\sum_{j=1}^{d} \beta_i q_i\right) + p_{d+2} = \left(\sum_{j=1}^{d} \beta_i p_i\right) + \left(-\sum_{j=1}^{d} \beta_i + 1\right) p_{d+2}.$$

Nun definieren wir $\beta_{d+2} := -\sum_{j=1}^{d} \beta_i + 1$, somit ist $\beta_{d+2} + \sum_{j=1}^{d} \beta_i = 1$ und p_{d+1} ist die Affinkombination der anderen $d+1$ Punkte mit diesen β_i. □

Definition 5.3: Konvexkombination

Eine Linearkombination

$$\sum_{i=1}^{n} \alpha_i p^i \quad \text{für } p_1, \ldots, p_n \in \mathbb{R}^d, \alpha_1, \ldots, \alpha_n \in \mathbb{R}$$

ist eine *Konvexkombination*, wenn

$$\sum_{i=1}^{n} \alpha_i = 1 \quad \text{und} \quad \alpha_i \geq 0 \text{ für alle } i \in \{1, \ldots, n\}$$

gilt.
Die Menge aller Konvexkombinationen einer Menge $P \subseteq \mathbb{R}^d$ ist ihre *konvexe Hülle* $\text{conv}(P)$.

Lemma 5.4: Radon

Für jede Menge A von $d+2$ Punkten im $\mathbb{R}^d$ existieren $A_1, A_2 \subseteq A$ mit $A_1 \cap A_2 = \emptyset$ und ein Punkt q, sodass $q \in \text{conv}(A_1)$ und $q \in \text{conv}(A_2)$.

Wir nennen q dann *Radonpunkt*.

Beweis. Sei $A = \{p_1, \ldots, p_{d+2}\}$. Diese ist nach Lemma 5.2 affin abhängig. Also existiert ein $i \in \{1, \ldots, d+2\}$, sodass

$$p_i = \sum_{\substack{j=1 \\ j \neq i}}^{d+2} \alpha_j p_j \quad \text{mit} \quad \sum_{\substack{j=1 \\ j \neq i}}^{d+2} \alpha_j = 1.$$

Wir setzen $\alpha_i := -1$. Dann ist

$$0 = p_i + \alpha_i p_i = \sum_{j=1}^{d+2} \alpha_j p_j \quad \text{und} \tag{5.1}$$

$$0 = \sum_{j=1}^{d+2} \alpha_j. \tag{5.2}$$

Wir setzen $I_1 := \{j \mid \alpha_j > 0\}$ und $I_2 := \{j \mid \alpha_j = 0\}$. Dann folgt aus (5.1)

$$0 = \sum_{j \in I_1} \alpha_j p_j + \sum_{j \in I_2} \alpha_j p_j,$$

und umgeformt

$$-\sum_{j \in I_2} \alpha_j p_j = \sum_{j \in I_1} \alpha_j p_j.$$

Analog folgt aus (5.2)

$$-\sum_{j \in I_2} \alpha_j = \sum_{j \in I_1} \alpha_j.$$

Setze nun $\gamma := \sum_{j \in I_1} \alpha_j$ und $\beta_j := \frac{\alpha_j}{\gamma}$ für $j \in I_1$, sowie $\beta_j := -\frac{\alpha_j}{\gamma}$ für $j \in I_2$. Dann ist $\sum_{j \in I_1} \beta_j = 1 = \sum_{j \in I_2} \beta_j$ und

$$q := \sum_{j \in I_2} -\frac{\alpha_j}{\gamma} p_j = \sum_{j \in I_1} \frac{\alpha_j}{\gamma} p_j.$$

Beide Seiten sind also disjunkte Konvexkombinationen für denselben Punkt q. □

Satz 5.5: VC-Dimension von Halbräumen: obere Schranke

Die VC-Dimension von Halbräumen im $\mathbb{R}^d$ ist höchstens $d + 1$.

Beweis. Angenommen, die VC-Dimension wäre mindestens $d + 2$. Wähle $A = \{p_1, \ldots, p_{d+2}\} \subseteq \mathbb{R}^d$, sodass A vollständig durch $\mathcal{R}$ aufgespalten werden kann. Nach Lemma 5.4 existieren Indexmengen $I_1, I_2 \subseteq \{1, \ldots, d + 2\}$ mit $I_1 \cap I_2 = \emptyset$, sodass Konvexkombinationen und ein Punkt q existieren mit

$$\sum_{i \in I_1} \alpha_i p_i = q = \sum_{i \in I_2} \beta_i p_i$$

und $\sum_{i \in I_1} \alpha_i = 1 = \sum_{i \in I_2} \beta_i$ mit $\alpha_i, \beta_i \geq 0$.

Sei $r_{a,b}$ der Halbraum, der $A_1 = \{p_i \mid i \in I_1\}$ von A abspaltet. Dann ist

$$A_1 = r_{a,b} \cap A \quad \text{und} \quad A_2 \cap r_{a,b} = \emptyset$$

für $A_2 = \{p_i \mid i \in I_2\}$. Also ist $\langle a, p_i \rangle \geq b$ für $i \in I_1$ und $\langle a, p_i \rangle < b$ für $i \in I_2$.

Nun gilt mit Bilinearität des Skalarproduktes sowie $\sum_{i \in I_1} \alpha_i = 1 = \sum_{i \in I_2} \beta_i$ und $\alpha_i, \beta_i \geq 0$

$$\langle a, q \rangle = \left\langle a, \sum_{i \in I_1} \alpha_i p_i \right\rangle = \sum_{i \in I_1} \alpha_i \langle a, p_i \rangle \geq \sum_{i \in I_1} \alpha_i \cdot b = b \cdot \sum_{i \in I_1} \alpha_i = b,$$

andererseits aber auch

$$\langle a, q \rangle = \left\langle a, \sum_{i \in I_2} \beta_i p_i \right\rangle = \sum_{i \in I_1} \beta_i \langle a, p_i \rangle < \sum_{i \in I_1} \beta_i \cdot b = b \cdot \sum_{i \in I_1} \beta_i = b,$$

Widerspruch! ↯ □

Satz 5.6: VC-Dimension von Halbräumen: untere Schranke

Die VC-Dimension von Halbräumen im $\mathbb{R}^d$ ist mindestens $d + 1$.

Beweis. Wir konstruieren $A \subset \mathbb{R}^d$ mit $|A| = d + 1$, sodass A aufgespalten wird. Sei e_i der $i$te Einheitsvektor und e_0 der Nullvektor. Dabei ist $A = \{e_i \mid i \in \{0, \ldots, d\}\}$ aufspaltbar:

Sei $A' \subseteq A$ beliebig. Dann wähle $a = (a_1, \ldots, a_d)$ und $b \in \mathbb{R}$ wie folgt, sodass $r_{a,b} \cap A = A'$ und $r_{a,b} \cap (A \setminus A') = \emptyset$:

$$a_i = \begin{cases} 1 & e_i \in A' \\ -1 & e_i \notin A', \end{cases} \qquad b = \begin{cases} 0 & e_0 \in A' \\ 1 & e_0 \notin A'. \end{cases}$$

Dann ist $\langle a, e_0 \rangle = 0$, passt also immer. Für $1 \leq i \leq d$ gilt

$$\langle a, e_i \rangle = a_i = \begin{cases} 1 \geq b & e_i \in A' \\ -1 < b & e_i \notin A'. \end{cases}$$

Somit ist $\langle a, e_i \rangle \geq b \iff e_i \in A'$, und A' kann immer durch einen Halbraum aufgespalten werden. □

Also ist $\dim(\mathcal{R}) = d + 1$.

5.2 Homogene Halbräume

Something something. Kommt nochmal wieder.

[28.04.2026, Vorlesung 5]
[30.04.2026, Vorlesung 6]

Kapitel 6

PAC-Lernbarkeit und ε-Netze

Heute wollen wir endlich Satz 3.4 beweisen.

Wir betrachten dafür das *Gegenereignis*: Es existiert eine Hypothese $h \in \mathcal{H}$ mit $\mathrm{err}_S(h) = 0$, aber $\mathrm{err}_{\mathcal{D},f}(h) \geq \varepsilon$.

Sei $\mathcal{R}$ das Mengensystem, das $\mathcal{H}$ entspricht, also sei $r_h = \{x \in \mathcal{X} \mid h(x) = 1\}$ für $h \in \mathcal{H}$. Sei $g = r_f$. Sei die *symmetrische Differenz* von g und r definiert als $g \Delta r_h \coloneqq (g \setminus r_h) \cup (r_h \setminus g)$.

Beispiel 6.1. Sei $\mathcal{X} = \mathbb{R}$ und $\mathcal{R}$ das Mengensystem der Intervalle. Sei $g \in \mathcal{R}$ das Intervall $[a, b]$, das der Grundwahrheit entspricht. Sei $r_h \in \mathcal{R}$ das Intervall $[a', b']$ welches der Hypothese h entspricht. Angenommen, $a \leq a' \leq b \leq b'$, dann ist $g \Delta r_h = [a, a') \cup (b, b']$.

Es gilt damit naheliegenderweise

$$\mathrm{err}_S(h) = \frac{1}{m} |\{h(x_i) \neq y_i\}| = \frac{|S \cap (g \Delta r_h)|}{|S|}$$

und

$$\mathrm{err}_{\mathcal{D},f}(h) = \mathbb{P}_{x \sim \mathcal{D}}[h(x) \neq f(x)] = \mathbb{P}_{x \sim \mathcal{D}}[x \in (g \Delta r_h)].$$

Damit das Gegenereignis bezüglich $h \in \mathcal{H}$ eintritt, muss gelten

(*i*) $(g \Delta r_h) \cap S = \emptyset$, und

(*ii*) $\mathbb{P}_{x \sim \mathcal{D}}[x \in (g \Delta r_h)] \geq \varepsilon$.

Für den Beweis von Satz 3.4 müssen wir über *alle* Hypothesen argumentieren. Dafür definieren wir das Mengensystem aller möglichen so bildbaren symmetrischen Differenzen: Sei

$$\mathcal{F} \coloneqq \{g \Delta r \mid r \in \mathcal{R}\}.$$

Definition 6.2: ε-Netz

Sei $\mathcal{F}$ ein Mengensystem mit Grundmenge $\mathcal{X}$ und $\mathcal{D}$ eine Wahrscheinlichkeitsverteilung über $\mathcal{X}$. Sei $\varepsilon \in [0, 1]$. Eine Menge $A \subseteq \mathcal{X}$ ist ein *ε-Netz für $\mathcal{F}$*, wenn für jedes $r \in \mathcal{F}$ mit $\mathbb{P}_{x \sim \mathcal{D}}[x \in r] \geq \varepsilon$ gilt, dass $A \cap r \neq \emptyset$.

Damit können wir Satz 3.4 wie folgt äquivalent formulieren:

> *Wenn Bedingung* (3.1) *erfüllt ist, dann ist die Sample-Menge S, die iid aus $\mathcal{D}$ gezogen ist, mit Wahrscheinlichkeit mindestens $1 - \delta$ ein ε-Netz für $\mathcal{F}$.*

Beweisen wollen wir den Satz mithilfe der Wachstumsfunktion, dafür schauen wir zunächst auf folgendes Lemma:

Lemma 6.3: Wachstumsfunktion des ε-Netzes

Es gilt $\Pi_{\mathcal{F}}(m) \leq \Pi_{\mathcal{H}}(m)$ für alle $m \in \mathbb{N}$.

Beweis. Jede Menge in $r \in \mathcal{R}$ erzeugt eine eindeutige Menge in $\mathcal{F}$. Daraus folgt $|\mathcal{F}| \leq |\mathcal{R}|$. Das gleiche Argument gilt in der Beschränkung auf beliebiges $S \subseteq \mathcal{X}$, also

$$|\mathcal{F}|_S| = |\{(g \Delta r) \cap r \mid r \in \mathcal{R}\}| = |\{(g \cap S) \Delta r \mid r \in \mathcal{R}|_S\}| \leq |\mathcal{R}|_S|$$

und somit

$$\Pi_{\mathcal{F}}(m) = \max_{\substack{S \subseteq \mathcal{X} \\ |S|=m}} |\mathcal{F}|_S| \leq \max_{\substack{S \subseteq \mathcal{X} \\ |S|=m}} |\mathcal{R}|_S| = \Pi_{\mathcal{R}}(m) = \Pi_{\mathcal{H}}(m),$$

was wir zeigen wollten. □

Beweis von Satz 3.4. Sei $\mathcal{F}$ das Mengensystem der symmetrischen Differenzen wie oben definiert, beschrieben durch $\mathcal{H}$ und f. Betrachte Samplemenge S von m Datenpunkten, iid verteilt aus $\mathcal{D}$, wobei m Bedingung (3.1) erfüllt. Sei A das folgende Ereignis:

$$\exists r \in \mathcal{F} \colon \mathbb{P}_{x \sim \mathcal{D}}[x \in r] \geq \varepsilon \quad \text{und} \quad |r \cap S| = 0.$$

Falls A eintritt, so ist S kein ε-Netz für $\mathcal{F}$. Für die Abschätzung definieren wir uns ein Hilfsereignis B. Dafür sei S' eine andere Menge von m Datenpunkten, die auch iid aus $\mathcal{D}$ gezogen werden. Sei B das folgende Ereignis:

$$\exists r \in \mathcal{F} \colon |r \cap S'| \geq \frac{\varepsilon m}{2} \quad \text{und} \quad |r \cap S| = 0.$$

Wir verwenden die folgenden zwei Behauptungen, die im Anschluss gezeigt werden:

Behauptung 6.4. Es gilt $\mathbb{P}[B \mid A] \geq \frac{1}{2}$.

Behauptung 6.5. Es gilt $\mathbb{P}[B] \leq \frac{\delta}{2}$

Es folgt mit beiden Behauptungen

$$\mathbb{P}[A] = \frac{\mathbb{P}[A \cap B]}{\mathbb{P}[B \mid A]} \leq \frac{\mathbb{P}[B]}{\mathbb{P}[B \mid A]} \leq \frac{\frac{\delta}{2}}{\frac{1}{2}} \leq \delta,$$

und damit ist der Satz gezegigt. □

Wir zeigen nun beide Behauptungen, brauchen dafür aber noch folgendes Lemma:

Lemma 6.6: Summe von Bernoulli-Variablen

Seien $Z_1, \ldots, Z_m$ iid Bernoulli-verteilt mit $\mathbb{P}[Z_i = 1] = p$ für alle i. Es gilt für die Summe $Z = \sum_{i=1}^{m} Z_i$

$$\mathbb{P}\left[Z \leq \frac{pm}{2}\right] \leq \frac{4(1-p)}{pm}.$$

Beweis. Es gelten $\mathbb{E}[Z] = pm$ und $\mathrm{Var}[Z] = p(1-p)m$. Die Čebyšev-Ungleichung besagt, dass für alle $a \in \mathbb{R}$

$$\mathbb{P}[|Z - \mathbb{E}[Z]| \geq a] \leq \frac{\mathrm{Var}[Z]}{a^2}.$$

Wir setzen $a = \frac{pm}{2}$ und erhalten

$$\frac{\mathrm{Var}[Z]}{a^2} \leq \frac{p(1-p)m}{\left(\frac{pm}{2}\right)^2} = \frac{4(1-p)}{m}.$$

Das liefert uns

$$\mathbb{P}\left[Z \leq \frac{pm}{2}\right] = \mathbb{P}\left[|Z - pm| \geq \frac{pm}{2}\right] = \mathbb{P}\left[|Z - \mathbb{E}[Z]| \geq \frac{pm}{2}\right] \leq \frac{4(1-p)}{pm}. \qquad \square$$

Beweis von Behauptung 6.4. Unter der Annahme, dass A eingetreten ist, existiert $r \in \mathcal{F}$, sodass $|r \cap S| = 0$ und $\mathbb{P}_{x\sim\mathcal{D}}[x \in r] \geq \varepsilon$.

Sei $Z_i = 1$ genau dann, wenn der $i$te Datenpunkt von S' in r fällt. Nach Lemma 6.6 mit $p \geq \varepsilon$ und $Z = |r \cap S'|$ erhalten wir

$$\mathbb{P}\left[|r \cap S'| \leq \frac{\varepsilon m}{2}\right] \leq \mathbb{P}\left[|r \cap S'| \leq \frac{pm}{2}\right] \leq \frac{4(1-p)}{pm} \leq \frac{1}{2},$$

da nach (3.1) gilt $m \geq \frac{8}{\varepsilon}$ und damit $pm \geq \varepsilon m \geq 8$. $\square$

Beweis von Behauptung 6.5. Äquivalenter Weg, um S und S' zu bestimmen: Ziehe $2m$ Datenpunkte iid gemäß $\mathcal{D}$, sei das Ergebnis T. Ziehe nun m mal *ohne* Zurücklegen aus T, nenne das Ergebnis S. Schließlich setze $S' = T \setminus S$.

Für festes T und festes $r \in \mathcal{F}$ setze $k \coloneqq |r \cap T|$. Es kann nur $|r \cap S'| \geq \frac{\varepsilon m}{2}$ gelten, wenn $k \geq \frac{\varepsilon}{2}m$ gilt. Es ist

$$\begin{aligned}\mathbb{P}[|r \cap S| = 0 \mid T] &= \frac{2m-k}{2m} \cdot \frac{2m-k-1}{2m-1} \cdot \dots \cdot \frac{m-k+1}{m+1} \\ &= \frac{m(m-1)\cdots(m-k+1)}{(2m)(2m-1)\cdots(2m-k+1)} \leq 2^{-k},\end{aligned}$$

weil sich alle Faktoren bis auf die ersten k im Nenner und die letzten k im Zähler wegkürzen. Für festes r und T erhalte

$$\mathbb{P}\left[|r \cap S'| \geq \frac{\varepsilon m}{2} \text{ und } |r \cap S| = 0 \;\middle|\; T\right] \leq \begin{cases} 0 & k < \frac{\varepsilon}{2}m \\ 2^{-k} & \text{sonst} \end{cases} \leq 2^{-\frac{\varepsilon}{2}m}.$$

Nun ist Ereignis B die Vereinignug all dieser Ereignisse über alle $r \in \mathcal{F}$

$$\mathbb{P}[B \mid T] = \Pi_{\mathcal{F}}(2m)2^{-\frac{\varepsilon}{2}m} \leq \Pi_{\mathcal{H}}(2m)2^{-\frac{\varepsilon}{2}m} \leq \frac{\delta}{2},$$

wobei die Ungleichungen durch (3.1) und Lemma 2.4 und Lemma 6.3 folgen, da es genügt, Mengen zu zählen, die sich auf T unterscheiden. Die Wachstumsfunktion davon ist beschränkt, da $|T| = 2m$. $\square$

[30.04.2026, Vorlesung 6]
[05.05.2026, Vorlesung 7]

Kapitel 7

Boosting

7.1 Einführendes Beispiel

Beispiel 7.1. Sei $\mathcal{X} = \mathbb{R}$ und $\mathcal{H}$ die Klasse der Schwellenwertfunktionen

$$h(x) \geq \begin{cases} 1 & x \geq a \\ -1 & x < a \end{cases} \quad \text{oder} \quad h(x) \geq \begin{cases} 1 & x \leq a \\ -1 & x > a \end{cases}$$

Für $a \in \mathbb{R}$ und $u \in \{-1, 1\}$ sei $h_{a,u}(x) = u \cdot \operatorname{sgn}(x - a)$ mit der Konvention $\operatorname{sgn}(0) = 1$

Angenommen, die Grundwahrheit klassifiziert $x \in [a, b]$ positiv und $x \notin [a, b]$ negativ. Im Allgemeinen können wir in diesem Fall keinen Trainingsfehler unter $\frac{1}{3}$ erreichen, da immer ein Punkt aus $S = \{(-1, -1), (0, 1), (1, -1)\}$ falsch klassifiziert wird. Deswegen definieren wir

$$h^* = \operatorname{sgn}(h_{a,1}(x) + h_{b,-1}(x) + h_{z,-1}(x))$$

mit $z < \min_i x_i$. Nun ist für $x \in [a, b]$ jeweils $h_{a,1}(x) = h_{b,-1}(x) = 1$ und $h_{z,-1}(x) = -1$, also $h^*(x) = 1$. Für $x \in (z, a) \cup (b, \infty)$ folgt $h^*(x) = -1$. Damit ist für alle i garantiert, dass $h^*(x_i) = y_i$ und somit $\operatorname{err}_S(h^*) = 0$ gilt. Da die Klassifizierung aber unterhalb von z falsch ist, ist h^* trotzdem noch nicht die Grundwahrheit.

7.2 Problemstellung

Sei $S = \{(x_i, y_i) \mid i = 1, \ldots, m\}$ mit $x_i \in \mathcal{X}$ und $y_i \in \{-1, 1\}$ gegeben.

Definition 7.2: Schwacher Lernalgorithmus

Ein Lernalgorithmus heißt *schwach*, wenn er neben der Samplemenge S auch beliebige Gewichte $p_1, \ldots, p_m \geq 0$ mit $\sum_{i=1}^m p_i = 1$ erhält.

Die Gewichte definieren also eine Wahrscheinlichkeitsverteilung auf S. Der schwache Lernalgorithmus berechnet daraufhin eine Hypothese h_p, sodass

$$\operatorname{err}_p(h_p) \coloneqq \sum_{\substack{i=1 \\ h_p(x_i) \neq y_i}}^{m} p_i \leq \frac{1}{2} - \gamma$$

für ein festes $\gamma > 0$. Für $p_i = \frac{1}{m}$ ist $\operatorname{err}_p(h_p)$ genau der Trainingsfehler. Das heißt, die Hypothese stellt sicher, dass eine gewichtete Verteilung des Trainingsfehlers klein ist.

Beispiel 7.3. Im Beispiel 7.1 erfüllt ein $h \in \mathcal{H}$, welches $\operatorname{err}_S(h)$ minimiert, diese Garantie mit $\gamma = \frac{1}{6}$:

Es gilt für alle p und alle $a < b$

$$\sum_{i:x_i<a} p_i \leq \frac{1}{3} \quad \text{oder} \quad \sum_{i:a\leq x_i\leq b} p_i \leq \frac{1}{3} \quad \text{oder} \quad \sum_{i:x_i>b} p_i \leq \frac{1}{3}.$$

Zwei der drei Datenpunkte können wir leicht durch eine Schwellenwertfunktion klassifizieren. Der kleinste Fehler wird also höchstens $\frac{1}{3} = \frac{1}{2} - \frac{1}{6}$ sein.

7.3 Idee für einen Algorithmus

Definition 7.4: Starker Lernalgorithmus

Seien $\varepsilon > 0$, die Samplemenge S und ein schwacher Lernalgorithmus gegeben. Ein Lernalgorithmus heißt *stark*, wenn er Hypothesen $h_1, \ldots, h_T$ und Koeffizienten $\alpha_1, \ldots \alpha_T$ berechnet, sodass für

$$h^*(x) := \operatorname{sgn}\left(\sum_{i=1}^{T} \alpha_i h_i(x)\right)$$

gilt, dass $\operatorname{err}_S(h^*) \leq \varepsilon$.

Die Idee für solch einen starken Lernalgorithmus ist wie folgt: Wir starten mit $p_i^{(1)} = \frac{1}{m}$ für alle i. Dann nutze den schwachen Lernalgorithmus, um die erste Hypothese h_1 zu berechnen.

Nun aktualisieren wir die p_i. Dafür definiere $w_i^{(t)}$ als die Gewichte, die in Iteration t neu berechnet werden. Setze dann

$$p_i^{(t)} := \frac{w_i^{(t)}}{W^t} \quad \text{wobei} \quad W^t = \sum_{i=1}^{m} w_i^{(t)}.$$

Dabei nutzen wir folgende Update-Regel:

$$w_i^{(t+1)} = \begin{cases} e^{-\eta} w_i^{(t)} & h_t(x_i) = y_i \\ e^{\eta_t} w_i^{(t)} & h_t(x_i) \neq y_i, \end{cases}$$

wobei $\eta^t > 0$ für alle i gleich ist. Wegen

$$h_t(x_i) y_i = \begin{cases} 1 & h_t(x_i) = y_i \\ -1 & h_t(x_i) \neq y_i \end{cases}$$

ist

$$w_i^{(t+1)} = w_i^{(t)} e^{-\eta_t y_i h_t(x_i)}.$$

7.4 AdaBoost

Der Algorithmus 7.5 (Adaptive Boosting (AdaBoost)) benutzt genau diese Ideen:

Satz 7.6: AdaBoost

AdaBoost garantiert $\operatorname{err}_S(h^*) \leq e^{-2\gamma^2 T}$.

Beweis. Wir werden zeigen, dass

$$W^{t+1} \leq e^{-2\gamma^2} W^t \tag{7.1}$$

gilt.

Algorithmus 7.5 AdaBoost

1: Initialisiere $w_i^{(1)}$ für alle i
2: **for** $t = 1, \dots, T$ **do**
3: $\quad W^{(t)} \leftarrow \sum_{i=1}^m w_i^{(t)}, \quad p_i^{(t)} \leftarrow \frac{w_i^{(t)}}{W^t}$ für alle i
4: $\quad h_t \leftarrow$ vom schwachen Lernalgorithmus auf $p^(t)$ berechnetes Ergenbnis
5: $\quad \varepsilon_t \leftarrow \sum_{i:h_t(x_i)\neq y_i} p_i^{(t)}$ ▷ *Fehler von h_t auf $p^{(t)}$*
6: $\quad \eta_t \leftarrow \frac{1}{2} \ln\left(\frac{1}{\varepsilon_t} - 1\right)$
7: $\quad w_i^{(t+1)} \leftarrow w_i^{(t)} e^{-\eta_t h_t(x_i) y_i}$ für alle i
8: $h^*(x) := \operatorname{sgn}\left(\sum_{t=1}^T \eta_t h_t(x)\right)$
9: **return** h^*

Mit (7.1) folgt

$$W^{(T+1)} \leq e^{-2\gamma^2 T} W^{(1)} = e^{-2\gamma^2 T} \cdot m.$$

Betrachte $\operatorname{err}_S(h^*) = \frac{1}{m}|\{i \mid h^*(x_i) \neq y_i\}|$. Wir zeigen als nächstes, dass die Anzahl falsch klassifizierter Datenpunkte durch $W^{(T+1)}$ nach oben beschränkt ist. Dazu definiere

$$g_t(x) := \sum_{t'=1}^{t} \eta_{t'} h_{t'}(x).$$

Per Definition ist $h^* = \operatorname{sgn}(g_T)$ und $w_i^{(t)} = e^{-y_i g_{t-1}(x_i)}$.
Es gilt für alle i mit $h^*(x_i) \neq y_i$ wieder $y_i g_T(x_i) \leq 0$ und damit erhalten wir

$$w_i^{(T+1)} = e^{-y_i g_T(x_i)} \geq 1.$$

Außerdem ist $w_i^{(T+1)} \geq 0$ für alle i, und daher gilt

$$|\{i \mid h^*(x_i) \neq y_i\}| \leq \sum_{i=1}^m w_i^{(t+1)} = W^{(T+1)}.$$

Damit folgt der Satz aus (7.1) und es bleibt lediglich (7.1) zu zeigen:

$$W^{(t+1)} = \sum_{i=1}^m w_i^{(t+1)} = \sum_{i=1}^m w_i^{(t)} e^{-y_i \eta_t h_t(x_i)},$$

und für den Quotienten erhalten wir

$$\frac{W^{(t+1)}}{W^{(t)}} = \sum_{i=1}^m \frac{w_i^{(t)}}{W^{(t)}} e^{-y_i \eta_t h_t(x_i)} = \sum_{i=1}^m p_i^{(t)} e^{-y_i \eta_t h_t(x_i)} = \sum_{i:h_t(x_i)=y_i} p_i^{(t)} e^{-\eta_t} + \sum_{i:h_t(x_i)\neq y_i} p_i^{(t)} e^{\eta_t}.$$

Nun gilt nach Definition $\sum_{i:h_t(x_i)\neq y_i} p_i^{(t)} = \varepsilon_t$ und η_t so, dass $e^{\eta_t} = \sqrt{\frac{1}{\varepsilon_t} - 1}$, damit folgt

$$\begin{aligned}\frac{W^{(t+1)}}{W^{(t)}} &= (1-\varepsilon_t)e^{-\eta_t} + \varepsilon_t e^{\eta_t} = (1-\varepsilon_t)\frac{1}{\sqrt{\frac{1}{\varepsilon_t} - 1}} + \varepsilon_t \sqrt{\frac{1}{\varepsilon_t} - 1} \\ &= (1-\varepsilon_t)\sqrt{\frac{\varepsilon_t}{1-\varepsilon_t}} + \varepsilon_t \sqrt{\frac{1-\varepsilon_t}{\varepsilon_t}} = 2\sqrt{\varepsilon_t(1-\varepsilon_t)}.\end{aligned}$$

Setze nun $\gamma_t = \frac{1}{2} - \gamma_t$. Der schwache Lernalgorithmus garantiert $\gamma_t \geq \gamma$ und somit

$$\frac{W^{(t+1)}}{W^{(t)}} = 2\sqrt{\varepsilon_t(1-\varepsilon_t)} = 2\sqrt{\left(\frac{1}{2}+\gamma_t\right)\left(\frac{1}{2}-\gamma_t\right)} = \sqrt{1-4\gamma_t^2} \leq \sqrt{e^{-4\gamma_t^2}} = e^{-2\gamma_t^2} \leq e^{-2\gamma^2}$$

mit $1 - x \leq e^{-x}$. Damit ist (7.1) gezeigt und Satz 7.6 vollständig bewiesen. □

Man muss aber aufpassen, möglicherweise führt ein sehr großes T einfach zu Overfitting, und nicht unbedingt zu kleinerem Fehler.

[05.05.2026, Vorlesung 7]
[07.05.2026, Vorlesung 8]

Kapitel 8

VC-Dimensionen von Kompositionen

[07.05.2026, Vorlesung 8]
[12.05.2026, Vorlesung 9]

Kapitel 9

Entscheidungsbäume

Mittels Entscheidungsbäumen können wir einfache Hypothesen zu komplexeren Hypothesen zusammenbauen. Beispielsweise: Bin ich gefährdet, an Covid-19 erkrankt zu sein? Dies kann auf Basis von Ja-Nein-Fragen herausgefunden werden.

Wir können also mittels Schwellenwertfunktionen („Ist $x_1 \geq a_1$?“) als Frageknoten unseres Entscheidungsbäumen das Quadrat $[0,1]^2$ in Rechtecke unterteilen, die jeweils einem Blattknoten aus dem Entscheidungsbaum entsprechen. Diesen Rechtecken können wir dann noch Labels zuweisen.

9.1 Hypothesenklasse

Sei T ein binärer Baum mit k inneren Knoten und Wurzel w. Sei jedem inneren Knoten v eine Hypothese $h_v \in \mathcal{H}$ sowie Kinder v_L und v_R zugewiesen, die das linke und das rechte Kind von v bezeichnen. Sei jedem Blattknoten v ein Label $\ell_v \in \{-1, 1\}$ zugewiesen. Definiere $g_v \colon \mathcal{X} \to \{-1, 1\}$ für einen inneren Knoten v durch

$$g_v(x) = \begin{cases} g_{v_R}(x) & h_v(x) = 1, \\ g_{v_L}(x) & h_v(x) = -1. \end{cases} \tag{9.1}$$

Ist v ein Blattknoten, so setzen wir $g_v(x) \equiv \ell_v$.

Die mit T assoziierte Hypothese ist $g_w(x)$, wobei w der Wurzelknoten ist.

Sei B_k die Menge der gewurzelten Binärbäume mit k inneren Knoten und $k+1$ Blättern. Gegeben eine Hypothesenklasse $\mathcal{H}$, sei $\mathcal{H}_{B_k}$ darüber hinaus Hypothesenklasse aller Funktionen $g_w : \mathcal{X} \to \{-1, 1\}$ definiert wie in (9.1), wobei $T \in B_k$ mit Wurzel w sein soll, sowie $h_v \in \mathcal{H}$ für alle inneren Knoten v mit $\ell_v \in \{-1, 1\}$ für alle Blattknoten v.

Lemma 9.1: Abschätzung $|B_k|$

Für alle $k \in \mathbb{N}$ mit $k \geq 1$ gilt

$$|B_k| \leq k!.$$

Beweis. Induktion über k. Für $k = 1$ gibt es nur einen möglichen Baum, und $1 \leq 1!$.

Sei also $k > 1$. Sei $T \in B_k$. Wir ersetzen einen inneren Knotenm der zwei Blätter als Kinder hat, durch ein Blatt. Sei $T' \in B_{k-1}$ der so entstandene Baum. Es gibt k Möglichkeiten, aus T' durch Ersetzen eines Blattknotens einen Baum $T \in B_k$ zu erzeugen, und jeder Baum in B_k kann so erzeugt werden. Somit gilt

$$|B_k| \leq k \cdot |B_{k-1}| \overset{\text{IV}}{\leq} k \cdot (k-1)! = k!$$

und das Lemma ist bewiesen. □

9.2 VC-Dimension

Satz 9.2: VC-Dimension von $\mathcal{H}_{B_k}$

Sei $\mathcal{H}$ eine Hypothesenklasse mit Grundmenge $\mathcal{X}$ und VC-Dimension $d < \infty$. Sei $k \in \mathbb{N}$ mit $k \geq 2$. Dann ist die VC-Dimension von $\mathcal{H}_{B_k}$ höchstens

$$20dk \ln(10k).$$

Beweis. Sei $A \subseteq \mathcal{X}$ mit $|A| = t$ eine Menge, die durch $\mathcal{H}_{B_k}$ aufgespalten gilt. Dann gelten

$$|\mathcal{H}_{B_k}|_A| = 2^t \tag{9.2}$$

sowie

$$|\mathcal{H}_{B_k}|_A| \leq |B_k| \cdot 2^{k+1} \cdot |\mathcal{H}|_A|^k \leq k! \cdot 2^{k+1} \cdot (\Pi_{\mathcal{H}}(t))^k \leq k! \cdot 2^{k+1} \cdot \left(\frac{et}{d}\right)^k, \tag{9.3}$$

wobei die Ungleichungen aus lemma 9.1 und Lemma 4.7 folgen.

Einsetzen ergibt

$$2^t \leq k! 2^{k+1} \left(\frac{et}{d}\right)^k \leq k^k \cdot k^{k+1} \cdot \left(\frac{t}{s}\right)^{2dk} \leq \left(\frac{t}{d}\right)^{k+k+1+2dk} \leq \left(\frac{t}{d}\right)^{5dk}$$

unter Verwendung von $t \geq de$ und $t \geq dk$. Logarithmus nehmen gibt

$$t \ln(2) \leq 5dk \ln\left(\frac{t}{d}\right)$$

und mit $1/2 \leq \ln(2)$ folgt

$$\frac{t}{d} \leq 10k \ln\left(\frac{t}{d}\right).$$

Da nach Chapter 8 gilt $x \leq u \ln(x) \implies x \leq 2u \ln(|u|)$ für alle $x, u > 0$, erhalten wir für $x = \frac{t}{d}$ und $u = 10k$

$$t \leq 20dk \ln(10k).$$

Da dies für jede aufgespaltene Menge A gilt, folgt direkt die obere Schranke für die VC-Dimension. □

Satz 9.2 sagt, die VC-Dimension von Entscheidungsbäumen hängt nur von der Anzahl innerer Knoten k und der VC-Dimension der Basisklasse ab. Gleichzeitig kann man für jede Menge $S \subseteq \mathbb{R}$ der Größe m einen Entscheidungsbaum mit $k = m - 1$ inneren Knoten finden, der Trainingsfehler Null hat, also für $k \to \infty$ ist die VC-Dimension von $\mathcal{H}_{B_k}$ im schlimmsten Fall sogar unbeschränkt.

9.3 Lernalgorithmen

Auch hier besteht, ähnlich wie beim Boosting, die Gefahr des Overfittings. Man möchte deswegen die Anzahl der inneren Knoten oft beschränken, was aber nicht effizient möglich ist. Wir optimieren Entscheidungsbäume in der Praxis also heuristisch, indem wir Knoten nacheinander hinzufügen, wobei in jedem Schritt die Zielfunktion lokal optimiert wird.

9.3.1 Greedy-Algorithmus

Jeder Knoten v hat eine assoziierte Menge $S_v \subseteq S$, welche nur für die Baumkonstruktion verwendet wird.

Algorithmus 9.3 decisionTree

Input: Parameter k, Trainingsmenge $S = \{(x_1, y_1), \ldots, (x_m, y_m)\}$
Output: Entscheidungsbaum T

Initialisiere T mit einem Blattknoten V
initLeaf(v, S)
for $i = 1, \ldots, k$ **do**
    Finde Blattknoten v in T mit größtem Klassifizierungsfehler $\text{err}_{S_v}(T)$
    split(v, T)
for v **in** Menge der Blattknoten von T **do**
    Entferne S_v vom Blattknoten v
return T

Algorithmus 9.4 split

Input: Blatt v, Entscheidungsbaum T
Output: Modifizierter T mit zwei Kindern von v

Berechne Hypothese $h \in \mathcal{H}$, welche $\text{err}_{S_v}(h)$ minimiert
Assoziiere mit v die Hypothese h
Entferne die Menge S_v von v
Füge v_L als linkes Kind von T hinzu
$S_{v_L} \leftarrow \{(x, y) \in S_v \mid h(x) = -1\}$
initLeaf(v_L, S_{v_L})
Füge v_R als rechtes Kind von T hinzu
$S_{v_R} \leftarrow \{(x, y) \in S_v \mid h(x) = 1\}$
initLeaf(v_R, S_{v_R})
return T

[12.05.2026, Vorlesung 9]
[14.05.2026, Vorlesung 10]

Anhang

Liste der Definitionen

1.2 Merkmalsraum 2
1.4 Hypothesenklasse 2
1.6 Grundwahrheit 3
1.7 Diskrete Wahrscheinlichkeitsverteilung 3
1.9 Tatsächlicher Fehler 3
1.11 Lernproblem 4
1.12 Trainingsfehler 4
2.2 PAC-Lernbarkeit 6
3.2 Wachstumsfunktion 8
4.1 Mengensystem, Aufspalten, Abspalten 11
4.2 VC-Dimension 11
4.6 Untersystem 13
5.1 Affinkombination, affine Abhängigkeit 14
5.3 Konvexkombination 15
6.2 ε-Netz 18
7.2 Schwacher Lernalgorithmus 21
7.4 Starker Lernalgorithmus 22

Liste der Aussagen

2.1 Abschätzung tatsächlicher Fehler der Schwellenwertfunktionen 5
2.3 Abschätzung tatsächlicher Fehler Intervalllernen 7
2.4 Union Bound 7
3.1 Tatsächlicher Fehler bei endlicher Hypothesenklasse 8
3.4 PAC-lernbar wenn Wachstumsfunktion subexponentiell 9
3.6 Sneak Peak: Wachstumslemma 10
3.7 PAC-Lernbarkeit mit VC-Dimension 10
4.5 Größe von Mengensystemen 12
4.7 Wachstumslemma 13
5.2 $d + 2$ Punkte sind affin abhängig 14
5.4 Radon 15
5.5 VC-Dimension von Halbräumen: obere Schranke 16
5.6 VC-Dimension von Halbräumen: untere Schranke 16
6.3 Wachstumsfunktion des ε-Netzes 18
6.6 Summe von Bernoulli-Variablen 19
7.6 AdaBoost 22
9.1 Abschätzung $|B_k|$ 26
9.2 VC-Dimension von $\mathcal{H}_{B_k}$ 27

Liste der Algorithmen

7.5 AdaBoost 23
9.3 decisionTree 28
9.4 split 28

Liste der Abkürzungen

AdaBoost Adaptive Boosting . . . . . 22, C f.

iid unabhängig und identisch verteilt (independent and identically distributed) 4 f., 8 ff., 18 ff.

PAC probably approximately correct . . . . . 5 ff., 9 f., 18, B f.

VC Vapnik-Chervonenkis . . . . . 8–14, 16, 25, 27, B f.

Index

Abspaltung (Menge), 11
AdaBoost, 22, C, D
affin abhängig, 14
Affinkombination, 14
Aufspaltung (Menge), 11

bag of words, 2

Entscheidungsbaum, 26
ε-Netz, 18

Fehler
    tatsächlicher -, 3
    Trainings-, 4

Grundwahrheit, 3

Hypothese, 2
Hypothesenklasse, 2

iid, 4, 5, 8–10, 18–20
Instanz, 2

konvexe Hülle, 15
Konvexkombination, 15

Label, 2
Lernalgorithmus
    schwacher -, 21
    starker -, 22

Mengensystem, 11
    Abspaltung, 11
    Aufspaltung, 11
    Untersystem, 13
Merkmalsraum, 2

PAC, 5–7, 9, 10, 18, B, C
PAC-Lernbarkeit, 6
    effiziente -, 6

Radonpunkt, 15
realisierbar, 5

Sample, 3, 4
symmetrische Differenz, 18

tatsächlicher Fehler, 3
Trainingsfehler, 4

Untersystem, 13

VC, 8–14, 16, 25, 27, B, C
VC-Dimension, 11

Wachstumfsunktion, 13
Wachstumsfunktion, 8
Wahrscheinlichkeitsmaß, 3
Wahrscheinlichkeitsverteilung, 3
    diskrete -, 3