Universität Bonn

Mitschrift zur Vorlesung

Randomisierte und Approximative Algorithmen

gehalten von

Prof. Dr. Thomas Kesselheim, Prof. Dr. Heiko Röglin

geTEXed von

Daniel Emse

Winter 2025/26

Anmerkungen und Korrekturen

Falls du Anmerkungen/Korrekturen hast, melde dich bei mir (`daniel.emse@uni-bonn.de`).

Inhaltsverzeichnis

Vorlesung **1**

I Randomisierte und Approximative Algorithmen **2**

1 Einleitung **3**

2 Greedy-Algorithmen **4**
2.1 Vertex Cover 4
2.2 Set Cover 5
2.3 Scheduling auf identischen Maschinen 6
2.4 Rucksackproblem 8

3 Runden und dynamische Programmierung **10**
3.1 Rucksackproblem 10
3.1.1 Dynamische Programmierung 10
3.1.2 Approximationsschema 11

Anhang **A**

Liste der Definitionen **B**

Liste der Aussagen **C**

Liste der Algorithmen **D**

Index **E**

Vorlesung

Teil I

Randomisierte und Approximative Algorithmen

Kapitel 1

Einleitung

Definition 1.1: Optimierungsproblem, Approximationsalgorithmus

Ein *Optimierungsproblem* Π besteht aus

- einer Meinge von Instanzen $\mathcal{I}_\Pi$
- für jede Instanz $I \in \mathcal{I}_\Pi$
  - einer Menge $\mathcal{S}_I$ von Lösungen
  - einer Zielfunktion $f_I : \mathcal{S}_I \to \mathbb{R}_{\geq 0}$.

Ein *Approximationsalgorithmus* nimmt I als Eingabe und berechnet $A(I) \in \mathcal{S}_I$ (in polynomieller Zeit).
Sei $w_A(I) = f_I(A(I))$. Ein Approximationsalgorithmus erreicht Approximationsfaktor r, falls

$$w_A(I) \leq r \cdot \mathrm{OPT}(I) \quad \forall I \in \mathcal{I}_\Pi \qquad \text{(für Minimierungsprobleme)},$$

bzw.

$$w_A(I) \geq \frac{1}{r} \cdot \mathrm{OPT}(I) \quad \forall I \in \mathcal{I}_\Pi \qquad \text{(für Maximierungsprobleme)}.$$

Kapitel 2

Greedy-Algorithmen

2.1 Vertex Cover

[14.10.2025, Vorlesung 1]

Problem 2.1: Vertex Cover

Input: Ungerichteter Graph $G = (V, E)$
Output: Alle $V' \subseteq V$, sodass $\forall e = (u, v) \in E$ gilt $u \in V'$ oder $v \in V'$
Objective: Minimiere $|V'|$

Definition 2.2: Matching

Ein *Matching* $M \subseteq E$ eines Graphen $G = (V, E)$ ist eine Teilmenge der Kanten, sodass es keinen Knoten gibt, der zu mehr als einer Kante aus M inzident ist.
Es heißt *inklusionsmaximal*, wenn für alle Kanten $e \in E \setminus M$ gilt: $M \cup \{e\}$ ist kein Matching.

Algorithmus 2.3 MATCHING-VC

Input: ungerichteter Graph $G = (V, E)$
Output: Vertex Cover $V' \subseteq V$ mit $|V'| \leq 2 \cdot \mathrm{OPT}(G)$

1: ▷ *Berechne inklusionsmaximales Matching $M \subseteq E$:* ◁
2: $M := \emptyset$
3: **for all** $e = \{u, v\} \in E$ **do**
4: **if** weder u noch v ist inzident zu einer Kante in M **then**
5: $M := M \cup \{e\}$
6: $V(M) := \{v \in V \mid v \text{ ist inzident zu einer Kante in } M\}$
7: **return** $V(M)$

Satz 2.4: Matching-VC

Matching-VC hat Laufzeit $\mathcal{O}(|V| + |E|)$ für Graphen in Adjazenzlistendarstellung. Er berechnet ein Vertex Cover der Größe höchstens $2 \cdot \mathrm{OPT}(G)$, wobei $\mathrm{OPT}(G)$ die Größe des kleinsten Vertex Covers ist.

Beweis. **Laufzeit:** In Schritt 1 wird jede Kante genau einmal betrachtet, $\mathcal{O}(|V| + |E|)$.

In Schritt 2 wird jeder Knoten höchstens einmal betrachtet, $\mathcal{O}(|V|)$. Gemeinsam ergibt sich $\mathcal{O}(|V| + |E|)$.

Korrektheit: Angenommen, $e = (u, v) \in E$ wurde nicht von $V(M)$ abgedeckt. Das heißt, es wären weder $u \in V(M)$ noch $v \in V(M)$. Dann wäre $M \cup \{e\}$ ein Matching und e würde in Schritt 1 zu M hinzugefügt werden. Widerspruch zur Inklusionsmaximalität von M. Also ist $V(M)$ ein Vertex Cover.

Approximation: Sei V^* ein minimales Vertex Cover. V^* muss alle Kanten $e \in E$ abdecken, also auch alle $e \in M$.

Außerdem haben in M keine zwei Kanten denselben Endpunkt. Deshalb ist $|M| \leq |V^*|$.

Für unsere Lösung gilt $|V(M)| = 2 \cdot |M| \leq 2 \cdot \mathrm{OPT}(G)$.

□

2.2 Set Cover

Problem 2.5: Set Cover

Input: Menge S mit n Elementen, n Teilmengen $S_1, \ldots, S_m \subseteq S$ mit $\bigcup_{i=1}^m S_i = S$, Kosten $c_1, \ldots, c_m \in \mathbb{N}$.
Output: Alle $A \subseteq \{1, \ldots, m\}$ mit $\bigcup_{i \in A} S_i = S$
Objective: Minimiere $\sum_{i \in A} c_i$

Algorithmus 2.6 GREEDY-SC

Input: Grundmenge S mit n Elementen, n Teilmengen $S_1, \ldots, S_m \subseteq S$ mit $\bigcup_{i=1}^m S_i = S$, Kosten $c_1, \ldots, c_m \in \mathbb{N}$.
Output: $A \subseteq \{1, \ldots, m\}$ mit $\bigcup_{i \in A} S_i = S$ und $\sum_{i \in A} c_i$ minimal

1: $A := \emptyset, C := \emptyset$
2: **while** $C \neq S$ **do**
3: Wähle S_i mit minimalen relativen Kosten $r_i(C) = \frac{c_i}{|S_i \setminus C|}$
4: Setze $\mathrm{price}(x) := r_i(C)$ für alle $x \in S_i \setminus C$
5: $A := A \cup \{i\}$
6: $C := C \cup S_i$
7: **return** A

Satz 2.7: Greedy-SC

GREEDY-SC ist ein H_n-Approximationsalgorithmus für Set Cover, wobei

$$H_n = \sum_{i=1}^{n} \frac{1}{i}$$

die n-te harmonische Zahl ist.

Untere Schranke für Greedy-SC: Sei $\varepsilon > 0$ sehr klein. Betrachte n Knoten und $m = n + 1$ Mengen, wobei $S_i = \{i\}$ mit Kosten $\frac{1}{n+1-i}$ ist (für $i \in S$) und $S_{n+1} = S$ mit Kosten $1 + \varepsilon$. Dann wählt GREEDY-SC wählt alle Einzelnen, OPT die gesamte Menge.

[14.10.2025, Vorlesung 1]
[15.10.2025, Vorlesung 2]

Beweis. Beobachtung: Es gilt

$$c(A) = \sum_{x \in S} \mathrm{price}(x).$$

Sei $x_1, \ldots, x_n$ die Reihenfolge der Elemente in S, wie sie vom GREEDY-SC abgedeckt werden (Beim Abdecken von mehreren Elementen in gleicher Iteration wähle beliebige Reihenfolge).

Lemma 2.8: Preis in Greedy-SC

Für alle $k \in \{1, \dots, n\}$ gilt

$$\text{price}(x_k) \leq \frac{\text{OPT}}{n-k+1}.$$

Beweis: Lemma 2.8. Betrachte ein beliebiges $k \in \{1, \dots, n\}$. Sei $i \in \{1, \dots, m\}$ der Index der Menge S_i, mit der x_k erstmalig abgedeckt wird. Bezeichne A die Auswahl der Mengen, *bevor* x_k abgedeckt wird.

Sei $C := \bigcup_{i \in A} S_i$. Es gilt $|C| \leq k-1$. Eine optimale Auswahl A^* von Mengen deckt ganz S ab, insbesondere auch $S \setminus C$, wobei $|S \setminus C| \geq n-k+1$.

Es gilt

$$\begin{aligned}\text{OPT} = \sum_{j \in A^*} c_j &\geq \sum_{\substack{j \in A^* \\ S_j \setminus C \neq \emptyset}} c_j = \sum_{\substack{j \in A^* \\ S_j \setminus C \neq \emptyset}} |S_j \setminus C| \underbrace{\frac{c_j}{|S_j \setminus C|}}_{= r_j(C) \geq r_i(C)} \\ &\geq r_i(C) \underbrace{\sum_{\substack{j \in A^* \\ S_j \setminus C \neq \emptyset}} |S_j \setminus C|}_{\geq |S \setminus C|} \geq \underbrace{r_i(C)}_{= \text{price}(x_k)} \cdot (n-k+1)\end{aligned}$$

wobei $r_j(C) \geq r_i(C)$ wegen der Greedy-Auswahl und

$$\sum_{\substack{j \in A^* \\ S_j \setminus C \neq \emptyset}} |S_j \setminus C| \geq |S \setminus C|,$$

weil A^* ganz $S \setminus C$ abdeckt. □

Nun gilt mit Lemma 2.8

$$c(A) = \sum_{k=1}^{n} \text{price}(x_k) \leq \sum_{k=1}^{n} \frac{\text{OPT}}{n-k+1} = \text{OPT} \sum_{i=1}^{n} \frac{1}{i} = \text{OPT} \cdot H_n$$

und Satz 2.7 ist gezeigt. □

2.3 Scheduling auf identischen Maschinen

Problem 2.9: Scheduling auf identischen Maschinen

Input: Menge $J = \{1, \dots, n\}$ von Jobs, Menge $M = \{1, \dots, m\}$ von Maschinen, Größen $p_j > 0$ für jeden Job $j \in J$

Output: Schedule $\pi : J \to M$, Last von Maschine i in Schedule π: $L_i(\pi) = \sum_{\substack{j \in J \\ \pi(j) = i}} p_j$,

Makespan $C(\pi) = \max_{i \in M} L_i(\pi)$

Objective: Finde Schedule π mit kleinstem Makespan

Algorithmus 2.10 LEASTLOADED

Input: Siehe Problem 2.9

Output: Siehe Problem 2.9

1: Betrachte Jobs in Reihenfolge $1, \dots, n$

2: Weise jedem Job der Maschine mit bislang kleinster Last zu

Satz 2.11: LeastLoaded

LeastLoaded ist ein $(2-\frac{1}{m})$-Approximationsalgorithmus für Scheduling auf identischen Maschinen.

Beweis. Sei π^* ein optimaler Schedule. Dann ist

$$C(\pi^*) \geq \frac{1}{m} \sum_{j \in J} p_j,$$

denn

$$C(\pi^*) = \max_{i \in M} \sum_{\substack{j \in J \\ \pi(j)=i}} p_j \geq \frac{1}{m} \sum_{i \in M} \sum_{\substack{j \in J \\ \pi(j)=i}} = \frac{1}{m} \sum_{j \in J} p_j.$$

Außerdem gilt $C(\pi^*) \geq \max_{j \in J} p_j$.

Sei π der Schedule, der LeastLoaded berechnet. Sei i die Maschine mit größter Last. Sei j der Job, der zuletzt zu i hinzugefügt wurde. Zu diesem Zeitpunkt war Maschine i diejenige mit der geringsten Last. Ihre Last war höchstens $\frac{1}{m}\sum_{k=1}^{j-1} p_k$. Es gilt

$$C(\pi) = L_i(\pi) \leq \frac{1}{m} \underbrace{\sum_{k=1}^{j-1} p_k}_{\leq \sum_{k \in J \setminus \{j\}} p_k} + p_j \leq \underbrace{\frac{1}{m} \sum_{k \in J} p_k}_{\leq C(\pi^*)} + \left(1 - \frac{1}{m}\right) \underbrace{p_j}_{\leq C(\pi^*)} \leq \left(2 - \frac{1}{m}\right) C(\pi^*)$$

und die Abschätzung ist gezeigt. □

Bemerkung 2.12. $2 - \frac{1}{m}$ ist eine untere Schranke für LeastLoaded.

Beweis. Sei $n = m(m-1)+1$ und $p_1 = \cdots = p_{m(m-1)} = 1$ und $p_{m(m-1)+1} = m$.

LeastLoaded führt auf jeder Maschine $m-1$ Jobs der Größe 1 durch. Auf einer Maschine wird zusätzlich ein Job der Größe m ausgeführt. Somit ist der Makespan $m-1+m = 2m-1$.

Eine optimale Belegung führt auf $m-1$ Maschinen je m Jobs der Größe 1 aus und auf der letzten Maschine einen Job der Größe m, wir haben also einen Makespan von m, und der Faktor stimmt. □

Algorithmus 2.13 LongestProcessingTime (LPT)

Input: Siehe Problem 2.9
Output: Siehe Problem 2.9

1: Sortiere Jobs so, dass $p_1 \geq p_2 \geq \cdots \geq p_n$.
2: Führe LeastLoaded auf den sortierten Jobs aus.

Satz 2.14: LPT

LongestProcessingTime ist ein $\frac{4}{3}$-Approximationsalgorithmus.

Beweis. Angenommen, es gäbe eine Instanz, sodass LPT einen Makespan von mehr als $\frac{4}{3} \cdot \mathrm{OPT}$ erreicht. Betrachte unter diesen Instanzen eine mit geringster Anzahl Jobs.

Sei i eine Maschine mit höchster Last in LPT-Schedule π. Sei j der letzte Job, der Maschine i zugewiesen wird. Es ist $j = n$, da sonst $p_1, \ldots, p_j$ ein Gegenbeispiel mit weniger Jobs wäre. Es gilt

$$C(\pi) = L_i(\pi) \leq \frac{1}{m} \sum_{k=1}^{n-1} p_k + p_n \leq \mathrm{OPT} + p_n.$$

Aus $C(\pi) > \frac{4}{3}\,\mathrm{OPT}$ folgt $p_n > \frac{1}{3}\,\mathrm{OPT}$. Da $p_1 \geq \cdots \geq p_n$ folgt $p_j > \frac{1}{3}\,\mathrm{OPT}$ für alle $j \in J$. Also erhält im optimalen Schedule jede Maschine höchstens zwei Jobs.

Sei k die Anzahl Jobs mit Größe $\frac{2}{3}\,\mathrm{OPT}$. Im optimalen Schedule sind k Jobs alleine auf einer Maschine und $n-k$ Jobs höchstens zu zweit.

Fall 1: $k = n$. Also ist $n \leq m$, Job n wird also einer leeren Maschine zugewiesen.

Fall 2: $k < n$. Zum Zeitpunkt bevor Job n hinzugefügt wird, hat LPT mindestens eine Maschine mit höchstens einem Job und dieser hat Größe höchstens $\frac{2}{3}\,\mathrm{OPT}$. Wegen $p_n \leq \frac{2}{3}\,\mathrm{OPT}$ ist die Last dieser Maschine im Anschluss höchstens $\frac{4}{3}\,\mathrm{OPT}$.

Beides ist ein Widerspruch zur Annahme. ↯ □

Bemerkung 2.15. $\frac{4}{3}$ ist eine untere Schranke für LONGESTPROCESSINGTIME.

Beweis. Übungsaufgabe. □

Wir werden später sehen, dass für alle $\varepsilon > 0$ ein $(1+\varepsilon)$-Approximationsalgorithmus existiert.

[15.10.2025, Vorlesung 2]
[21.10.2025, Vorlesung 3]

2.4 Rucksackproblem

Problem 2.16: Rucksackproblem (Knapsack Problem, KP)

Input: Kapazität $t \in \mathbb{N}$, Nutzen $p_1, \ldots, p_n \in \mathbb{N}$, Gewichte $w_1, \ldots, w_n \in \{1, \ldots, t\}$
Output: Teilmenge $A \subseteq \{1, \ldots, n\}$ mit $w(A) := \sum_{i \in A} w_i \leq t$
Objective: Maximiere $p(A) := \sum_{i \in A} p_i$

Algorithmus 2.17 GREEDY-KP

Input: Siehe Problem 2.16
Output: Siehe Problem 2.16

```
1: Sortiere Objekte nach Effizienz, sodass p_1/w_1 ≥ ··· ≥ p_n/w_n
2: B := ∅, i := 1
3: while i ≤ n and w(B) + w_i ≤ t do
4:     B := B ∪ {i}
5:     i := i + 1
6: Sei i* ein Objekt mit dem größten Nutzen
7: if p(B) < p_{i*} then
8:     A := {i*}
9: else A := B
10: return A
```

Satz 2.18: Greedy-KP

GREEDY-KP ist ein $\frac{1}{2}$-Approximationsalgorithmus.

Beweis. Sei $B := \{1, \ldots, i\}$ die im Algorithmus berechnete Menge. Falls $i = n$, gibt es nichts zu zeigen.

Falls $i < n$, gilt $w(B) + w_{i+1} > t$.

Behauptung: Es gilt $p(B) + p_{i+1} \geq \text{OPT}$:

Angenommen, $\text{OPT} > p(B) + p_{i+1}$. Dann gibt es eine Menge $A' \subseteq \{1, \ldots, n\}$, für die gilt, dass $w(A') \leq t < w(B) + w_{i+1}$ und $p(A') = \text{OPT} > p(B) + p_{i+1}$.

Betrachte $J := \{1, \ldots, i+1\} \setminus A'$ und $J' := A' \setminus \{1, \ldots, i+1\}$. Nun gilt

$$p(B) + p_{i+1} < p(A') = (p(B) + p_{i+1}) + p(J') - p(J) \implies p(J') > p(J)$$

und analog

$$w(B) + w_{i+1} > w(A') = (w(B) + w_{i+1}) + w(J') - w(J) \implies w(J') < w(J).$$

Sei $r = \frac{p_{i+1}}{w_{i+1}}$, dann

$$p(J) \geq r \cdot w(J), \qquad p(J') \leq r \cdot w(J').$$

Zusammen ergibt sich

$$p(J) \geq r \cdot w(J) > r \cdot w(J') \geq p(J') > p(J). \qquad \lightning$$

Damit ist die Behauptung gezeigt und es gilt $p(B) + p_{i+1} \geq \text{OPT}$.

Somit gilt

$$p(A) = \max\{p(B), p_{i^*}\} \geq \frac{1}{2}(p(B) + p_{i^*}) \geq \frac{1}{2}(p(B) + p_{i+1}) \geq \frac{1}{2}\,\text{OPT}$$

und die Aussage ist gezeigt. □

Kapitel 3

Runden und dynamische Programmierung

Definition 3.1: Approximationsschema, PTAS, FPATS

Ein *Approximationsschema* A für ein Optimierungsproblem Π ist ein Algorithmus, der zu jeder Eingabe (I, ε) mit $I \in \mathcal{I}_\Pi, \varepsilon > 0$ eine Lösung $A(I,\varepsilon) \in \mathcal{S}_I$ berechnet und es gilt

$$f(A(I,\varepsilon)) \leq (1+\varepsilon)\,\mathrm{OPT}(I) \qquad \text{bei Minimierungsproblemen, bzw.}$$
$$f(A(I,\varepsilon)) \geq (1-\varepsilon)\,\mathrm{OPT}(I) \qquad \text{bei Maximierungsproblemen.}$$

A heißt *polynomielles Approximationsschema* (PTAS), wenn die Laufzeit für jedes ε polynomiell in $|I|$ beschränkt ist.
A heißt *voll-polynomielles Approximationsschema* (FPTAS), wenn die Laufzeit polynomiell in $\frac{1}{\varepsilon}$ und $|I|$ ist.

Beispiel 3.2.

- $\Theta(|I|^{1/\varepsilon})$ ist PTAS, aber kein FPTAS
- $\Theta\left(\frac{|I|^{100}}{\varepsilon^{10}}\right)$ ist ein FPTAS

3.1 Rucksackproblem

3.1.1 Dynamische Programmierung

Sei $W(I,p)$ *geringste* Gewicht unter allen Teilmengen von $\{1,\dots,i\}$, die Nutzen mindestens p erreichen, bzw. ∞, wenn das nicht möglich ist.

Falls $I \subseteq \{1,\dots,i\}$ gilt: Falls $\sum_{i\in I} p_i \geq p$, dann ist $\sum_{i\in I} w_i \geq W(I,p)$.

Es gilt

$$W(0,p) = \begin{cases} 0 & p \leq 0 \\ \infty & p > 0, \end{cases}$$

$$W(1,p) = \begin{cases} 0 & p \leq 0 \\ w_1 & 0 < p \leq p_1 \\ \infty & p > p_1. \end{cases}$$

Sei $P := \max_{\{1,\dots,n\}} p_i$. Uns interessieren $W(i,p)$ für $i = 0,\dots,n$ und $p = 0,\dots,nP$.

Rekursionsformel für $W(i,p)$:

Sei $I \subseteq \{1,\dots,i\}$ diejenige Teilmenge mit minimalem Gewicht unter allen mit $\sum_{j\in I} p_j \geq p$.

Fall 1: $i \notin I$. Dann gilt $W(i,p) = W(i-1,p)$.

Fall 2: $i \in I$. Dann betrachte $I \setminus \{i\}$. Es ist $W(I \setminus \{i\}) = W(i,p) - w(i)$ und $p(I \setminus \{i\}) \geq p - p_i$. Daraus folgt

$$W(i-1, p-p_i) \leq W(i,p) - w_i.$$

Umgekehrt sei $I' \subseteq \{1,\dots,i-1\}$ diejenige Menge, die $W(i-1,p-p_i)$ liefert. Nun gilt

$$W(I' \cup \{i\}) = W(i-1,p-p_i) + w_i, \qquad p(I' \cup \{i\}) = p(I') + p_i \geq p.$$

Daraus folgt, dass $W(i,p) \leq W(i-1,p-p_i) + w_i$.

Umstellen liefert

$$W(i,p) = W(i-1,p-p_i) + w_i.$$

Insgesamt ergibt sich die Rekursion

$$W(i,p) = \min\{W(i-1,p), W(i-1,p-p_i) + w_i\}, \qquad W(0,p) = \begin{cases} \infty & p > 0 \\ 0 & p \leq 0. \end{cases}$$

Algorithmus 3.3 DYNKP

Input: Siehe Problem 2.16
Output: Siehe Problem 2.16

1: $P := \max_{i \in \{1,\dots,n\}} p_i$
2: **for** $i = 1$ **to** n **do**
3: **for** $p = 1$ **to** nP **do**
4: $W(i,p) = \min\{W(i-1,p), W(i-1,p-p_i) + w_i\}$
5: **return** maximales $p \in \{1,\dots,nP\}$ mit $W(n,p) \leq t$.

Satz 3.4: DynKP

DYNKP liefert in Zeit $\Theta(n^2 P)$ den maximal erreichbaren Nutzen.

3.1.2 Approximationsschema

Algorithmus 3.5 FPTAS-KP

Input: Siehe Problem 2.16, $\varepsilon > 0$
Output: Siehe Problem 2.16

1: $P := \max_{i \in 1,\dots,n} p_i$
2: $K := \frac{\varepsilon P}{n}$
3: **for** $i = 1$ **to** n **do**
4: $p'_i = \lfloor \frac{p_i}{K} \rfloor$
5: Benutze DYNKP auf $p'_1,\dots,p'_n, w_1,\dots,w_n, t$

Satz 3.6: FPTAS-KP

FPTAS-KP hat eine Laufzeit von $\mathcal{O}(\frac{n^3}{\varepsilon})$ und berechnet eine $1-\varepsilon$-Approximation.

Beweis.

Laufzeit: DYNKP braucht Zeit $\Theta(n^2 P')$, wobei $P' = \max_{i \in \{1,\dots,n\}} p'_i$. Es gilt für alle i:

$$p'_i = \left\lfloor \frac{p_i}{K} \right\rfloor \leq \left\lfloor \frac{P}{K} \right\rfloor = \left\lfloor \frac{n}{\varepsilon} \right\rfloor \leq \frac{n}{\varepsilon},$$

also ist auch $P' \leq \frac{n}{\varepsilon}$.

Approximationsfaktor: Sei I' eine optimale Lösung auf $p'_1, \ldots, p'_n$ und I eine optimale Lösung auf $p_1, \ldots, p_n$.

I' ist auch eine optimale Lösung auf $\{p_i^*\} := \{K \cdot p'_i\}$.

Beispiel 3.7. Für $n = 4, P = 50, \varepsilon = \frac{4}{5}, K = \frac{\varepsilon P}{n} = 10$. Für $p_1 = 33$ erhalten wir $p'_1 = 3$ bzw. $p_1^* = 30$.

Es gilt $p_i^* = K \cdot \lfloor \frac{p_i}{K} \rfloor \geq K \cdot \left(\frac{p_i}{K} - 1\right) = p_i - K$ und $p_i^* \leq K \cdot \frac{p_i}{K} = p_i$, also $p_i^* \in [p_i - K, p_i]$.

Für alle $J \subseteq \{1, \ldots, n\}$ gilt

$$p^*(J) := \sum_{i \in J} p_i^* \leq \sum_{i \in J} p_i = p(J)$$

und

$$p^*(J) = \sum_{i \in J} p_i^* \geq \sum_{i \in J} (p_i - K) = \sum_{i \in J} p_i - |J| \cdot K \geq p(J) - nK.$$

Damit ist $p(I') \geq p^*(I') \geq p^*(I) \geq p(I) - nK$, da I' optimal hinsichtlich p^* ist.

Weiterhin ist $p(I) \geq P$, also gilt

$$\frac{p(I')}{p(I)} = \frac{p(I) - nK}{\mathrm{OPT}} \geq 1 - \frac{nK}{P} = 1 - \varepsilon$$

und wir erhalten $1 - \varepsilon$ als Approximationsfehler.

□

[21.10.2025, Vorlesung 3]
[22.10.2025, Vorlesung 4]

[22.10.2025, Vorlesung 4]
[28.10.2025, Vorlesung 5]

Anhang

Liste der Definitionen

1.1 Optimierungsproblem, Approximationsalgorithmus 3
2.1 Vertex Cover 4
2.2 Matching 4
2.5 Set Cover 5
2.9 Scheduling auf identischen Maschinen 6
2.16 Rucksackproblem (Knapsack Problem, KP) 8
3.1 Approximationsschema, PTAS, FPATS 10

Liste der Aussagen

2.4 Matching-VC 4
2.7 Greedy-SC 5
2.8 Preis in Greedy-SC 6
2.11 LeastLoaded 7
2.14 LPT 7
2.18 Greedy-KP 8
3.4 DynKP 11
3.6 FPTAS-KP 11

Liste der Algorithmen

2.3 Matching-VC 4
2.6 Greedy-SC 5
2.10 LeastLoaded 6
2.13 LongestProcessingTime (LPT) 7
2.17 Greedy-KP 8
3.3 DynKP 11
3.5 FPTAS-KP 11

Index

Approximationsschema, 10
    polynomielles -, 10
    voll-polynomielles -, 10

DynKP, 11

FPATS, 10
FPTAS-KP, 11

Greedy-KP, 8
Greedy-SC, 5

Knapsack-Problem, 8, 10
KP, 8, 10

LeastLoaded, 6
LongestProcessingTime, 7
LPT, 7

Matching, 4
    inklusionsmaximal, 4
Matching-VC, 4

PTAS, 10

Rucksackproblem, 8, 10

Scheduling, 6
    auf identischen Maschinen, 6
Set Cover, 5

Vertex Cover, 4