Anton Bovier

Einführung in die Wahrscheinlichkeitstheorie

Vorlesung Winter 2024/25, Bonn

18. Juni 2024

UNIVERSITÄT BONN IAM

Inhaltsverzeichnis

1 Wahrscheinlichkeit 1
- 1.1 Zufallsexperimente und Glückspiele 2
- 1.2 Allgemeine Eigenschaften von Bewertungen. 3
- 1.3 Wahrscheinlichkeitsmaße. 6
- 1.4 Wahrscheinlichkeit und Frequenz 7
- 1.5 Wahrscheinlichkeit und Information 9
- 1.6 Wahrscheinlichkeit und Versicherung. 9

2 Elemente der Maßtheorie 11
- 2.1 Messräume und Maße 11
  - 2.1.1 σ-Algebren 11
  - 2.1.2 Wahrscheinlichkeitsmaße 13
  - 2.1.3 Die Borel'sche σ-Algebra. 14
  - 2.1.4 Maßbestimmende Mengen und Satz von Carathéodory. 16
  - 2.1.5 Wahrscheinlichkeitsmaße auf $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$ 20
- 2.2 Integration 23
  - 2.2.1 Messbare Abbildungen und Zufallsvariablen 23
  - 2.2.2 Integrale von Zufallsvariablen. 24
  - 2.2.3 Abbildungen von Maßen 31
  - 2.2.4 Absolut stetige Maße. Wahrscheinlichkeitsdichten. 32
- 2.3 Beispiele von Wahrscheinlichkeitsmaßen. 33

3 Bedingte Wahrscheinlichkeiten, Unabhängigkeit, Produktmaße 39
- 3.1 Bedingte Wahrscheinlichkeiten 40
- 3.2 Unabhängige Zufallsvariablen 43
- 3.3 Produkträume 46
- 3.4 Der Satz von Fubini 50
- 3.5 Unendliche Produkte 52

4 Summen von unabhängigen Zufallsvariablen 55
4.1 Die Irrfahrt 56
4.2 Optionspreise 58
4.3 Das Ruin-Problem 61
4.4 Das Arcussinusgesetz 62
4.5 Faltungen 67

5 Konvergenzbegriffe 71
5.1 Konvergenz von Verteilungsfunktionen 71
5.2 Konvergenz von Zufallsvariablen 73
5.2.1 Konvergenz in Verteilung 73
5.2.2 Konvergenz in Wahrscheinlichkeit 77
5.2.3 Fast sichere Konvergenz 78

6 Das Gesetz der großen Zahlen. 85
6.1 Erwartungswert, Varianz, Momente 85
6.2 Die Chebyshev Ungleichung 87
6.3 Das Gesetz der großen Zahlen 89
6.3.1 Das schwache Gesetz unter Momentenannahmen. 89
6.3.2 Das starke Gesetz unter Momentenbedingungen 90
6.3.3 Kolmogorov's Ungleichung 91
6.3.4 Beweis des starken Gesetzes der großen Zahlen 93

7 Der zentrale Grenzwertsatz 97
7.1 Grenzwertsätze 97
7.2 Charakteristische Funktionen 98
7.3 Der zentrale Grenzwertsatz 105
7.4 Stabile Verteilungen 107

8 Markov Prozesse 109
8.1 Definitionen 109
8.2 Markovketten mit stationären Überganswahrscheinlichkeiten 112
8.3 Invariante Verteilungen 115
8.3.1 Markovketten und Graphen. Klassifizierung der Zustände . . 116
8.3.2 Die Sätze von Perron und Frobenius 123
8.3.3 Wesentliche und unwesentliche Klassen. 125
8.4 Stoppzeiten und der starke Ergodensatz 127
8.4.1 Die starke Markoveigenschaft 128
8.4.2 Der starke Ergodensatz 131
8.4.3 Markovketten Monte-Carlo Verfahren. 132
8.5 Vorwärtsgleichungen, Eintrittswahrscheinlichkeiten und Zeiten. 133
8.6 Markovketten mit abzählbarem Zustandsraum 137

Literaturverzeichnis 143

Glossary 145

Sachverzeichnis 147

Kapitel 1
Wahrscheinlichkeit

Il est remarquable qu'une science, qui a commencé par la considération des jeux, ce soit élévée aux plus importants objects des connaissances humaines[a].
Pierre Simon de Laplace, Théorie Analytique des Probabilités

[a] Es ist bemerkenswert, dass eine Wissenschaft, die mit der Betrachtung von Glücksspielen begonnen hat, sich zu einem der wichtigsten Gegenstände der menschlichen Erkenntnis erhoben hat.



In dieser Vorlesung werden wir ein Gebiet der Mathematik behandeln, das sich von anderen dadurch hervorhebt, dass viele seiner Begriffe weitgehend Eingang in die Umgangssprache gefunden haben, ja, dass Fragen behandelt werden, die viele Menschen im täglichen Leben betreffen und von denen fast jedermann gewisse, ob falsche oder richtige, Vorstellungen hat.

Der zentrale Begriff, der uns hier beschäftigt, ist der des *Zufalls*. Was Zufall ist, oder ob es so etwas überhaupt gibt, ist eine tiefe philosphische Frage, der wir uns hier nur in wenigen Punkten annähern können; sie ist auch nicht der zentrale Gegenstand der Vorlesung. Grob gesprochen reden wir von "Zufall", wenn es sich um den Eintritt von *Ereignissen* handelt, die wir nicht oder nicht im Detail vorhersehen können. Typischerweise sind für ein solches Ereignis mehrere Varianten möglich, und wir reden von der Wahrscheinlichkeit des einen oder anderen Ausgangs. Ein beliebtes Beispiel ist etwa die Frage, ob es morgen regnet. In vielen Fällen ist dies möglich, aber nicht sicher. Der Wetterbericht macht darüber zwar Vorhersagen, aber auch diese treffen nur "mit einer gewissen Wahrscheinlichkeit ein". Wir können die Frage auch noch weiter spezifizieren, etwa danach wieviel Regen morgen fallen wird, und werden noch weniger sichere Vorhersagen bekommen. Gleiches gilt für sehr viele Vorkommnisse des täglichen Lebens. Der Begriff des Zufalls und der Wahrscheinlichkeit wird gebraucht, um solche Unsicherheiten qualitativ und quantitativ genauer zu beschreiben.

Unsicherheit tritt in vielen Situationen auf und wird sehr unterschiedlich wahrgenommen. Vielfach betrachten wir sie als Ärgernis und suchen eigentlich nach einer deterministischen Gesetzmässigkeit, die genauere Vorhersagen erlaubt. Dies betrifft insbesondere viele Bereiche von Naturwissenschaft und Technik, wo uns der Zufall vielfach nur in der Form von "Fehlern" und Ungenauigkeiten begegnet, und wir bestrebt sind seine Effekte möglichst zu eleminiern oder doch zu minimieren.

In anderen Fällen ist der Zufall wesentlicher Motor des Geschehens und seine Existenz ist sogar gewollt und wird gezielt ausgenutzt. Am ausgeprägtesten ist dies

sicher im *Glückspiel*, und in vieler Hinsicht ist hier die Wahrscheinlichkeitstheorie genuin zuhause and kann in ihrer reinsten Form beobachtet werden. Wie das Zitat von Laplace am Anfang dieses Kapitels belegt, sind die grundlegenden Prinzipien der Wahrscheinlichkeitstheorie zunächst in diesem Kontext entwickelt worden. In diesem Zusammenhang steht auch der Erfolg der Wahrscheinlichkeit unter dem Namen Finanzmathematik. Interessanterweise sind viele der mathematischen Prinzipien die hier entwickelt wurden, von der genauen Interpretation von Zufall gar nicht abhängig.

Literaturhinweise: Es gibt eine große Zahl von Lehrbüchern zur Wahrscheinlichkeitstheorie. Für die Vorlesung beziehe ich mich vielfach auf das Buch von Hans-Otto Georgii [6]. Ein Klassiker ist das zweibändige Werk von Feller [3, 4]. Persönlich gefällt mir auch das Buch von Chow und Teicher [2], dass allerdings in vielen Teilen schon eher das Niveau der Vorlesung Stochastische Prozesse hat. Ein Buch auf ähnlichem Niveau ist die Wahrscheinlichkeitstheorie von Achim Klenke [9]. Eine sehr elementare schöne Einführung ist ein Buch von Kersting und Wakolbinger [8], das aber eher dem ALMA 2 Stoff entspricht.

1.1 Zufallsexperimente und Glückspiele

Die meisten klassischen Glückspiele beruhen auf einer Vorrichtung, die es erlaubt in unvorhersahbarer Weise wiederholbar eines aus einer Reihe möglicher Ausgänge eines Experiments zu produzieren. Typische Beispiele sind:

- **Münzwurf.** Eine Münze mit zwei unterschiedlich bedruckten Seiten (“Kopf” und “Zahl”) wird in die Luft geworfen. Sie kommt schließlich auf dem Boden zu liegen und zeigt nun mit einer ihrer Seiten nach oben. Diese zwei möglichen Ausgänge stellen die zwei Ereignisse “Kopf” oder “Zahl” dar. Wir gehen davon aus, dass es uns nicht möglich ist den Ausgang vorherzusehen, wir betrachten diesen als völlig zufällig [dies mag eine Idealisierung sein, da ein sehr geschickter Münzwerfer den Ausgang des Experiments beeinflussen kann. Wir wollen hiervon aber absehen]. Wichtig ist hier, dass wir einen solchen Wurf beliebig oft wiederholen können, ohne irgendeine zusätzliche Information über den Ausgang des nächsten Wurfes zu bekommen.
- **Roulette.** Hier wird eine Kugel auf eine sich drehende Scheibe geworfen, die 37 numerierte identische Vertiefungen enthält, in einer von denen die Kugel am Ende des Experiments liegenbleibt. Auch hier wird eines der 37 möglichen Ereignisse in unvorhersehbarer Weise realisiert.
- **Würfeln.** Ähnlich wie der Münzwurf, es sind hier aber 6 Ereignisse möglich.
- **Lotto.** Aus einem Behälter, der 49 numerierte Kugeln enthält, werden 6 davon mit einem komplizierten Mechanismus herausgefischt. Aufgrund der Durchmischung am Anfang ist das Ergebnis nicht vorhersehbar. Die möglichen Ereignisse sind “sechs Zahlen aus den 49 ersten natürlichen Zahlen”, zum Beispiel

$3, 8, 19, 23, 25, 45$. Die Zahl der möglichen Ausgänge ist recht groß, nämlich $49!/43!/6! = \binom{49}{6} = 1\,398\,316$.

- **Zufallszahlengeneratoren.** Zufallszahlengeneratoren sind numerische Algorithmen, mit denen ein Computer Zahlenreihen (etwa aus $\{0, 1\}$) produziert, die möglichst zufällig sein sollen. In Wirklichkeit sind diese Reihen allerdings völlig deterministisch, können aber sehr irregulär von einem Anfangswert ("seed") abhängen. Die Erzeugung von Zufallszahlen ist ein wichtiges Problem, dem wir uns aber zunächst nicht weiter widmen wollen.

Wir wollen die Durchführung eines solchen "Experiments" in Zukunft als *Zufallsexperiment* bezeichnen. Jedem Zufallsexperiment kommt eine Menge möglicher Ausgänge zu. Diese Menge bezeichnen wir meist mit Ω; sie wird den Namen *Wahrscheinlichkeitsraum* erhalten.

Ein Glücksspiel besteht nun darin, auf den Ausgang eines (oder mehrerer) Zufallsexperiments zu wetten. Der Übersichtlichkeit halber wollen wir uns auf das Roulettespiel konzentrieren. Hier gibt es "Spieler" sowie eine "Bank". Jeder Spieler hat die Möglichkeit einen von ihm gewählten Geldbetrag, g, darauf zu wetten, dass die nächste Ausführung des Zufallsexperiments "Ball-auf-Scheibe-werfen" damit endet, dass die Kugel in einer bestimmten Untermenge, $A \subset \Omega = \{0, \ldots, 36\}$, liegen bleibt. Wir wollen den Ausgang des Experimentes mit X bezeichnen. Als mögliche Untermengen sind eine Reihe Optionen auf dem Tisch vorgegeben, unter anderem aber auch jede beliebige Zahl von 0 bis 36. Die Wette besteht darin, dass die Bank den Einsatz, g, des Spielers einstreicht und verspricht, wenn das vom Spieler vorhergesagte Ereigniss, also $X \in A$, eintritt, ein festgelegtes Vielfaches des Einsatzes, gn_A, an den Spieler auszuzahlen (beachte, dass der Gewinn natürlich nur $(n_A - 1)g$ ist). Die Zahlen n_A sind von der Bank von Anfang an festgesetzt.

Die Bank wettet also mit $n_A : 1$ gegen das Eintreten des Ereignisses $X \in A$, der Spieler setzt $1 : n_A$ dafür. Diese Verhältnisse ("odds") geben in gewisser objektiver (jedenfalls aus Sicht der rational handelnden Bank) eine Einschätzung der Gewinnchancen wieder. Letzlich sind sie in gewisser Weise "objektive", weil in Geld umsetzbare, Bewertungen der Wahrscheinlichkeiten dieser Ereignisse.

Die Frage, wie solche Bewertungen gewählt werden sollen, ist die grundlegende Frage des Anwenders an den Mathematiker und steht am historischen Ursprung der Wahrscheinlichkeitstheorie. Wir wollen uns daher diesem Problem von verschiedenen Seiten zuwenden.

1.2 Allgemeine Eigenschaften von Bewertungen.

Im Fall des Roulette Spiels wird man sich leicht davon überzeugen lassen, dass die Bewertugen n_A umgekehrt proportional zu der Grösse der Menge A sein sollten (bereits bei einem elektronischen Roulette, dessen Programm man nicht kennt, wird man wesentlich skeptischer sein). Wir wollen aber vorerst von solchen speziellen Annahmen absehen und Eigenschaften herleiten, die unter allen Umständen gelten müssen, damit die Bank nicht unversehens ruiniert werden kann. Wir betrachen da-

zu einen viel allgemeineren Fall als das Roulette Spiel. Dazu sei Ω zunächst nicht weiter spezifiziert. Den Spielern sei eine Menge, $\mathfrak{A}$, von Teilmengen von Ω gegeben auf die sie beliebige Geldbeträge setzen dürfen. Über die Menge $\mathfrak{A}$ sei folgendes angenommen:

- Wenn $A, B \in \mathfrak{A}$, dann ist auch $A \cup B \in \mathfrak{A}$.
- Wenn $A \in \mathfrak{A}$, dann ist auch $A^c \equiv \Omega \backslash A \in \mathfrak{A}$.
- Der Form halber nehmen wir an, dass $\Omega \in \mathfrak{A}$ und somit auch $\emptyset \in \mathfrak{A}$.

Der erste Punkt ist unvermeidbar wenn A und B disjunkt sind, andernfalls ist diese Konvention eher vom mathematischen Standpunkt aus notwendig. Die zweite Bedingung erlaubt es dem Spieler "mit" der Bank zu spielen, was einer gewissen Fairness entspricht.

Die Bank möchte nun alle Mengen $A \in \mathfrak{A}$ bewerten. Dabei muss sie zunächst folgendes Prinzip beachten:
Keine risikofreien Gewinne: Es darf für die Spieler nicht möglich sein Einsätze zu tätigen, die ihnen mit Sicherheit, d.h. unabhängig vom Ausgang des Zufallsexperiments, einen Gewinn versprechen. Wir nennen eine solche Bewertung *zulässig*.

Lemma 1.1. *Jede zulässige Bewertung muss die Eigenschaft*

$$n_A^{-1} + n_{A^c}^{-1} \geq 1 \tag{1.1}$$

erfüllen.

Beweis. Ein Spieler könnte die Strategie verfolgen Beträge g_A und g_{A^c} auf die Mengen A und A^c so zu setzen, dass die erzielte Auszahlung, $g_A n_A \mathbb{1}_A + g_{A^c} n_{A^c} \mathbb{1}_{A^c}$, unabhängig von Ausgang des Experiments wird. ($\mathbb{1}_A$ bezeichnet hier die *Indikatorfunktion* des Ereignisses "die Kugel fällt in die Menge A" und nimmt den Wert 1 an, falls das Ereignis eintritt, und den Wert 0, falls das Ereignis nicht eintritt). Dazu muss lediglich

$$g_A n_A = g_{A^c} n_{A^c}$$

gelten, also $g_{A^c} = g_A n_A / n_{A^c}$. Es muss sichergestellt sein, dass in diesem Fall die Auszahlung, $g_A n_A$, den Einsatz, $g_A + g_{A^c}$, nicht übersteigt, also

$$g_A n_A \leq g_A + g_{A^c} = g_A \left(1 + n_A / n_{A^c}\right),$$

also

$$1 \leq n_A^{-1} + n_{A^c}^{-1},$$

wie behauptet. □

Insbesondere muss natürlich auch $n_\Omega \leq 1$ gelten, falls $\Omega \in \mathfrak{A}$.

In der Tat wählt die Bank, etwa im Roulette, Bewertungen so, dass die Ungleichung in (1.1) streng ist. Dies ist der Grund, warum Spielbanken meist viel Geld verdienen. Im Gegensatz zu dieser Praxis stehen
Faire Bewertungen: Eine zulässige Bewertung heißt fair (oder maximal), wenn für jede Menge $A \in \mathfrak{A}$ gilt, dass

$$n_A^{-1} + n_{A^c}^{-1} = 1 \tag{1.2}$$

Die Bezeichnung "fair" begründet sich daher, dass hiermit dem Spieler, der auf A^c setzt, die gleiche Chance eingeräumt wird wie der Bank, wenn der Spieler auf A setzt. Die Bezeichnung "maximal" begründet sich daher, dass die Bank nicht systematisch unterboten werden kann, d.h. es ist nicht möglich eine Bewertung, n', zu finden mit der Eigenschaft, dass für alle $A \in \mathfrak{A}$, $n_A \leq n'_A$, ohne dass $n_A = n'_A$, für alle $A \in \mathfrak{A}$.

Satz 1.2. *Eine maximale zulässige Bewertung hat die Eigenschaft, dass, für alle* $A, B \in \mathfrak{A}$,

$$n_{A\cup B}^{-1} = n_A^{-1} + n_B^{-1} - n_{A\cap B}^{-1} \tag{1.3}$$

Insbesondere gilt, wenn $A \cap B = \emptyset$,

$$n_A^{-1} + n_B^{-1} = n_{A\cup B}^{-1} \tag{1.4}$$

Beweis. Wir zeigen zunächst (1.4). Wegen der Fairness der Bewertung ist schon einmal $n_{A\cup B}^{-1} = 1 - n_{(A\cup B)^c}^{-1}$, und der Spieler kann auf $A \cup B$ und $(A \cup B)^c$ so setzen, dass er sicher seinen Einsatz zurückerhält. Nun könnte er versuchen den Einsatz auf $A\cup B$ dadurch zu reproduzieren, dass er getrennt auf A und B die Beträge g_A, g_B setzt, so dass $n_A g_A = n_B g_B$ ist, d.h. es werden $g_A n_A$ ausgezahlt, wenn immer $X \in A \cup B$. Ferner soll dies der Auszahlung entsprechen, die der Spieler im umgekehrten Fall erhält, nämlich $n_{(A\cup B)^c} g_{(A\cup B)^c}$. Es folgt, dass $g_B = g_A \frac{n_A}{n_B}$ und $g_{(A\cup B)^c} = g_A \frac{n_A}{n_{(A\cup B)^c}}$. Damit ist der gesamte Einsatz

$$g_A + g_B + g_{(A\cup B)^c} = g_A \left(1 + \frac{n_A}{n_B} + \frac{n_A}{n_{(A\cup B)^c}}\right).$$

Die sichere Auszahlung, $n_A g_A$, darf diesen Betrag nicht überschreiten, was bedeutet, dass

$$n_A \leq 1 + \frac{n_A}{n_B} + \frac{n_A}{n_{(A\cup B)^c}} = 1 + n_A + \frac{n_A}{n_B} - \frac{n_A}{n_{A\cup B}}, \tag{1.5}$$

oder,

$$\frac{1}{n_{A\cup B}} \leq \frac{1}{n_A} + \frac{1}{n_B}. \tag{1.6}$$

Um zu zeigen, dass auch die umgekehrte Ungleichung gelten muss, müssen wir zeigen, dass es andernfalls möglich ist, statt auf $(A\cup B)^c$, auf A^c und B^c zu setzen um einen Einsatz auf $A \cup B$ abzusichern, und damit einen sicheren Gewinn zu machen. Die nötigen Einsätze sind dabei: $g_{A^c}, g_{B^c} = g_{A^c} \frac{n_{A^c}}{n_{B^c}}$, und $g_{A\cup B} = g_{A^c} \frac{n_{A^c}}{n_{A\cup B}}$. Es sei dem Leser überlassen, nachzuprüfen, dass dies einen sicheren Gewinn abwirft, ausser wenn

$$\frac{1}{n_{A\cup B}} \geq \frac{1}{n_A} + \frac{1}{n_B}. \tag{1.7}$$

Damit ist (1.4) gezeigt.

Falls A und B nicht-leeren Durchschnitt haben, können wir $A \cup B$ in die drei disjunkten Mengen $A\backslash B$, $B\backslash A$, und $A \cap B$ zerlegen, und das vorherige Resultat ausnutzen um (1.3) zu erhalten. □

Wir wollen noch schnell den Umkehrschluss machen und nachprüfen, dass die Eigenschaften von Theorem 1.2 ausreichend sind, so dass kein risikofreier Einsatz mit Gewinnoption existiert. Dazu betrachten wir einen allgemeinen Einsatz mit Wetten g_A auf alle Mengen $A \in \mathfrak{A}$. Wir nehmen der Einfachheit halber an, dass Ω eine endliche Menge ist, und dass alle einpunktigen Mengen, $x \in \Omega$, in $\mathfrak{A}$ enthalten sind. Der Gewinn bzw. Verlust im Fall des Ausgangs $X = x \in \Omega$ ist dann

$$r(x) = \sum_{A\in\mathfrak{A}} g_A n_A \mathbb{1}_{x\in A} - \sum_{A\in\mathfrak{A}} g_A \tag{1.8}$$

Nun ist $\sum_{x\in\Omega} n_x^{-1} = 1$, und daher

$$\begin{aligned}\sum_{x\in\Omega} n_x^{-1} r(x) &= \sum_{x\in\Omega} n_x^{-1} \sum_{A\in\mathfrak{A}} g_A n_A \mathbb{1}_{x\in A} - \sum_{A\in\mathfrak{A}} g_A \\ &= \sum_{A\in\mathfrak{A}} g_A \left(\sum_{x\in A} n_x^{-1} n_A - 1 \right) = 0, \end{aligned} \tag{1.9}$$

weil nach (1.4)

$$\sum_{x\in A} n_x^{-1} n_A = 1. \tag{1.10}$$

Falls also in der Summe über $x \in \Omega$ einer der Terme $n_x^{-1} r(x) > 0$, so muss mindestens ein anderer Term $n_y^{-1} r(y) < 0$ sein. Unser Resultat zeigt, dass aus dem einfachen Prinzip, dass keine "sicheren" Gewinne in einer Spielbank möglich sein dürfen, erhebliche Einschränkungen an maximal mögliche Bewertung der verschiedenen Wetten hergeleitet werden können. Natürlich sind weiterhin noch viele Freiheiten vorhanden, und die Bank ist gut beraten, die genaue Auswahl sorgsam zu treffen. Auf diese Frage kommen wir gleich ausführlicher zu sprechen.

1.3 Wahrscheinlichkeitsmaße.

Wir wollen nun konzeptuell den Begriff der Wahrscheinlichkeit mit dem einer fairen Bewertung verbinden. Es scheint nämlich naheliegend, die Aussage "morgen regnet es mit 90-prozentiger Wahrscheinlichkeit" mit dem Angebot "ich wette zehn zu 1 darauf, dass es morgen regnen wird" gleichzusetzen. Wie sonst soll nämlich eine solche Aussage einen Nutzen haben? Im Roullettespiel heißt dass: Die Aussage,"die Kugel fällt in die Menge A mit Wahrscheinlichkeit $\mathbb{P}(A)$" bedeutet, dass die Bank dem Spieler das $n_A = 1/\mathbb{P}(A)$-fache seines Einsatzes, g_A, auszahlt, wenn dieses Ereignis eintritt. (dass Banken unfaire Bewertungen anwenden wollen wir in diesem Zusammenhang nicht berücksichtigen). Natürlich sind diese so definierten

Wahrscheinlichkeiten im Prinzip *subjektiv*: a priori könnte die Bank jede zulässige Bewertung anwenden.

1.4 Wahrscheinlichkeit und Frequenz

Wir haben bisher das Konzept eines Wahrscheinlichkeitsmaßes mit einem Wettangebot identifiziert. Im Prinzip besteht damit noch überhaupt kein Zusammenhang zwischen einem solchen Maß und dem betrachteten Zufallsexperiment. Vielmehr ist es als eine subjektive Bewertung der Ereignisse durch die Spielbank zu betrachten. In den vorhergehenden Abschnitten haben wir nur gesehen, welche Restriktionen solche Bewertungen erfüllen müssen um überhaupt akzeptabel zu sein, ganz unabhängig vom Ausgang des Zufallsexperiments.

Es stellt sich im Weiteren die Frage, wie irgend jemand, etwa eine Spielbank, zur Wahl einer konkreten Bewertung, also der Wahl einer Wahrscheinlichkeitsverteilung kommt. Dabei will eine Spielbank ja klarerweise Geld zu verdienen. Unter Annahme einer fairen Bewertung ist dies freilich nicht mit Sicherheit möglich; die Bank wird also versuchen die Aufgabe zu lösen, unter allen Bewertungen diejenige zu finden, bei der ihr auf lange Sicht der geringste Verlust droht, unabhängig davon, wie die Spieler agieren (und dann etwa weniger auszuzahlen). Es muss also die Bewertung in irgendeiner Form mit dem Ausgang der Zufallsexperimente in Bezug gesetzt werden. Dies ist die Aufgabe der *Statistik*.

Wir gehen dabei zunächst von der Prämisse wiederholbarer Spiele aus. Wir nehmen an, dass die Bank ihre Bewertung ein für alle mal festlegt. Weiter nehmen wir (der Einfachheit halber) an, dass ein Spieler eine (beliebig) große Anzahl von Spielen zu spielen bereit ist, und dabei stets gleiche Einsätze macht[1].

Wir definieren nun die *Frequenzen* der Ausgänge der Roulettespiele,

$$f_k(A) \equiv \frac{1}{k} \sum_{i=1}^{k} \mathbb{1}_{X_i \in A}, \tag{1.11}$$

für $A \in \mathfrak{A}$, wo X_i der Ausgang des i-ten Spiels ist.

Notation: Wir schreiben ohne Unterscheidung

$$\mathbb{1}_{X \in A} = \mathbb{1}_A(X) = \begin{cases} 1, \text{wenn } X \in A, \\ 0, \text{ wenn } X \notin A. \end{cases} \tag{1.12}$$

Wir bemerken zunächst:

Lemma 1.3. *Die Abbildung $f_k : \mathfrak{A} \to \mathbb{R}_+$ ist ein Wahrscheinlichkeitsmaß.*

Beweis. Der Beweis ist eine Übungsaufgabe. □

[1] Diese Annahme ist nicht notwendig, vereinfacht aber die Diskussion an dieser Stelle. Wir behandeln den allgemeinen Fall später.

Die Wahrscheinlichkeitsverteilung f_k heißt auch die *empirische Verteilung*, das heißt, die tatsächlich beobachtete Verteilung der Ausgänge.

Lemma 1.4. *Es sei angenommen, dass die Frequenzen $f_k(A)$ für alle $A \in \mathfrak{A}$ konvergieren, d.h.*

$$\lim_{k\to\infty} f_k(A) \equiv f(A) \tag{1.13}$$

existiert. Dann ist $f : \mathfrak{A} \to \mathbb{R}_+$ ein Wahrscheinlichkeitsmaß, und die Bewertung $n_A = 1/f(A)$ optimal im Sinne, dass sie die einzige Bewertung ist, so dass, für jede Einsatzstrategie g_A,

$$\lim_{k\to\infty} \frac{1}{k} \sum_{i=1}^{k} \sum_{A} g_A \left(n_A \mathbb{1}_{X_i \in A} - 1\right) = 0 \tag{1.14}$$

während es für jede andere Bewertung eine Strategie g_A gibt, so dass

$$\lim_{k\to\infty} \frac{1}{k} \sum_{i=1}^{k} \sum_{A} g_A \left(n_A \mathbb{1}_{X_i \in A} - 1\right) > 0 \tag{1.15}$$

Beweis. Übung! □

Die Idee ist hier natürlich, dass man eine große Anzahl, sagen wir k, Experimente durchführt und sich mit f_k eine gute Approximation des Limes f verschafft, bevor man den Spielbetrieb aufnimmt. f_k heißt in der Statistik ein *Schätzer* für die tatsächlichen Wahrscheinlichkeiten f.

Anmerkung. Mathematisch steht obiges Lemma auf sehr wackeligen Beinen. f_k ist ja eine Funktion der Ausgänge der Spiele 1 bis k, also von $X_1, \ldots, X_k$. Wir könnten das Lemma mit Sinn erfüllen, wenn wir etwa fordern, dass der Limes für alle mögliche Spielausgänge existiert und unabhängig von diesem ist. Man kann sich aber leicht davon überzeugen, dass dies praktisch nie der Fall sein wird (man betrachte etwa den trivialen Fall $X_1 = X_2 = X_3 = \cdots = \omega$). Wir werden später sehen, dass es sinnvolle Konvergenzbegriffe für Folgen zufälliger Grössen gibt (insbes. die *fast sichere Konvergenz*), die es erlauben, sinnvolle und mathematisch rigorose Versionen dieses Lemmas zu formulieren.

Die obigen Beobachtungen bilden die Grundlage der *frequentistischen* Betrachtung von Wahrscheinlichkeiten. Ihr liegt immer die Annahme zugrunde, ein zufälliges Experiment könne beliebig oft wiederholt werden. Wenn dann die so gemessenen Frequenzen konvergieren, stellen sie ein Maß für die Wahrscheinlichkeitsverteilung des Ausgangs dar, was nach obigem Lemma offenbar sinnvoll ist. Viele Statistiker lassen nur diese Interpretation von Wahrscheinlichkeit gelten, womit aber nur in speziellen Situationen tatsächlich von Wahrscheinlichkeit gesprochen werden kann. Das Glückspiel ist offenbar ein Beispiel dafür.

Die frequentistische Interpretation erlaubt der Bank ihre Bewertung an Erfahrungswerte anzupassen. So wird sich beim Roulette herausstellen, dass nach vielen

Spielen, jede Zahl mit einer Frequenz nahe $1/37$ herauskommt. Dabei mag es auch Roulettetische geben, bei denen andere Werte beobachtet werden. Den Spielern ist diese Information in der Regel nicht zugänglich. Sie vertrauen darauf, dass dies dennoch so ist. Natürlich kann die Bank hier manipuliert haben. Eigentlich hat sie daran aber kein Interesse, da ihre Bewertung ja für diese Frequenzen optimiert ist. Gäbe es Abweichungen, und ein Spieler würde abweichende Frequenzen beobachten, könnte er seinen Einsatz dem anpassen, und so einen Vorteil erlangen.

1.5 Wahrscheinlichkeit und Information

Die frequentistische Interpretation von Wahrscheinlichkeit ist in vielen Fällen, in denen dennoch gerne von "Wahrscheinlichkeit" geredet wird, nicht sinnvoll, da es keine Wiederholung des Experiments unter gleichen Bedingungen geben kann oder wird. Das betrifft etwa die Aussage des Wetterberichts "die Wahrscheinlichkeit, dass es morgen regnet ist 30%". Am nächsten Tag wird es entweder regnen oder nicht regnen, und die Interpretation, dass es in 30 Prozent der Fälle morgen regnet, ist sinnlos. Allenfalls kann man sagen, dass Wettervorhersagen im allgemeinen mit einer gewissen Wahrscheinlichkeit richtig sind, was hier aber nicht gemeint ist.

dasselbe Problem tritt bei manchen Formen des Glückspiels ein, insbesondere etwa bei Pferdewetten. Da auch hier kein Rennen wie ein anderes ist, stellt sich für die Bank hier die Frage nach der Bewertung der Ergebnisses anders als im Roulette. Tatsächlich wird hier die Bank auch keine festen "a priori" Bewertungen verwenden, sondern diese werden von Rennen zu Rennen festgesetzt, und zwar *nachdem* die Spieler ihre Wetteinsätze getätigt haben. Dies erlaubt der Bank eine faire Bewertung zu finden, die wiederum für sie völlig risikofrei ist (und mittels eines Abschlags an eine faire Bewertung, sogar risikofrei Geld zu verdienen). Betrachten wir dies im einfachsten Fall, in dem jeweils nur auf den Sieg eines Pferdes der Betrag g_i gesetzt werden kann. Dann stellt $\mathbb{P}(i) \equiv g_i / \sum_{j\in\Omega} g_j$ eine Wahrscheinlichkeitsverteilung auf Ω dar, die die Erwartungen der Spieler über den Ausgang des Rennens widerspiegelt. Wenn die Bank nun die Auszahlungen so wählt, dass beim Sieg von i eine Quote $n_i = 1/\mathbb{P}(i)$ auf den Einsatz g_i gezahlt wird, so zahlt sie unabhängig vom Ausgang des Rennens gerade den gesamten Einsatz wieder aus.

1.6 Wahrscheinlichkeit und Versicherung.

Bisher hatten wir Wahrscheinlichkeit stark in einem "spielerischen" Kontext gesehen. Oft sind wir aber unvorhersehbaren Ereignissen ausgesetzt und wollen unser handeln an Wahrscheinlichkeitsbewertungen solcher Ereignisse ausrichten. Dabei handelt es sich in aller Regel, zumindest aus der Sicht der Betroffenen, nicht um reproduzierbare Ereignisse. Machen wir das an einem einfachen Beispiel klar.

Ein Landwirt wird im Falle einer längeren Dürreperiode eine Verlust von $X = 10000\$$ hinnehmen müssen. Er möchte naturgemäss das Risiko, dem er ausgesetzt ist, bewerten. Dazu würde er gerne Aussagen über die Wahrscheinlichkeit des Ereignisses "Dürre" heranziehen. Angenommen, er bekommt eine Einschätzung dieser Wahrscheinlichkeit als $p = 0.001$. Wenn diese Aussage mit einem Wettangebot gekoppelt ist, kann er nun folgendes machen: Er setzt einen Betrag Y auf das Ereignis "Dürre" derart, dass er im Fall des Eintritts aus der Wette gerade seinen Verlust $X = 10000\$$ ausgleicht. Dazu muss er nur $10\$$ einsetzen (da $(1/p) * Y = 1000 * 10 = 10000 = X$). Er wird nun in jedem Fall, d.h. egal ob die Dürre kommt oder nicht jeweils nur seinen Einsatz von $10\$ = p * X$ verlieren. Das Dürrerisiko ist damit mit $10\$$ vernünftig bewertet. Für den Landwirt ist nunmehr gleich, was mit der Wahrscheinlichkeit p gemeint ist: worauf es ankommt, ist ein damit gekoppeltes Wettangebot, dass ihm erlaubt seinen Schaden unabhängig von der Dürre zu machen, d.h. sein Risiko gegen eine "Versicherungsprämie" zu eliminieren.

Fragt sich, warum der Versicherer ein solches Wettangebot machen kann. Idealerweise könnte der Versicherer sein Angebot auf einer frequentistischen Wahrscheinlichkeitsinterpretation aufbauen: er macht sehr viele solcher Geschäfte die vergleichbar sind und er mag Erfahrungen über die Häufigkeit solcher Ereignisse haben.

Anmerkung. Damit für den Versicherten die Risikobewertung durch eine Versicherung Sinn macht, muss von der Solvenz des Versicherers ausgegangen werden. Bei enorm großen Schadenssummen ist letztere durchaus zweifelhaft. Aus pragmatischer Sicht ist dann eine wahrscheinlichkeitsbasierte Risikobewertung fragwürdig. Weiter ist die Sinnhaftigkeit einer solchen Risikobewertung auch nur dann gegeben, wenn eine entsprechender Versicherungswette auch abgeschlossen wird. Die gegenwärtige Finanzkrise ist teilweise auch dadurch begründet, dass Risikobewertung auf der Basis von Wahrscheinlichkeiten vorgenommen wurden, die entsprechenden risikobegrenzenden Wetten aber nie abgeschlossen wurden.

Kapitel 2
Elemente der Maßtheorie

On voit, par cet Essaie, que la théorie des probabilités n'est, au fond, que le bon sens reduit au calcul; elle fait apprécier avec exactitude ce que les esprits justes sentent par une sorte d'instinct, sans qu'ils puissent souvent s'en rendre compte[a].
Pierre Simon de Laplace, Théorie Analytique des Probabilités

[a] Man sieht durch diese Abhandlung, dass die Wahrscheinlichkeitstheorie im Grunde nur gesunder Menschverstand reduziert auf Berechnung ist; sie lässt mit Genauigkeit das erkennen, was verständige Geister durch eine Art Instinkt erfühlen, oft ohne dass sie dafür Rechenschaft ablegen könnten.



Wir haben im ersten Kapitel gesehen, dass unter einer vernünftig erscheinenden Definition des Wahrscheinlichkeitsbegriffes, in natürlicher Weise der Begriff eines Wahrscheinlichkeitsmaßes auftaucht. Wir wollen nun einen rigorosen und sehr allgemeinen mathematischen Rahmen einführen, auf dem die Wahrscheinlichkeitstheorie betrieben werden kann.

2.1 Messräume und Maße

Im Folgenden bezeichnet Ω stets eine beliebige *nicht leere* Menge. Dieser Fakt wird nicht mehr wiederholt werden. Wir stellen uns Ω als die Menge aller möglichen Ausgänge eines Zufallsexperiments vor.

2.1.1 σ-Algebren

Definition 2.1 (Mengenalgebra). Sei Ω eine Menge und sei $\mathfrak{A}$ eine Menge von Teilmengen ("Mengensystem"). von Ω. Man stattet $\mathfrak{A}$ mit den Operationen $\cup$ ("Vereinigung") und definiert als *Komplement*, A^c, die kleinste Teilmenge von Ω, so dass $A \cup A^c = \Omega$. Falls $\mathfrak{A}$ die leere Menge $\emptyset$ enthält, und mit $A, B \in \mathfrak{A}$ auch $A \cup B \in \mathfrak{A}$ und $A^c \in \mathfrak{A}$, so heißt $\mathfrak{A}$ eine (Mengen)-*Algebra*.

Aus Vereinigung und Komplementbildung kann man auch den Durchschnitt von Mengen konstruieren als $A \cap B = (A^c \cup B^c)^c$. Somit ist eine Mengenalgebra auch unter dem Durchschnitt abgeschlossen. Klarerweise entspricht $\cup$ der Addition und $\cap$ der Multiplikation. Die Menge $\emptyset$ ist das neutrale Element der Addition und Ω das neutrale Element der Multiplikation.

Anmerkung. Im Sinne der Aussagenlogik entsprechen die Mengenoperationen der **Negation**, dem logischen **oder** und dem logischen **und**. Oft werden in der Wahrscheinlichkeitstheorie die Mengen A mit der Aussage "ein Zufallsexperiment hat einen Ausgang in der Menge A" identifiziert, und die Mengenoperationen daher mit den logischen Operationen bezeichnet.

Mengenalgebren scheinen zunächst der richtige Spielplatz für die Wahrscheinlichkeitstheorie. Für den Fall endlicher Mengen Ω ist das auch so. Wir werden aber sehen, dass wir im Allgemeinen um interessante Dinge machen zu können, noch eine zusätzliche Forderung stellen müssen.

Definition 2.2 (σ-Algebra). Sei Ω eine beliebige (nicht leere) Menge, und sei $\mathfrak{F}$ eine Menge von Teilmengen von Ω mit der Eigenschaft, dass

(i) $\Omega \in \mathfrak{F}$,
(ii) Falls $A \in \mathfrak{F}$, dann ist auch $A^c \equiv \Omega \backslash A \in \mathfrak{F}$.
(iii) Falls $A_n \in \mathfrak{F}$, für alle $n \in \mathbb{N}$, dann ist auch $\cup_{n\in\mathbb{N}} A_n \in \mathfrak{F}$.

Dann heißt $\mathfrak{F}$ eine σ-Algebra, und das Paar $(\Omega, \mathfrak{F})$ heißt ein *Messraum*.

Anmerkung. Aus (i) und (ii) folgt sogleich, dass auch $\emptyset \in \mathfrak{F}$. Die Forderung (iii) impliziert natürlich auch, dass endliche Vereinigungen Elementen von $\mathfrak{F}$ in $\mathfrak{F}$ enthalten sind. Formal nimmt man dazu einfach eine Sammlung $(A_n)_{n\in\mathbb{N}}$ von der nur endlich viele Elemente nicht gleich der leeren Menge sind.

Die Forderung (iii) wird es uns erlauben, Wahrscheinlichkeitsaussagen über Grenzwerte zu machen. Dies bringt gegenüber der elementaren kombinatorischen Wahrscheinlichkeit ganz neue und interessante Fragestellungen.

Üblicherweise geht man bei der Beschreibung einer σ-Algebra so vor, dass man eine gewisse Menge von Teilmengen, die man in der σ-Algebra haben möchte vorgibt, und diese dann zu einer σ-Algebra ergänzt, indem man alle gemäß der Definition nötigen Mengen dazufügt.

Definition 2.3. Sei $\mathcal{E}$ eine Menge von Teilmengen von Ω. Die kleinste σ-Algebra, die $\mathcal{E}$ enthält, heißt die von $\mathcal{E}$ *erzeugte* σ-Algebra.

Die Existenz einer kleinsten σ-Algebra folgt aus der Tatsache, dass der Durchschnitt von σ-Algebren, die ein Mengensystem $\mathcal{E}$ enthalten, wiederum eine solche σ-Algebra ist, wie man sehr leicht nachprüfen kann. Damit kann man die kleinste σ-Algebra als den Durchschnitt aller solcher σ-Algebren charakterisieren.

Wir bezeichnen diese oft mit $\sigma(\mathcal{E})$. Für eine gegebene σ-Algebra, $\mathfrak{F}$, heißt eine Menge von Mengen, $\mathcal{E}$, *Erzeuger* (oder *Generator*) von $\mathfrak{F}$, wenn $\sigma(\mathcal{E}) = \mathfrak{F}$.

Wenn Ω *endlich* ist, ist es recht einfach, sowohl alle σ-Algebren (die dann auch einfach Algebren sind) zu beschreiben anzugeben. Der Grund ist folgendes einfaches Lemma.

Lemma 2.4. *Sei $(\Omega, \mathfrak{F})$ ein Messraum und Ω endlich. Dann enthält $\mathfrak{F}$ eine eindeutige minimale (kleinstmögliche Zahl von Elementen) Partition, $\Pi = (\pi_1, \ldots, \pi_n)$, von Ω mit folgenden Eigenschaften:*

(i) $\bigcup_{i=1}^{n} \pi_i = \Omega$*;*
(ii) Für alle $B \in \mathfrak{F}$ *und alle* $k = 1, \ldots, n$*, gilt* $B \cap \pi_k \in \{\emptyset, \pi_k\}$*. Insbesondere gilt für alle* $i \neq j$*, dass* $\pi_i \cap \pi_j = \emptyset$*.*

Insbesondere ist $\sigma(\Pi) = \mathfrak{F}$*.*

Beweis. Übung! □

Im allgemeinen ist es viel schwieriger eine σ-Algebra zu beschreiben. Dies ist schon für $\Omega = \mathbb{R}$ der Fall. Wie wir aber sehen werden, ist es auch nicht wirklich notwendig, diese Mengen *explizit* angeben zu können.

2.1.2 Wahrscheinlichkeitsmaße

σ-Algebren, bzw. Messräume, sind die richtigen Objekte, um auf ihnen Maße zu definieren. Auch hier gibt es im Allgemeinen eine Komplikation gegenüber dem Fall endlicher Mengen.

Definition 2.5. Sei $(\Omega, \mathfrak{F})$ ein Messraum und sei $\mathbb{P} : \mathfrak{F} \to [0, 1]$ eine Abbildung von $\mathfrak{F}$ in die positiven reellen Zahlen mit folgenden Eigenschaften:

(i) $\mathbb{P}(\Omega) = 1$.
(ii)$\mathbb{P}(\emptyset) = 0$.
(iii) Falls die Mengen $A_i \in \mathfrak{F}$, $i \in \mathbb{N}$, paarweise disjunkt sind, dann gilt

$$\mathbb{P}\Big(\bigcup_{i=1}^{\infty} A_i\Big) = \sum_{i=1}^{\infty} \mathbb{P}(A_i). \tag{2.1}$$

Dann heißt $\mathbb{P}$ ein *Wahrscheinlichkeitsmaß* auf dem Messraum $(\Omega, \mathfrak{F})$, und das Tripel $(\Omega, \mathfrak{F}, \mathbb{P})$ wird ein *Wahrscheinlichkeitsraum* genannt.

Anmerkung. In der Wahrscheinlichkeitstheorie benutzen wir stets die Konvention $0 \times \infty = 0$, bzw. $\sum_{n=k}^{\infty} 0 = 0$. Zeige, dass damit aus Punkt (iii) notwendig $\mathbb{P}(\emptyset) = 0$ folgt, und dass andererseits diese Konvention nötig ist, damit (2.1) mit $A_i = \emptyset$ für alle i gelten kann.

Anmerkung. Die Punkte (i) und (ii) aus Definition 2.2 sowie (i) und (ii) aus der Definition 2.5 sind aus den Betrachtungen in einleitenden Kapitel über die Bedeutung von Wahrscheinlichkeit sehr natürlich wenn nicht zwingend. Die Punkte (iii) wären nur für endliche Vereinigungen zwingend, die Forderung dass die σ-Algebra auch unendliche Vereinigungen enthält ist aber mathematisch bequem, um im Fall unendlicher Mengen Ω nicht an unendlichen Iterationen zu scheitern. Ebenso ist Punkt (iii) in Definition 2.5 in diesem Fall praktisch. Eigenschaft (iii) nennt man σ-Additivität. Die in der Definition 2.5 aufgestellten Bedingungen heißen *Kolmogorov's Axiome*. Sie bilden die Grundlage der abstrakten Theorie der Wahrscheinlichkeitsmaße.

Terminologie. Man verwendet gemeinhin die Bezeichnungen *Wahrscheinlichkeitsmaß, Wahrscheinlichkeitsverteilung* oder auch einfach *Verteilung* synonym. Die ebenfalls synonyme Bezeichnung *Wahrscheinlichkeitsgesetz* ist im Deutschen eher veraltet, wird aber sowohl im Englischen *"probability law", "law"*, wie auch im Französischen *"loi de probabilités", "loi"*, noch gängig gebraucht.

Für unseren späteren Gebrauch definieren wir gleich noch einige Verallgemeinerungen des Maßkonzepts.

Definition 2.6. Eine Abbildung $\mu : \mathfrak{F} \to [0, +\infty]$, die alle Eigenschaften der Definition 2.5 erfüllt, außer $\mu(\Omega) = 1$ heißt ein Maß auf $(\Omega, \mathfrak{F})$. Falls $\mu(\Omega) < \infty$ heißt es ein endliches Maß. Ein Maß heißt σ-*endlich*, falls eine Folge $(\Omega_n)_{n\in\mathbb{N}}$ existiert, so dass $\cup_{n\in\mathbb{N}}\Omega_n = \Omega$ und für alle $n \in \mathbb{N}$ $\Omega_n \in \mathfrak{F}$ und $\mu(\Omega_n) < \infty$.

2.1.3 Die Borel'sche σ-Algebra.

Es sei $\Omega = \mathbb{R}$. Hier gibt es eine kanonische σ-Algebra, die sogenannte *Borel'schen* σ-Algebra, $\mathfrak{B} \equiv \mathfrak{B}(\mathbb{R})$. Wir definieren sie auf dem shon beschriebenen Weg als kleinste σ-Algebra, die eine vorgeschriebene Menge von Teilmengen hält.

Definition 2.7. Die kleinste σ-Algebra über den reellen Zahlen, die alle offenen Teilmengen von $\mathbb{R}$ enthält, heißt die Borel-σ-Algebra über $\mathbb{R}$ und wird mit $\mathfrak{B}(\mathbb{R})$ bezeichnet. Entsprechend bezeichnet, für $I \subset \mathbb{R}$, $\mathfrak{B}(I)$ die kleinste σ-Algebra über I, die alle offenen Teilmengen von I enthält.

Anmerkung. Beachte, dass wir hier stets die reellen Zahlen mit der Euklidischen Topologie versehen verstehen.

Nach Definition einer σ-Algebra enthält $\mathfrak{B}$ dann alle Mengen, die durch abzählbare Vereinigung und Bildung von Komplementen, sowie die Grenzwertbildung von solchen Operationen erhalten werden können. Die Borel'sche σ-Algebra ist nun genau diejenige σ-Algebra, die eben auch gerade nur diese Mengen enthält, d.h. sie ist *die kleinste σ-Algebra, die alle offenen Intervalle* enthält.

Die in $\mathfrak{B}$ enthaltenen Teilmengen der reellen Zahlen heißen *Borel-Mengen.*

Die Borel-Mengen stellen eine äußerst reiche Klasse von Mengen dar. Insbesondere sind die folgenden Mengen allesamt Borel'sch:

(i) alle offenen Mengen;
(ii) alle abgeschlossenen Mengen.

Dies ist aber bei Weitem nicht alles. Eine explizite Angabe aller Borel-Mengen ist nicht möglich.

Anmerkung. Die Borel'sche σ Algebra ist strikt kleiner als die Potenzmenge von $\mathbb{R}$, d.h. es gibt Untermengen von $\mathbb{R}$, die nicht in $\mathfrak{B}$ enthalten sind. Solche Mengen sind in der Regel durch implizite Beschreibungen definiert. Die Borel'sche σ-Algebra ist für unsere Zwecke reich genug. Insbesondere kann auf ihr in sinnvoller Weise ein uniformes Maß, dass Lebesgue-Maß, definiert werden.

Beispiel einer nicht-Borel'schen Menge.

Wir definieren zunächst eine Äquivalenzrelation $\sim$ auf den reellen Zahlen in $[0,1]$ wie folgt: $x \sim y$ genau dann, wenn sie sich um eine rationale Zahl unterscheiden, also $x - y \in \mathbb{Q}$. Damit wird $[0,1]$ (und als Folge auch $\mathbb{R}$) in Äquivalenzklassen zerlegt. Wähle nun aus jeder Äquivalenzklasse ein Element aus (dies ist möglich unter Berufung auf das Auswahlaxiom) und bilde die Vereinigungsmenge, A, dieser ausgewählten Elemente. Dann gilt offenbar dass die reellen Zahlen die disjunkte Vereinigung der Mengen $A + q$, mit $q \in \mathbb{Q}$ sind (hier ist $A + q = \cup_{y\in A}\{y + q\}$. Die Menge A ist nicht Borel'sch[1]. Das interessante an ihr ist, dass es unmöglich ist, ihr in konsistenter Weise eine Masse unter der Gleichverteilung μ zuzuordnen. Es muss dann nämlich gelten, dass $\mu(A) = \mu(A + q)$ für alle $q \in \mathbb{R}$; wenn nun aber $\mu(A) > 0$, dann gilt für jedes Intervall $I = [a, b]$

$$\sum_{q\in\mathbb{Q}\cap I} \mu(A + q) = \infty. \tag{2.2}$$

Andererseits ist

$$\cup_{q\in\mathbb{Q}\cap I} \{A + q\} \subset I' = [a, b + 1] \tag{2.3}$$

und somit

$$\infty = \sum_{q\in\mathbb{Q}\cap I} \mu(A + q) = \mu\Big(\bigcup_{q\in\mathbb{Q}\cap I} \{A + q\}\Big) \leq \mu(I') \tag{2.4}$$

gelten muss. Dann müsste also jedes Interval unendliche Masse haben.

Also bliebe nur die Option $\mu(A) = 0$; dann aber wäre

$$\mu(\mathbb{R}) = \sum_{q\in\mathbb{Q}} \mu(A + q) = 0, \tag{2.5}$$

was offenbar auch nicht in unserem Sinn sein kann. Daher ist es besser, den Versuch dieser Menge eine Masse zu geben, zu unterlassen. Da wir später zeigen werden, dass es ein Maß auf $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$ gibt, dass jedem Intervall seine Länge zuordnet (das Lebesgue Maß), folgt, dass die Menge A nicht in $\mathfrak{B}(\mathbb{R})$ liegt.

Die Borel'sche σ-Algebra enthält ansonsten alle vernünftigen Mengen. Insbesondere enthält sie alle Punkte, $x \in \mathbb{R}$, alle kompakten Intervalle, alle halb-offenen Intervalle, sowie alle Halbachsen. Auch gibt es viele andere Charakterisierungen. Insbesondere die folgende ist für uns interessant (wegen Theorem 2.17).

Lemma 2.8. *Die Borel'sche σ-Algebra über $\mathbb{R}$ ist die kleinste σ-Algebra, die alle Mengen der Form*

$$H_x \equiv \{y \in \mathbb{R} : y \leq x\}, \quad x \in \mathbb{Q} \tag{2.6}$$

enthält.

[1] Wir beweisen dies im Moment nicht. Da wir aber später zeigen werden, dass es eine uniformes Maß auf der Borel-σ-Algebra gibt, folgt dies aus der nachfolgenden Beobachtung.

Beweis. Wir bezeichnen die Menge aller $H_x, x \in \mathbb{Q}$ mit $\mathcal{H}$. Wir müssen nur zeigen, dass die von $\mathcal{H}$ erzeugte σ-Algebra $\sigma(\mathcal{H})$ alle offenen Teilmengen von $\mathbb{R}$ enthält. Für rationale $y < x$ ist $H_y^c \cap H_x = (y, x]$ in $\sigma(\mathcal{H})$. Weiter ist $\cap_{n\in\mathbb{N}}(y - 1/n, x] = [y, x]$ ebenso in $\sigma(\mathcal{H})$. Ebenso ist $\cup_{n\in\mathbb{N}}(y, x - 1/n] = (y, x)$. Also sind aller rationalen offenen und geschlossenen Intervalle in $\sigma(\mathcal{H})$. Schliesslich ist eine offenen Menge O dadurch charakterisiert, dass jeder Punkt $x \in O$ eine offene Umgebung mit rationalen Endpunkten besitzt, die in O liegt. Daher können wir O mit solchen Umgebungen ausschöpfen: $O = \bigcup_{p<q\in\mathbb{Q}:(p,q)\subset O}(p, q)$. Dies ist eine abzählbare Vereinigung von Intervallen, die in $\sigma(\mathcal{H})$ liegen, und somit ist jede offene Menge $O \in \sigma(\mathcal{H})$. Damit ist $\sigma(\mathcal{H}) \subseteq \mathfrak{B}(\mathcal{R})$. Andererseits ist $\mathcal{H} \subset \mathfrak{B}(\mathbb{R})$, und also auch $\mathfrak{B}(\mathbb{R}) \subseteq \sigma(\mathcal{H})$. Damit ist das Lemma bewiesen. □

Anmerkung. Das Konzept der Borel'schen σ-Algebra benötigt nur die topologische Struktur von $\mathbb{R}$. Es lässt sich daher ohne weiteres auf den Fall, dass Ω ein topologischer Raum ist übertragen.

2.1.4 Maßbestimmende Mengen und Satz von Carathéodory.

Für unsere Zwecke ist das wichtigste Problem der Maßtheorie das folgende: Wie können wir in minimaler Weise ein Maß charakterisieren? Im Fall endlicher Mengen ist das einfach; schlimmstenfalls hätten wir die Werte auf allen (endlich vielen!) Elementen der σ-Algebra angegeben, aber wie sich herausstellt genügt wegen der Additivität bereits die Kenntnis der Werte auf einer viel kleineren Menge, etwa auf allen Elementen von Ω. Genauer haben wir folgenden Satz (siehe Lemma 2.4).

Proposition 2.9. *Sei Ω eine endliche Menge und $(\Omega, \mathfrak{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum. Sie $\Pi = (\pi_1, \ldots, \pi_n)$ einen Partition von Ω, die $\mathfrak{F}$ erzeugt Dann ist das Maß $\mathbb{P}$ eindeutig durch die Werte $p_i = \mathbb{P}(\pi_i)$, $i = 1, \ldots, n$, festgelegt. Umgekehrt gibt es für jede Sammlung von Werten $p_i \geq 0$, $i = 1, \ldots, n$, mit $\sum_{i=1}^n p_i = 1$ ein Wahrscheinlichkeitsmaß auf $(\Omega, \mathfrak{F})$, so dass $p_i = \mathbb{P}(\pi_i)$.*

Beweis. Übung! □

Im Fall unendlicher oder gar überabzählbarer Mengen Ω ist das Problem dringlicher: die gesamte σ-Algebra ist oft viel zu groß und unhandlich, als das wir die Maße aller ihrer Mengen angeben wollten. Wir machen es also wie die Mathematiker es immer machen: Wir arbeiten einmal, und zeigen eine kleinere Menge von Mengen auf, die ausreicht, dass Maß auf allen Elementen der σ-Algebra zu bestimmen. Diese einmalige Anstrengung wird uns später dann das Leben enorm erleichtern.

Wir definieren dazu als erstes die Begriffe von *durchschnitts-stabilen* Mengensystemen und *Dynkin-Systemen*.

Definition 2.10. Sei Ω eine Menge, und $\mathfrak{C}$ eine nicht-leere Teilmenge der Potenzmenge von Ω.

(i) $\mathfrak{C}$ heißt *durchschnittsstabil*, falls für jedes $A, B \in \mathfrak{C}$ auch $A \cap B \in \mathfrak{C}$ gilt.

(ii) $\mathfrak{C}$ heißt ein Dynkin-System, genau dann, wenn

a) $\Omega \in \mathfrak{C}$.
b) wenn $A, B \in \mathfrak{C}$ und $A \subset B$, dann ist auch $B \setminus A \in \mathfrak{C}$;
c) falls $A_1, A_2, \cdots \in \mathfrak{C}$ paarweise disjunkt sind, dann gilt $\cup_{n\in\mathbb{N}} A_n \in \mathfrak{C}$.

Anmerkung. In der englischsprachigen Literatur nennt man ein durchschnittsstabiles Mengensystem ein *π-system* und ein Dynkin-System ein *λ-system*, entsprechend der ursprünglichen Notation von Dynkin.

Dynkin-Systeme erfüllen weniger Bedingungen als σ-Algebren. Andererseits fehlt Dynkin-Systemen zur σ-Algebra nur die Durchschnittsstabilität.

Lemma 2.11. *Jede σ-Algebra ist ein Dynkin-System. Jedes durchschnittsstabile Dynkin-System ist eine σ-Algebra.*

Beweis. Da σ-Algebren sogar allgemeine Vereinigungen enthalten, sind sie insbesondere auch Dynkin-Systeme. Zu beweisen ist die zweite Aussage des Lemmas. Sei $\mathcal{D}$ ein Dynkin-System für das gilt, dass aus $A, B \in \mathcal{D}$ auch $A \cap B \in \mathcal{D}$. Wir wollen zeigen, dass dann $\mathcal{D}$ eine σ-Algebra ist. Dazu zeigen wir zunächst, dass $\mathcal{D}$ unter endlichen Vereinigungen abgeschlossen ist. Wenn $A_1, A_2 \in \mathcal{D}$ sind, so is auch $A_1 \cap A_2 \in \mathcal{D}$. Ferner ist $B \equiv A_2 \setminus (A_1 \cap A_2) \in \mathcal{D}$. Dann sind aber A_1 und B disjunkt und $A_1 \cup B = A_1 \cup A_2$. Also ist $A_1 \cup A_2 \in \mathcal{D}$. Durch Iteration sind alle endlichen Vereinigungen in $\mathcal{D}$.

Nachdem wir wissen, dass endliche Vereinigungen in $\mathcal{D}$ liegen, können wir nun jede abzählbare Vereinigung, $\bigcup_{n\in\mathbb{N}} A_n$, in eine abzählbare Vereinigung, $\bigcup_{n\in\mathbb{N}} B_n$, paarweise disjunkter Mengen verwandeln. Zunächst können wir annehmen, dass die Mengen A_n aufsteigend sind, ansonsten setzen wir $\tilde{A}_n = \cup_{k=1}^{n} A_n$ und benutzen, dass $\bigcup A_n = \bigcup \tilde{A}_n$. Wie wissen schon, dass $\tilde{A}_k$ in $\mathcal{D}$. Dann sind die Mengen $B_n \equiv \tilde{A}_n \setminus \tilde{A}_{n-1}$, disjunkt und in $\mathcal{D}$. Andererseits ist offenbar $\bigcup \tilde{A}_n = \bigcup B_n$, wegen der Dynkin-Eigenschaft ist letztere Vereinigung aber in $\mathcal{D}$ enthalten. Damit ist $\mathcal{D}$ eine σ-Algebra. □

Ferner gilt der Satz von Dynkin:

Satz 2.12. *Wenn $\mathfrak{C}$ ein durchschnittsstabiles Mengensystem ist, dann ist das kleinste Dynkin-System, das $\mathfrak{C}$ enthält, gerade die von $\mathfrak{C}$ erzeugte σ-Algebra.*

Beweis. Hier gehen wir etwas indirekt vor. Für ein Mengensystem $\mathcal{S}$ schreiben wir $\mathcal{D}(\mathcal{S})$ für das kleinste Dynkin-System, dass $\mathcal{S}$ enthält. Für $A \in \mathcal{D}(\mathfrak{C})$ definieren wir die Menge

$$D_A \equiv \{B \in \mathcal{D}(\mathfrak{C}) : A \cap B \in \mathcal{D}(\mathfrak{C})\} \subset \mathcal{D}(\mathfrak{C}). \tag{2.7}$$

D_A ist ein Dynkin-System, weil:

(1)$A \cap \Omega = A \in \mathcal{D}(\mathfrak{C})$, also ist $\Omega \in D_A$;
(2)Wenn $B_1 \subset B_2$, und $A \cap B_i \in \mathcal{D}(\mathfrak{C})$, dann ist $(B_2 \setminus B_1) \cap A = (B_2 \cap A) \setminus (B_1 \cap A)$ und letztere Menge ist in $\mathcal{D}(\mathfrak{C})$ weil $\mathcal{D}(\mathfrak{C})$ ein Dynkin-System ist; also ist $B_2 \setminus B_1 \in D_A$;

(3)Wenn $B_n, n \in \mathbb{N}$ paarweise disjunkt sind, und $B_n \cap A \in \mathcal{D}(\mathfrak{C})$, dann ist $(\cup_{n\in\mathbb{N}} B_n) \cap A = \cup_{n\in\mathbb{N}}(B_n \cap A)$; letzteres ist eine Vereinigung paarweise disjunkter Mengen $(B_n \cap A)$ aus $\mathcal{D}(\mathfrak{C})$, also auch in $\mathcal{D}(\mathfrak{C})$ und somit ist $\cup_{n\in\mathbb{N}} B_n$ in D_A.

Damit ist für jedes $A \in \mathcal{D}(\mathfrak{C})$ das Mengensystem D_A ein Dynkin-System.

Da $\mathfrak{C}$ durchschnittsstabil ist, gilt für jedes $A, B \in \mathfrak{C}$, $A \cap B \in \mathfrak{C} \subset \mathcal{D}(\mathfrak{C})$. also ist $\mathfrak{C} \subset D_A$ und da D_A Dykin System ist, $\mathcal{D}(\mathfrak{C}) \subseteq D_A$. Also ist also für alle $A \in \mathfrak{C}$, $D_A = \mathcal{D}(\mathfrak{C})$. Wir müssen noch zeigen, dass D_A durchschnittsstabil ist. Wir wissen bereits, dass für alle $A \in \mathfrak{C}$ und alle $B \in \mathcal{D}(\mathfrak{C})$, $A \cap B \in \mathcal{D}(\mathfrak{C})$. Andererseits gilt für jedes $B \in \mathcal{D}(\mathfrak{C})$, dass jedes $A \in \mathfrak{C}$ in D_B liegt. Also ist $\mathfrak{C} \subset D_B$ und damit $\mathcal{D}(\mathfrak{C}) \subseteq D_B$, mithin $D_B = \mathcal{D}(\mathfrak{C})$. Das heisst aber, dass für alle $B \in \mathcal{D}(\mathfrak{C})$ und alle $A \in \mathcal{D}(\mathfrak{C})$, $A \cap B \in \mathcal{D}(\mathfrak{C})$. Also ist $\mathcal{D}(\mathfrak{C})$ nach Lemma 2.11, eine σ-Algebra, die $\mathfrak{C}$ enthält und somit $\sigma(\mathfrak{C}) \subset \mathcal{D}(\mathfrak{C})$. Da außerdem $\sigma(\mathfrak{C})$ ein Dynkin-System ist, dass $\mathfrak{C}$ enthält, gilt auch, wegen der Minimalität, dass $\mathcal{D}(\mathfrak{C}) \subset \sigma(\mathfrak{C})$, mithin $\mathcal{D}(\mathfrak{C}) = \sigma(\mathfrak{C})$. □

Der Unterschied einer Algebra zur σ-Algebra ist, dass keine abzählbaren Vereinigungen in $\mathfrak{A}$ enthalten sein müssen. Daher ist die durch ein Mengensystem erzeugte Algebra (die kleinste Algebra, die dieses Mengensystem enthält) viel kleiner, als die davon erzeugte σ-Algebra. (Insbesondere ist die σ-Algebra auch dann, wenn der Erzeuger abzählbar unendlich ist, überabzählbar, während die erzeugte Algebra nur abzählbar wäre).

Auf einer Algebra definiert man nun etwas, was schon fast ein Maß ist:

Definition 2.13. Sei $\mathfrak{A}$ eine Mengenalgebra.

(i) Eine Abbildung $\mu : \mathfrak{A} \to [0, +\infty]$, heißt ein *Inhalt*, wenn $\mu(\emptyset) = 0$ und für alle disjunkten Mengen $A, B \in \mathfrak{A}$, $\mu(A \cup B) = \mu(A) + \mu(B)$.

(ii) Ein Inhalt heißt ein *Prämaß*, wenn für Folgen disjunkter Mengen $A_1, A_2 \cdots \in \mathfrak{A}$ für die $\cup_{n\in\mathbb{N}} A_n \in \mathfrak{A}$,

$$\mu\Big(\bigcup_{n\in\mathbb{N}} A_n\Big) = \sum_{n\in\mathbb{N}} \mu(A_n) \tag{2.8}$$

gilt.

Anmerkung. Falls $\mathfrak{A}$ eine σ-Algebra ist, und μ ein Prämaß, dann ist μ ein Maß. Wenn darüber hinaus $\mu(\Omega) = 1$, dann ist μ ein Wahrscheinlichkeitsmaß. Die Eigenschaft (ii) heißt σ-Additivität.

Die σ-Additivität ist in der Regel nicht sonderlich schwer nachzuprüfen. Das folgende Lemma macht dies transparent, und erklärt zum Teil warum wir die abzählbare Additivität für Maße fordern.

Lemma 2.14. *Sei μ ein endlicher Inhalt auf einer Algebra $\mathfrak{A}$. Dann sind die folgenden Aussagen äquivalent:*

(i) μ ist ein Prämaß.

(ii) Sei $(A_n \in \mathfrak{A}, n \in \mathbb{N})$ eine Folge von Mengen, so dass für alle $n \in \mathbb{N}$, $A_n \supset A_{n+1}$ und $\bigcap_{n\in\mathbb{N}} A_n = \emptyset$ (wir schreiben dafür auch kurz $A_n \downarrow \emptyset$). Dann ist $\lim_{n\to\infty} \mu(A_n) = 0$.

Anmerkung. Die Eigenschaft (ii) bezeichnet man auch als *Stetigkeit bei der leeren Menge*.

Beweis. Wir zeigen zunächst, dass (i) (ii) impliziert. Dazu sei $B_n \equiv A_n \backslash A_{n+1}$. Die Mengen B_n sind disjunkt, und $A_n = \cup_{m=n}^{\infty} B_m$, für jedes n. Also ist nach (i) $\sum_{m=n}^{\infty} \mu(B_m) = \mu(A_n)$. Die Konvergenz der Summe impliziert dass $\mu(A_n)$ nach Null konvergiert.

Wir zeigen nun die Gegenrichtung. Es sei nun $(B_n, n \in \mathbb{N})$ eine Folge disjunkter Mengen in $\mathfrak{A}$ so dass $B \equiv \cup_{n\in\mathbb{N}} B_n \in \mathfrak{A}$. Setze nun $A_{n+1} \equiv \cup_{m=n+1}^{\infty} B_m = B \setminus \cup_{i=1}^{n} B_i \in \mathfrak{A}$. Wegen der endlichen Additivität des Inhalts gilt

$$\mu(B) = \sum_{i=1}^{n} \mu(B_i) + \mu(A_{n+1}). \tag{2.9}$$

Da aber nach (ii) $\mu(A_{n+1}) \downarrow 0$, (denn $A_n \downarrow \emptyset$), so folgt dass $\mu(B) = \sum_{i=1}^{\infty} \mu(B_i)$, und der Beweis ist erbracht. □

Satz 2.15. *Sei $\mathfrak{F}$ eine σ-Algebra über Ω, und $\mathfrak{C}$ ein durchschnittstabiles Mengensystem das $\mathfrak{F}$ erzeugt. Falls zwei Wahrscheinlichkeitsmaße μ und ν auf $\mathfrak{C}$ übereinstimmen, dann gilt $\mu = \nu$ auf $\mathfrak{F}$.*

Beweis. Wir definieren

$$\widetilde{\mathfrak{F}} \equiv \{A \in \mathfrak{F} : \mu(A) = \nu(A)\}. \tag{2.10}$$

Wir wollen zeigen, dass $\mathfrak{F} = \widetilde{\mathfrak{F}}$. Dazu genügt es zu zeigen, dass $\widetilde{\mathfrak{F}}$ ein Dynkin-System ist. Denn da $\mathfrak{C}$ durchschnittsstabil ist, ist das kleinste Dynkin-System, dass $\mathfrak{C}$ enthält ja auch gerade die von $\mathfrak{C}$ erzeugte σ-Algebra, also $\mathfrak{F}$. Da aber nach Voraussetzung $\widetilde{\mathfrak{F}}$ gerade $\mathfrak{C}$ enthält, wären wir fertig. Prüfen wir also ob $\widetilde{\mathfrak{F}}$ ein Dynkin-System ist. Zunächst testen wir, ob relative Komplemente enthalten sind. Es ist aber, wenn $A, B \in \widetilde{\mathfrak{F}}$ und $A \subset B$,

$$\mu(B \setminus A) = \mu(B) - \mu(A) = \nu(B) - \nu(A) = \nu(B \setminus A), \tag{2.11}$$

also $B \setminus A \in \widetilde{\mathfrak{F}}$. Für paarweise disjunkte Mengen $D_n \in \widetilde{\mathfrak{F}}$ gilt

$$\mu\Big(\bigcup_{n\in\mathbb{N}} D_n\Big) = \sum_{n\in\mathbb{N}} \mu(D_n) = \sum_{n\in\mathbb{N}} \nu(D_n) = \nu\Big(\bigcup_{n\in\mathbb{N}} D_n\Big), \tag{2.12}$$

also ist auch $\cup_{n\in\mathbb{N}} D_n \in \widetilde{\mathfrak{F}}$. Damit ist die Behauptung bewiesen. □

Anmerkung. Die Aussage des Satzes gilt für allgemeine Maße, wenn zusätzlich angenommen wird, dass $\mathfrak{F}$ eine Folge von Mengen Ω_n mit den Eigenschaften $\mu(\Omega_n) = \nu(\Omega_n) < \infty$ und $\Omega_n \uparrow \Omega$ enthält, also wenn μ σ-endlich ist. Der Beweis in diesem Fall besteht darin, zu beobachten, dass die Maße μ_n und ν_n, definiert durch $\mu_n(A) \equiv \mu(A \cap \Omega_n)$, bzw. $\nu_n(A) \equiv \nu(A \cap \Omega_n)$ identisch sind, und andererseits $\mu_n \to \mu$, resp. $\nu_n \to \nu$ gilt.

Ein Mengensystem, das die Voraussetzung des Satzes erfüllt, nennt man *maßbestimmend*.

Zu unserem Glück fehlt nun nur noch die Beobachtung, dass aus Prämaßen Maße werden. Dies besagt der folgende wichtige Satz.

Satz 2.16 (Satz von Carathéodory). *Sei μ_0 ein (σ-)endliches Prämaß auf einer Algebra $\mathfrak{A}$. Dann gibt es genau ein Maß, μ, auf der von $\mathfrak{A}$ erzeugten σ-Algebra, das mit μ_0 auf $\mathfrak{A}$ übereinstimmt. μ heißt die Erweiterung von μ_0 auf $\sigma(\mathfrak{A})$.*

Beweis. Die Eindeutigkeit folgt aus dem Satz 2.15. Angenommen, es gäbe zwei Maße, μ, ν, die auf $\mathfrak{A}$ übereinstimmen. Da die Algebra $\mathfrak{A}$ insbesondere durchschnittstabil ist, so ist nach Satz 2.15 $\nu = \mu$ auf der von $\mathfrak{A}$ erzeugten σ-Algebra. Der Existenzbeweis würde hier zu weit führen. □

Anmerkung. Der Beweis der Existenz wird in der Vorlesung Analysis 3 erbracht. Interessanterweise zeigt dieser auch, dass die Borel'sch σ-Algebra im wesentlichen die grösstmögliche σ-Algebra ist auf der sich Maße konstruieren lassen, die die abzählbare Additivitätseigenschaft besitzen.

2.1.5 Wahrscheinlichkeitsmaße auf $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$

Ein praktisch wichtiger Spezialfall ist die Konstruktion von Maßen auf $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$.

Die für uns zunächst wichtigste Anwendung des Satzes von Carathéodory ist die Beobachtung, dass ein Wahrscheinlichkeitsmaß auf $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$ durch seine *Verteilungsfunktion* eindeutig charakterisiert ist.

Satz 2.17. *Zu jeder monoton wachsenden, rechtsstetigen Funktion $F : \mathbb{R} \to \mathbb{R}$ gibt es genau ein (σ-endliches) Maß μ auf $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$ so, dass $\mu((s,t]) = F(t) - F(s)$ ist, für alle $s < t \in \mathbb{R}$. Umgekehrt gibt es für jedes Maß auf $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$ für das für alle $s < t \in \mathbb{R}$ $\mu((s,t]) < \infty$ eine monoton wachsende, rechtsstetige Funktion so, dass für alle $s < t \in \mathbb{R}$ $\mu((s,t]) = F(t) - F(s)$ gilt. F ist bis auf eine additive Konstante festgelegt.*

Beweis. Die zweite Aussage ist trivial. Falls μ endlich ist, kann man einfach setzen $F(x) \equiv \mu((-\infty, x])$. Ansonsten, setz man z.B. $F(x) \equiv \mu((0,x])$ für $x > 0$ und $F(x) = -\mu((x,0])$ für $x \leq 0$. Dann ist $F(t)$ offenbar monoton wachsend und es gilt $\mu((s,t]) = F(t) - F(s)$. Weiter ist

$$\lim_{\epsilon \downarrow 0}(F(t+\epsilon) - F(t) = \lim_{\epsilon \downarrow 0} \mu((t, t+\epsilon]) = \mu(\emptyset) = 0, \tag{2.13}$$

so dass F rechtsstetig ist. Hier haben wir in der vorletzten Gleichung die Stetigkeit bei der leeren Menge (Lemma 2.14) benutzt.

Der Beweis der ersten Aussage ist etwas aufwendiger. Wir nehmen ein Mengensystem $\mathfrak{C}$ dass aus allen Intervallen der Form $(s,t]$ besteht, mit $-\infty \leq s < t < \infty$,

sowie zusätzlich allen Intervallen $(s, +\infty)$. Es sei $a(\mathfrak{C})$ die von diesen Intervallen erzeugte Algebra. Offenbar sind dies gerade alle endlichen Vereinigungen von halboffenen Intervallen und den Halbachsen $(s, +\infty)$. Wir können nun für jedes solche Intervall den Wert von μ festsetzen als

$$\mu((s,t]) \equiv F(t) - F(s), \tag{2.14}$$

bzw.

$$\mu((s,\infty)) = \lim_{t\to\infty} F(t) - F(s) \equiv F(\infty) - F(s). \tag{2.15}$$

Wir sehen auch, dass durch endliche Additivität diese Funktion auf die ganze Algebra erweitert werden kann, denn die Maße von disjunkten Vereinigungen sind gerade die Summe der Maßen. Wichtig ist dabei die Konsistenz, nämlich, dass

$$\mu((s,t]) + \mu((t,r]) = \mu((s,r]), \tag{2.16}$$

wie man leicht nachprüft. Damit können wir μ auf $a(\mathfrak{C})$ erweitern und erhalten einen Inhalt. Dieser ist, da $\mu((-n,n]) = F(n) - F(-n) < \infty$, σ-endlich. Um den Satz von Carathéodory anwenden zu können, bleibt nur noch übrig zu zeigen, dass μ ein Prämaß ist. Dann liefert dieser Existenz und Eindeutigkeit des Maßes μ auf der Borel-σ-Algebra.

Dazu benutzen wir Lemma 2.14 und zeigen, dass für jede Folge $(A_n \in a(\mathfrak{C}), n \in \mathbb{N})$ mit der Eigenschaft, dass $A_n \downarrow \emptyset$ gilt, dass $\mu(A_n) \downarrow 0$. Dies wieder werden wir dadurch beweisen, dass aus der Annahme $\lim_{n\to\infty} \mu(A_n) = a > 0$ folgt, dass $\cap_{n\in\mathbb{N}} A_n \neq \emptyset$. Ohne Beschränkung der Allgemeinheit können wir A_n aus $\mathfrak{C}$ wählen. Wir wollen nun zeigen, dass in jedem A_n noch eine nicht leere kompakte Menge K_n steckt, derart, dass die Folge K_n absteigend ist.

Wie konstruieren wir nun diese Mengen? Wir zeigen zunächst, dass für jedes Intervall $I \in \mathfrak{C}$ mit $\mu(I) > 0$ und jedes $\epsilon > 0$ eine kompakte Menge L und ein Intervall $I' \in \mathfrak{C}$ existieren, so dass

$$I' \subset L \subset I, \quad \text{und} \quad \mu(I') \geq \mu(I) - \epsilon. \tag{2.17}$$

Sei nämlich $I = (s,t]$, so wähle man $I' = (s',t]$ mit $s' \in (s,t)$ derart, dass $F(s') \leq F(s) + \epsilon$ (dies ist stets möglich, da F rechtsstetig ist). Dann wählen wir zum Beispiel $L = [(s+s')/2, t]$, wenn $s \in \mathbb{R}$. Wenn $s = -\infty$ ist, wählt man stattdessen $L = [s'-1, t]$.

Wir konstruieren mit diesem Verfahren nun für jede Folge $A_n \in a(\mathfrak{C})$ Mengen $B_n \in a(\mathfrak{C})$ und kompakte K_n so, dass $B_n \subset K_n \subset A_n$ und $\mu(B_n) \geq \mu(A_n) - a2^{-n-1}$. Weiter ist

$$A_n \setminus (B_1 \cap \cdots \cap B_n) \subseteq \bigcup_{i=1}^{n} (A_i \setminus B_i). \tag{2.18}$$

Daher ist

$$\mu(B_1 \cap \cdots \cap B_n) \geq \mu(A_n) - \mu\left(\bigcup_{i=1}^{n}(A_i \setminus B_1)\right)$$
$$\geq \mu(A_n) - \sum_{i=1}^{n} \mu(A_1 \setminus B_i) \geq a - \sum_{i=1}^{n} a2^{-i-1} \geq a/2.$$

Somit ist $B_1 \cap \cdots \cap B_n \neq \emptyset$ und da $B_k \subset K_k$, auch die Menge $K_1 \cap \cdots \cap K_n \neq \emptyset$ für alle $n \in \mathbb{N}$. Nun gilt aber (siehe das nachfolgende Lemma), dass dann auch $\cap_{n\in\mathbb{N}} K_n \neq \emptyset$ und somit a fortiori $\cap_{n\in\mathbb{N}} A_n \neq \emptyset$, was zu beweisen war. □

Anmerkung. Wir benutzen hier ein Resultat der Topologie, dass wir sehr allgemein formulieren, aber nur für den Fall $\Omega = \mathbb{R}$ brauchen.

Lemma 2.18. *Sei Ω ein Hausdorffraum. Falls K_n, $n \in \mathbb{N}$ kompakte Teilmengen von Ω sind, so dass der Durchschnitt jeder endlichen Teilmenge dieser Mengen nicht leer ist, so ist $\bigcap_{n\in\mathbb{N}} K_n \neq \emptyset$.*

Beweis. Der Beweis ist einfach: Wenn $\bigcap_{n\in\mathbb{N}} K_n = \emptyset$, dann ist $\bigcup_{n\in\mathbb{N}} K_n^c = \Omega$. Insbesondere ist für jedes m, $K_m \subset \bigcup_{n\in\mathbb{N}} K_n^c$. Da die Mengen K_n^c offen sind (kompakte Teilmengen eines Hausdorffraums sind stets abgeschlossen), bilden sie eine offene Überdeckung der kompakten Menge K_m. Da K_m kompakt ist, so besitzt nach Definition jede offenen Überdeckung eine endliche Teilüberdeckung, also $K_m \subset \bigcup_{i=1}^{\ell} K_{n_i}^c$. Daher ist $K_m^c \supset \bigcap_{i=1}^{\ell} K_{n_i}$, also $K_m \cap \bigcap_{i=1}^{\ell} K_{n_i} = \emptyset$. Letzteres steht aber im Widerspruch zur Annahme an die Mengen K_n, dass alle endlichen Durchschnitte nicht leer seien. Daher ist $\bigcap_{n\in\mathbb{N}} K_n \neq \emptyset$. □

Korollar 2.19. *Es existiert ein Maß auf $(\mathbb{R}, \mathfrak{B})$, das jedem Intervall gerade seine Länge zuordnet. Dieses Maß heißt das Lebesgue-Maß* [2].

Beweis. Wähle $F(t) = t$ im vorhergehenden Satz! □

Falls $F(\infty) - F(-\infty) = 1$, so ist das resultierende Maß ein Wahrscheinlichkeitsmaß, $\mathbb{P}$. Indem wir noch $F(-\infty) = 0$ festlegen, ist F gerade die Verteilungsfunktion von $\mathbb{P}$,

$$F(t) = \mathbb{P}((-\infty, t]) \tag{2.19}$$

Aus dem Beweis des Satzes von Carathéodory können wir ein einfaches Beispiel für einen Inhalt der kein Prämaß ist ableiten. Dazu sei

$$F(t) = \begin{cases} 0, & t < 0, \\ 1/2, & x = 0, \\ 1, & x > 0. \end{cases} \tag{2.20}$$

Wir setzen $\mu((s,t]) = F(t) - F(s)$, für $s < t \in \mathbb{R}$. Offenbar ist dies ein Inhalt. Andererseits ist $\mu((0, 1/n]) = 1/2$, für alle $n \in \mathbb{N}$, also auch $\lim_{n\uparrow\infty} \mu((0, 1/n]) = 1/2$. Andererseits ist $\cup_{n\in\mathbb{N}}(0, 1/n] = \emptyset$, und somit ist μ nicht stetig bei der leeren Menge, mithin kein Prämaß.

[2] Benannt nach dem französischen Mathematiker Henri Léon Lebesgue (28.06.1875–26.07.1941).

2.2 Integration


Henri Lebesgue

Wir wollen nun den Begriff der Integration gegen Maße in großer Allgemeinheit definieren. Dazu müssen zunächst den Begriff messbarer Funktionen definieren.

Messbare Abbildungen und Zufallsvariablen

Definition 2.20. Sei $(\Omega, \mathfrak{F})$ ein Messraum, und $f : \Omega \to \mathbb{R}$ eine reellwertige Funktion. Dann heißt f eine *messbare Funktion* von $(\Omega, \mathfrak{F})$ nach $(\mathbb{R}, \mathfrak{B})$, genau dann, wenn für alle $B \in \mathfrak{B}$,

$$f^{-1}(B) \equiv \{\omega \in \Omega : f(\omega) \in B\} \in \mathfrak{F}. \tag{2.21}$$

Wenn $(\Omega, \mathfrak{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum ist und $X : \Omega \to \mathbb{R}$ eine messbare Funktion ist, so nennen wir X eine *Zufallsvariable*.

Anmerkung. Genauer ist X eine *reellwertige Zufallsvariable*. Wenn wir von Zufallsvariablen ohne weitere Spezifizierung reden, ist darunter stets eine reellwertige Zufallsvariable zu verstehen.

Diese Definition lässt sich aber leicht auf Funktionen zwischen beliebigen Messräumen übertragen:

Definition 2.21. Seien $(\Omega, \mathfrak{F})$ und $(\widetilde{\Omega}, \widetilde{\mathfrak{F}})$ Messräume, und $f : \Omega \to \widetilde{\Omega}$ eine Funktion. Dann heißt f eine messbare Funktion von $(\Omega, \mathfrak{F})$ nach $(\widetilde{\Omega}, \widetilde{\mathfrak{F}})$, genau dann, wenn für alle $B \in \widetilde{\mathfrak{F}}$,

$$f^{-1}(B) \equiv \{\omega \in \Omega : f(\omega) \in B\} \in \mathfrak{F}. \tag{2.22}$$

Anmerkung. Wenn $(\Omega, \mathfrak{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum ist und $X : \Omega \to \widetilde{\Omega}$ eine messbare Funktion ist, so nennt man X auch eine $\widetilde{\Omega}$-wertige Zufallsvariable.

Eine nützliche Beobachtung, die insbesondere die Nachprüfung der Messbarkeit von Funktionen erleichtert, ist die folgende:

Lemma 2.22. *Sei $(\Omega, \mathfrak{F})$ ein Messraum, $\widetilde{\Omega}$ eine Menge und sei $f : \Omega \to \widetilde{\Omega}$. Sei $\mathfrak{A}$ die Menge aller Teilmengen von $\widetilde{\Omega}$, deren Urbilder in $\mathfrak{F}$ liegen, also*

$$\mathfrak{A} \equiv \{A \subset \widetilde{\Omega} : f^{-1}(A) \in \mathfrak{F}\}. \tag{2.23}$$

Dann ist $\mathfrak{A}$ eine σ-Algebra.

Beweis. Zunächst ist klar, dass $f^{-1}(\widetilde{\Omega}) = \Omega$, so dass $\widetilde{\Omega} \in \mathfrak{A}$. Auch ist $f^{-1}(\emptyset) = \emptyset \in \mathfrak{F}$, so dass auch $\emptyset \in \mathfrak{A}$. Sei $A \in \mathfrak{A}$; dann ist

$$f^{-1}(A^c) \equiv \{\omega \in \Omega : f(\omega) \notin A\} = \{\omega : f(\omega) \in A\}^c, \tag{2.24}$$

also das Komplement einer Menge in $\mathfrak{F}$, mithin selbst in $\mathfrak{F}$. Somit ist auch $A^c \in \mathfrak{A}$. Seien schließlich A_i, $i \in \mathbb{N}$ in $\mathfrak{A}$. Dann ist

$$f^{-1}(\cup_i A_i) \equiv \{\omega \in \Omega : f(\omega) \in \cup_i A_i\} = \cup_i \{\omega \in \Omega : f(\omega) \in A_i\} \in \mathfrak{F}, \tag{2.25}$$

und so $\cup_i A_i \in \mathfrak{A}$. Mithin ist $\mathfrak{A}$ eine σ-Algebra. □

Korollar 2.23. *Falls $\mathfrak{C}$ ein Mengensystem ist, das $\widetilde{\mathfrak{F}}$ erzeugt, dann ist f messbar, wenn für alle $C \in \mathfrak{C}$, $f^{-1}(C) \in \mathfrak{F}$.*

Beweis. Der Beweis ist denkbar einfach. Einerseits ist die Menge $\mathfrak{A} \equiv \{A : f^{-1}(A) \in \mathfrak{F}\}$ nach dem vorigen Lemma eine σ-Algebra, andererseits enthält sie einen Erzeuger, $\mathfrak{C}$ der σ-Algebra. Dann enthält sie mindestens die erzeugte σ-Algebra, mithin $\widetilde{\mathfrak{F}}$. □

Korollar 2.24. *Sei $f : \mathbb{R} \to \mathbb{R}$ eine stetige Funktion. Dann ist f messbar als Funktion von $(\mathbb{R}, \mathfrak{B}(\mathbb{R})) \to (\mathbb{R}, \mathfrak{B}(\mathbb{R}))$.*

Beweis. Wir müssen nur (z.B.) zeigen, dass die Urbilder von offenen Mengen unter f Borelmengen sind. Nun ist aber das Urbild von offenen Mengen unter stetigen Abbildungen offen, und alle offenen Mengen sind Borel-Mengen. □

In obigem Korollar kann $\mathbb{R}$ durch einen beliebigen topologischen Raum ersetzt werden.

2.2.2 Integrale von Zufallsvariablen.

Zufallsvariablen sind geradezu dazu geschaffen, um gegen Wahrscheinlichkeitsmaße integriert zu werden. Dazu wollen wir nun einen sehr vorteilhaften Integralbegriff definieren, der wesentlich besser ist, als der des aus der Analysis bekannten Riemann-Integrals.

Dabei gehen wir in gewisser Hinsicht ähnlich vor wie in der Analysis 1, aber mit einem entscheidenden Unterschied. Dieser liegt in der Wahl dessen, was wir als *einfache Funktionen* erkären.

Wir erinnern uns zunächst an die Definition der Indikatorfunktion einer Teilmenge $A \subseteq \Omega$:

$$\mathbb{1}_A(\omega) = \begin{cases} 1, & \text{wenn } \omega \in A, \\ 0, & \text{wenn } \omega \in A^c. \end{cases} \tag{2.26}$$

Lemma 2.25. *Die Indikatorfunktion $\mathbb{1}_A$ ist messbar bezüglich des Messraums $(\Omega, \mathfrak{F})$ genau dann, wenn $A \in \mathfrak{F}$.*

Beweis. Übung! □

Definition 2.26. Eine messbare Funktion $g : \Omega \to \mathbb{R}$ heißt *einfach*, wenn es Zahlen $k \in \mathbb{N}$, $w_1, \ldots, w_k \in \mathbb{R}$ und Mengen $A_1, \ldots, A_k \in \mathfrak{F}$ gibt, so dass

$$g(\omega) = \sum_{i=1}^{k} w_i \mathbb{1}_{A_i}(\omega). \tag{2.27}$$

Wir bezeichnen den Raum aller einfachen messbaren Funktion mit $\mathcal{E}$, und den Raum aller positiven einfachen messbaren Funktionen mit $\mathcal{E}_+$.

Anmerkung. Ohne Beschränkung der Allgemeinheit können wir annahmen, dass die A_i eine Partition von Ω bilden. Entsprechend sind einfache Funktionen charakterisiert als messbare Funktionen, die nur endliche viele Werte annehmen.

Für einfache Funktionen ist das Integral nun wie früher erklärt. (Im Folgenden schreiben wir P für ein Maß, das nicht notwendig ein Wahrscheinlichkeitsmaß sein muss. Wer möchte, kann sich aber auf diesen Fall beschränken).

Zunächst ist

$$\int \mathbb{1}_A(\omega) \mathrm{d}P \equiv P(A). \tag{2.28}$$

Im Fall von Wahrscheinlichkeitsmaßen heißt das, dass bei Eintreten des Ereignisses $\{\omega \in A\}$ der Betrag 1 ausgezahlt wird. Die erwartete Auszahlung ist dann gerade die Wahrscheinlichkeit dieses Ereignisses.

Definition 2.27. Sei $(\Omega, \mathfrak{F}, P)$ ein Maßraum und $g = \sum_{i=1}^{k} w_i \mathbb{1}_{A_i}$ eine positive einfache Funktion. Dann ist

$$\int_\Omega g \, \mathrm{d}P = \sum_{i=1}^{k} w_i P(A_i) \in [0, +\infty]. \tag{2.29}$$

Diese Definition ist die einzig sinnvolle, wenn wir fordern, dass dass das Integral einer Indikatorfunktion einer Menge gerade das Maß dieser Menge ist, und dass das Integral eine lineare Abbildung sein soll.

Sei nun f eine positive, messbare Funktion. Die Grundidee ist, dass wir f durch einfache Funktionen annähern. Daher definieren wir

Definition 2.28. Sei f positiv und messbar. Dann ist

$$\int_\Omega f \, \mathrm{d}P \equiv \sup_{g \le f, g \in \mathcal{E}_+} \int_\Omega g \, \mathrm{d}P \tag{2.30}$$

Beachte, dass der Wert des Integrals in $[0, +\infty]$ liegt.

Schließlich zerlegt man eine allgemeine Funktion in ihren positiven (genauer nicht-negativen) und negativen Teil durch

$$f(\omega) = \mathbb{1}_{f(\omega) \ge 0} f(\omega) + \mathbb{1}_{f(\omega) < 0} f(\omega) \equiv f_+(\omega) - f_-(\omega) \tag{2.31}$$

und definiert:

Definition 2.29. Sei f eine messbare Funktion und sei entweder $\int_\Omega f_+ \, \mathrm{d}P < \infty$ oder $\int_\Omega f_- \, \mathrm{d}P < \infty$. Dann ist das Integral von f bezüglich P gegeben durch

$$\int_\Omega f \, \mathrm{d}P \equiv \int_\Omega f_+(\omega) - \int_\Omega f_-(\omega) \, \mathrm{d}P. \tag{2.32}$$

Eine messbare Funktion heißt *integrierbar* (oder *absolut integrierbar*) bezüglich P, wenn $\int_\Omega f_+ \, \mathrm{d}P < \infty$ und $\int_\Omega f_- \, \mathrm{d}P < \infty$, oder, äquivalent, $\int_\Omega |f| \, \mathrm{d}P < \infty$.

Man bezeichnet den Raum der gegen P integrierbaren Funktionen mit $L^1(\Omega, \mathfrak{F}, P)$ oder einfacher $L^1(\Omega, P)$.

Man benutzt die folgenden Notationen ohne Unterschied:

$$\int_\Omega f \, \mathrm{d}P = \int_\Omega f(\omega) \, \mathrm{d}P(\omega) = \int_\Omega f(\omega) P(\mathrm{d}\omega), \tag{2.33}$$

wobei wir die Angabe des Integrationsgebietes der Bequemlichkeit halber auch oft weglassen.

Wenn $\mathbb{P}$ ein Wahrscheinlichkeitsmaß ist und X eine Zufallsvariable, denn nennt man das integral $\int X d\mathbb{P}$ den *Erwartungswert* von X und schreibt

$$\int X d\mathbb{P} \equiv \mathbb{E}[X]. \tag{2.34}$$

Der folgende Satz von der monotonen Konvergenz stellt eine der wichtigsten Eigenschaften des Integrals fest.

Satz 2.30 (Monotone Konvergenz). *Sei $(\Omega, \mathfrak{F}, P)$ ein Maßraum und f eine nicht-negative reellwertige messbare Funktion. Sei $f_1 \le f_2 \le \cdots \le f$ eine monoton wachsende Folge von nicht-negativen messbaren Funktionen, die punktweise gegen f streben, d.h., für jedes $\omega \in \Omega$ gilt $\lim_{n\to\infty} f_n(\omega) = f(\omega)$. Dann gilt*

$$\int_\Omega f \, \mathrm{d}P = \lim_{n\to\infty} \int_\Omega f_n \, \mathrm{d}P \tag{2.35}$$

Beweis. Es ist klar, dass

$$\int_\Omega f_n \, \mathrm{d}P \le \int_\Omega f \, \mathrm{d}P, \tag{2.36}$$

und damit auch $\lim_{n\to\infty} \int_\Omega f_n \, \mathrm{d}P \le \int_\Omega f \, \mathrm{d}P$. Wir müssen nur die umgekehrte Ungleichung beweisen. Sei $h = \sum_{i=1}^k h_i \mathbb{1}_{A_i} \in \mathcal{E}_+$ mit $h \le f$ und $a < 1$. Wir wollen zunächst zeigen, dass dann

$$\lim_{n\uparrow\infty} \int_\Omega f_n \, \mathrm{d}P \ge a \int_\Omega h \, \mathrm{d}P. \tag{2.37}$$

Sei E_n die messbare Menge $E_n \equiv \{\omega \in \Omega : ah(\omega) \le f_n(\omega)\}$. Da $a < 1$ und $f_n \uparrow f$, muss die Folge E_n wachsend sein und $\Omega = \cup_n E_n$. Wir setzen

$$h_n(\omega) = ah(\omega) \mathbb{1}_{E_n}(\omega). \tag{2.38}$$

Dann ist $h_n \leq f_n$. Also ist

$$\int_\Omega f_n \, \mathrm{d}P \equiv \sup_{g \leq f_n, g \in \mathcal{E}_+} \int_\Omega g \, \mathrm{d}P \geq \int_\Omega h_n \, \mathrm{d}P = a \sum_{i=1}^{k} h_i P(A_i \cap E_n). \tag{2.39}$$

Da nun aber $E_n \uparrow \Omega$, gilt auch $A_i \cap E_n \uparrow A_i$, wenn $n \to \infty$ und somit auch $P(A_i \cap E_n) \uparrow P(A_i)$. Also ist

$$\lim_{n\to\infty} \int_\Omega f_n \, \mathrm{d}P \geq a \sum_{i=1}^{k} h_i P(A_i) = a \int_\Omega h \, \mathrm{d}P. \tag{2.40}$$

Da letzteres für jedes $a < 1$ und $h \in \mathcal{E}_+, h \leq f$ gilt, ist auch

$$\lim_{n\to\infty} \int_\Omega f_n \, \mathrm{d}P \geq \sup_{a<1} \sup_{h \in \mathcal{E}_+, h \leq f} a \int_\Omega h \, \mathrm{d}P = \sup_{a<1} a \int_\Omega f \, \mathrm{d}P = \int_\Omega f \, \mathrm{d}P. \tag{2.41}$$

Hieraus folgt mit (2.36) die Behauptung sofort. □

Der Satz von der monotonen Konvergenz erlaubt uns nun eine "explizite" Konstruktion des Integrals anzugeben.

Lemma 2.31. *Sei f eine nicht-negative messbare Funktion. Dann ist*

$$\int_\Omega f \, \mathrm{d}P \equiv \lim_{n\to\infty} \Bigg[\sum_{k=0}^{n2^n-1} 2^{-n} k P\left(\omega : 2^{-n}k \leq f(\omega) < 2^{-n}(k+1)\right) + nP\left(\omega : f(\omega) \geq n\right) \Bigg] \tag{2.42}$$

Beweis. Wir bemerken, dass auf der rechten Seite der Gleichung der Limes der Integrale der messbaren positiven, einfachen Funktionen f_n mit

$$f_n(\omega) \equiv \sum_{k=0}^{n2^n-1} 2^{-n} k \mathbb{1}_{\{\omega : 2^{-n}k \leq f(\omega) < 2^{-n}(k+1)\}} + n \mathbb{1}_{\{\omega : f(\omega) \geq n\}} \tag{2.43}$$

steht. Diese sind offenbar monoton wachsend und streben gegen f. Damit folgt das Lemma aus dem Satz von der monotonen Konvergenz. □

Der Satz von der monotonen Konvergenz impliziert insbesondere auch, dass das Integral eine lineare Operation ist.

Lemma 2.32. *Seien f, g messbare gegen ein Maß P integrable Funktionen. Dann gilt, für alle $\alpha, \beta \in \mathbb{R}$, dass*

$$\int (\alpha f + \beta g) \, dP = \alpha \int f dP + \beta \int g dP. \tag{2.44}$$

Beweis. Zunächst bemerken wir, dass für alle einfachen Funktionen $f_n, g_n \in \mathcal{E}$ die Gleichung (2.44) offensichtlich gilt. Seien nun f, g positive messbare Funktionen. Dann wählen wir monoton wachsende Folgen nicht-negativer Funktionen $f_n, g_n, n \in \mathbb{N}$, die punktweise gegen f bzw. g konvergieren. Dann ist auch die Folge der Funktionen $f_n + g_n$ monoton wachsend und konvergier Punktweise gegen $f + g$. Damit folgt aus Satz 2.30, dass

$$\int (f+g)\,dP = \lim_n \int (f_n + g_n)\,dP = \lim_n \int f_n dP + \lim_n \int g_n dP = \int f dP + \int g dP. \tag{2.45}$$

Weiter ist aber $(f+g)_+ - (f+g)_- = f + g = f_+ - f_- + g_+ - g_-$. Außerdem ist $(f+g)_+ \leq f_+ + g_+$ und $(f+g)_- \leq f_- + g_-$. Daraus folgt, dass es eine nicht-negative messbare Funktion v gibt, so dass

$$\begin{aligned} f_+ + g_+ &= (f+g)_+ + v \\ f_- + g_- &= (f+g)_- + v \end{aligned}$$

Damit haben wir aber

$$\begin{aligned} \int f_+ dP + \int g_+ dP &= \int (f+g)_+ dP + \int v dP \\ \int f_- dP + \int g_- dP &= \int (f+g)_- dP + \int v dP \end{aligned} \tag{2.46}$$

Wenn wir die zweite Zeile von der ersten abziehen erhalten und beachten, dass sich die Integrale von v wegheben, wir gewünscht

$$\begin{aligned} \int f_+ dP - \int f_- dP + \int g_+ dP - \int g_- dP &= \int f dP + \int g dP \\ = \int (f+g)_+ dP - \int (f+g)_- dP &= \int (f+g) dP \end{aligned}$$

Es bleibt nur noch zu zeigen, dass $\int \alpha f dP = \alpha \int f dP$, was aber sehr einfach ist. □

Anmerkung. Anders als beim Riemann Integral benutzen wir in der Definition des Integrals keine Ober- und Untersummen. Man kann sich fragen, was passiert wäre, wenn wir das Riemann Integral als Supremum definiert hätten? Wir erinnern uns, dass im Riemann Fall statt einfacher Funktionen Treppenfunktionen verwendet wurden. Wenn wir nun die Funktion f betrachten, die auf den rationalen Zahlen gleich 1 und sonst 0 ist, so ist die größte Treppenfunktion die unter dieser Funktion liegt gerade die Null-Funktion. Andererseits gilt dasselbe für die Funktion $1 - f$. Also wäre das Integral beider Funktionen gleich Null. Da aber $f + 1 - f = 1$, ist die Linearität sehr massiv verletzt.

Anmerkung. Das hier verwendete Integral geht auf Lebesgue zurück und wird Lebesgue Integral bezüglich des Masses P bezeichnet. Wenn P das Lebesgue Maß ist,

nennt man es einfach Lebesgue Maß. Das Lebesgue Integral verallgemeinert das *Riemann Integral* insofern, als sehr viel mehr Funktionen im Lebesgue'schen Sinn integrierbar sind als im Riemann'schen. Andererseits gilt, dass jede Riemann integrierbare Funktion über einem kompakten Interval auch Lebesgue integrierbar ist, und dass in diesem Fall beide Integrale übereinstimmen.

Übung. Sei $I \subset \mathbb{R}$ ein kompaktes Intervall. Zeigen Sie, dass eine positive Riemann integrierbare Funktion $f : I \to \mathbb{R}_+$ integrierbar gegen das Lebesguemaß auf I ist (so wie oben definiert) und dass das Riemann und das Lebesgue Integral übereinstimmen.

Die zwei folgenden Eigenschaften des Integrals werden immer wieder benötigt und sollen daher hier bewiesen werden. Der erste ist das *Lemma von Fatou:*

Lemma 2.33 (Lemma von Fatou). *Sei f_n eine Folge positiver messbarer Funktionen. Dann gilt*

$$\int_\Omega \liminf_n f_n \, \mathrm{d}P \leq \liminf_n \int_\Omega f_n \, \mathrm{d}P. \tag{2.47}$$

Beweis. Es ist

$$\liminf_n f_n(\omega) = \lim_{k\to\infty} \left(\inf_{n\geq k} f_n(\omega) \right) \tag{2.48}$$

wobei das Infimum in der Klammer eine monoton wachsende Funktionenfolge ist ist. Daher liefert der Satz von der monotonen Konvergenz, dass

$$\int_\Omega \liminf_n f_n(\omega) \, \mathrm{d}P(\omega) = \lim_{k\to\infty} \int_\Omega \left(\inf_{n\geq k} f_n(\omega) \right) \mathrm{d}P(\omega). \tag{2.49}$$

Andererseits ist für jedes $p \geq k$, und jedes $\omega \in \Omega$

$$\inf_{n\geq k} f_n(\omega) \leq f_p(\omega). \tag{2.50}$$

Deswegen ist

$$\int_\Omega \left(\inf_{n\geq k} f_n(\omega) \right) \mathrm{d}P(\omega) \leq \inf_{p\geq k} \int_\Omega f_p(\omega) \, \mathrm{d}P(\omega). \tag{2.51}$$

Daher erhalten wir aber, dass

$$\lim_{k\to\infty} \int_\Omega \left(\inf_{n\geq k} f_n(\omega) \right) \mathrm{d}P(\omega) \leq \lim_{k\to\infty} \inf_{p\geq k} \int_\Omega f_p(\omega) \, \mathrm{d}P(\omega) = \liminf_p \int_\Omega f_p(\omega) \, \mathrm{d}P(\omega), \tag{2.52}$$

was zu zeigen war. □

Der zweite zentrale Satz ist Lebesgues Satz von der dominierten Konvergenz.

Wir sagen dass eine Folge von Funktionen f_n *P-fast überall* gegen eine Funktion f konvergiert, wenn

$$P\left(\{\omega : \lim_{n\to\infty} f_n(\omega) \neq f(\omega)\} \right) = 0. \tag{2.53}$$

Satz 2.34 (Dominierte Konvergenz). *Sei $(\Omega, \mathfrak{F}, P)$ ein Maßraum, f_n eine Folge von absolut gegen P integrierbaren Funktionen, f eine messbare Funktion und es gelte*

$$\lim_n f_n(\omega) = f(\omega) \quad P\text{-fast überall}. \tag{2.54}$$

Sei ferner $g \geq 0$ eine positive Funktion so dass $\int g \, \mathrm{d}P < \infty$ und es gelte

$$|f_n(\omega)| \leq g(\omega) \quad P\text{-fast überall}. \tag{2.55}$$

Dann ist f absolut integrierbar bezüglich P und

$$\lim_{n\to\infty} \int_\Omega f_n \, \mathrm{d}P = \int_\Omega f \, \mathrm{d}P. \tag{2.56}$$

Beweis. Wir nehmen zunächst an, dass die Annahmen, die fast überall gelten sollen sogar überall zutreffen.

Dann ist zunächst einmal $|f| \leq g$, und somit die absolute Integrierbarkeit von f eine direkte Folge der Integrierbarkeit von g. Da ferner $|f_n - f| \leq 2g$, und $|f_n - f| \to 0$, folgt mit Fatous Lemma, dass

$$\liminf_n \int_\Omega (2g - |f_n - f|) \, \mathrm{d}P \geq \int_\Omega \liminf_n (2g - |f_n - f|) \, \mathrm{d}P = 2 \int_\Omega g \, \mathrm{d}P. \tag{2.57}$$

Wegen der Linearität des Integrals ist das aber äquivalent zu

$$2 \int_\Omega g \, \mathrm{d}P - \limsup_n \int_\Omega |f_n - f| \, \mathrm{d}P \geq 2 \int_\Omega g \, \mathrm{d}P, \tag{2.58}$$

und daher

$$\limsup_n \int_\Omega |f_n - f| \, \mathrm{d}P = 0. \tag{2.59}$$

Dann folgt das Resultat wegen

$$\left| \int_\Omega f \, \mathrm{d}P - \int_\Omega f_n \, \mathrm{d}P \right| \leq \int_\Omega |f_n - f| \, \mathrm{d}P. \tag{2.60}$$

Um den allgemeinen Fall mit den nur fast sicheren Annahmen zu behandeln, setzen wir

$$A = \{\omega : f_n(\omega) \to f(\omega) \text{ und } |f_n(\omega)| \leq g(\omega) \text{ für alle } n\}. \tag{2.61}$$

Dann ist $P(A^c) = 0$. Aus dem vorherigen folgt, dass für die Funktionen $\tilde{f_n} \equiv f_n \mathbb{1}_A, \tilde{f} \equiv f \mathbb{1}_A$, die Aussage des Satzes gilt, während andererseits

$$\int_\Omega f_n \mathbb{1}_{A^c} \mathrm{d}P = \int_\Omega f \mathbb{1}_{A^c} \mathrm{d}P = 0. \tag{2.62}$$

Damit ist der Satz bewiesen. □

Ein einfaches Beispiel für eine Funktionenfolge, die die Voraussetzunges des Satzen von Lebesgue nicht erfüllt, ist

$$f_n(x) = \mathbb{1}_{[n,n+1]}(x). \tag{2.63}$$

Offensichtlich gilt für jedes $x \in \mathbb{R}$, $\lim_{n\uparrow\infty} f_n(x) = 0$. Die kleinste Majorante, die wir für f_n finden können ist $\mathbb{1}_{\mathbb{R}_+}$. Sei nun P das Lebesguemaß. Dann ist das Integral dieser Majorante unendlich. In der Tat gilt aber auch, dass

$$\int_{\mathbb{R}} f_n(x)dx = 1, \quad \text{für alle } n, \tag{2.64}$$

und somit $1 = \lim_{n\uparrow\infty} \int f_n dx \neq \int \lim_n f_n dx = 0$.

2.2.3 Abbildungen von Maßen

Zufallsvariablen auf Wahrscheinlichkeitsräumen induzieren auf natürliche Weise ein neues Maß auf dem Bildraum. Dies führt uns zum Begriff der Verteilung einer Zufallsvariablen. Wir haben zwei Messräume, $(\Omega, \mathfrak{F})$ und $(\widetilde{\Omega}, \widetilde{\mathfrak{F}})$, ein W-Maß, $\mathbb{P}$, auf $(\Omega, \mathfrak{F})$ und eine messbare Abbildung $f : (\Omega, \mathfrak{F}) \to (\widetilde{\Omega}, \widetilde{\mathfrak{F}})$. Dann können wir auf $(\widetilde{\Omega}, \widetilde{\mathfrak{F}})$ ein neues Maß, P_f definieren durch die Forderung, dass für alle $A \in \widetilde{\mathfrak{F}}$,

$$P_f(A) \equiv \mathbb{P}(\{\omega \in \Omega : f(\omega) \in A\}) = \mathbb{P}\left(f^{-1}(A)\right). \tag{2.65}$$

Aufgrund der Messbarkeit von f ist dieses Maß offenbar wohldefiniert. Wir schreiben häufig

$$P_f \equiv \mathbb{P} \circ f^{-1}, \tag{2.66}$$

und nennen P_f das von f auf $(\widetilde{\Omega}, \widetilde{\mathfrak{F}})$ *induzierte* Maß oder das Bildmaß von $\mathbb{P}$ unter f.

Wenn insbesondere $(\widetilde{\Omega}, \widetilde{\mathfrak{F}}) = (\mathbb{R}, \mathfrak{B}(\mathbb{R}))$ ist, nennen wir P_f auch die Verteilung der Zufallsvariablen f.

Lemma 2.35. *Sei $(\Omega, \mathfrak{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $X : \Omega \to \mathbb{R}$ eine reellwertige, integrierbare Zufallsvariable. Dann gilt*

$$\int_\Omega X(\omega)\, \mathrm{d}\mathbb{P}(\omega) = \int_{\mathbb{R}} x\, \mathrm{d}P_X(x). \tag{2.67}$$

Weiter ist, wenn $g : \mathbb{R} \to \mathbb{R}$ eine reellwertige messbare Funktion ist und $g \circ X$[3] integrierbar ist, dass

$$\int_\Omega g \circ X(\omega)\, \mathrm{d}\mathbb{P}(\omega) = \int_{\mathbb{R}} g(x)\, \mathrm{d}P_X(x). \tag{2.68}$$

[3] $\circ$ steht für Verkettung, also $g \circ X(\omega) \equiv g(X(\omega))$.

Beweis. Es genügt Eq. (2.68) zu zeigen, da (2.67) ein Spezialfall mit $g(x) = x$ ist. Wir nehmen zunächst $g(x) = \mathbb{1}_B(x)$, mit $B \in \mathfrak{B}(\mathbb{R})$. Dann ist

$$\begin{aligned}\int_\Omega (\mathbb{1}_B \circ X)(\omega) \mathrm{d}\mathbb{P}(\omega) &= \int_\Omega \mathbb{1}_B(X(\omega)) \mathrm{d}\mathbb{P}(\omega) \\ &= \mathbb{P}(\{\omega \in \Omega : X(\omega) \in B\}) = P_X(B) = \int_{\mathbb{R}} \mathbb{1}_B(x) \mathrm{d}P_X(x),\end{aligned} \tag{2.69}$$

d.h. (2.68) gilt für diesen Fall. Wenn g eine einfache Funktion ist, so folgt (2.68) aus (2.69) und der Linearität des Integrals. Als nächstes sei g positiv. Dann wählen wir eine Folge $g_n \uparrow g$ von positiven einfachen Funktionen, die punktweise gegen g konvergiert. Dann gilt auch, dass die Funktionen $h_n \equiv g_n \circ X : \Omega \to \mathbb{R}_+$ einfache Funktionen sind, die monoton punktwise gegen $h \equiv g \circ X$ konvergieren. Es gilt dann nach dem Satz von der monotonen Konvergenz, dass

$$\int_\Omega g \circ X(\omega) \mathrm{d}\mathbb{P}(\omega) = \lim_{n\uparrow\infty} \int g_n \circ X(\omega) \mathrm{d}\mathbb{P}(\omega) = \lim_{n\uparrow\infty} \int_{\mathbb{R}} g_n(x) \mathrm{d}P_X(x) = \int_{\mathbb{R}} g(x) \mathrm{d}P_X(x). \tag{2.70}$$

Schliesslich zerlegt man eine allgemeine messbare Funktion g in ihren positiven und negativen Teil und benutzt das schon bewiesene für beide Teile. □

Insoweit wir uns nur für die Zufallsvariable X interessieren, können wir durch diese Abbildung unser Problem auf den Wahrscheinlichkeitsraum $(\mathbb{R}, \mathfrak{B}(\mathbb{R}), P_X)$ zurückführen auf dem unsere Zufallsvariable gerade die identische Abbildung ist. Für praktische Zwecke ist daher eine Zufallsvariable insbesondere durch ihre Verteilung charakterisiert.

Anmerkung. Wir haben oft folgendes Bild vor Augen: Wir beginnen mit einem Wahrscheinlichkeitsraum $(\Omega, \mathfrak{F}, \mathbb{P})$, den wir oft einen *abstrakten Wahrscheinlichkeitsraum* nennen. Auf diesem definieren wir dann Zufallsvariablen, die wir durch ihre Verteilungen charakterisieren (während wir nie weder das Maß $\mathbb{P}$ noch die Zufallsvariablen als Abbildungen explizit angeben). Der Vorteil dieser Betrachtung liegt, wie wir später sehen werden, darin, dass wir auf ein und demselben Wahrscheinlichkeitsraum mehrere (und sogar unendlich viele) Zufallsvariablen haben können.

2.2.4 Absolut stetige Maße. Wahrscheinlichkeitsdichten.

Ein besonderer Fall von Wahrscheinlichkeitsmaßen auf $\mathbb{R}$ liegt vor, wenn die Verteilungsfunktion in einem schwachen Sinn differenzierbar ist. Genauer:

Definition 2.36. Sei $(\mathbb{R}, \mathfrak{B}(\mathbb{R}), \mathbb{P})$ ein Wahrscheinlichkeitsraum und F Verteilungsfunktion von $\mathbb{P}$. Dann heißt F absolut stetig (bezüglich des Lebesgue Maßes), falls es eine positive, messbare Funktion $\rho : \mathbb{R} \to [0, \infty)$ gibt, so dass für alle $s < t \in \mathbb{R}$,

$$\mathbb{P}((s,t]) = F(t) - F(s) = \int_s^t \rho(x)\,\mathrm{d}\lambda(x) \tag{2.71}$$

gilt, wobei λ das Lebesgue-Maß[4] ist. Wir nennen in diesem Fall die Funktion ρ die *Wahrscheinlichkeitsdichte* des Wahrscheinlichkeitsmaßes $\mathbb{P}$.

Jede positive messbare Funktion ρ mit der Eigenschaft, dass $\int_{-\infty}^{\infty} \rho(x)d\lambda(x) = 1$ bestimmt eine Verteilungsfunktion durch $F(z) \equiv \int_{-\infty}^{z} \rho(x)d\lambda(x)$ und mithin ein Wahrscheinlichkeitsmaß auf $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$.

Beachte, dass eine Wahrscheinlichkeitsdichte nicht eindeutig bestimmt ist. Wenn ρ, ρ' Wahrscheinlichkeitdichten sind und außer auf einer Menge vom Lebesgue Maß Null $\rho(x) = \rho'(x)$, dann bestimmen ρ und ρ' das selbe Wahrscheinlichkeitsmaß.

Es gilt ferner, dass wenn F absolut stetig ist, dann ist F fast überall differenzierbar und für jede Dichte ρ von F gilt, dass für Lebesgue-fast alle x, $\rho(x) = F'(x)$. (Der Beweis dieser Aussage findet sich in fast jedem Lehrbuch der Maßtheorie, z.B. Satz 31.3 in [1]).

Warnung: In der nicht-mathematischen Literatur werden die Begriffe Verteilungsfunktion und Wahrscheinlichkeitsdichte häufig durcheinander geworfen. Vor allem in der englischsprachigen Literatur, wo diese *probability distribution function* und *probability density (function)* heißen, ist die Gefahr der Verwechslung groß. In der physikalischen Literatur wird häufig die Fiktion aufrechterhalten, alle Wahrscheinlichkeitsvereilungen besässen Dichten. Dazu wird insbesondere der Begriff der Dirac'schen Delta-Funktion eingeführt, der die Gleichung $\delta_x(y) = \delta(x-y)\,\mathrm{d}y$ zu schreiben erlaubt. Man muss sich aber klar sein, dass es viele Maße gibt, die werder eine Dichte haben, noch als abzählbare Summen von Dirac-Maßen geschrieben werden können.

2.3 Beispiele von Wahrscheinlichkeitsmaßen.

Das einfachste Wahrscheinlichkeitsmaß auf jedem Raum $(\Omega, \mathfrak{F})$ ist das sogenannte *Dirac-Maß* an einem Punkt $t \in \Omega$, bezeichnet als δ_t. Es ist definiert durch

$$\delta_t(A) \equiv \mathbb{1}_A(t), \tag{2.72}$$

für jede Menge $A \in \mathfrak{F}$.

Das Dirac-Maß δ_t ist die Verteilung einer Zufallsvariablen, die stets den Wert t annimmt. Eine solche Zufallsvariable nennt man "deterministisch".

[4] Oft schreiben wir auch einfach dx für das Integral bezl. des Lebesgue Maßes.

2.3.0.1 Diskrete Wahrscheinlichkeitsmaße.

Aus Dirac-Maßen kann man nicht-triviale Zufallsmaße durch die Bildung von konvexen Linearkombiationen bilden. Dazu benutzen wir den allgemein gültigen einfachen Satz:

Lemma 2.37. *Seien $\nu_1, \nu_2, \ldots$ Wahrscheinlichkeitsmaße auf einem Messraum $(\Omega, \mathfrak{F})$, und $p_i \geq 0$ für alle $i \in \mathbb{N}$ positive reelle Zahlen mit $\sum_{i\in\mathbb{N}} p_i = 1$, dann ist*

$$\mu \equiv \sum_{i\in\mathbb{N}} p_i \nu_i \tag{2.73}$$

ebenfalls ein Wahrscheinlichkeitsmaß auf $(\Omega, \mathfrak{F})$.

Beweis. Übung! □

Einige besonders wichtige diskrete Verteilungen sind:

Bernoulli Verteilung Ber(p).

$$\mathbb{P} = p\,\delta_1 + (1-p)\,\delta_0. \tag{2.74}$$

Diese Verteilung kommt von einem Münzwurf, in dem mit Wahrscheinlichkeit p Kopf (und mit Wahrscheinlichkeit $(1-p)$ Zahl erscheint). Die Zufallsvariable f, definiert durch $f(\text{Kopf}) = 1, f(\text{Zahl}) = 0$ hat dann die Verteilung $\mathbb{P}$.

Binomialverteilung Bin(n, p).

Eine besonders wichtige Verteilung ist die Binomialverteilung. Wir betrachten n Münzen aus dem vorherigen Beispiel, die mit Wahrscheinlichkeit p Kopf (= 0) zeigen und die gleichzeitig geworfen werden. Der Zustandsraum dieses Experiments ist $\Omega = \{0,1\}^n$. Wir definieren nun eine Funktion f auf Ω, durch

$$f(\omega) = \sum_{i=1}^{n} \mathbb{1}_{\{0\}}(\omega_i), \tag{2.75}$$

wo $\omega = (\omega_1, \ldots, \omega_n)$. Offenbar nimmt f Werte in $\{0, \ldots, n\}$ an. Wir überlegen uns leicht, dass

$$\mathbb{P}(f = k) = \binom{n}{k} p^k (1-p)^{n-k}. \tag{2.76}$$

Daraus sehen wir, dass die Verteilung von f gegeben ist durch

$$P_{n,p} = \sum_{k=0}^{n} \binom{n}{k} p^k (1-p)^{n-k} \delta_k. \tag{2.77}$$

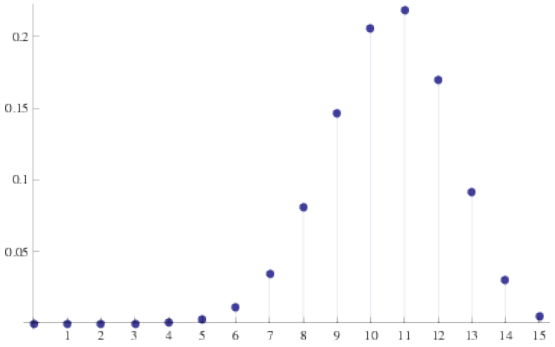


Abb. 2.1 Wahrscheinlichkeiten für Bin($n = 15, p = 0.7$).

Poissonverteilung Poi(ρ).

Eine weitere wichtige Verteilung is die Poissonverteilung, eingeführt von Simón-Denis Poisson (1781–1840). Sie ist gegeben durch

$$P_\rho = \sum_{n=0}^{\infty} \frac{\rho^n}{n!} \mathrm{e}^{-\rho} \delta_n. \tag{2.78}$$

wobei $\rho > 0$ ein Parameter ist. Die Poissonverteilung hängt mit der Binomialverteilung durch einen Grenzübergang zusammen. So können wir leicht sehen dass, wenn $p = \rho/n$ gewählt wird, die Koeffizienten $P_{n,\rho/n}(k)$ der Binomialverteilung gegen $P_\rho(k)$ (für festes k) konvergieren (im $n \to \infty$ Limes):

$$P_{n,\rho/n}(k) = \frac{n!}{k!(n-k)!} \frac{\rho^k}{n^k} (1 - \rho/n)^{n-k} \to \frac{\rho^k}{k!} \mathrm{e}^{-\rho}, \tag{2.79}$$

denn

$$\frac{n!}{n^k (n-k)!} \to 1 \tag{2.80}$$

und

$$(1 - \rho/n)^n \to \mathrm{e}^{-\rho} \tag{2.81}$$

und $(1 - \rho/n)^{-k} \to 1$.

Wir werden in Kürze sehen, dass solche Grenzwertbildungen von zentralem Interesse in der W-Theorie sind und diese Problematik dementsprechend gründlich behandeln.

Geometrische Verteilung Geo(q).

Dies ist wieder eine Verteilung auf den positiven ganzen Zahlen mit

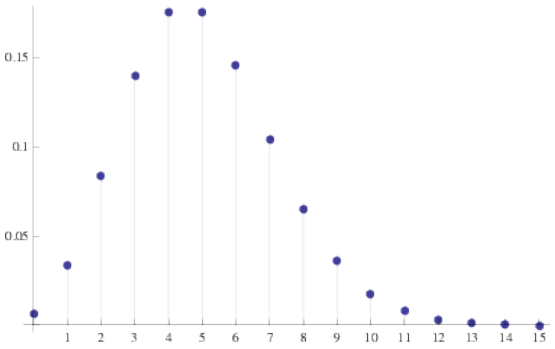


Abb. 2.2 Wahrscheinlichkeiten für Poi($\rho = 5$).

$$P_q(k) = q^k(1-q), \quad k \geq 0. \tag{2.82}$$

Sie hat eine wichtige Interpretation im Kontext des unendlich oft wiederholten Münzwurfs mit Parameter q: Wenn N die Nummer des Münzwurfs bezeichnet, bei dem erstmalig "Zahl" (= 0) erscheint, dann ist

$$\mathbb{P}(\{N = k\}) = q^{k-1}(1-q) = P_q(k-1). \tag{2.83}$$

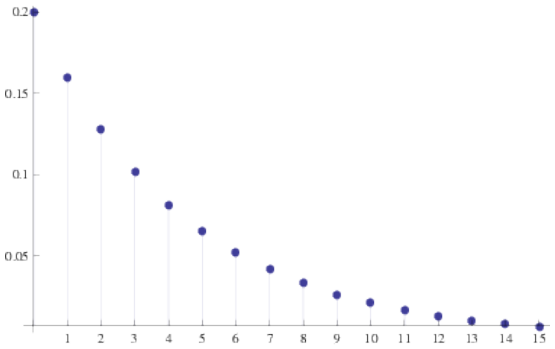


Abb. 2.3 Wahrscheinlichkeiten für Geo($q = 0.2$).

Eine Vielzahl in der Praxis verwendeter Wahrscheinlichkeitsmaße ist absolut stetig. Dies liegt, wenigstens zum Teil, daran, dass diese einfacher zu handhaben sind wenn es um konkrete Berechnungen geht. Wichtige Beispiele sind etwa:

Gleichverteilung $\mathcal{U}_I$.

Für ein Intervall $I \subset \mathbb{R}$ ist die Gleichverteilung auf I definiert als

$$\mathrm{d}P_I(x) = |I|^{-1}\mathbb{1}_I(x)\,\mathrm{d}x \tag{2.84}$$

wo dx für das Lebesgue-Maß steht. Die Funktion $|I|^{-1}\mathbb{1}_I(x)$ ist die Wahrscheinlichkeitsdichte.

Gaußverteilung $\mathcal{N}(m, \sigma^2)$.

Die mit Abstand wichtigste Verteilung hat die Dichte

$$\phi_{m,\sigma^2}(x) \equiv \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-m)^2}{2\sigma^2}\right) \tag{2.85}$$

wobei $m \in \mathbb{R}$ Mittelwert, $\sigma > 0$ Standardabweichung und σ^2 Varianz heißt. Parameter sind auf die wir noch zu sprechen kommen. Aus vielen guten Gründen ist die Gaußverteilung die erste Wahl, wenn es um die Verteilung von Abweichungen um ein typisches Verhalten geht. Der Grund hierfür wird sich bei der Diskussion des zentralen Grenzwertsatzes offenbaren.

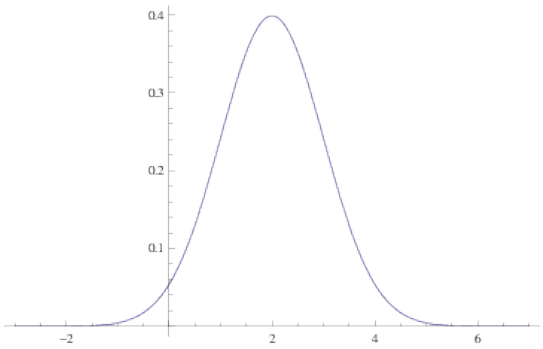


Abb. 2.4 Dichte der Gaussverteilung für $m = 2$ und $\sigma = 1$.

Interessanterweise wurde die Gauß'verteilung von dem in England lebenden Franzosen Abraham de Moivre (26.05.1667–27.11.1754) 1733 als Approximation der Binomialverteilung eingeführt. Gauß benutzte sie erst 1794 (publiziert 1809) in der Fehlerrechnung (Methode der kleinsten Quadrate).

Exponentialverteilung Exp(a).

Hier ist die Dichte

$$\rho(x) = a\mathrm{e}^{-ax}\mathbb{1}_{[0,\infty)}(x) \tag{2.86}$$

Die Exponentialverteilung tritt insbesondere als Verteilung von Wartezeiten gerne auf. Ihr Charakteristikum ist die "Gedächtnislosigkeit". $a > 0$ is ein Parameter.

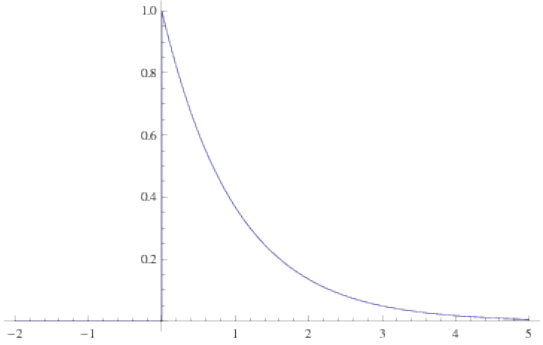


Abb. 2.5 Dichte der Exponentialverteilung mit $a = 1$.

Cauchy-Verteilung Cauchy(a).

Diese hat die Dichte

$$\rho(x) = \frac{a}{\pi}\frac{1}{a^2 + x^2} \tag{2.87}$$

Diese Verteilung zeichnet sich dadurch aus, dass die Funktion $f(x) = x$ nicht gegen $\rho(x)dx$ integrierbar ist (sowohl $\int_{-\infty}^{0}(-x)\rho(x)dx$ als auch $\int_{0}^{\infty} x\rho(x)dx$ sind $+\infty$). Daher hat eine Zufallsvariable, die Cauchy-verteilt ist, keinen endlichen Erwartungswert.

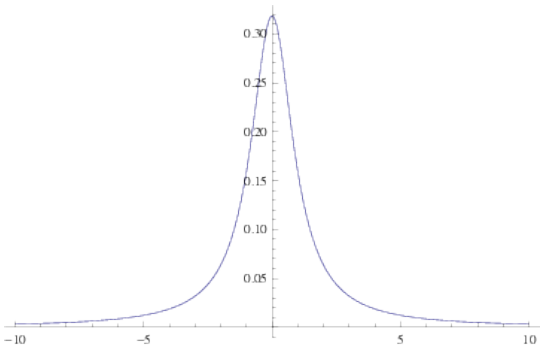


Abb. 2.6 Dichte der Cauchyverteilung mit $a = 1$.

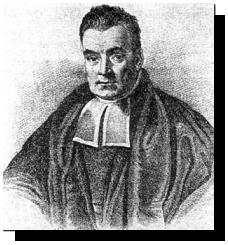
Kapitel 3
Bedingte Wahrscheinlichkeiten, Unabhängigkeit, Produktmaße

Si l'on considère les méthodes analytiques auxquelles cette théorie a donné naissance, la vérité des principes qui lui servent de base, la logique fine et délicate qu'exige leur emploi dans la solution des problemes, les établissements d'utilité publique qui s'appuient sur elle, et l'extension qu'elle a reçue et qu'elle peut recevoir encore par son application aux questions les plus importantes de la Philosopie naturelle et des Sciences morales; si l'on observe ensuite que, dans les choses mêmes qui ne peuvent être soumises au calcul, elle donne les aperçus les plus sûrs qui puissent nous guider dans nos jugements, et qu'elle apprend à se garantir des illusions qui souvent nous égarent, on verra qu'il n'est point de science plus digne des nos méditations et qu'il soit plus utile de faire entrer dans le système de l'instruction publique[a].
Pierre Simon de Laplace, Theorie Analytique des Probabilités

[a] Bedenkt man die analytischen Methoden, die diese Theorie hervorgebracht hat, die Wahrheit der ihr zugrundeliegenden Prinzipien, die feine und delikate Logik, die ihr Gebrauch bei der Lösung von Problemen erfordert, die gemeinnützigen Einrichtungen, die auf ihr beruhen, sowie die Erweiterungen, die sie erfahren hat und durch ihre Anwendung auf die wichtigsten Fragen der Naturphilosopie und der Geisteswissenschaften noch erfahren kann; wenn man weiter beobachtet, dass selbst in den Dingen, die sich der Berechenbarkeit entziehen, sie die sichertesten Erkenntnissen liefert, die unser Urteil lenken können, und dass sie lehrt, sich vor Illusionen, die uns häufig in die Irre führen, zu bewahren, so sieht man, dass es keine Wissenschaft gibt, die unserer Meditationen würdiger wäre, und die in das öffentliche Bildungssystem aufzunehmen nützlicher wäre.

Bisher haben wir Wahrscheinlichkeitstheorie weitgehend wie einen Teil der Analysis behandelt. In diesem Kapitel kommen wir nun zu zentralen Konzepten, die mathematisch die Eigenständigkeit der Wahrscheinlichkeitstheorie begründen.

3.1 Bedingte Wahrscheinlichkeiten



Wir betrachten nunmehr einen beliebigen Wahrscheinlichkeitsraum $(\Omega, \mathfrak{F}, \mathbb{P})$. Es seien $A, B \in \mathfrak{F}$ zwei Ereignisse. Die Wahrscheinlichkeit von $A \cap B$, d.h. das gleichzeitige Eintreten beider Ereignisse ist $\mathbb{P}(A \cap B) \leq \min(\mathbb{P}(A), \mathbb{P}(B))$. Was uns nun interessiert ist, wie Information über das Ereignis B unsere Annahmen über das Ereignis A beeinflussen. Dazu definieren wir die *bedingte Wahrscheinlichkeit:*

Definition 3.1. Sei $(\Omega, \mathfrak{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und seien $A, B \in \mathfrak{F}$. Sei $\mathbb{P}(B) > 0$. Dann heißt

$$\mathbb{P}(A|B) \equiv \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \tag{3.1}$$

die *bedingte Wahrscheinlichkeit* von A gegeben B.

Diese Definition der bedingten Wahrscheinlichkeit ist einleuchtend und kompatibel mit der frequentistischen Interpretation von Wahrscheinlichkeiten: Wenn $\mathbb{P}$ eine empirische Verteilung ist, dann stellt $\mathbb{P}(A|B)$ offenbar die Frequenz des Eintretens von A unter all den Experimenten mit Ausgang in B dar.

Die bedingte Wahrscheinlichkeit hat zwei wichtige Eigenschaften:

Satz 3.2. *Sei $B \in \mathfrak{F}$ mit $\mathbb{P}(B) > 0$.*

(i) Die bedingte Wahrscheinlichkeit, $\mathbb{P}(\cdot|B)$ definiert ein Wahrscheinlichkeitsmaß auf dem Raum $(\Omega, \mathfrak{F})$ mit der Eigenschaft $\mathbb{P}(B|B) = 1$.

(ii) Sei $B_n \in \mathfrak{F}$, $n \in \mathbb{N}$, eine paarweise disjunkte Folge von Mengen, so dass (a) $\cup_{n\in\mathbb{N}} B_n = \Omega$, (b) $\mathbb{P}(B_n) > 0$, für alle n. Dann gilt, dass, für alle $A \in \mathfrak{F}$,

$$\sum_{n\in\mathbb{N}} \mathbb{P}(A|B_n)\mathbb{P}(B_n) = \mathbb{P}(A) \tag{3.2}$$

Beweis. Als nächstes prüfen wir, ob $\mathbb{P}(\cdot|B)$ ein Wahrscheinlichkeitsmaß ist. Offenbar gilt $\mathbb{P}(B|B) = 1$ und $\mathbb{P}(\emptyset|B) = 0$. Weiterhin gilt, dass

$$\begin{aligned}\mathbb{P}(A^c|B) &= \frac{\mathbb{P}(A^c \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B\backslash(A \cap B)}{\mathbb{P}(B)} \\ &= \frac{\mathbb{P}(B) - \mathbb{P}(A \cap B)}{\mathbb{P}(B)} = 1 - \mathbb{P}(A|B).\end{aligned} \tag{3.3}$$

Sei schliesslich $A_n \in \mathfrak{F}$ eine Folge paarweise disjunkter Teilmengen. Dann gilt

$$\mathbb{P}\Big(\bigcup_n A_n \Big| B\Big) = \frac{\mathbb{P}(\cup_n A_n \cap B)}{\mathbb{P}(B)} = \sum_n \frac{\mathbb{P}(A_n \cap B)}{\mathbb{P}(B)} = \sum_n \mathbb{P}(A_n|B), \tag{3.4}$$

und somit gilt (i).

Wegen (ii) schreiben wir

$$\sum_{n\in\mathbb{N}} \mathbb{P}(A|B_n)\mathbb{P}(B_n) = \sum_{n\in\mathbb{N}} \mathbb{P}(A\cap B_n)$$
$$= \mathbb{P}(A\cap \cup_n B_n) = \mathbb{P}(A\cap\Omega) = \mathbb{P}(A). \tag{3.5}$$

□

Anmerkung. Wenn $A\subset B$, dann gilt $\mathbb{P}(A|B) = \mathbb{P}(A)/\mathbb{P}(B)$. Die bedingte Wahrscheinlichkeit kann daher auch als ein Wahrscheinlichkeitsmass auf $(B, \mathfrak{F}\cap B)$, wobei

$$\mathfrak{F}\cap B \equiv \{A\cap B, A\in\mathfrak{F}\} \tag{3.6}$$

ist, angesehen werden.

Die Definition der bedingten Wahrscheinlichkeit legt den Begriff der (stochastischen) Unabhängigkeit nahe.

Definition 3.3. Zwei Ereignisse $A, B\in\mathfrak{F}$ heißen *unabhängig*, genau dann wenn

$$\mathbb{P}(A\cap B) = \mathbb{P}(A)\mathbb{P}(B). \tag{3.7}$$

Falls $\mathbb{P}(B) > 0$ und $\mathbb{P}(A) > 0$, so ist dies gleichbedeutend mit

$$\mathbb{P}(A|B) = \mathbb{P}(A) \text{ und } \mathbb{P}(B|A) = \mathbb{P}(B). \tag{3.8}$$

Allgemeiner heißt eine Familie von Ereignissen, $A_i, i\in I$ mit $I\subseteq\mathbb{N}$ unabhängig genau dann, wenn für jede endliche Familie von Indizes $1\le i_1 < i_2 < \ldots < i_m \in I$ gilt, dass

$$\mathbb{P}\Big(\bigcap_{k=1}^{m} A_{i_k}\Big) = \prod_{k=1}^{m} \mathbb{P}(A_{i_k}) \tag{3.9}$$

Anmerkung. Es genügt nicht, zu fordern, dass für alle $1\le i < j\in I$ die Ereignisse A_i und A_j unabhängig sind. In letzterem Fall sagt man, die Ereignisse seinen *paarweise unabhängig*. Diese Eigenschaft ist strikt schwächer als die Unabhängigkeit.

Anmerkung. Nach unserer Definition sind Mengen vom Maß Null stets unabhängig von allen Mengen. Dieser Fall ist natürlich nicht besonders interessant.

Ein triviales Korollar aus der Definition der bedingten Wahrscheinlichkeit ist die berühmte *Bayes'sche Formel:*

Satz 3.4. *Seien* $A, B\in\mathfrak{F}$ *und* $\mathbb{P}(A) > 0$, $\mathbb{P}(B) > 0$. *Dann gilt*

$$\mathbb{P}(B|A) = \mathbb{P}(A|B)\frac{\mathbb{P}(B)}{\mathbb{P}(A)} \tag{3.10}$$

Beweis. Der Beweis ist trivial. □

Die Formel ist in der Statistik von grosser Bedeutung. Thomas Bayes (1702 - 1761) (siehe das Bild am Kapitelanfang) hat diesen Satz in seinem Werk *"Essay towards solving a problem in the doctrine of chances"* in einem speziellen Fall hergeleitet. Da Bayes von Beruf Priester war, ist sein Interesse an Wahrscheinlichkeiten wohl rein akademischer Natur gewesen. Ein Beispiel soll zeigen, dass man aus ihr durchaus nicht völlig intuitive Ergebnisse gewinnen kann.

Beispiel. Es gibt eine Reihe von un-intuitiven wahrscheinlichkeitstheoretischen Fakten, mit denen man Laien verwirren kann. Eines davon ist das "zwei Umschläge Problem". In zwei geschlossenen Briefumschlägen werden jeweils die Geldbeträge X und $2X$ getan. Ein Spieler wählt einen der Umschläge und darf diesen öffnen. Danach darf er entscheiden, das Geld zu behalten, oder den anderen Umschlag zu nehmen und das dort enthaltene Geld zu behalten. Die naive Antwort ist, dass er immer den anderen Umschlag wählen soll. Das Argument ist dabei, dass wenn er in dem ersten Umschlag den Betrag x gefunden hat, in dem anderen Umschlag mit jeweils Wahrscheinlichkeit $1/2$ die Beträge $x/2$ und $2x$ sind. Damit wird der erwartete Gewinn beim Wechsel $x/4 + x = 5/4x$, was mehr ist als x. Tatsächlich ist diese Argumentation aber falsch. Sie beruht auf der Annahme, dass unabhängig von dem vorgefundenen Betrag x, die Wahrscheinlichkeiten dessen was im zweiten Umschlag ist jeweils gleich sind, was unrealistisch ist. Was passiert nun wenn wir annehmen, dass der Betrag X eine Zufallsvariable ist? Dann haben wir in dem Spiel zwei Zufallsvariablen: Der Geldbetrag X und eine Zufallsvariable Z, die mit gleicher Wahrscheinlichkeit die Werte 1 oder 2 annimmt. Das im ersten Umschlag gefundene Geld ist dann XZ.

Die Aufgabe des Spielers ist nun, zu entscheiden, on $Z = 1$ oder $Z = 2$, nachdem er gesehen hat, dass $ZX = x$ ist, d.h. es gilt zu berechnen $\mathbb{P}(Z = 1|ZX = x)$. Hier können wir nun den Satz von Bayes anwenden:

$$\mathbb{P}(Z = 1|ZX = x) = \mathbb{P}(XZ = x|Z = 1)\,\frac{\mathbb{P}(Z = 1)}{\mathbb{P}(ZX = x)}. \tag{3.11}$$

Nun ist aber

$$\mathbb{P}(ZX = x|Z = 1) = \frac{\mathbb{P}(\{ZX = x\} \cap \{Z = 1\})}{\mathbb{P}(Z = 1)} = \frac{\mathbb{P}(\{X = x\} \cap \{Z = 1\})}{\mathbb{P}(Z = 1)} = \mathbb{P}(\{X = x\}), \tag{3.12}$$

wobei wir benutzt haben, dass wenn $Z = 1$, $ZX = X$ ist, und dass die Ereignisse unabhängig sind, d.h. $\mathbb{P}(\{X = x\} \cap \{Z = 1\}) = \mathbb{P}(\{X = x\})\,\mathbb{P}(\{Z = 1\})$ gilt. Weiter ist $\mathbb{P}(ZX = x) = \frac{1}{2}\mathbb{P}(2X = x) + \frac{1}{2}\mathbb{P}(X = x)$. Damit erhalten wir

$$\mathbb{P}(Z = 1|ZX = x) = \frac{\mathbb{P}(X = x)}{2\mathbb{P}(ZX = x)} = \frac{1}{1 + \frac{\mathbb{P}(X=x/2)}{\mathbb{P}(X=x)}}. \tag{3.13}$$

Damit können wir den Erwartungswert des Inhalts des zweiten Umschlags, gegen dass der erste Umschlag x enthielt ausrechnen. Diese enthält ja $2Y$, fall $Z = 1$ und $Y/2$, falls $Z = 2$. Also ist dieser Erwartungswert gegeben durch

$$2x\mathbb{P}(Z=1|ZX=x)+\frac{x}{2}\mathbb{P}(Z=2|XZ=x)=\frac{x}{2}+\frac{3x}{2}\mathbb{P}(Z=1|XZ=x)=\frac{x}{2}+\frac{3x}{2}\frac{1}{1+\frac{\mathbb{P}(X=x/2)}{\mathbb{P}(X=x)}}. \tag{3.14}$$

Ob diese grösser oder kleiner ist als x hängt vom dem Verhältniss $\frac{\mathbb{P}(X=x/2)}{\mathbb{P}(X=x)}$ ab. Unter vernünftigen Vorraussetzungen wird man davon ausgehen, dass $\frac{\mathbb{P}(X=x/2)}{\mathbb{P}(X=x)} \uparrow \infty$, wenn $x \uparrow \infty$. In diesem Grenzfall wird der bedingte Erwartungswert dann gegen $x/2$ gehen, so dass ein Wechsel bei hohen Werten von x eher nachteilig sein wird.

3.2 Unabhängige Zufallsvariablen

Wir haben bereits den Begriff der Unabhängigkeit für Ereignisse definiert.

Wir erweitern nun diesen Unabhängigkeitsbegriff auf σ-Algebren.

Definition 3.5. Sei $(\Omega, \mathfrak{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und seien $\mathcal{E}, \mathfrak{G} \subset \mathfrak{F}$ Unter-σ-Algebren. Dann sagen wir $\mathcal{E}$ und $\mathfrak{G}$ sind *unabhängig* genau dann, wenn für alle $A \in \mathcal{E}$ und $B \in \mathfrak{G}$ die Ereignisse A und B unabhängig sind.

Zuletzt definieren wir die Unabhängigkeit von Zufallsvariablen. Dazu benötigen wir zunächst den Begriff der von einer Zufallsvariablen erzeugten σ-Algebra.

Definition 3.6. Sei $(\Omega, \mathfrak{F})$ ein Messraum, und $X : \Omega \to \mathbb{R}$ eine messbare Funktion. Sei $\sigma(X)$ die kleinste Unter-σ-Algebra von $\mathfrak{F}$ mit der Eigenschaft dass X bezüglich $\sigma(X)$ messbar ist. Wir sagen $\sigma(X)$ sei die von X erzeugte σ-Algebra.

Lemma 3.7. *Sei X eine reelle Zufallsvariable auf einem Messraum $(\Omega, \mathfrak{F})$. Dann ist $\sigma(X) = X^{-1}(\mathfrak{B}(\mathbb{R}))$, die Menge aller Urbilder von Elementen der Borel'schen σ-Algebra.*

Beweis. Damit X messbar bezüglich $\sigma(X)$ ist, muss jedes Urbild einer Borel-Menge enthalten sein, also gilt $X^{-1}(\mathfrak{B}(\mathbb{R})) \subseteq \sigma(X)$.

Damit ist $\sigma(X)$ die kleinste σ-Algebra, die $X^{-1}(\mathfrak{B}(\mathbb{R}))$ enthält. Andererseits sieht man leicht, dass $X^{-1}(\mathfrak{B}(\mathbb{R}))$ selbst eine σ-Algebra ist. Es ist nämlich

(i) $\Omega = X^{-1}(\mathbb{R}) \in X^{-1}(\mathfrak{B})$;

(ii) Wenn $A = X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\}$, für $B \in \mathfrak{B}$, dann ist

$$A^c = \{\omega \in \Omega : X(\omega) \notin B\} = \{\omega \in \Omega : X(\omega) \in B^c\} = X^{-1}(B^c) \in X^{-1}(\mathfrak{B}); \tag{3.15}$$

(iii) Wenn $(A_n)_{n\in\mathbb{N}}$ in $X^{-1}(\mathfrak{B})$, also für alle $n \in \mathbb{N}$ gibt es $B_n \in \mathfrak{B}$ so dass $A_n = X^{-1}(B_n)$. Dann ist

$$\cup_{n\in\mathbb{N}} A_n = \cup_{n\in\mathbb{N}}\{\omega \in \Omega : X(\omega) \in B_n)\} = \{\omega \in \Omega : X(\omega) \in \cup_{n\in\mathbb{N}} B_n\} \in X^{-1}(\mathfrak{B}), \tag{3.16}$$

weswegen alle Forderungen an eine σ-Algebra erfüllt sind. Daher ist $\sigma(X) = X^{-1}(\mathfrak{B})$. □

Definition 3.8. Sei $(\Omega, \mathfrak{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum, und seien X_1, X_2 Zufallsvariablen. X_1 und X_2 heißen *unabhängig*, genau dann wenn die σ-Algebren $\sigma(X_1)$ und $\sigma(X_2)$ unabhängig sind.

Anmerkung. Da $\sigma(X) = X^{-1}(\mathfrak{B})$, folgt sofort, dass zwei Zufallsvariablen X_1, X_2, genau dann unabhängig sind, wenn für alle Mengen $B_1, B_2 \in \mathfrak{B}$,

$$\mathbb{P}(\{X_1 \in B_1\} \cap \{X_2 \in B_2\}) = \mathbb{P}(\{X_1 \in B_1\})\mathbb{P}(\{X_2 \in B_2\}). \tag{3.17}$$

Das folgende Lemma gibt eine alternative Definition der Unabhängigkeit.

Lemma 3.9. *Sei $(\Omega, \mathfrak{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum, und seien X_1, X_2 Zufallsvariablen. Dann sind X_1 und X_2 genau dann unabhängig, wenn für alle messbaren Funktionen g_1, g_2 von $(\mathbb{R}, \mathfrak{B})$ nach $(\mathbb{R}, \mathfrak{B})$ für die $\int_\Omega |g_i(X_i)| \, \mathrm{d}\mathbb{P} < \infty$, gilt, dass*

$$\int_\Omega g_1(X_1)g_2(X_2) \, \mathrm{d}\mathbb{P} = \int_\Omega g_1(X_1) \, \mathrm{d}\mathbb{P} \int_\Omega g_2(X_2) \, \mathrm{d}\mathbb{P} \tag{3.18}$$

Beweis. Wir bemerken zunächst, dass unter den Annahmen das Satzes $g_i(X_i)$ messbare Abbildungen von $(\Omega, \sigma(X_i))$ nach $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$ sind. Denn offenbar ist $(g_i(X_i))^{-1}(\mathfrak{B}) = X_i^{-1} \circ g_i^{-1}(\mathfrak{B}) \subset X_i^{-1}(\mathfrak{B}) = \sigma(X_i)$. Es seien nun X_1 und X_2 unabhängig. Wir zeigen als erstes, dass (3.18) gilt wenn g_i Indikator-Funktionen sind. Denn für $A_i \in \mathfrak{B}(\mathbb{R})$, $i = 1, 2$, ist

$$\int_\Omega \mathbb{1}_{A_i}(X_i) \, \mathrm{d}\mathbb{P} = \mathbb{P}(X_i \in A_i), \tag{3.19}$$

und

$$\begin{aligned} \int_\Omega \mathbb{1}_{A_1}(X_1)\mathbb{1}_{A_2}(X_2) \, \mathrm{d}\mathbb{P} &= \mathbb{P}(\{X_1 \in A_1\} \cap \{X_2 \in A_2\}) \\ &= \mathbb{P}(X_1 \in A_1)\mathbb{P}(X_2 \in A_2) \end{aligned} \tag{3.20}$$

was sofort (3.18) für diesen Fall liefert.

Als nächstes folgt dann, unter Benutzung der Linearität des Integrals, dass (3.18) für alle positiven einfachen Funktionen gilt.

Der entscheidende Schritt ist jetzt, dass der Satz von der monotonen Konvergenz erlaubt, hieraus die Gültigkeit für positive messbare Funktionen zu zeigen. Dazu seien $h_n^{(i)}$, $i = 1, 2$, zwei monoton (in n) wachsende Folgen einfacher Funktionen die punktweise gegen die positiven messbaren Funktionen g_i konvergieren. Somit ist

$$\int_\Omega g_i(X_i) \, \mathrm{d}\mathbb{P} = \lim_{n\to\infty} \int_\Omega h_n^{(i)}(X_i) \, \mathrm{d}\mathbb{P}. \tag{3.21}$$

Da auch $h_n^{(1)}(X_1)h_n^{(2)}(X_2)$ eine wachsende Folge positiver einfacher Funktionen ist, die gegen $g_1(X_1)g_2(X_2)$ konvergiert, ist auch

$$\int_\Omega g_1(X_1)g_2(X_2) \, \mathrm{d}\mathbb{P} = \lim_{n\to\infty} \int_\Omega h_n^{(1)}(X_1)h_n^{(2)}(X_2) \, \mathrm{d}\mathbb{P}. \tag{3.22}$$

Andererseits ist wegen der Gültigkeit von (3.18) für einfache Funktionen,

$$\begin{aligned}(3.22) &= \lim_{n\to\infty} \int_\Omega h_n^{(1)}(X_1) h_n^{(2)}(X_2)\, \mathrm{d}\mathbb{P} \\ &= \lim_{n\to\infty} \int_\Omega h_n^{(1)}(X_1)\, \mathrm{d}\mathbb{P} \int_\Omega h_n^{(2)}(X_2)\, \mathrm{d}\mathbb{P} \qquad (3.23) \\ &= \lim_{n\to\infty} \int_\Omega h_n^{(1)}(X_1)\, \mathrm{d}\mathbb{P} \lim_{n\to\infty} \int_\Omega h_n^{(2)}(X_2)\, \mathrm{d}\mathbb{P}.\end{aligned}$$

Hieraus folgt (3.18) sofort.

Zum Schluss zeigt man noch mittels der Zerlegung in positive und negative Teile, dass (3.18) auch für allgemeine integrierbare Funktionen gilt.

Es gelte nun umgekehrt (3.18) für alle g_i mit den geforderten Eigenschaften. Dann gilt dies insbesondere wenn g_i Indikatorfunktionen sind. Daraus folgt aber sofort die Unabhängigeit von X_1 und X_2. □

Eine Eigenschaft, die der aus dem Lemma ähnlich sieht, aber deutlich schwächer ist, ist die sogenannte *Unkorreliertheit* von Zufallsvariablen.

Definition 3.10. Sei $(\Omega, \mathfrak{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum, und seien X_1, X_2 Zufallsvariablen. X_1 und X_2 heißen *unkorreliert*, genau dann wenn gilt

$$\int_\Omega X_1 X_2\, \mathrm{d}\mathbb{P} = \int_\Omega X_1\, \mathrm{d}\mathbb{P} \int_\Omega X_2\, \mathrm{d}\mathbb{P}. \qquad (3.24)$$

Offensichtlich ist die Unkorreliertheit viel leichter nachzuprüfen als die Unabhängigkeit. Häufig wird erstere darum auch als erstes Indiz für die Unabhängigkeit benutzt. Allerdings muss man sich klarmachen, dass dieses Indiz keinesfalls schlüssig ist. So seien X, Y zwei unabhängige, gleichverteilte Zufallsvariablen, und $Z_+ \equiv X + Y$, $Z_- \equiv X - Y$. Dann sind Z_+, Z_- unkorreliert. Im allgemeinen sind sie aber nicht unabhängig. Dazu betrachten wir den Fall der Bernoulli Verteilung mit Parameter $p = 1/2$. Dann ist

$$\mathbb{P}(Z_- = 0 | Z_+ = 2) = 1 \quad \text{aber} \quad \mathbb{P}(Z_- = 0 | Z_+ = 1) = 0, \qquad (3.25)$$

was sofort die Unabhängigkeit falsifiziert.

Anmerkung. Wir werden später sehen, dass es genau eine Verteilungsklasse gibt, in der Unkorreliertheit zur Unabhängigkeit äquivalent ist, nämlich die Gaußverteilungen.

Wir können den Unabhängigkeitsbegriff auch auf Familien von Zufallsvariablen erweitern.

Definition 3.11. Sei $(\Omega, \mathfrak{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum.

(i) Eine endliche Familie $X_1, \ldots, X_n$ von Zufallsvariablen heisst unabhängig, falls für alle $B_1, \ldots, B_n \in \mathfrak{B}(\mathbb{R})$ gilt,

$$\mathbb{P}\left(\{X_1 \in B_1\} \cap \cdots \cap \{X_n \in B_n\}\right) = \prod_{k=1}^{n} \mathbb{P}\left(\{X_k \in B_k\}\right). \tag{3.26}$$

(ii) Eine Familie $(X_n)_{n\in\mathbb{N}}$ von Zufallsvariablen heisst unabhängig, falls jede endliche Teilmenge dieser Familie unabhängig ist.

3.3 Produkträume

Unabhängige Zufallsvariablen können wir explizit konstruieren. Dazu betrachten wir zwei Wahrscheinlichkeitsräume, $(\Omega_1, \mathfrak{F}_1, \mathbb{P}_1)$ und $(\Omega_2, \mathfrak{F}_2, \mathbb{P}_2)$ und messbare Funktionen $X_1 : \Omega_1 \to \mathbb{R}$, $X_2 : \Omega_2 \to \mathbb{R}$. Die Idee ist, einen Wahrscheinlichkeitsraum über dem Produktraum $\Omega_1 \times \Omega_2$ zu konstruieren, und X_1 und X_2 zu Abbildungen auf diesem Raum zu erweitern, so dass diese dann unabhängige Zufallsvariablen sind. Dazu führen wir zunächst die entsprechende σ-Algebra ein.

Definition 3.12. Die *Produkt-σ-Algebra*, $\mathfrak{F}_1 \otimes \mathfrak{F}_2$, ist die kleinste σ-Algebra über $\Omega_1 \times \Omega_2$, die alle Mengen der Form $C = A \times B$ mit $A \in \mathfrak{F}_1, B \in \mathfrak{F}_2$ enthält.

Wir nennen Mengen der Form $A\times B$ gelegentlich Rechtecke, obwohl das etwas irreführend ist. Man beachte, dass die Menge aller Rechtecke ein durchschnittsstabiler Erzeuger der Produkt-σ-Algebra ist, da $(A_1 \times B_1) \cap (A_2 \times B_2) = (A_1 \cap A_2) \times (B_1 \cap B_2)$.

Der nächste Schritt ist die Konstruktion eines W-Maßes auf $(\Omega_1 \times \Omega_2, \mathfrak{F}_1 \otimes \mathfrak{F}_2)$ für das die Unter-σ-Algebren $\mathfrak{F}_1 \times \Omega_2$ und $\Omega_1 \times \mathfrak{F}_2$ unabhängig sind (hier ist $\mathfrak{F}_1 \times \Omega_2$ die Menge aller Mengen der Form $A \times \Omega_2$ mit $A \in \mathfrak{F}_1$, etc.).

Sei $C \in \mathfrak{F}_1 \otimes \mathfrak{F}_2$. Für jedes $x \in \Omega_1$ und jedes $y \in \Omega_2$ führen wir die Mengen

$$C_x \equiv \{y \in \Omega_2 : (x, y) \in C\} \tag{3.27}$$

und

$$C^y \equiv \{x \in \Omega_1 : (x, y) \in C\} \tag{3.28}$$

ein. Entsprechend definieren wir auch für jede messbare Funktion X auf $\Omega_1 \times \Omega_2$ für jedes $x \in \Omega_1$ die Funktion $X_x(y) \equiv X(x, y)$ und für jedes $y \in \Omega_2$ die Funktion $X^y(x) \equiv X(x, y)$. Dann gilt folgendes:

Lemma 3.13. *Mit den Definitionen von oben gilt:*

(i) Für jedes $C \in \mathfrak{F}_1 \otimes \mathfrak{F}_2$ und $x \in \Omega_1, y \in \Omega_2$ ist $C_x \in \mathfrak{F}_2$ und $C^y \in \mathfrak{F}_1$.
(ii) Für jede messbare Funktion, $X : \Omega_1 \times \Omega_2 \to \mathbb{R}$, und $x \in \Omega_1, y \in \Omega_2$ ist X_x messbar bezüglich $\mathfrak{F}_2$ und X^y messbar bezüglich $\mathfrak{F}_1$.

Beweis. Wir setzen für $x \in \Omega_1$ (für $y \in \Omega_2$ ist das Beweis analog),

$$\mathfrak{C}_x \equiv \{C \in \mathfrak{F}_1 \otimes \mathfrak{F}_2 : C_x \in \mathfrak{F}_2\}. \tag{3.29}$$

Dann enthält $\mathfrak{C}_x$ sicher die Rechtecke $C = A \times B$ mit $A \in \mathfrak{F}_1$ und $B \in \mathfrak{F}_2$. Denn entweder ist dann $x \in A$ und $C_x = B$, oder $x \notin A$ und $C_x = \emptyset$. In beiden Fällen ist

$C_x \in \mathfrak{F}_2$. Nun kann man andererseits leicht nachweisen, dass $\mathfrak{C}_x$ eine σ-Algebra ist. Da diese aber den Erzeuger von $\mathfrak{F}_1 \otimes \mathfrak{F}_2$ enthält, andererseits per Konstruktion nicht grösser als $\mathfrak{F}_1 \otimes \mathfrak{F}_2$ ist, muss $\mathfrak{C}_x = \mathfrak{F}_1 \otimes \mathfrak{F}_2$ gelten.

Weiter ist für jede messbare Menge $D \in \mathfrak{B}(\mathbb{R})$,

$$\begin{aligned} X_x^{-1}(D) &= \{y \in \Omega_2 : X_x(y) \in D\} = \{y \in \Omega_2 : X(x,y) \in D\} \\ &= \{y \in \Omega_2 : (x,y) \in X^{-1}(D)\} = (X^{-1}(D))_x, \end{aligned} \tag{3.30}$$

die aber nach (i) in $\mathfrak{F}_2$ liegt. Damit ist das Lemma bewiesen. □

Satz 3.14. *Seien $\mathbb{P}_1, \mathbb{P}_2$ Wahrscheinlichkeitsmaße auf $(\Omega_1, \mathfrak{F}_1)$, bzw. $(\Omega_2, \mathfrak{F}_2)$.*

(i) Dann existiert ein einziges Wahrscheinlichkeitsmaß, $\mathbb{P} \equiv \mathbb{P}_1 \otimes \mathbb{P}_2$, genannt das Produktmaß*, auf der Produkt-σ-Algebra $\mathfrak{F}_1 \otimes \mathfrak{F}_2$ mit der Eigenschaft, dass für alle $A \in \mathfrak{F}_1$ und $B \in \mathfrak{F}_2$*

$$\mathbb{P}(A \times B) = \mathbb{P}_1(A)\mathbb{P}_2(B). \tag{3.31}$$

(ii) Wenn $C \in \mathfrak{F}_1 \otimes \mathfrak{F}_2$, so gilt dass

$$\mathbb{P}(C) = \int_{\Omega_1} \mathbb{P}_2(C_x) \mathrm{d}\mathbb{P}_1(x) = \int_{\Omega_2} \mathbb{P}_1(C^y) \mathrm{d}\mathbb{P}_2(y). \tag{3.32}$$

Beweis. Die Tatsache, dass es nur ein Wahrscheinlichkeitsmass geben kann, dass (3.31) erfüllt folgt aus der Tatsache, dass die Mengen der Rechtecke $A \times B$ ein durchschnittsstabiles Mengensystem bilden und $\mathfrak{F}_1 \otimes \mathfrak{F}_2$ erzeugen.

Um die Existenz und die zweite Aussage zu beweisen, setzen wir zunächst für $C \in \mathfrak{F}_1 \otimes \mathfrak{F}_2$

$$\mathbb{P}(C) \equiv \int_{\Omega_1} \mathbb{P}_2(C_x) \mathrm{d}\mathbb{P}_1(x). \tag{3.33}$$

Dies ist wohldefiniert, wenn $\mathbb{P}_2(C_x)$ messbar bzgl. $\mathfrak{F}_1$ ist. In der Tat ist zunächst $\mathbb{P}_2(C_x)$ wohldefiniert, da $C_x \in \mathfrak{F}_2$ wegen Lemma 3.13. Wir definieren nun

$$\mathfrak{G} \equiv \{C \in \mathfrak{F}_1 \otimes \mathfrak{F}_2 : \mathbb{P}_2(C_x) \text{ ist } \mathfrak{F}_1\text{-messbar}\}. \tag{3.34}$$

Für Rechtecke $C = A \times B$ gilt, dass $\mathbb{P}_2(C_x) = \mathbb{1}_A(x)\mathbb{P}_2(B)$, was offenbar eine $\mathfrak{F}_1$-messbare Funktion ist. Daher sind alle solchen Mengen in $\mathfrak{G}$ enthalten. Wir zeigen noch, dass $\mathfrak{G}$ ein Dynkin-System ist. Wir wissen schon, dass $\Omega_1 \times \Omega_2 \in \mathfrak{G}$. Sei $D \supset C$ und beide in $\mathfrak{G}$. Aus der Definition sieht man, dass $(D \setminus C)_x = (D_x \setminus C_x)$, und daher $\mathbb{P}_2((D \setminus C)_x) = \mathbb{P}_2(D_x \setminus C_x) = \mathbb{P}_2(D_x) - \mathbb{P}_2(C_x)$, was auch eine messbare Funktion ist. Somit ist mit mit C und D auch $D \setminus C$ in $\mathfrak{G}$. Weiter ist, wenn $(C_i)_{i\in\mathbb{N}}$ eine abzählbare Familie disjunkter Mengen in $\mathfrak{G}$ ist,

$$(\cup_i C_i)_x = \cup_i (C_i)_x, \tag{3.35}$$

wobei auch die $(C_i)_x$ paarweise disjunkt sind. Mithin ist wegen der σ-Additivität

$$\mathbb{P}_2\left((\cup_i C_i)_x\right) = \sum_i \mathbb{P}_2\left((C_i)_x\right), \tag{3.36}$$

was als abzählbare Summe messbarer Funktionen ebenfalls messbar ist. Damit ist $(\cup_i C_i)_x \in \mathfrak{G}$, und $\mathfrak{G}$ ist ein Dynkin-System, das den durchschnittsstabilen Erzeuger von $\mathfrak{F}_1 \otimes \mathfrak{F}_2$ enthält. Also ist $\mathfrak{G} = \mathfrak{F}_1 \otimes \mathfrak{F}_2$. Damit aber sind alle Funktionen $\mathbb{P}_2(C_x)$ messbar bezüglich $\mathfrak{F}_1$, und $\mathbb{P}(C)$ ist durch (3.33) wohldefiniert. Wir sehen auch, dass, wenn $C = A \times B$ ist,

$$\mathbb{P}(A \times B) = \mathbb{P}_2(B) \int_{\Omega_1} \mathbb{1}_A(x)\mathbb{P}_1(\mathrm{d}x) = \mathbb{P}_2(B)\mathbb{P}_1(A). \tag{3.37}$$

Es bleibt zu zeigen, dass $\mathbb{P}$ ein Wahrscheinlichkeitsmass ist. Wir haben aber schon gesehen, dass für disjunkte Familien C_i, $i \in \mathbb{N}$,

$$\begin{aligned} \mathbb{P}(\cup_i C_i) &= \int_{\Omega_1} \mathbb{P}_2((\cup_i C_i)_x)\mathbb{P}_1(\mathrm{d}x) \\ &= \sum_i \int_{\Omega_1} \mathbb{P}_2((C_i)_x)\mathbb{P}_1(\mathrm{d}x) = \sum_i \mathbb{P}(C_i), \end{aligned} \tag{3.38}$$

d.h. $\mathbb{P}$ ist σ-additiv. Da auch $\mathbb{P}(\Omega_1 \times \Omega_2) = 1$ gilt, ist $\mathbb{P}$ ein W-Maß auf unserem Produktraum, dass der Bedingung (i) des Satzes genügt. Damit ist die Existenz gezeigt. Die alternative Formel in der rechten Seite von (3.32) beweist man in völlig gleicher Weise, und die Gleichheit beider Ausdrücke folgt aus der schon bewiesenen Eindeutigkeit. □

Der Punkt ist nun, dass, wenn X_i Zufallsvariablen auf $(\Omega_i, \mathfrak{F}_i)$, $i = 1, 2$, sind, dann sind $\widehat{X}_1(x, y) \equiv X_1(x)$ und $\widehat{X}_2(x, y) \equiv X_2(y)$ unabhängige Zufallsvariablen auf dem Wahrscheinlichkeitsraum $(\Omega_1 \times \Omega_2, \mathfrak{F}_1 \otimes \mathfrak{F}_2, \mathbb{P}_1 \otimes \mathbb{P}_2)$ sind. Dies ist die kanonische Konstruktion von unabhängigen Zufallsvariablen.

Es ist offensichtlich, dass durch Iteration die obige Konstruktion auf beliebige endliche Produkte von Wahrscheinlichkeitsmaßen ausgedehnt werden kann.

Beispiel. Wir betrachten das Werfen von n Münzen. Der Zustandsraum jeder Münze ist $\Omega_i = \{0, 1\}$. Dann ist der Zustandsraum der n Würfe $\Omega_1 \times \cdots \times \Omega_n = \{0, 1\}^n$. Jede einzelne Münze hat eine Bernoulliverteillung mit Parameter p. Die Zufallsvariablen $X_1, \ldots, X_n$, wo $X_i(\omega_1, \ldots, \omega_n) = \omega_i$ sind dann unter dem n-fachen Produktmaß unabhängig und gleichverteilt.

Beispiel. Sei $\Omega = \mathbb{R}$, dann ist der $\mathbb{R}^n$ ein Produktraum mit $\mathfrak{B}^n$ der Produkt-Borel-σ-Algebra. Das Gauß'sche Maß mit Dichte

$$\frac{1}{(2\pi)^{n/2} \prod_{i=1}^n \sigma_i} \exp\left(-\sum_{i=1}^n \frac{x_i^2}{2\sigma_i^2}\right) \tag{3.39}$$

auf $\mathbb{R}^n$ is dann ein Produktmaß. Die Koordinaten des Vektors $X = (x_1, \ldots, x_n)$ sind dann unabhängige Zufallsvariablen.

Unabhängige Zufallsvariablen sind ein wesentlicher Baustein der Wahrscheinlichkeitstheorie. Vielfach wird im alltäglichen Sprachgebrauch der Begriff Unabhängigkeit mit dem der Zufälligkeit gleichgesetzt. So geht man stillschweigend davon aus, dass die sukzessiven Ausgänge eines Roullettspiels unabhängig sind, und wird dies als den zufälligen Charakter des Spiels betrachten.

Beispiel. (Gewinnen mit bedingter Wahrscheinlichkeit). Ein schönes Beispiel, das zeigt wie man Nutzen aus der Kenntnis des Konzepts der bedingten Wahrscheinlichkeit und Produktmaß ziehen kann, ist folgendes Spiel (dies ist eine Verallgemeinerung des Spiels mit den zwei Umschlägen von oben). Alice schreibt zwei Zahlen, auf je einen Zettel. Dann wirft sie eine faire Münze und zeigt Bob je nach Ausgang des Wurfs entweder den einen oder den anderen Zettel. Nennen wir die gezeigte Zahl im folgenden y und die versteckte Zahl x. Die Aufgabe von Bob besteht darin, zu erraten, ob $x > y$ oder ob $x < y$. Alice bietet Bob eine Wette mit Quote $1 : 2$ an. Soll Bob die Wette annehmen?

Die Antwort auf die Frage ist ja, und zwar weil Bob in der Lage ist, die richtige Antwort mit einer Wahrscheinlichkeit vom mehr als $1/2$ zu geben. Dazu muss er sich nur eine geschickte Strategie ausdenken!

Eine solche Strategie sieht so aus: Bob zieht gemäß einer Gaußverteilung $\mathcal{N}(0, 100)$ eine Zufallszahl, Z. Nun vergleicht er xy mit Z: Wenn $Z \geq y$, so rät er $y < x$, wenn $Z < y$ rät er $x < y$.

Um zu sehen, warum das funktioniert, wollen wir das ganze etwas formalisieren. Gegeben sind zwei Zahlen, $x_0 < x_1$. Ferner gibt es eine Bernoulli Zufallsvariable, B, mit Parameter $1/2$, definiert auf einem W-Raum $(\Omega_1, \mathfrak{F}_1, \mathbb{P}_1)$. Die Bob zugängliche Information ist nur die Zufallsvariable $Y = x_B$. Ziel des Spiels ist es, B zu schätzen, denn wenn Bob B kennt, kann es sagen, ob Y gleich x_0 oder x_1 ist, mithin ob es die grössere oder die kleinere Zahl war. Das bedeutet, dass Bob eine neue Zufallsvariable konstruieren will, die von Y abhängt und B voraussagen lässt. Dazu führt der Spieler einen neuen Wahrscheinlichkeitsraum $(\Omega_2, \mathfrak{F}_2, \mathbb{P}_2)$ ein, auf dem er eine Gauß'sche Zufallsvariable, Z konstruiert. Nun betrachten wir den Raum, $(\Omega_1 \times \Omega_2, \mathfrak{F}_1 \otimes \mathfrak{F}_2, \mathbb{P} \equiv \mathbb{P}_1 \otimes \mathbb{P}_2)$. Auf diesem sind die Zufallsvariablen B und Z unabhängig. Bob's Strategie ist es, auf diesem Produktraum eine neue Zufallsvariable, A, zu konstruieren, deren Wert nur von (den dem Spieler bekannten Werten von) Z und Y abhängt ist, die aber mit B positiv korreliert in dem Sinne, dass

$$\mathbb{P}(A = B) > 1/2. \tag{3.40}$$

Die Wahl von A ist

$$A \equiv \mathbb{1}_{Z<Y} \tag{3.41}$$

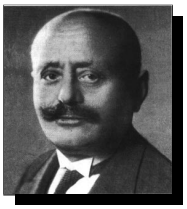
Wir sehen, dass, da Y ja von B abhängt, A und B nicht unabhängig sind. In der Tat ist

Nun können wir benutzen, dass, wenn $B = 1$, $Y = x_1$, und wenn $B = 0$, $Y = x_0$. Also folgt

$$\begin{aligned}\mathbb{P}(A = B) &= \mathbb{P}(\{Z < Y\} \cap \{B = 1\}) + \mathbb{P}(\{Z \geq Y\} \cap \{B = 0\}) \\ &= \frac{1}{2}\mathbb{P}(\{Z < x_B\}|\{B = 1\}) + \frac{1}{2}\mathbb{P}(\{Z \geq x_B\}|\{B = 0\} \\ &= \frac{1}{2}\left(\mathbb{P}_2(Z < x_1) + \mathbb{P}_2(Z \geq x_0)\right) \\ &= \frac{1}{2} + \frac{1}{2}\mathbb{P}_2(x_0 \leq Z < x_1) > \frac{1}{2}.\end{aligned}$$

Das wollten wir aber nur zeigen.

3.4 Der Satz von Fubini



Eines der wichtigsten Hilfmittel zur Berechnung komplizierter Integrale auf Produkträumen ist die Vertauschung der Integrationsreihenfolge. Bedingungen die solche Operationen erlauben sind durch ein nach Guido Fubini (19.01.1879–6.06.1943) benanntes Theorem gegeben.

Der erste Schritt ist ein entsprechender Satz für *positive* Funtionen. Hier braucht es erstaunlicherweise gar keine Voraussetzungen.

Satz 3.15 (Fubini-Tonnelli). *Seien* $(\Omega_1, \mathfrak{F}_1, \mathbb{P}_1)$ *und* $(\Omega_2, \mathfrak{F}_2, \mathbb{P}_2)$ *zwei Wahrscheinlichkeitsräume, und sei* f *eine reellwertige, positive, messbare Funktion auf* $(\Omega_1 \times \Omega_2, \mathfrak{F}_1 \otimes \mathfrak{F}_2)$*. Dann sind die Funktionen*

$$h(x) \equiv \int_{\Omega_2} f(x, y)\mathrm{d}\mathbb{P}_2(y) \quad \textit{und} \quad g(y) \equiv \int_{\Omega_1} f(x, y)\mathrm{d}\mathbb{P}_1(x) \tag{3.42}$$

messbare bezüglich $\mathfrak{F}_1$ *bzw.* $\mathfrak{F}_2$*, und es gilt*

$$\int_{\Omega_1\times\Omega_2} f\,\mathrm{d}(\mathbb{P}_1 \otimes \mathbb{P}_2) = \int_{\Omega_1} h\,\mathrm{d}\mathbb{P}_1 = \int_{\Omega_2} g\,\mathrm{d}\mathbb{P}_2. \tag{3.43}$$

Beweis. Wir beginnen mit den Messbarkeitsaussagen. Für $C \in \mathfrak{F}_1 \otimes \mathfrak{F}_2$ und $f = \mathbb{1}_C$ ist haben wir bereits im Beweis von Theorem 3.14 gesehen, dass

$$h(x) = \int_{\Omega_2} f(x, y)\mathbb{P}_2(\mathrm{d}y) = \mathbb{P}_2(C_x) \tag{3.44}$$

und

$$g(y) = \int_{\Omega_1} f(x, y)\mathbb{P}_1(\mathrm{d}x) = \mathbb{P}_1(C^y) \tag{3.45}$$

messbar sind wir behauptet. Wegen der Linearität des Integrals folgt dann dasselbe für jede einfache Funktion. Schliesslich stellen wir jede messbare positive Funk-

tion als monotonen Limes von einfachen Funktionen dar und schliesst daraus das Resultat im allgemeinen Fall.

Gleichung (3.43) ist im Fall wo f Indikatorfunktion ist schon Teil des Theorems 3.14. Wieder folgt der Fall einfacher Funktionen aus der Linearität und der allgemeine Fall durch Approximation durch monotone Folgen von einfachen Funktionen und der (zweifachen) Anwendung des Satzes von der monotonen Konvergenz.

□

Als nächstes betrachten wir den Fall allgemeiner messbarer Funktionen.

Satz 3.16 (Fubini-Lebesgue). *Sei $f : (\Omega_1 \times \Omega_2, \mathfrak{F}_1 \otimes \mathfrak{F}_2) \to (\mathbb{R}, \mathfrak{B}(\mathbb{R}))$ messbar und absolut integrierbar bezüglich des Produktmasses $\mathbb{P}_1 \otimes \mathbb{P}_2$. Dann ist*

(i) $f(x, y)$ ist für $\mathbb{P}_1$-fast-alle x absolut integrierbar bezüglich $\mathbb{P}_2$, und umgekehrt.
(ii) Die Funktionen

$$h(x) \equiv \int_{\Omega_2} f(x, y) \mathrm{d}\mathbb{P}_2(y) \quad bzw. \quad g(y) \equiv \int_{\Omega_1} f(x, y) \mathrm{d}\mathbb{P}_1(x) \tag{3.46}$$

sind wohldefiniert, ausser möglicherweise auf Mengen vom Maß Null bezüglich $\mathbb{P}_1$ bzw. $\mathbb{P}_2$, und absolut integrierbar bezüglich dieser Maße.
(iii) Es gilt, dass

$$\int_{\Omega_1 \times \Omega_2} f \, \mathrm{d}(\mathbb{P}_1 \otimes \mathbb{P}_2) = \int_{\Omega_1} h(x) \mathrm{d}\mathbb{P}_1(x) = \int_{\Omega_2} g(y) \mathrm{d}\mathbb{P}_2(y). \tag{3.47}$$

Beweis. Indem wir den vorhergehenden Satz auf die Funktion $|f|$ anwenden, erhalten wir, dass

$$\int_{\Omega_1} \left(\int_{\Omega_2} |f(x, y)| \mathrm{d}\mathbb{P}_2(y) \right) \mathrm{d}\mathbb{P}_1(x) = \int_{\Omega_1 \times \Omega_2} |f| \, \mathrm{d}(\mathbb{P}_1 \otimes \mathbb{P}_2) < \infty. \tag{3.48}$$

Daher folgt, dass $\int_{\Omega_2} |f(x, y)| \mathbb{P}_2(\mathrm{d}y)$ nur auf einer Menge vom $\mathbb{P}_1$-Maß null nicht endlich sein kann. Hieraus folgt die erste Behauptung.

Indem wir nun f in den positiven und negativen Teil zerlegen und wieder das Resultat von oben verwenden, finden wir sofort, dass $h(x)$ und $g(y)$ wie behauptet messbar sind (als Differenzen entsprechender messbarer Funktionen), wobei wir genau genommen diesen Funktionen einen beliebigen Wert, etwa 0 für diejenigen x (bzw. y) zuschreiben muss, an denen die die absolute Integrierbarkeit nicht gilt. Da dies Nullmengen sind, spielen sie keine Rolle.

Weiter ist

$$\int_{\Omega_1} |h(x)| \mathrm{d}\mathbb{P}_1(x) \leq \int_{\Omega_1} \left(\int_{\Omega_2} |f(x, y)| \mathrm{d}\mathbb{P}_2(y) \right) \mathrm{d}\mathbb{P}_1(x) < \infty, \tag{3.49}$$

so dass auch die behauptete Integrierbarkeit bewiesen ist.

Um schliesslich den Punkt (iii) zu beweisen genügt es zu benutzen, dass

$$\int_{\Omega_1\times\Omega_2} f \,\mathrm{d}(\mathbb{P}_1\otimes\mathbb{P}_2) = \int_{\Omega_1\times\Omega_2} f_+ \,\mathrm{d}(\mathbb{P}_1\otimes\mathbb{P}_2) - \int_{\Omega_1\times\Omega_2} f_- \,\mathrm{d}(\mathbb{P}_1\otimes\mathbb{P}_2) \tag{3.50}$$

gilt, und den Satz von Fubini-Tonnelli auf beide Terme anzuwenden. □

Anmerkung. In beiden vorgehenden Sätzen ist die Tatsache, dass wir es mit Wahrscheinlichkeitsmaßen zu tun haben nicht wesentlich. Sie gelten auch für allgemeine σ-endliche Maße.

Wenn man sich die Details des Beweises anschaut, sieht man, dass die absolute Integrierbarkeit von f wesentlich benutzt wird. Insbesondere ist andernfalls die Schlussfolgerung im Allgemeinen falsch. Um die absolute Integrierbarkeit von f nachzuweisen, kann man natürlich den Satz von Fubini-Tonnelli auf die Funktion $|f|$ anwenden.

Übung. Zeige, dass die Voraussetzungen des Satzes von Fubini für die Funktion $f(x,y) = 2\mathrm{e}^{-2xy} - \mathrm{e}^{-xy}$ auf $(0,\infty)\times(0,1)$ bezüglich des Lebesguemaßes nicht erfüllt ist.

3.5 Unendliche Produkte

Natürlich würden wir letztlich gerne von der Verteilung von "beliebig", also "unendlich" vielen Zufallsexperimenten, etwa Münzwürfen, sprechen. Ist das wirklich so schwierig? Wir könnten zunächst geneigt sein, diese Frage zu verneinen. Nehmen wir dazu als einfache Räume Ω_i endliche Mengen (etwa $\Omega_i = \{0,1\}$). Die Frage ist dann, was die geeignete σ-Algebra für den unendlichen Produktraum $\bigtimes_{i=1}^{\infty}\Omega_i$ sein soll. Wir könnten uns vorstellen, wie im Falle endlicher Produkte, die Potenzmenge zuwählen. Ein wenig Nachdenken sollte uns aber skeptisch stimmen: es ist ja bekanntlich so, dass der Raum $\{0,1\}^{\mathbb{N}}$ isomorph zu dem Intervall $[0,1]$ ist (bekanntlich via der Abbildung $\omega \equiv (\omega_1,\omega_2,\ldots) \mapsto \sum_{i=1}^{\infty}\omega_i 2^{-i}$); insbesondere ist stets $\Omega^{\mathbb{N}}$ überabzählbar. Würden wir also einen Wahrscheinlichkeitsraum über $\Omega^{\mathbb{N}}$ mit der σ-Algebra der Potenzmenge konstruieren, so hätten wir implizit dasselbe für die reellen Zahlen getan, was aber auf die bekannten Schwierigkeiten stossen muss. Wir müssen also davon ausgehen, dass wir eine kleinere σ-Algebra konstruieren müssen, ähnlich der Borel σ-Algebra im reellen Fall (in der Tat könnte wir dies sogar via obiger Abbildung genau so tun).

Wir wollen uns bei unserem Vorgehen aber lieber von praktischen Erwägungen leiten lassen. Nun ist es ja so, dass wir auch wenn wir unendlich viele Münzwürfe durchführen wollen, uns stets zunächst für den Ausgang der ersten n davon interessieren, d.h. wie betrachten zunächst jeweils nur endlich viele auf einmal. Das heißt, dass unsere σ-Algebra sicher alle endlichen Produkte von Elementen der σ-Algebren der einfachen Mengen Ω_i enthalten soll. Wir können uns ohne weiteres auf den Standpunkt stellen, dass ausser diesen nur das Unvermeidliche noch dazu genommen werden soll, also dass die σ-Algebra $\mathfrak{B}(\times_i\Omega_i)$ gerade die von diesen Mengen erzeugte σ-Algebra sein soll.

Definition 3.17. Seien $(\Omega_i, \mathfrak{F}_i)$, $i \in \mathbb{N}$, Messräume, $\widehat{\Omega} \equiv \times_{i=1}^{\infty} \Omega_i$ der unendlich Produktraum. Dann definieren wir die Produkt-σ-Algebra, $\widehat{\mathfrak{F}}$, über $\widehat{\Omega}$ als die kleinste σ-Algebra, die alle Teilmengen von $\widehat{\Omega}$ der Form

$$A = \times_{i\in I} A_i \times_{j\notin I} \Omega_j \tag{3.51}$$

enthält, wo $A_i \in \mathfrak{F}_i$ und $I = (i_1, \ldots, i_k) \subset \mathbb{N}$ endlich ist. Die Mengen A der Form (3.51) heißen *Zylindermengen*.

Satz 3.18. *Seien $(\Omega_i, \mathfrak{F}_i, \mathbb{P}_i), i \in \mathbb{N}$, Wahrscheinlichkeitsräume. Dann existiert ein einziges Wahrscheinlichkeitsmaß, $\widehat{\mathbb{P}} \equiv \otimes_i \mathbb{P}_i$, genannt das Produktmaß, auf $(\widehat{\Omega}, \widehat{\mathfrak{F}})$ mit der Eigenschaft, dass für alle Zylindermengen A der Form (3.51)*

$$\widehat{\mathbb{P}}(A) = \prod_{i\in I} \mathbb{P}_i(A_i). \tag{3.52}$$

Wir werden den Existenzbeweis an dieser Stelle nicht geben. Die Eindeutigkeit folgt aus Satz 2.15, da die Zylindermengen ein durchschnittsstabiles Mengensystem sind.

Die Produkt-σ-Algebra enthält eine äusserst reiche Klasse von Mengen, jedoch ist sie wieder, und zwar selbst in dem Fall, dass Ω endlich ist, kleiner als die Potenzmenge. In der Tat ist sie ihrer Natur nach der Borel'schen σ-Algebra vergleichbar. In der Tat gilt folgender Satz, den wir hier aber nicht beweisen wollen.

Satz 3.19. *Seien Ω_i, $i \in \mathbb{N}$, metrische Räume (etwa $\Omega_i = \mathbb{R}$), und $\mathfrak{B}(\Omega_i)$ die zugehörigen Borel'schen σ-Algebren. Dann kann der unendliche Produktraum $\widehat{\Omega} \equiv \times_i \Omega_i$ mit einer Metrik versehen werden, so dass die Produkt-σ-Algebra die Borel'sche σ-Algebra bezüglich $\widehat{\Omega}$ ist, d.h. es ist die von den offenen Mengen bezüglich der metrischen Topologie erzeugte σ-Algebra.*

In anderen Worten, die Produkt-σ-Algebra enthält alle offenen Mengen (und somit auch alle abgeschlossenen Mengen) bezüglich der *Produktopologie* auf $\widehat{\Omega}$. Für unsere Zwecke heißt das letztlich einfach: keine Angst vor unendlichen Produkträumen, sie sind nicht schlimmer als die reellen Zahlen!

Übung. Benutze den Isomorphismus $I : \{0,1\}^{\mathbb{N}} \to [0,1]$, $I(\omega) = \sum_{i=1}^{\infty} \omega_i 2^{-i}$ und das Beispiel einer nicht-Borel'schen Menge aus Kapitel 2, um eine Menge in $\{0,1\}^{\mathbb{N}}$ zu konstruieren, die nicht in der Produkt-σ-Algebra enthalten ist.

Wir können mittels der Konstruktion unendlicher Produkträume nun unendliche Folgen von Zufallsvariablen konstruieren.

Definition 3.20. Sei $(\Omega, \mathfrak{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum. Eine Folge $X = (X_n)_{n\in\mathbb{N}}$ von messbaren Abbildungen von $\Omega \to \mathbb{R}$, heisst (reelle) *Zufallsfolge* oder ein *stochastischer Prozess* (mit diskreter Zeit). Eine Zufallsfolge heißt eine Folge *unabhängiger Zufallsvariablen*, wenn die $(X_n)_{n\in\mathbb{N}}$ unabhängig sind.

Anmerkung. Aus Satz 3.18 folgt, dass wir abzählbare Folgen von unabhängigen Zufallsvariablen auf einem geeigneten Wahrscheinlichlichkeitsraum konstruieren können. Dazu nehmen wir den Produktraume $(\widehat{\Omega}, \widehat{\mathfrak{F}}, \widehat{\mathbb{P}})$ und die messbaren Abbildungen $X_n : \Omega_n \to \mathbb{R}$. Aus diesen konstruieren wir die Zufallsvariablen $\widehat{X}_n : \widehat{\Omega} \to \mathbb{R}$ durch $\widehat{X}_n(\omega) \equiv X_n(\omega_n)$, $n \in \mathbb{N}$. Man prüft leicht nach, dass diese unabhängig sind und die gleiche Verteilung wie X_n haben.

Anmerkung. Wir können auch einen etwas anderen Standpunkt einnehmen und eine stochastischen Prozess als messbare Abbildung, $X : (\Omega, \mathfrak{F}) \to (\mathbb{R}^{\mathbb{N}}, \mathfrak{B}(\mathbb{R}^{\mathbb{N}}))$ definieren. Dieser ist dann eine Folge von unabhängigen Zufallsvariablen, wenn das Bildmass $P_X \equiv \mathbb{P} \circ X^{-1}$ ein Produktmass auf $(\mathbb{R}^{\mathbb{N}}, \mathfrak{B}(\mathbb{R}^{\mathbb{N}}))$ ist. Sind die Verteilungen der Komponentenfunktionen darüber hinaus identisch, so heißt die Folge eine Folge unabhängiger, identisch verteilter Zufallsvariablen.

Anmerkung. Die Definition einer Familie unabhängiger (reeller) Zufallsvariablen können wir auch so formulieren: $X = (X_i, i \in \mathbb{N})$ ist eine Folge unabhängiger Zufallsvariablen genau dann, wenn für jedes $n \in \mathbb{N}$ für beliebige messbare Funktionen $h_i : \Omega \to \mathbb{R}$ gilt, dass

$$\mathbb{E}\left[\prod_{i=1}^{n} h_i(X_i)\right] = \prod_{i=1}^{n} \mathbb{E}\left[h_i(X_i)\right]. \tag{3.53}$$

Übung: Beweisen Sie die Aussage in der Anmerkung!!

Unendliche Folgen unabhängiger Zufallsvariablen sind die wichtigsten Bausteine der Wahrscheinlichkeitstheorie. Mit ihrer Hilfe können wir insbesondere die Folge der Ergebnisse von (beliebig oft) wiederholten identischen Zufallsexperimenten modellieren, also etwa wiederholte Münzwürfe, Roulettespiele, etc.

Kapitel 4
Summen von unabhängigen Zufallsvariablen

Ein weiter Teil der Wahrscheinlichkeitstheorie behandelt die Eigenschaften von Funktionen von unabhängigen Zufallsvariablen. Insbesondere deren Summen, aber auch anderer, wie etwa der Maxima. Im Folgenden werden wir uns auf Eigenschaften von Summen unabhängiger, gleichverteilter Zufallsvariablen konzentrieren.

Seien $X_1, \ldots, X_n$ unabhängige Zufallsvariablen mit Verteilung $\mathbb{P}$. Eine naheliegende Frage ist, was ist die Verteilung der Zufallsvariablen

$$S_n \equiv \sum_{i=1}^{n} X_i \tag{4.1}$$

Beispiel. Seien X_i unabhängige Bernoulli Variablen mit Parameter p. In diesem Fall können wir die Verteilung von S_n elementar kombinatorisch bestimmen:

$$\mathbb{P}(S_n = k) = \tag{4.2}$$
$$\mathbb{P}(\text{“}k \text{ der Variablen nehmen den Wert 1 an, alle anderen den Wert 0”})$$

Also ist

$$\begin{aligned}\mathbb{P}(S_n = k) &= \sum_{(i_1,\ldots,i_k)\subset(1,\ldots,n)} \mathbb{P}(\forall_{j=1}^{k} X_{i_j} = 1, \forall_{l\notin\{i_1,\ldots,i_k\}} X_l = 0) \\ &= \binom{n}{k} p^k (1-p)^{n-k}, \end{aligned} \tag{4.3}$$

d.h. S_n is binomial verteilt mit Parametern n, p.

4.1 Die Irrfahrt

Gerne betrachten wir eine leichte Abwandlung der Summe S_n: Wir wählen statt der Bernoulli-Variablen X_i die (manchmal[1]) sogenannten *Rademacher Variablen*, Y_i, mit der Eigenschaft, dass

$$\mathbb{P}(Y_i = 1) = 1 - \mathbb{P}(Y_i = -1) = p, \tag{4.4}$$

wobei der Fall $p = 1/2$ von besonderem Interesse ist. In diesem Fall nennen wir die Folge von Zufallsvariablem

$$S_n = \sum_{i=1}^{n} Y_i \tag{4.5}$$

die *einfache (falls $p = 1/2$ symmetrische) Irrfahrt* auf $\mathbb{Z}$. Beachte dass die Folge S_n, $n \in \mathbb{N}$ selbst wieder eine Zufallsfolge ist, allerdings natürlich keine unabhängigen. S_n ist unser erster *stochastische Prozess* neben unabhängigen Zufallsvariablen.

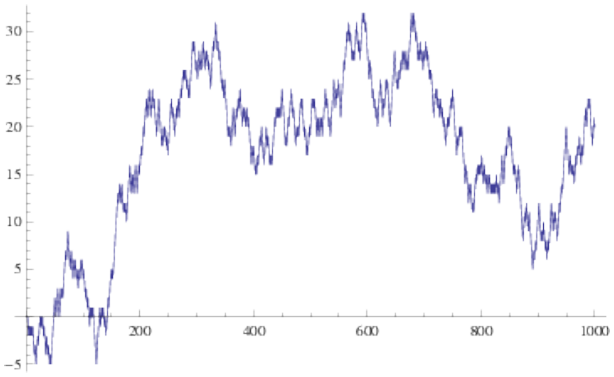


Abb. 4.1 Eine Realisierung der symmetrischen Irrfahrt: Abbildung von $\{(k, S_k), 0 \leq k \leq n = 1000\}$.

Das Interesse an S_n ist in natürlicher Weise dadurch begründet, dass es die Entwicklung des Gewinns (oder Verlustes) eines Spielers darstellt, der wiederholt auf den Ausgang von Münzwürfen wettet und dabei jeweils einen festen Betrag, 1, setzt, wobei die Bank ihm im Gewinnfalle den doppelten Betrag auszahlt (d.h., die Bank bewertet das Spiel so, als wäre die Münze fair, also $p = 1/2$).

Unser Formalismus, d.h. die Modellierung von wiederholten Spielen durch unabhängige Zufallsvariablen, erlaubt es uns nun nicht nur einzelne Spiele, sondern ganze Folgen von Spielen zu analysieren. An dieser Stelle ist es vielleicht interessant, zwei Beispiele von Resultaten, die wir damit erhalten können zu betrachten.

Beispiel: Strategien. Ein Spieler könnte versuchen, seine Gewinnchancen in einer Folge von Spielen zu verbessern, indem er in irgendeiner Weise statt immer auf

[1] Oft werden auch die folgenden Rademacher Variablen als Bernoulli Variablen bezeichnet.

Kopf zu setzen, wahlweise auf Kopf oder Zahl setzt. Eine solche Strategie ist dann gegeben durch eine Folge $a_i \in \{0,1\}$, $i \in \mathbb{N}$. Gegeben eine solche Strategie ist die Auszahlung im i-ten Spiel

$$r(i) \equiv 2\mathbb{1}_{X_i=a_i} - 1. \tag{4.6}$$

Es ist klar, dass, wenn die Folge a_i von vorneherein festgesetzt wird, die $r(i)$ unabhängige Rademachervariablen sind, der akkumulierte Gewinn also die gleiche Verteilung für jede Wahl der Folge a_i hat. Nun könnte aber der Spieler seine Strategie dem Spielverlauf anpassen, d.h. a_k könnte als Funktion der Ausgänge der vorangegangenen Spiele gewählt werden (etwa $a_i = X_{i-1}$), d.h. $a_k = a_k(X_1, \ldots, X_{k-1})$. (Natürlich kann a_k von X_k nur dann abhängen, wenn der Spieler betrügt (bzw. "Insiderwissen" hat)). Interessanterweise ist auch damit nichts gewonnen, und die Auszahlungen $r(i)$ bleiben unabhängige Rademachervariablen.

Satz 4.1. *Sei a_k, $k \in \mathbb{N}$, eine Folge von bezüglich der von den Bernoulli Zufallsvariablen $X_1, \ldots, X_{k-1}$ erzeugten σ-Algebren (im weiteren $\mathfrak{F}_{k-1}$ genannt) messbaren Funktionen mit Werten in $\{0,1\}$. Dann ist die durch (4.6) definierte Folge von Zufallsvariablen unabhängig.*

Beweis. Da alle Zufallsvariablen nur die Werte ± 1 annehmen, genügt es zu zeigen, dass für alle $k \in \mathbb{N}$, und jede Wahl von $s_1, \ldots, s_k \in \pm 1$,

$$\mathbb{P}\left(r(k) = s_k \wedge r(k-1) = s_{k-1} \wedge \cdots \wedge r(1) = s_1\right) = \prod_{i=1}^{k} \mathbb{P}\left(r(i) = s_i\right) = 2^{-k}, \tag{4.7}$$

gilt. Nun ist aber

$$\begin{aligned} &\mathbb{P}\left(r(k) = s_k \wedge r(n-1) = s_{k-1} \wedge \cdots \wedge r(1) = s_1\right) \\ &= \mathbb{P}\left(r(k) = s_k | r(k-1) = s_{k-1} \wedge \cdots \wedge r(1) = s_1\right) \\ &\quad \times \mathbb{P}\left(r(k-1) = s_{k-1} \wedge \cdots \wedge r(1) = s_1\right), \end{aligned} \tag{4.8}$$

woraus (4.8) rekursiv folgt, sofern wir nur zeigen, dass

$$\mathbb{P}\left(r(k) = s_k | r(k-1) = s_{k-1} \wedge \cdots \wedge r(1) = s_1\right) = \frac{1}{2}. \tag{4.9}$$

Nun ist aber klar, dass $r(i)$ nur von X_i und a_i abhängt, welche wiederum nur von den $X_1, \ldots, X_{i-1}$ abhängen. Damit ist die von $r(1), \ldots, r(k-1)$ erzeugte σ-Algebra in $\mathfrak{F}_{k-1}$ enthalten. Sei nun $R_k \in \sigma(r(1), \ldots, r(k-1))$. Dann ist

$$\begin{aligned} &\mathbb{P}(r(k) = 1 | R_k) = \mathbb{P}(X_k = a_k | R_k) \\ &= \frac{\mathbb{P}(\{X_k = 0\} \cap \{a_k = 0\} \cap R_k)}{\mathbb{P}(R_k)} + \frac{\mathbb{P}(\{X_k = 1\} \cap \{a_k = 1\} \cap R_k)}{\mathbb{P}(R_k)} \\ &= \frac{1}{2}\mathbb{P}(a_k = 0 | R_k) + \frac{1}{2}\mathbb{P}(a_k = 1 | R_k) = \frac{1}{2}, \end{aligned} \tag{4.10}$$

da nämlich das Ereignis $r(k) = 1$ nur von X_k und a_k abhängt und $\{X_k = i\}$ von $a_k = i$ und B_k unabhängig sind. Genauso ist

$$\mathbb{P}(r(k) = -1|R_k) = \mathbb{P}(X_k \neq a_k|R_k) = 1/2, \tag{4.11}$$

was die Aussage beweist. □

4.2 Optionspreise

Wir kommen im Kontext der Irrfahrt wieder auf unser Problem der Bewertung von Wetten zurück. Dazu betrachten wir eine Summe, S_n, von unabhängigen Rademacher Zufallsvariablen, Y_n, mit Parameter p. Diese stelle den Logarithmus des Wertes einer Aktie zum Zeitpunkt n dar. Das heißt, der Kurs der Aktie

$$W_n = \exp\left(\delta \sum_{i=1}^{n} Y_i\right) = \exp(\delta S_n), \tag{4.12}$$

wo $\delta > 0$ ein Parameter ist. Eine (europäische) Option ist eine Wette auf den Wert, S_N (bzw W_N), zu einem festen Zeitpunkt N. Der Begeber der Option (etwa eine Bank) verpflichtet sich, dem Optionsinhaber, einen Betrag $F(x) \geq 0$ auszuzahlen, wenn $S_N = x$ (aus Bequemlichkeit denken wir lieber an F als Funktion von S_N statt von W_N). Das Problem besteht darin, zu bestimmen, was der *Wert* der Option ist, d.h. was der niedrigste Preis, V, ist, der es der Bank möglich macht, mit der Option die Option ohne Verlustrisiko verkauft werden kann.

Anmerkung. Klassische "call" bzw. "put" Optionen bestehen in dem Recht, zum Zeitpunkt N die Aktie zum Preis W_c zu kaufen, bzw. zum Preis W_p zu verkaufen. Man sieht, dass dies den Funktionen $F(S_N) = (W_N - W_c)_+$, bzw. $F(S_N) = -(W_p - W_N)_+$ entspricht. Die Theorie der Optionspreisbewertung hat dazu geführt, dass auch viel "exotischere" Optionen angeboten werden. Dabei hofft der Optionsgeber, dem Kunden eine überteuerte Option verkaufen zu können, um so selbst einen sicheren Gewinn zu erwirtschaften.

Wie ist das überhaupt möglich? Um risikofrei wetten zu können, müssen wir in der Lage sein, eine Zufallsvariable zu konstruieren, die mit Sicherheit grösser oder gleich dem Wert der Auzahlung der Option, $F(S_N)$ ist. Genauer gesagt, die Bank verkauft die Option zur Zeit $n = 0$ zum Preis V_0, und investiert einen Teil dieser Summe, a_0 in die Aktie. Am nächsten Zeitpunkt, $n = 1$, hat sie dann das Kapital $V_1 = V_0 - a_0 + a_0 e^{Y_1 \delta}$; von diesem wird wieder ein Teil, a_1 in die Aktie investiert, und so weiter. Dann entwickelt sich ein Anfangskapital V_0 mit der Zeit wie

$$V_n = V_0 + \sum_{i=1}^{n} a_{i-1}(e^{\delta Y_i} - 1). \tag{4.13}$$

Wenn wir also die Option zum Preis V_0 verkaufen, und sicherstellen können, durch geeignete Wahl der a_i am Ende $V_N \geq F(S_N)$ zu erzielen, dann können wir offenbar $F(S_N)$ bezahlen, und haben sogar noch den Betrag $V_N - F(S_N)$ als Gewinn übrig. Man bezeichnet eine solche Reproduktionsstrategie auch gerne als *"hedging"*. Der minimale oder "faire" Preis der Option ergibt sich aus der Forderung, dass $V_N = F(S_N)$ gelten soll.

Dass so etwas möglich ist, wollen wir im einfachsten Fall, wo S_n die gewöhnliche Irrfahrt ist, nachprüfen. Wir wollen im Folgenden mit $V_n(x)$ den "Wert" der Option zum Zeitpunkt n bezeichnen, wenn $S_n = x$ ist.

Dazu betrachten wir zunächst den letzten Zeitschritt. Zum Zeitpunkt $N-1$ sei $S_{N-1} = x$. Unser Kapital zu diesem Zeitpunkt sei K. Dann wollen wir einen Betrag a in die Aktie so investieren, dass unser Kapital zum Zeitpunkt N gerade $F(S_N)$ ist, und zwar unabhängig davon, ob im letzten Schritt die Aktie steigt oder fällt. Das heißt, K und a müssen so gewählt sein, dass

$$F(x+1) = K + a(\mathrm{e}^{\delta} - 1), \quad \text{und} \quad F(x-1) = K + a(\mathrm{e}^{-\delta} - 1) \tag{4.14}$$

gelten. Dieses Gleichungen sind aber leicht zu lösen, mit

$$\begin{aligned} a = a(x) &= \frac{1}{2}\left[F(x+1) - F(x-1)\right] / \sinh\delta \qquad (4.15)\\ K = K(x) &= \frac{1}{2}\left[F(x+1) + F(x-1)\right] - a(x)(\cosh\delta - 1)\\ &= \left[\frac{1-\mathrm{e}^{-\delta}}{\mathrm{e}^{\delta}-\mathrm{e}^{-\delta}}F(x+1) + \frac{\mathrm{e}^{\delta}-1}{\mathrm{e}^{\delta}-\mathrm{e}^{-\delta}}F(x-1)\right] \end{aligned}$$

$K(x)$ is dann der faire Preis der Option zum Zeitpunkt $N-1$, wenn $S_{N-1} = x$.

Anmerkung. Die Lösung des Gleichungssystems (**??**) ist auch die Lösung des Ungleichungssystems

$$F(x+1) \leq K + a(\mathrm{e}^{\delta} - 1), \quad \text{und} \quad F(x-1) \leq K + a(\mathrm{e}^{-\delta} - 1) \tag{4.16}$$

mit dem kleinsten Wert für K.

Als nächstes können wir berechnen, wieviel Kapital zum Zeitpunkt $N-2$ nötig ist, um zum Zeitpunkt $N-1$ den Betrag $V_{N-1}(S_{N-1})$ zur Verfügung zu haben, wenn wir wissen, dass $S_{N-2} = x$, unabhängig davon was im nächsten Schritt passiert, d.h. wir müssen im Zeitpunkt $N-2$ eine Strategie fahren, die uns sicherstellt, dass wenn $S_{N-2} = x$,

$$V_{N-1}(x \pm 1) = V_{N-2}(x) + a_{N-1}(x)(\mathrm{e}^{\pm\delta} - 1). \tag{4.17}$$

Iterativ folgt, dass

$$a_{j-1}(x) = \frac{1}{2}\Big[V_j(x+1) - V_j(x-1)\Big] / \sinh\delta \tag{4.18}$$

$$V_{j-1}(x) = \frac{1-\mathrm{e}^{-\delta}}{\mathrm{e}^{\delta}-\mathrm{e}^{-\delta}}V_j(x+1) + \frac{\mathrm{e}^{\delta}-1}{\mathrm{e}^{\delta}-\mathrm{e}^{-\delta}}V_j(x-1), \tag{4.19}$$

bis wir schliesslich V_0 erreichen.

Beachte, dass die Rekursion für V_j geschlossen ist, und wir a_j nicht notwendig berechnen müssen. Wir können diese in der Form

$$V_{j-1}(x) = \mathbb{E}_{p^*} V_j(x + Y_j) \tag{4.20}$$

wo $\mathbb{E}_{p^*}$ die Erwartung bezüglich einer neuen Verteilung der Zufallslvariablen Y_j ist, für die

$$p^* = \mathbb{P}_{p^*}(Y_1 = 1) = \frac{1 - \mathrm{e}^{-\delta}}{\mathrm{e}^{\delta} - \mathrm{e}^{-\delta}}, \quad \mathbb{P}_{p^*}(Y_1 = -1) = 1 - p^*. \tag{4.21}$$

Damit können wir Schlussresultat in der Form

$$V_0 = \mathbb{E}_{p^*} F(S_N) \tag{4.22}$$

schreiben, wobei $S_N = \sum_{i=1}^{N} Y_i$ und Y_i unabhängige Zufallsvariablen mit Verteilung $\mathbb{P}_{p^*}$ sind.

Wie man leicht nachrechnet, ist diese neue Verteilung dadurch charakterisiert, dass $\mathbb{E}_{p^*} \mathrm{e}^{\delta Y_i} = 1$ gilt. Die Formel (4.22) heisst die *Black-Sholes* Formel in der Optionspreistheorie. Es mag vielleicht noch überraschender sein, dass wir die Formel (4.22) auch ohne viel zu rechnen herleiten können. Wir beobachten dazu, dass (4.13) mit Koeffizienten a_i die $\mathfrak{F}_i$, messbar sind, also nur von $Y_1, \ldots, Y_i$ abhängen, die einzigen zulässigen Investmentstrategien darstellen. Nehmen wir nun an, dass es möglich ist a_i so zu finden, dass

$$V_N = F(S_N) \tag{4.23}$$

gilt. Dann ist für jedes Produktmass $\mathbb{P}_p$ mit $\mathbb{P}_p(Y_i = 1) = p$ und $\mathbb{P}_p(Y_i = -1) = 1 - p$,

$$\mathbb{E}_p F(S_n) = \mathbb{E}_p V_n = V_0 + \sum_{i=1}^{n} \mathbb{E}_p(a_{i-1}) \mathbb{E}_p \left(\mathrm{e}^{\delta Y_i} - 1 \right). \tag{4.24}$$

Wählen wir nun $p = p^*$, so erhalten wir

$$\mathbb{E}_{p^*} F(S_N) = V_0. \tag{4.25}$$

Diese Beobachtung ist viel allgemeiner als unser spezielles Modell für den Aktienkurs. Sie sagt, dass, für jedes Modell mit unabhängigen Zuwächsen des Aktienkurses, für dass es eine zulässige Anlagestrategie gibt, die die Option zur Zeit n exakt reproduziert, gilt die Gleichung (4.22) für dasjenige Maß, unter dem die Zuwächse Erwartungswert Null haben. Das Maß $\mathbb{E}_{p^*}$ ist in der Optionspreistheorie als "äquivalentes Martingalmaß" bekannt. Beachte, dass der Parameter p der ursprünglichen Verteilung der Zufallsvariablen Y_i nirgendwo eine Rolle gespielt hat!

In dieser zweiten Herleitung der Optionspreisformel wird die Hedging-Strategie a gar nicht mehr berechnet. Allerdings setzten wir voraus, dass es eine solche Strategie gibt! Man bezeichnet ein Modell, in dem solche Strategien existieren als *vollständigen Markt*.

Übung. Wir haben bisher angenommen, dass das nicht investierte Kapital mit einem Zinssatz Null verzinst wird. Wie ändern sich die obigen Resultate, wenn das nicht in die Aktie inverstierte Kapital mit einem Zinssatz q verzinst wird?

Das hier betrachtete Modell für W_n ist sehr unrealistisch. Tatsächlich aber ist das Grundprinzip, das wir hier dargelegt haben, die Grundlage der modernen Optionspreistheorie.

4.3 Das Ruin-Problem

Eine andere Form der Spielstrategie ist es, solange zu spielen, bis entweder ein festgesetzter Gewinn oder Verlust erreicht wird. Wir gehen davon aus, dass ein Spieler ein Anfangskapital $V > 0$ besitzt und nun solange spielt bis er entweder sein Kapital auf $G > V$ vermehrt hat, oder alles verloren hat und nicht mehr weiterspielen kann erreicht ist. Sei also $K(0) = V$ als das Anfangskapital des Spielers. Wir nehmen an, dass nach jedem Spiel das Kapital um einen Betrag $X_i \in \{-1, +1\}$ anwächst, wobei X_i unabhängige, identisch verteilte (Rademacher) Zufallsvariablen mit $\mathbb{P}(X_i = 1) = p = 1 - \mathbb{P}(X_i = -1)$ seien. Dann ist das Kapital des Spielers zum Zeitpunkt n gegeben durch die Zufallsvariable $K(n) = K(0) + S_n$, wo wieder $S_n = \sum_{i=1}^{n} X_i$.

In einem solchen Spiel können wir die Frage stellen, wie wahrscheinlich es ist, dass die Spielfolge mit dem Ruin des Spielers endet. Wir sehen dass hier die Anzahl der Spiele nicht von vorherein feststeht, wir also wirklich eine Frage im unendlichen Produktraum $\{-1, 1\}^{\mathbb{N}}$ stellen.

Wie können wir das gesuchte Ereignis formal beschreiben: Dazu legen wir zunächst den Wert, n, an dem das Spiel endet fest, und betrachten dann die Vereinigung über alle diese Werte. Wir setzen also

$$A_n = \{S_n = -V\} \bigcap_{k=1}^{n-1} \{-V < S_k < G - V\} \tag{4.26}$$

und unser gesuchtes Ereignis ist

$$A = \bigcup_{n=1}^{\infty} A_n. \tag{4.27}$$

Wir sehen sofort an der Konstruktion, dass $A \in \widehat{\mathfrak{F}}$ ist.

Es gibt allerdings eine in mancher Hinsicht einfachere Beschreibung desselben Ereignisses:

$$\begin{aligned} A &= \{\inf\{n : S_n = -V\} < \inf\{n : S_n = G - V\}\} \\ &= \{\inf\{n : K(n) = 0\} < \inf\{n : K(n) = G\}\}. \end{aligned}$$

Mathematisch formuliert sieht unsere Frage wie folgt aus: Was ist $\mathbb{P}(A)$?

Diese Frage sieht zunächst nach einem äusserst üblen kombinatorischen Problem aus. Zum Glück kann man sich das mühsame Zählen sparen, wenn man geschickt vorgeht.

Nun können wir zunächst einmal in Gedanken das erste Spiel ausführen. Mit Wahrscheinlichkeit von je p bzw. $1-p$ ist nach dem ersten Spiel das Kapital, $K(1)$, des Spielers gleich $K(0)+1$ bzw. $K(0)-1$. Wenn $K(1)=0$ ist, so ist das Spiel beendet, und A ist eingetreten, während im Falle $K(1)=G$, das Spiel ebenfalls beendet ist, aber A nicht eingetreten ist. In allen Anderen Fällen wird weitergespielt wie zuvor, nur dass jetzt das Anfangskapital $K(1)$ ist. Wir sehen daher, dass es sinnvoll ist, die Wahrscheinlichkeit von A als Funktion des Anfangskapitals einzuführen. Wir setzen dazu

$$h(K) = \mathbb{P}\left(\inf\{n : K(n) = 0\} < \inf\{n : K(n) = G\} \middle| K(0) = K\right), \tag{4.28}$$

falls $0 < K < G$; es wird zweckmässig sein $h(0) = 1$ und $h(G) = 0$ zu setzen. Dann ist die gesuchte Wahrscheinlichkeit gegeben durch

$$\mathbb{P}(A) = h(V). \tag{4.29}$$

Aus den obigen Überlegungen erhalten wir die Gleichung

$$\begin{aligned} h(K) &= (1-p)\mathbb{1}_{K=1} + (1-p)\mathbb{1}_{K>1}h(K-1) + p\mathbb{1}_{K<G-1}h(K+1) \\ &\quad + 0 \times p\,\mathbb{1}_{K=G-1} \\ &= (1-p)h(K-1) + ph(K+1), \end{aligned} \tag{4.30}$$

für $0 < K < G$. Da die "Randwerte" $h(0) = 1$ und $h(G) = 0$ festgelegt ist, stellt (4.30) eine *diskretes Randwertaufgabe* dar, die in Analogie zu der entsprechenden Differentialgleichung auch *Dirichletproblem* genannt wird.

Die Lösung dieser Aufgabe kann man leicht über eine Rekursion erhalten (Übung!). Im einfachsten Fall, wenn $p = 1/2$, ist

$$h(K) = 1 - K/G \tag{4.31}$$

wie man leicht nachprüft. Aus (4.29) folgt

$$\mathbb{P}(A) = (G-V)/G \quad \text{für } p = 1/2. \tag{4.32}$$

4.4 Das Arcussinusgesetz

Ein interessantes, weil nicht intuitives Resultat über die einfache Irrfahrt ist das sogenannte Arcussinusgesetz. Wir betrachten wieder die Irrfahrt, $S_n = \sum_{i=1}^{n} X_i$, wo X_i unabhängige Rademachervariablen mit Parameter $1/2$ sind. Die Frage, die wir uns stellen wollen ist die nach dem Verhältnis der Zeit, die eine solche Irrfahrt positiv, bzw. negativ ist. Man sollte denken, dass mit grosser Wahrscheinlichkeit diese Zei-

ten in etwa gleich sind. Tatsächlich aber gilt der folgende Satz. Wir sagen, dass die Irrfahrt zur Zeit i in der Gewinnzone ist, wenn entweder $S_i > 0$ ist oder $S_{i+1} > 0$ ist.

Satz 4.2. *Sei S die einfache symmetrische Irrfahrt. Sei $p_{2k,2n}$ die Wahrscheinlichkeit, bis zur Zeit $2n$ $2k$-mal in der Gewinnzone zu sein, d.h.*

$$p_{2k,2n} \equiv \mathbb{P}\left(\sum_{i=1}^{2n} Y_i = 2k\right). \tag{4.33}$$

wo $Y_i \equiv \mathbb{1}_{\{S_i>0\}\vee\{S_{i+1}>0\}}$.

$$p_{2k,2n} = 2^{-2k}\binom{2k}{k}2^{-2(n-k)}\binom{2(n-k)}{n-k} \tag{4.34}$$

Beweis. Sei $0 < k < n$. Dann muss die Irrfahrt irgendwann die Null-Linie kreuzen, und dies insbesondere irgendwann zum ersten Mal tun. Sei f_{2r} die Wahrscheinlichkeit, dass die erste Rückkehr der Irrfahrt nach 0 zur Zeit $2r$ passiert,

$$f_{2r} = \mathbb{P}(\inf(i > 0 : S_i = 0) = 2r). \tag{4.35}$$

Bis zu dieser Zeit ist S_i entweder stets positiv, oder stets negativ. Beides tritt mit gleicher Wahrscheinlichkeit ein. Im Fall, dass sie bis $2r$ positiv bleibt, kann r nicht grösser sein als k, und im umgekehrten Fall nicht grösser als $n - k$. Nach der ersten Rückkehr nach Null sieht im weiteren alles so aus wie am Anfang, nur dass wir nur noch $2n - 2r$ Schritte zu tun haben. Also haben wir

$$p_{2k,2n} = \frac{1}{2}\sum_{r=1}^{k} f_{2r}p_{2k-2r,2n-2r} + \frac{1}{2}\sum_{r=1}^{n-k} f_{2r}p_{2k,2n-2r}. \tag{4.36}$$

Wir versuchen diese Rekursion lösen, ohne zunächst f_{2r} zu berechnen. Dazu bemerken wir zunächst, dass

$$\mathbb{P}(S_{2n} = 0) = \frac{1}{2^{2n}}\binom{2n}{n} \equiv u_{2n}. \tag{4.37}$$

Ausserdem ist

$$u_{2n} = \mathbb{P}(S_{2n} = 0) = \sum_{r=1}^{n} f_{2r}\mathbb{P}(S_{2n-2r} = 0) = \sum_{r=1}^{n} f_{2r}u_{2n-2r}. \tag{4.38}$$

Die Aussage des Satzes ist also $p_{2k,2n} = u_{2k}u_{2n-2k}$.

Nun können wir unseren Satz per Induktion beweisen. Dazu nehmen wir als Induktionshypothese and, dass wir diese Gleichung bereits für alle $m \leq n - 1$ und alle $0 < k < m$ gezeigt. Dann sind alle p, die in der Gleichung (4.36) für $p_{2k,2n}$ mit $0 < k < n$ auf der rechten Seite auftreten bekannt, ausser dem Term mit $r = k$ in der ersten Summe und dem mit $r = n - k$ in der zweiten Summe. Dort haben wir nämlich $p_{0,2(n-k)}$ bzw. $p_{2k,2k}$.

Wir zeigen daher zunächst die Induktionsvorraussetzung, dass für alle $n \in \mathbb{N}$, $p_{0,2n} = p_{2n,2n} = u_{2n}$.

Nun ist S_ℓ nie in der Gewinnzone, wenn er niemals die Null-Achse durchstösst, also

$$p_{0,2n} = \mathbb{P}\left[\forall_{k\leq 2n} S_k \leq 0\right] = \mathbb{P}\left[\forall_{k\leq 2n} S_k \geq 0\right]. \tag{4.39}$$

Die letztere Wahrscheinlichkeit kann mit der Wahrscheinlichkeit, dass S_k stets strikt positiv bleibt verknüpft werden. Offensichtlich ist

$$\begin{aligned}\mathbb{P}\left[\forall_{k\leq 2n} S_k \geq 0\right] &= 1 - \mathbb{P}\left(\exists_{r\leq n} S_{2r-1} < 0, S_k \geq 0, \forall_{k<2r-1}\right) \\ &= 1 - \sum_{r\leq n} \mathbb{P}\left(S_{2r-1} > 0, S_k \geq 0, \forall_{k<2r-1}\right).\end{aligned} \tag{4.40}$$

Nun kann man sich aber überlegen, dass

$$\mathbb{P}\left(S_{2r-1} < 0, S_k \geq 0, \forall_{k<2r-1}\right) = f_{2r}. \tag{4.41}$$

Denn wenn S_{2r-1} erstmals negativ ist, so muss $S_{2r-1} = -1$ sein. Addiert man nun einen ersten positiven Schritt an den Anfang eines Pfades der hier beiträgt, erhält man genau einen Beitrag zu f_{2r}. Wir haben also

$$p_{0,2n} = 1 - \sum_{r=1}^{n} f_{2r}. \tag{4.42}$$

Wir müssen also doch f_{2r} berechnen. Dies ist natürlich auch von unabhängigem Interesse.

Lemma 4.3. *Sei S_n eine symmetrische einfache Irrfahrt und f_{2r} definiert durch (4.35). Dann gilt*

$$f_{2r} = \frac{1}{2r} u_{2r} = u_{2r-2} - u_{2r}. \tag{4.43}$$

Beweis. Wir betrachten dazu zunächst die Wahrscheinlichkeit

$$g_{2n} \equiv \mathbb{P}\left[\forall_{1\leq k\leq 2n-1} S_k > 0 \wedge S_{2n} = 0\right]. \tag{4.44}$$

Es ist aber klar, dass $f_{2n} = 2g_{2n}$. Offenbar ist

$$g_{2n} = \frac{1}{2}\mathbb{P}\left[S_k > 0, \forall_{1\leq k\leq 2n-2} \wedge S_{2n-1} = 1\right]. \tag{4.45}$$

Weiter ist

$$\begin{aligned}&\mathbb{P}\left[S_k > 0, \forall_{1\leq k\leq 2n-2} \wedge S_{2n-1} = 1\right] \\ &= \mathbb{P}\left[S_1 = 1 \wedge S_{2n-1} = 1\right] - \mathbb{P}\left[S_1 = 1 \wedge \exists_{1<k\leq 2n-2} : S_k \leq 0 \wedge S_{2n-1} = 1\right].\end{aligned} \tag{4.46}$$

Der erste Term auf der rechten Seite ist elementar zu berechnen:

$$\mathbb{P}\left[S_1 = 1 \wedge S_{2n-1} = 1\right] = 2^{-2n+1}\binom{2n-2}{n-1}. \tag{4.47}$$

Für den zweiten Term benutzen wir eine elementare geometrische Überlegung, die als *Reflektionsprinzip* bekannt ist:

$$\begin{aligned}&\mathbb{P}\left[S_1 = 1 \wedge \exists_{1<k\leq 2n-2} : S_k \leq 0 \wedge S_{2n-1} = 1\right] \\ &= \mathbb{P}\left[S_1 = 1 \wedge S_{2n-1} = -1\right].\end{aligned} \tag{4.48}$$

Um dies zu sehen, bemerken wir, dass jeder Pfad der zuerst eine Schritt nach oben macht und in -1 ankommt, irgendwann erstmals die Null treffen muss, Wenn wir dann von dort an den gespiegelten Pfad betrachten, so kommt dieser in $+1$ an und trägt genau in der ersten Wahrscheinlichkeit bei. (Siehe Abbildung 4.2). Die letzte

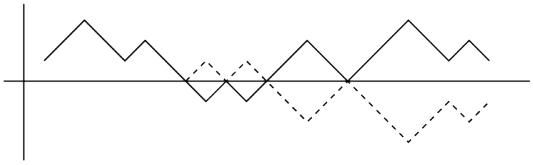


Abb. 4.2 Illustrations des Reflexionsprinzips.

Wahrscheinlichkeit ist wieder elementar,

$$\mathbb{P}\left[S_1 = 1 \wedge S_{2n-1} = -1\right] = 2^{-2n+1}\binom{2n-2}{n}, \tag{4.49}$$

so dass schliesslich

$$\begin{aligned}f_{2n} = 2g_n &= 2^{-2n}\left(\binom{2n-2}{n-1} - \binom{2n-2}{n}\right) \\ &= 2^{-2n}\frac{1}{n}\binom{2n-2}{n-1} = \frac{1}{2n}u_{2n-2}.\end{aligned} \tag{4.50}$$

Schliesslich ist $f_{2r} = u_{2r-2} - u_{2r}$ leicht nachzurechnen.

Setzen wir dieses Resultat in (4.42) ein, erhalten wir $p_{0,2n} = u_{2n}$, wie gewünscht.

Wir kommen nun zum Induktionsschritt und nehmen an, dass für $m \leq n-1$ und für alle $0 < k < m$ gilt, dass

$$p_{2k,2m} = u_{2k}u_{2m-2k}. \tag{4.51}$$

Dann folgt für $m = n$ und alle $0 < k < n$, unter Benutzung der Induktionsvoraussetzung und der Induktionshypothese, dass

$$p_{2k,2n} = \frac{1}{2}u_{2n-2k}\sum_{r=1}^{k} f_{2r}u_{2k-2r} + \frac{1}{2}u_{2k}\sum_{r=1}^{n-k} f_{2r}u_{2n-2k-2r}, \tag{4.52}$$

Beide Summen können wir dann mittels (4.38) berechnen und erhalten

$$p_{2k,2n} = \frac{1}{2}u_{2k}u_{2n-2k} + \frac{1}{2}u_{2k}u_{2n-2k} = u_{2n-2k}u_{2k}, \tag{4.53}$$

wie behauptet. □

Anmerkung. Im Beweis haben wir das sogenannte Reflexionsprinzip entdeckt, dass für viele Berechnungen zu Irrfahrten nützlich ist.

Asymptotisches Verhalten für grosse n, k. Mittels der Approximation der Binomialkoeffizienten durch die Stirlingformel,

$$n! \sim \sqrt{2\pi n}\, n^n \mathrm{e}^{-n}, \tag{4.54}$$

erhalten wir für grosse n und k

$$p_{2k,2n} \sim \frac{1}{\pi\sqrt{k}\sqrt{n-k}} = n^{-1}\frac{1}{\pi\sqrt{k/n}\sqrt{1-k/n}}. \tag{4.55}$$

Mithin ist die Wahrscheinlichkeit, dass k/n zwischen $1/2$ und $\alpha > 1/2$ liegt

$$\begin{aligned}\sum_{n/2\le k\le \alpha n} p_{2k,2n} &\sim \frac{1}{\pi n}\sum_{n/2\le k\le \alpha n}\frac{1}{\sqrt{k/n}\sqrt{1-k/n}} \\ &\sim \pi^{-1}\int_{1/2}^{\alpha}\frac{\mathrm{d}x}{\sqrt{x(1-x)}} = \frac{2}{\pi}\arcsin\sqrt{\alpha} - \frac{1}{2}.\end{aligned} \tag{4.56}$$

Aus Symmetriegründen ist gilt das gleiche für $0 < \alpha \le 1/2$.

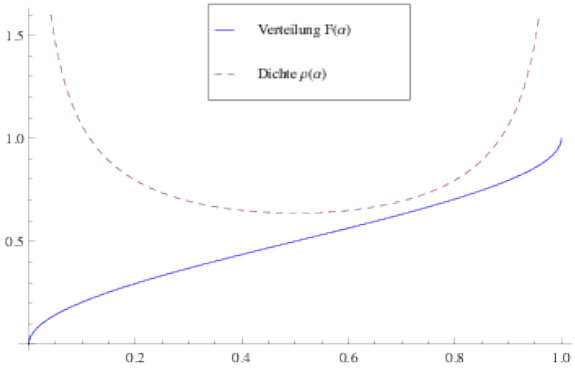


Abb. 4.3 Die Arcussinusverteilung.

So ist die asymptotische Verteilungsfunktion $F(\alpha)$ gegeben durch

$$F(\alpha) \equiv \lim_{n\to\infty}\mathbb{P}\left(\sum_{i=1}^{2n} Y_1 \le \alpha n\right) = \frac{2}{\pi}\arcsin\sqrt{\alpha} \tag{4.57}$$

und hat Wahrscheinlichkeitsdichte (siehe Fig. 4.3)

$$\rho(\alpha) = \frac{d}{d\alpha} F(\alpha) = \frac{1}{\pi \sqrt{\alpha(1-\alpha)}}. \tag{4.58}$$

Die Botschaft dieser Rechnung ist, dass die Irrfahrt mit hoher Wahrscheinlichkeit sehr einseitig ist, während der ausgeglichene Fall, halb positiv, halb negativ, kaum vorkommt (siehe Fig. 4.4)).

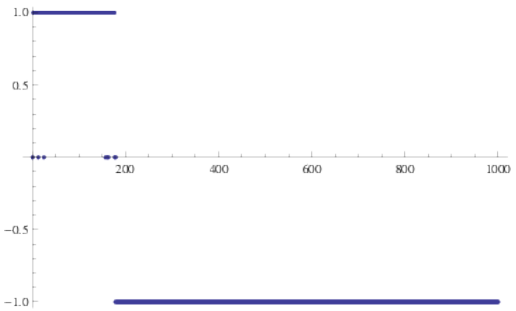


Abb. 4.4 Eine Realisierungen von $\mathrm{sign}\,(S_n)$.

4.5 Faltungen

Für die Verteilungsfunktion der Summe zweier unabhängiger Zufallsvariablen ergibt sich in einfacher Weise der folgende Ausdruck. Seien F_X, F_Y, F_{X+Y} die Verteilungsfunktionen der jeweiligen Variablen, dann ist

$$\begin{aligned} F_{X+Y}(a) &= \int_{\mathbb{R}^2} \mathbb{1}_{x+y\le a} \mathrm{d}P_X(x) \otimes \mathrm{d}P_Y(y) = \int_{\mathbb{R}} \left(\int_{\mathbb{R}} \mathbb{1}_{x\le a-y} \mathrm{d}P_X(x) \right) \mathrm{d}P_Y(y) \\ &= \int_{\mathbb{R}} F_X(a-y)\, \mathrm{d}P_Y(y) = \int_{\mathbb{R}} F_Y(a-x)\, \mathrm{d}P_X(x). \end{aligned} \tag{4.59}$$

Hier haben wir den Satz von Fubini-Tonelli benutzt um das Integral bezüglich des Produktmaßes sukzessive auszuführen. Die letzte Gleichung folgt indem wir die Integrationen bez. x und y in umgekehrter Reihenfolge ausführen. Man nennt die Verteilung F_{X+Y} auch *Faltung* der Verteilungsfunktionen F_X und F_Y und schreibt $F_{X+Y} = F_X \star F_Y$.

Wenn die Zufallsvariablen X und Y Verteilungen mit Dichten ρ_X, ρ_Y haben, prüft man leicht nach, dass

$$\rho_{X+Y}(z) = \int_{\mathbb{R}} \rho_X(z-x)\rho_Y(x)\mathrm{d}x = \int_{\mathbb{R}} \rho_Y(z-x)\rho_X(x)\mathrm{d}x \tag{4.60}$$

gilt.

Man kann sich die Frage stellen, ob es Typen von Verteilungen gibt, die unter der Faltungsoperation invariant bleiben. Solche Verteilungen nennt man *stabil*. Wir werden diese Frage hier nicht im allgemeinen untersuchen, sondern nur ein wichtiges Beispiel betrachten.

Satz 4.4 (Stabilität der Gaußverteilung). *Seien X_1, X_2 zwei unabhängige Gauß'sche Zufallsvariablen mit Varianz σ_1^2, σ_2^2 und Mittelwerten m_1, m_2. Dann ist $X_1 + X_2$ Gaußverteilt mit Mittelwert $m_1 + m_2$ und Varianz $\sigma_1^2 + \sigma_2^2$.*

Beweis. Zum Beweis benutzen wir die Formel (4.60) für die Dichte der Faltung. Wir sehen dass

$$\rho_{X_1+X_2-m_1-m_2}(z) = \frac{1}{2\pi\sigma_1\sigma_2} \int_{\mathbb{R}} \mathrm{d}x \exp\left(-\frac{(z-x)^2}{2\sigma_2^2} - \frac{x^2}{2\sigma_1^2}\right). \tag{4.61}$$

Nun benutzen wir nur noch, dass

$$\begin{aligned}
\frac{(z-x)^2}{\sigma_2^2} + \frac{x^2}{\sigma_1^2} &= \frac{z^2\sigma_1^2 + x^2(\sigma_1^2+\sigma_2^2) - 2xz\sigma_1^2}{\sigma_2^2\sigma_1^2} \\
&= \frac{z^2\left(\sigma_1^2 - \frac{\sigma_1^4}{\sigma_1^2+\sigma_2^2}\right) + (\sigma_1^2+\sigma_2^2)\left(x - \frac{z\sigma_1^2}{\sigma_1^2+\sigma_2^2}\right)^2}{\sigma_1^2\sigma_2^2} \\
&= \frac{z^2}{\sigma_1^2+\sigma_2^2} + \frac{(\sigma_1^2+\sigma_2^2)\left(x - \frac{z\sigma_1^2}{\sigma_1^2+\sigma_2^2}\right)^2}{\sigma_1^2\sigma_2^2}.
\end{aligned}$$

Wenn wir diese Gleichung in (4.61) einsetzen und die Integration über x ausführen, erhalten wir

$$\rho_{X_1+X_2-m_1-m_2}(z) = \frac{1}{\sqrt{2\pi(\sigma_1^2+\sigma_2^2)}} \exp\left(-\frac{z^2}{2(\sigma_1^2+\sigma_2^2)}\right). \tag{4.62}$$

Da

$$\rho_{X_1+X_2}(z) = \rho_{X_1+X_2-m_1-m_2}(z - m_1 - m_2) \tag{4.63}$$

gilt, erhalten wir die Dichte einer Gaußverteilung mit Varianz $\sigma_1^2+\sigma_2^2$ und Mittelwert $m_1 + m_2$. □

Korollar 4.5. *Seien $X_i, i \in \mathbb{N}$ unabhängige Gauß'sche Zufallsvariablen mit Varianz σ^2 und Mittelwert 0. Dann hat $n^{-1/2}(X_1 + \cdots + X_n)$ dieselbe Verteilung wie X_1.*

Anmerkung. Stabilität einer Klasse von Verteilungen lässt sich auch mit Hilfe der sogenannten charakteristischen Funktionen (die wir in Kapitel 7 einführen werden, siehe Beispiel 7.5) bestimmen.

Die Gaußverteilung ist nicht die einzige Verteilungsfunktion, die stabil bezüglich Faltung ist: Seien X und Y unabhängig, dann:

- $X \sim \text{Poi}(\lambda_1)$ und $Y \sim \text{Poi}(\lambda_2) \Rightarrow X + Y \sim \text{Poi}(\lambda_1 + \lambda_2)$
- $X \sim \text{Bin}(n_1, p)$ und $Y \sim \text{Bin}(n_2, p) \Rightarrow X + Y \sim \text{Bin}(n_2 + n_2, p)$
- $X \sim \text{Cauchy}(a_1)$ und $Y \sim \text{Cauchy}(a_2) \Rightarrow X + Y \sim \text{Cauchy}(a_1 + a_2)$

Dagegen ist die Exponentialverteilung nicht stabil.

Kapitel 5
Konvergenzbegriffe

Un des points les plus importants de la Théorie des Probabilités, et celui qui prète le plus aux illusions, est la manière dont les probabilités augmentent ou dimunuent par leurs combinaisons mutuelles[a].
Pierre Simon de Laplace, Théorie Analytique des Probabilités

[a] Einer der wichtigsten Punkte in der Wahrscheinlichkeitstheorie, und derjenige, der am meissten Anlass zu Irrglauben gibt, ist die Art, in der Wahrscheinlichkeiten aufgrund ihrer gegenseitigen Verknüpfungen anwachsen oder abnehmen.

Wie immer in der Analysis ist auch in der Wahrscheinlichkeitstheorie der Konvergenzbegriff ein ganz zentrales Konzept. Dabei gibt es einige Besonderheiten, und es ist sinnvoll, sich die Begrifflichkeiten von Anfang an klar zu machen. Wir werden in der Folge dann verschiedene wichtige Beispiele kennenlernen.

5.1 Konvergenz von Verteilungsfunktionen

Wahrscheinlichkeitsmaße waren die ersten Objekte die wie kennengelernt haben. Klarerweise ist die Konvergenz von Folgen von Wahrscheinlichkeitsmaßen nun auch das erste, was wir betrachten müssen.

Wir wollen dafür zunächst nur Wahrscheinlichkeitsmaße auf $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$, also Verteilungen von reellwertigen Zufallsvariablen, betrachten. Wir hatten gesehen, dass diese eindeutig durch ihre Verteilungsfunktionen charakterisiert sind. Daher können wir diese auch zur Definition von Konvergenz heranziehen.

Definition 5.1. Seien F_n, $n \in \mathbb{N}$ eine Folge von Verteilungsfunktionen. Dann konvergiert F_n *schwach* gegen eine Verteilungsfunktion F, genau dann wenn

$$F_n(c) \to F(c), \tag{5.1}$$

für alle $c \in \mathbb{R}$ für welche F stetig ist.

Die Einschränkung der Konvergenzforderung auf die Stetigkeitstellen der Funktion F mag zunächst überraschen. Doch wissen wir ja, dass die einzigen Unstetigkeiten von F Sprungstellen sind, an denen F rechtststetig ist. Nun kann man sich leicht Funktionenfolgen konstruieren, die an den Unstetigkeitstellen nicht konvergieren, oder keinen rechtstetigen Limes haben. Zum Beispiel konvergiert die Folge von Verteilungsfunktionen $F_n(x) = (1 + \tanh(nx))/2$ gegen eine nicht-rechtstetige Funktion

$$\lim_{n\to\infty} F_n(x) = \begin{cases} 0, & \text{für } x < 0, \\ 1/2, & \text{für } x = 0, \\ 1, & \text{für } x > 0. \end{cases} \tag{5.2}$$

Dann würde man dennoch die rechtsstetige Variante als Limes akzeptieren wollen, d.h. F_n konvergiert schwach gegen $F(x) = \mathbb{1}_{x\geq 0}$.

Schwache Konvergenz von Verteilungsfunktionen ist äquivalent zur schwachen Konvergenz von Wahrscheinlichkeitsmaßen, die wie folgt definiert wird:

Definition 5.2. Sei Ω ein topologischer Raum und $\mathfrak{B}(\Omega)$ die Borel-σ-Algebra. Sei $\mathbb{P}_n$ eine Folge von Wahrscheinlichkeitsmaßen auf $(\Omega, \mathfrak{B}(\Omega))$. Dann konvergiert $\mathbb{P}_n$ *schwach* gegen ein Wahrscheinlichleitsmaß $\mathbb{P}$ AUC $(\Omega, \mathfrak{B}(\Omega))$, genau dann wenn für alle beschränkten *stetigen* Funktionen $g : \Omega \to \mathbb{R}$,

$$\int_\Omega g \, \mathrm{d}\mathbb{P}_n \to \int_\Omega g \, \mathrm{d}\mathbb{P}. \tag{5.3}$$

Der Zusammenhang ist durch den folgend Satz gegeben:

Satz 5.3. *Sei $\mathbb{P}_n$, $n \in \mathbb{N}$, eine Folge von Wahrscheinlichkeitsmaßen auf $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$ und seien F_n die zugehörigen Verteilungsfunktionen. Dann konvergiert $\mathbb{P}_n$* schwach *gegen ein Wahrscheinlichkeitsmaß $\mathbb{P}$ mit Verteilungsfunktion F genau dann, wenn die Folge F_n schwach gegen F konvergiert.*

Beweis. Wir zeigen zuerst, dass aus $\mathbb{P}_n$ schwach gegen $\mathbb{P}$ konvergiert folgt, dass $F_n(c) \to F(c)$, für alle $c \in \mathbb{R}$ an denen F stetig ist. Dazu definieren wir für jedes $\epsilon > 0$ eine stetige Funktion g_ϵ mit der Eigenschaft

$$\mathbb{1}_{x\leq c} \leq g_\epsilon(x) \leq \mathbb{1}_{x\leq c+\epsilon} \tag{5.4}$$

(zum Beispier durch lineare Interpolation). Dann gilt

$$F_n(c) \leq \int_{\mathbb{R}} g_\epsilon(x) \, \mathrm{d}\mathbb{P}_n(x) \to \int_{\mathbb{R}} g_\epsilon(x) \, \mathrm{d}\mathbb{P}(x) \leq F(c+\epsilon). \tag{5.5}$$

Daher ist für jedes $\epsilon > 0$, $\limsup_{n\to\infty} F_n(c) \leq F(c+\epsilon)$. Daraus folgt, da F bei c stetig ist, $\limsup_{n\to\infty} F_n(c) \leq F(c)$. Analog zeigt man, dass $\liminf_{n\to\infty} F_n(c) \geq F(c-\epsilon)$ für jedes $\epsilon > 0$, und so $\lim_{n\to\infty} F_n(c) = F(c)$.

Der Beweis des Umkehrschlusses folgt im Wesentlichen durch Approximation einer stetigen Funktion durch einfache Funktionen. Zunächst bestimmen wir, für beliebiges $\epsilon > 0$, ein beschränktes Intervall $[a, b]$ durch die Forderung $F(a) \leq \epsilon$ und $1 - F(b) \leq \epsilon$. Es gilt dann auch, dass für alle hinreichend großen n, $F_n(a) \leq 2\epsilon$ und $1 - F_n(b) \leq 2\epsilon$.

Nun sei g ist stetig und daher auf dem beschränkten Intervall $[a, b]$ gleichmässig stetig. Für jedes $\delta > 0$ können wir dann ein $N = N(\delta)$ und Stetigkeitsstellen von F, $a_1 = a < a_2 < \ldots < a_N = b$, finden, so dass $\sup_{x\in(a_k,a_{k+1}]} |g(x) - g(a_k)| \leq \delta$. Definiere

$$h(x) = \sum_{k=1}^{N} \mathbb{1}_{(a_k,a_{k+1}]}(x) g(a_k). \tag{5.6}$$

Dann ist

$$\int_{\mathbb{R}} h(x)\,\mathrm{d}\mathbb{P}_n(x) = \sum_{k=1}^{N} g(a_k)(F_n(a_{k+1}) - F_n(a_k)) \tag{5.7}$$

und daher $\int_{\mathbb{R}} h(x)\mathrm{d}\mathbb{P}_n(x) \to \int_{\mathbb{R}} h(x)\mathrm{d}\mathbb{P}(x)$. Sei nun g beschränkt, also $|g(x)| \leq M$, für alle $x \in \mathbb{R}$.

$$\begin{aligned}\Big|\int_{\mathbb{R}} (g(x) - h(x))\,\mathrm{d}\mathbb{P}_n(x)\Big| &\leq \Big|\int_a^b (g(x) - h(x))\,\mathrm{d}\mathbb{P}_n(x)\Big| + M\mathbb{P}_n([a,b]^c) \\ &\leq \delta + 4M\epsilon\end{aligned}$$

und dasselbe gilt für $\mathbb{P}$ statt $\mathbb{P}_n$. Es folgt nun leicht, dass

$$\limsup_{n\to\infty} \Big|\int_{\mathbb{R}} g(x)\,\mathrm{d}\mathbb{P}_n(x) - \int_{\mathbb{R}} g(x)\,\mathrm{d}\mathbb{P}(x)\Big| \leq 2\delta + 8M\epsilon, \tag{5.8}$$

für alle $\epsilon, \delta > 0$. Daraus folgt aber die gewünschte Konvergenz. □

5.2 Konvergenz von Zufallsvariablen

Als nächstes betrachten wir nun die Frage der Konvergenz von Folgen von Zufallsvariablen. Hier ergeben sich interessante neue Begriffe.

5.2.1 Konvergenz in Verteilung

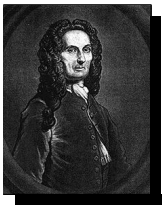
Definition 5.4. Sei $\{X_n\}_{n\in\mathbb{N}}$ eine Folge von (reellen) Zufallsvariablen. Dann konvergiert die Folge X_n *in Verteilung* gegen eine Zufallsvariable X,

$$X_n \xrightarrow{\mathcal{D}} X, \tag{5.9}$$

genau dann, wenn die Verteilungsfunktionen, $F_n(x) \equiv \mathbb{P}(X_n \leq x)$, schwach gegen die Verteilungsfunktion $F(x) \equiv \mathbb{P}(X \leq x)$ der Zufallsvariablen X konvergieren.

Anmerkung. Die schwache Konvergenz einer Folge $X_1, X_2, \ldots$ von Zufallsvariablen gegen eine Zufallsvariable X erfordert nicht, dass diese auf demselben Wahrscheinlichkeitsraum definiert sind, da es nur auf die Bildmasse P_{X_n} ankommt. Es ist aber bequem alle Zufallsvariablen auf demselben zu definieren.

5.2.1.1 Beispiel: Der Satz von de Moivre-Laplace.



Wir können aus der Definition und der Rechnung, die wir schon bei der Betrachtung von Summen von Zufallsvariablen im Kapitel 3 ausgeführt haben, unsere erste Version des *zentralen Grenzwertsatzes* wie er im 17. Jahrhundert zuerst von de Moivre bewiesen wurde, erhalten.

Satz 5.5 (Der Satz von de Moivre-Laplace). *Seien X_i eine Folge von unabhängigen Bernoullivariablen mit Parameter p. Dann konvergiert die Folge $Z_n \equiv \frac{1}{\sqrt{n}} \sum_{i=1}^{n} (X_i - p)$ in Verteilung gegen eine Gaußverteilte Zufallsvariable $\mathcal{N}(0, p(1-p))$.*

Beweis. Wir wählen ein Intervall $I = [a, b]$, $a < b \in \mathbb{R}$. Wir wollen zeigen, dass

$$\lim_{n\uparrow\infty} \mathbb{P}(Z_n \in I) = \frac{1}{\sqrt{2\pi p(1-p)}} \int_a^b \mathrm{e}^{-\frac{x^2}{2p(1-p)}} dx. \tag{5.10}$$

Wir setzen $S_n \equiv \sum_{i=1}^{n} X_i$. Dann ist $Z_n = \frac{1}{\sqrt{n}}(S_n - pn)$ und

$$\mathbb{P}(Z_n \in I) = \sum_{k:\, \frac{1}{\sqrt{n}}(k-pn)\in I} \mathbb{P}(S_n = k). \tag{5.11}$$

Wir wissen aber schon, dass die Zufallsvariablen S_n binomial verteilt ist mit mit Parametern n, p, also

$$\mathbb{P}(S_n = k) = p^k (1-p)^{n-k} \binom{n}{k}.$$

Für die Binomialkoeffizienten benutzen wir die Stirling'sche Approximation für die Fakuläten. Diese sagt, dass

$$\sqrt{2\pi} n^{n+1/2} \mathrm{e}^{-n} (1 + 1/(12n)) \le n! \le \sqrt{2\pi} n^{n+1/2} \mathrm{e}^{-n} (1 + 1/(12n-1)). \tag{5.12}$$

Wir schreiben hierfür auch kurz

$$n! = \sqrt{2\pi} n^{n+1/2} \mathrm{e}^{-n} ((1 + O(1/n)). \tag{5.13}$$

Damit haben wir

$$\begin{aligned}\binom{n}{k} &= \frac{n!}{(n-k)!k!} = \frac{1}{\sqrt{2\pi}}\sqrt{\frac{n}{(n-k)k}}\,\frac{n^n}{(n-k)^{n-k}k^k} \\ &\quad\times(1+O(1/n)+O(1/k)+O(1/(n-k))) \\ &= \frac{1}{\sqrt{2\pi n}}\sqrt{\frac{1}{(1-k/n)k/n}}\,\frac{1}{(1-k/n)^{n-k}(k/n)^k} \\ &\quad\times(1+O(1/n)+O(1/k)+O(1/(n-k))) \\ &= \frac{1}{\sqrt{2\pi n}}\sqrt{\frac{1}{(1-k/n)k/n}}\left(\frac{1}{(1-k/n)^{1-k/n}(k/n)^{k/n}}\right)^n \\ &\quad\times(1+O(1/n)+O(1/k)+O(1/(n-k)))\,. \end{aligned} \tag{5.14}$$

Für die Werte von k, die in der Summe (5.11) auftreten sind sowohl k als $n-k$ von der Ordnung n. Daher sind alle Fehlerterme von der Ordnung $O(n^{-1})$.

Setzen wir nun $k/n = x$ und all dies in die Formel (5.12) für $\mathbb{P}(S_n = nx)$ ein, so ist

$$\begin{aligned}\mathbb{P}(S_n = nx) &= \frac{1}{\sqrt{2\pi n}}\sqrt{\frac{1}{(1-x)x}}\left(\frac{p^x(1-p)^{1-x}}{(1-x)^{1-x}(x)^x}\right)^n(1+O(n^{-1})) \\ &= \frac{1}{\sqrt{2\pi n}}\sqrt{\frac{1}{(1-x)x}}\exp\left(-nI(p,x)\right)(1+O(n^{-1})) \end{aligned} \tag{5.15}$$

wo

$$\begin{aligned} I(p,x) &= \ln\left((x/p)^x[(1-x)/(1-p)]^{1-x}\right) \\ &= x\ln(x/p)+(1-x)\ln((1-x)/(1-p)) \end{aligned} \tag{5.16}$$

Folgende einfache Sachverhalte sind leicht nachzuprüfen (Übung!):

(i) $I(p,p) = 0$
(ii) $I(p,x)$ ist konvex als Funktion von $x \in (0,1)$ und nimmt ihr einziges Minimum $x = p$ an.
(iii) $\frac{\partial^2 I(p,x)}{\partial x^2} = \frac{1}{x} + \frac{1}{1-x} = \frac{1}{x(1-x)} \geq 4$.
(iv) $I(p,x)$ ist unendlich oft differenzierbar in $x \in (0,1)$.

Wir sehen an den obigen Rechnungen, dass $\mathbb{P}(S_n = nx)$ nur dann nicht exponentiell klein in n wird, wenn x sehr nahe bei p liegt. Nun ist aber für alle Terme, die in der Summe (5.11) auftreten, $|k/n - p| \leq (b-a)/\sqrt{n}$.

Mittels der Taylorformel dritter Ordnung zeigt man nun leicht, dass für diese Werte von k/n die Funktion I gut quadratisch aproximiert ist, nämlich

$$\left| I(p,k/n) - \frac{(k/n-p)^2}{2p(1-p)} \right| \leq Cn^{-3/2}, \tag{5.17}$$

wo die Konstante C nur von p, a, b abhängt. Weiter ist für diese Werte

$$\left| \sqrt{\frac{1}{(1-k/n)k/n}} - \sqrt{\frac{1}{p(1-p)}} \right| \leq Cn^{-1/2}. \tag{5.18}$$

Damit erhalten wir

$$\begin{aligned} &\mathbb{P}(Z_n \in I) \qquad (5.19)\\ &= \sum_{k:\frac{1}{\sqrt{n}}(k-pn)\in I} \frac{1}{\sqrt{2\pi n}} \sqrt{\frac{1}{(1-p)p}} \exp\left(-n\frac{(k/n-p)^2}{2p(1-p)}(1+O(n^{-3/2}))\right)(1+O(n^{-1/2})) \end{aligned}$$

Wir erkennen die Dichte der Gaußverteilung mit Varianz $\sigma^2 = (1-p)p$. Jetzt brauchen wir nur noch die Summe durch ein Integral zu ersetzen. Dazu bemerkt man wie üblich, dass

$$\begin{aligned} &\frac{1}{n} \exp\left(-n\frac{(k/n-p)^2}{2p(1-p)}(1+O(n^{-3/2}))\right)(1+O(n^{-1/2})) \qquad (5.20)\\ &= \int_{k/n-p}^{(k+1)/n-p} \exp\left(-n\frac{y^2}{2p(1-p)}(1+O(n^{-3/2}))\right)(1+O(n^{-1/2}))\mathrm{d}y, \end{aligned}$$

da sich der Integrand zwischen den Integrationsgrenzen nur um einen Faktor höchstens der Form $1 + O(1/n)$ unterscheidet. Somit haben wir

$$\begin{aligned} &\sum_{k:\frac{1}{\sqrt{n}}(k-pn)\in I} \frac{1}{\sqrt{2\pi n}} \sqrt{\frac{1}{(1-p)p}} \exp\left(-n\frac{(k/n-p)^2}{2p(1-p)}(1+O(n^{-3/2}))\right)(1+O(n^{-1/2}))\\ &= \int_{a/\sqrt{n}}^{b/\sqrt{n}} \frac{\sqrt{n}}{\sqrt{2\pi p(1-p)}} \exp\left(-n\frac{y^2}{2p(1-p)}(1+O(n^{-3/2}))\right)(1+O(n^{-1/2}))\mathrm{d}y\\ &= \int_a^b \frac{1}{\sqrt{2\pi p(1-p)}} \exp\left(-\frac{x^2}{2p(1-p)}(1+O(n^{-1/2}))\right)(1+O(n^{-1/2}))\mathrm{d}x\\ &\to \int_a^b \frac{1}{\sqrt{2\pi p(1-p)}} \exp\left(-\frac{x^2}{2p(1-p)}\right)\mathrm{d}x \qquad (5.21) \end{aligned}$$

Da dies für jedes Intervall (a, b) gilt, folgt schliesslich auch die Konvergenz der Verteilungsfunktionen. Damit haben wir aber das behauptete Resultat bewiesen. □

Anmerkung. Die Abschätzungen, die wir im Beweis benutzen, sind sogar stärker als das Endresultat. So können wir auch genaue asymptotische Abschätzungen für die Masse von Intervallen geben, deren Länge mit n schrumpft.

5.2.2 Konvergenz in Wahrscheinlichkeit

Die Konvergenz in Wahrscheinlichkeit erfordert nicht, dass für irgendein $\omega \in \Omega$, $X_n(\omega)$ gegen $X(\omega)$ konvergiert, oder überhaupt $X_n(\omega)$ in irgendeinem Sinn nahe bei $X(\omega)$ liegt. So sieht man etwas im Fall von de Moivre-Laplace, dass z.B. $Z_{n^2}(\omega)$ praktisch nicht vom Wert von $Z_n(\omega)$ abhängt. Eine etwas stärkere Forderung in diese Richtung ist die Konvergenz in Wahrscheinlichkeit.

Definition 5.6. Seien $X, X_n, n \in \mathbb{N}$ Zufallsvariablen auf einem Wahrscheinlichkeitsraum $(\Omega, \mathfrak{F}, \mathbb{P})$. Die Folge $(X_n)_{n\geq 1}$ konvergiert *in Wahrscheinlichkeit* gegen X, falls für alle $\epsilon > 0$,

$$\lim_{n\to\infty} \mathbb{P}(|X_n - X| > \epsilon) = 0. \tag{5.22}$$

Hier hat also die Menge der ω für die $X_n(\omega)$ nahe bei $X(\omega)$ liegt zunehmend wachsende Wahrscheinlichkeit. Konvergenz in Wahrscheinlichkeit impliziert Konvergenz in Verteilung, wie man vermuten würde.

Proposition 5.7. *Falls eine Folge von Zufallsvariablen X_n in Wahrscheinlichkeit gegen eine Zufallsvariable X konvergiert, dann konvergiert X_n in Verteilung gegen X.*

Beweis. Sei $g : \mathbb{R} \to \mathbb{R}$ beschränkt und stetig. Wir müssen zweigen, dass

$$\lim_{n\uparrow\infty} \mathbb{E}\left[g(X_n)\right] = \mathbb{E}\left[g(X)\right]. \tag{5.23}$$

Dazu schreiben wir

$$\begin{aligned}
\mathbb{E}\left[g(X_n)\right] &= \mathbb{E}\left[g(X_n)\mathbb{1}_{|X_n(\omega)-X(\omega)|\leq\epsilon}\right] + \mathbb{E}\left[g(X_n)\mathbb{1}_{|X_n(\omega)-X(\omega_|>\epsilon}\right] \\
&= \mathbb{E}\left[g(X)\mathbb{1}_{|X_n(\omega)-X(\omega)|\leq\epsilon}\right] + \mathbb{E}\left[(g(X_n)-g(X))\mathbb{1}_{|X_n(\omega)-X(\omega)|\leq\epsilon}\right] \\
&\quad +\mathbb{E}\left[g(X_n)\mathbb{1}_{|X_n(\omega)-X(\omega)|>\epsilon}\right] \\
&= \mathbb{E}\left[g(X)\right] + \mathbb{E}\left[(g(X_n)-g(X))\mathbb{1}_{|X_n(\omega)-X(\omega)|\leq\epsilon}\right] \\
&\quad +\mathbb{E}\left[(g(X_n)-g(X))\mathbb{1}_{|X_n(\omega)-X(\omega)|>\epsilon}\right].
\end{aligned} \tag{5.24}$$

Für $\delta > 0$ wählen wir n so gross, dass $\mathbb{P}(|X_n - X| > \epsilon) \leq \delta$. Sei $|g| \leq M < \infty$. Dann ist die letzte Zeile im Betrag kleiner als $M\delta$. Wenn g gleichmäßig stetig wäre, dann könnten wir den Term davor durch δ beschränken, wenn wir ϵ klein genug wählen. Nun wissen wir aber, dass für jedes $\delta > 0$ ein K existiert, so dass $\mathbb{P}(|X| > K) \leq \delta$. Dann ist aber

$$\begin{aligned}
\mathbb{E}\left[|g(X_n)-g(X)|\mathbb{1}_{|X_n(\omega)-X(\omega)|\leq\epsilon}\right] &= \mathbb{E}\left[|g(X_n)-g(X)|\mathbb{1}_{|X_n(\omega)-X(\omega)|\leq\epsilon}\mathbb{1}_{|X(\omega)|\leq K}\right] \\
&\quad + \mathbb{E}\left[|g(X_n)-g(X)|\mathbb{1}_{|X_n(\omega)-X(\omega)|\leq\epsilon}\mathbb{1}_{|X(\omega)|>K}\right] \\
&\quad \leq \delta + 2M\delta.
\end{aligned} \tag{5.25}$$

Insgesamt ist also

$$\left|\mathbb{E}\left[g(X_n)\right] - \mathbb{E}\left[g(X)\right]\right| \leq (4M+1)\delta. \tag{5.26}$$

Da dies für jedes $\delta > 0$ gilt, ist der Satz bewiesen. □

Ein besonderer Fall liegt vor, wenn die Zufallsvariablen X_n gegen eine deterministische Zufallsvariable, also eine Konstante konvergieren, wie wir es etwa im Gesetz der großen Zahlen sehen werden.

Definition 5.8. Eine Folge von Zufallsvariablen, $(X_n)_{n\geq 1}$, konvergiert *in Wahrscheinlichkeit* gegen eine Konstante, x, genau dann, wenn, für alle $\epsilon > 0$,

$$\lim_{n\to\infty} \mathbb{P}(|X_n - x| > \epsilon) = 0. \tag{5.27}$$

Es ist leicht einzusehen, dass eine Zufallsvariable genau dann in Wahrscheinlichkeit gegen eine Konstante x konvergiert, wenn ihre Verteilung gegen die Dirac-Verteilung δ_x konvergiert.

5.2.3 Fast sichere Konvergenz

Ein wesentlich stärkerer Konvergenzbegriff für Zufallsvariablen ist allerdings der der sogenannten *fast sicheren* Konvergenz. Wir rufen uns ins Gedächtnis, dass eine Folge von Zufallsvariablen ja eine messbare Funktion von Ω in den Produktraum $\mathbb{R}^{\mathbb{N}}$ ist. Wir können uns also fragen, ob tatsächlich diese Folgen (fast) alle gegen den gleichen Wert x, bzw. eine Zufallsvariable X streben. Hier betrachten wir also wieder einmal Wahrscheinlichkeiten auf dem gesamten unendlichen Produktraum.

Definition 5.9. Sei X_n eine Folge von Zufallsvariablen auf einem Wahrscheinlichkeitsraum $(\Omega, \mathfrak{F}, \mathbb{P})$. Dann sagen wir, dass X_n *fast sicher* (f.s.) gegen eine Zufallsvariable X konvergiert,

$$X_n \to X \quad \text{f.s.}, \tag{5.28}$$

genau dann, wenn

$$\mathbb{P}\left(\lim_{n\to\infty} X_n = X\right) \equiv \mathbb{P}\left(\left\{\omega \in \Omega : \lim_{n\uparrow\infty} X_n(\omega) = X(\omega)\right\}\right) = 1. \tag{5.29}$$

Anmerkung. Natürlich kann die Zufallsvariable X auch deterministisch sein, d.h. X kann eine Konstante x sein.

Wir sollten als erstes nachprüfen, ob diese Definition sinnvoll ist, d.h. ob das Ereignis $\{\lim_{n\to\infty} X_n = X\}$ überhaupt in $\mathfrak{F}$ liegt.

Dazu müssen wir das Ereignis $\{\lim_{n\to\infty} X_n = X\}$ unter Verwendung der Definition der Konvergenz ausschreiben:

$$\begin{aligned}\left\{\omega :\in \Omega : \lim_{n\to\infty} X_n(\omega) = X(\omega)\right\} &= \left\{\omega \in \Omega : \forall_{k\in\mathbb{N}} \exists_{n_0\in\mathbb{N}} \forall_{n\geq n_0} |X_n(\omega) - X(\omega)| \leq \tfrac{1}{k}\right\} \\ &= \bigcap_{k\in\mathbb{N}} \bigcup_{n_0\in\mathbb{N}} \bigcap_{n\geq n_0} \left\{\omega \in \Omega : |X_n(\omega) - X(\omega)| \leq \tfrac{1}{k}\right\} \end{aligned} \tag{5.30}$$

Nun sind die Mengen $\{|X_n(\omega) - X(\omega)| \leq 1/k\}$ wegen der Messbarkeit von X_n und X in $\mathfrak{F}$, und somit is $\{\omega :\in \Omega : \lim_{n\to\infty} X_n(\omega) = X(\omega)\}$ als abzählbare Vereinigungen und Durchschnitte messbarer Mengen in $\mathfrak{F}$.

In Worten lautet die rechte Seite von (5.30): "Für alle $k \in \mathbb{N}$ ist, bis auf endlich viele Werte von n, $|X_n - X| \leq 1/k$". Das komplementäre Ereignis ist dann "Es gibt k so, dass für unendlich viele Werte des Indexes n, $|X_n - X| > 1/k$ gilt". Damit ist

$$\mathbb{P}\left(\lim_{n\to\infty} X_n = X\right) = 1 - \mathbb{P}\left(\bigcup_{k\in\mathbb{N}} \{|X_n - X| > 1/k \text{ für unendlich viele } n\}\right) \tag{5.31}$$

Üblicherweise benutzt man die Notation

$$\{A_n, \text{ u.o.}\} \equiv \{A_n, \text{ für unendlich viele } n\} \equiv \bigcap_{n_0\in\mathbb{N}} \bigcup_{n\geq n_0} A_n, \tag{5.32}$$

wo $A_n \in \mathfrak{F}$ eine Folge von Ereignissen ist. Somit ist $\mathbb{P}(\lim_{n\to\infty} X_n = X) = 1$ genau dann, wenn $\mathbb{P}(\bigcup_{k\in\mathbb{N}}\{|X_n - X| > 1/k, \text{ u.o.}\}) = 0$.

Lemma 5.10. *Sei X_n eine Folge von Zufallsvariablen auf einem Wahrscheinlichkeitsraum $(\Omega, \mathfrak{F}, \mathbb{P})$. Dann ist*

$$\mathbb{P}\left(\lim_{n\to\infty} X_n = X\right) = 1 \quad \Longleftrightarrow \quad \forall k \in \mathbb{N},\ \mathbb{P}(\{|X_n - X| > 1/k, \text{ u.o.}\}) = 0. \tag{5.33}$$

Beweis. Wir sehen, dass

$$\begin{aligned} \sum_{k\in\mathbb{N}} \mathbb{P}(\{|X_n - X| > 1/k, \text{ u.o.}\}) &\geq \mathbb{P}\left(\bigcup_{k\in\mathbb{N}} \{|X_n - X| > 1/k, \text{ u.o.}\}\right) \\ &\geq \sup_{k\in\mathbb{N}} \mathbb{P}(\{|X_n - X| > 1/k, \text{ u.o.}\}). \end{aligned} \tag{5.34}$$

Daher ist $\mathbb{P}(\bigcup_{k\in\mathbb{N}}\{|X_n - X| > 1/k, \text{ u.o.}\}) = 0$ genau dann wenn $\mathbb{P}(\{|X_n - X| > 1/k, \text{ u.o.}\}) = 0$ für alle k ist. □



Letztere Frage kann nun mit einem der wichtigsten Lemma der Wahrscheinlichkeitstheorie entschieden werden, dem sogenannten *Borel-Cantelli Lemmas*.

Lemma 5.11 (Erstes Borel-Cantelli Lemma). *Sei $(\Omega, \mathfrak{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum, und seien $A_n \in \mathfrak{F}$ eine Folge von Ereignissen. Wenn $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$, dann gilt*

$$\mathbb{P}(A_n, \text{ u.o.}) = 0. \tag{5.35}$$

Lemma 5.12 (Zweites Borel-Cantelli Lemma). *Sei $(\Omega, \mathfrak{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum, und seien $A_n \in \mathfrak{F}$ eine Folge von* unabhängigen *Ereignissen. Wenn $\sum_{n=1}^{\infty} P(A_n) = +\infty$, dann gilt*

$$\mathbb{P}(A_n, \text{ u.o.}) = 1. \tag{5.36}$$

Beweis. Wir beweisen zunächst das wichtigere erste Borel-Cantelli Lemma. Wir haben

$$\mathbb{P}(A_n, \text{ u.o.}) = \mathbb{P}\left(\bigcap_{k\in\mathbb{N}}\bigcup_{n\geq k} A_n\right) = \lim_{k\to\infty}\mathbb{P}\left(\bigcup_{n\geq k} A_n\right) \leq \lim_{k\to\infty}\sum_{n=k}^{\infty}\mathbb{P}(A_n). \tag{5.37}$$

Nun ist nach Voraussetzung die Reihe $\sum_{n=1}^{\infty}\mathbb{P}(A_n)$ konvergent, woraus folgt, dass die Folge $r_k \equiv \sum_{n=k}^{\infty}\mathbb{P}(A_n)$ eine Nullfolge ist. Damit ist die Aussage des Lemma evident.

Beweisen wir nun noch das zweite Lemma. Wieder ist

$$\mathbb{P}(A_n, \text{ u.o.}) = \mathbb{P}\left(\bigcap_{k\in\mathbb{N}}\bigcup_{n\geq k} A_n\right) = \lim_{k\to\infty}\mathbb{P}\left(\bigcup_{n\geq k} A_n\right). \tag{5.38}$$

Aber

$$\begin{aligned} 0 \leq 1 - \mathbb{P}\left(\bigcup_{n\geq k} A_n\right) &= \mathbb{P}\left(\left(\bigcup_{n\geq k} A_n\right)^c\right) = \mathbb{P}\left(\bigcap_{n\geq k} A_n^c\right) \\ &= \lim_{N\to\infty}\mathbb{P}\left(\bigcap_{N\geq n\geq k} A_n^c\right) \overset{\text{unab.}}{=} \lim_{N\to\infty}\prod_{n=k}^{N}\mathbb{P}\left(A_n^c\right) \\ &= \prod_{n=k}^{\infty}\left(1-\mathbb{P}\left(A_n\right)\right) \leq \exp\Big(-\sum_{n=k}^{\infty}\mathbb{P}\left(A_n\right)\Big) = 0 \end{aligned} \tag{5.39}$$

da ja für jedes k, $\sum_{n=k}^{\infty}\mathbb{P}\left(A_n\right) = +\infty$ ist. Ausserdem haben wir hier noch die (auch sonst) sehr nützliche Abschätzung

$$1 - x \leq \mathrm{e}^{-x} \tag{5.40}$$

benutzt. Damit ist für alle $k < \infty\,\mathbb{P}\left(\bigcup_{n\geq k} A_n\right) = 1$ und somit auch $\lim_{k\uparrow\infty}\mathbb{P}\left(\bigcup_{n\geq k} A_n\right) = 1$. Daraus folgt (5.36). □

Wir können diese Lemmata sofort auf die Frage der fast sicheren Konvergenz anwenden.

Korollar 5.13. *Eine Folge von Zufallsvariablen X_n konvergiert fast sicher gegen eine Zufallsvariable X, wenn für alle $\epsilon > 0$*

$$\sum_{n=1}^{\infty}\mathbb{P}(|X_n - X| > \epsilon) < \infty. \tag{5.41}$$

Wenn die Zufallsvariablen $X_n - X$ unabhängig sind, so ist die Bedingung (5.41) auch notwendig.

Anmerkung. Der Fall, dass $X_n - X$ unabhängige Zufallsvariable sind ist insbesondere dann gegeben, wenn die X_n unabhängig sind und X eine Konstante ist.

Beweis. Wir haben zu gesehen, dass X_n genau dann fast sicher gegen x konvergiert, wenn für alle $1 \leq k < \infty$, $\mathbb{P}(|X_n - x| > 1/k, \text{u.o.}) = 0$. Wegen dem ersten Borel-Cantelli Lemma gilt dies aber wegen (5.41). Die Notwendigkeit folgt aus dem zweiten Borel-Cantelli Lemma. □

Wir sehen aus dem Korollar leicht, dass es möglich ist, dass eine Folge von Zufallsvariablen in Wahrscheinlichkeit gegen eine Konstante x konvergiert, nicht aber fast sicher. Das einfachste Beispiel ist durch eine Folge von unabhängigen Zufallsvariables X_n gegeben, bei denen

$$\mathbb{P}(X_n = 0) = 1 - n^{-\alpha} \quad \text{und} \quad \mathbb{P}(X_n = 1) = n^{-\alpha}. \tag{5.42}$$

Diese Folge konvergiert für jedes $\alpha > 0$ in Wahrscheinlichkeit gegen 0, aber nur für $\alpha > 1$ tut sie das auch fast sicher.

Anmerkung. Die fast sichere Konvergenz ist die stärkste Konvergenzform: Wenn $X_n \to X$, f.s., dann konvergiert X_n auch in Wahrscheinlichkeit gegen X. Wenn X_n in Wahrscheinlichkeit gegen X konvergiert, so konvergiert X_n auch in Verteilung gegen X. Die umgekehrten Schlüsse gelten nicht.

Anmerkung. Die Bedingung im 2. Borel-Cantelli lemma, dass die Ereignisse unabhängig sind kann nicht fallen gelassen werden. Ein einfaches Gegenbeispiel geht wie folgt. Sei eine Zufallsvariable U gleichverteilt auf $[0, 1]$. Definiere die Zufallsvariablen $X_n = \mathbb{1}_{U \leq n^{-1/2}}$. Offenbar gilt $\mathbb{P}(X_n = 1) = n^{-1/2} = 1 - \mathbb{P}(X_n = 0)$. Obwohl $\sum_{n=1}^{\infty} \mathbb{P}(X_n = 1) = +\infty$, ist

$$\mathbb{P}(X_n = 1, \ u.o.) = \mathbb{P}(U = 0) = 0. \tag{5.43}$$

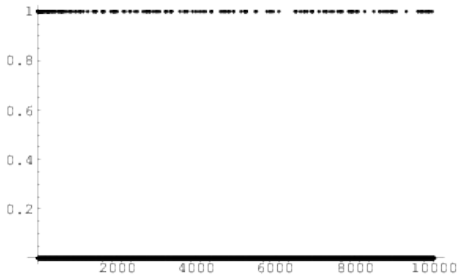


Abb. 5.1 Folge von Bernoullivariablen mit $p_n = 1/\sqrt{n}$.

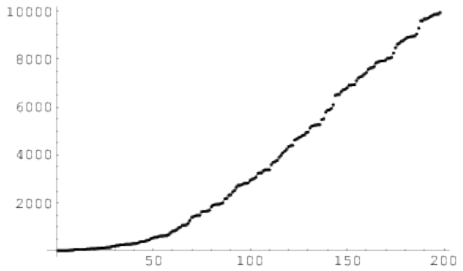


Abb. 5.2 Folge der Werte n mit $X_n = 1$, mit $p_n = 1/\sqrt{n}$.

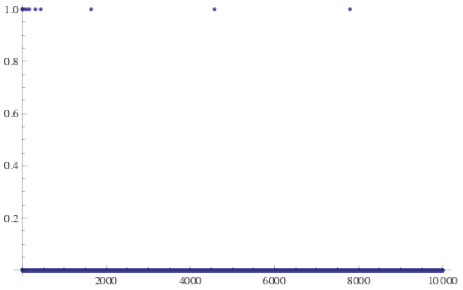


Abb. 5.3 Folge von Bernoullivariablen mit $p_n = n^{-1}$.

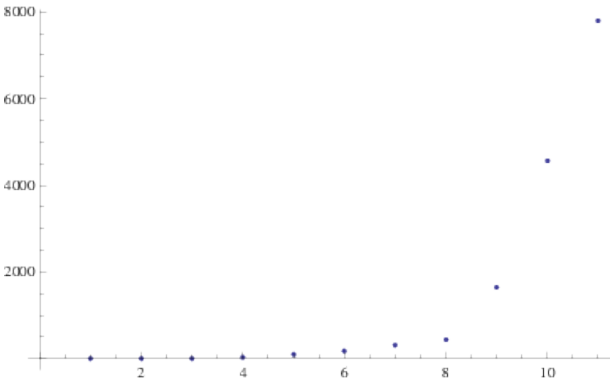


Abb. 5.4 Folge der Werte n mit $X_n = 1$, mit $p_n = n^{-1}$.

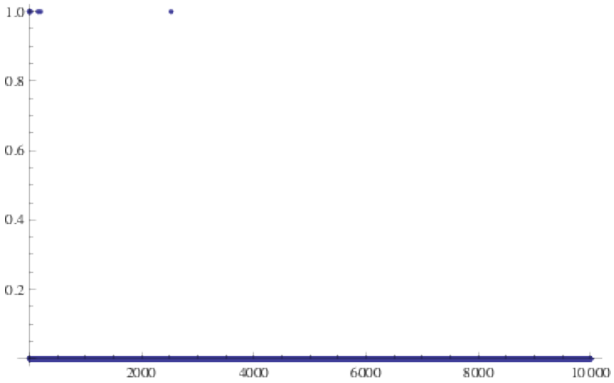


Abb. 5.5 Folge von Bernoullivariablen mit $p_n = n^{-1.1}$.

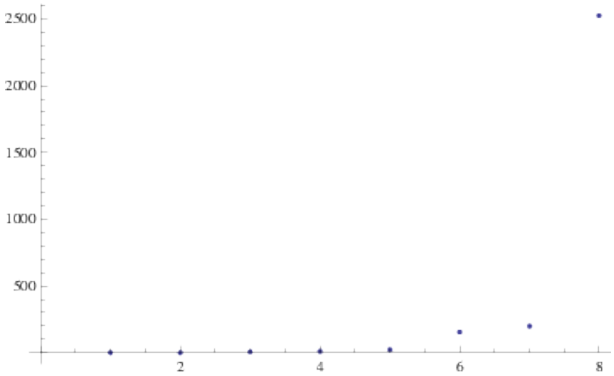


Abb. 5.6 Folge der Werte n mit $X_n = 1$, mit $p_n = n^{-1.1}$.

Kapitel 6
Das Gesetz der großen Zahlen.

Au milieu des causes variables et inconnues que nous comprenons sous le nom de hazard*, et qui rendent incertaine et irrégulière la marche des événements, on voit naître, à mesure qu'ils se multiplient, une régularité frappante, qui semble tenir à un dessein et que l'on a considérée comme une preuve de la providence*[a]*,*
Pierre Simon de Laplace, Théorie Analytique des Probabilités

[a] Inmitten der veränderlichen und unbekannten Ursachen, die wir unter dem Namen *Zufall* verstehen, und die den Ablauf der Ereignisse unsicher und irregulär machen, sieht man, während ihre Zahl verfielfacht eine frappierende Regularität zum Vorschein kommen, die sich an einem Plan zu halten scheint und die man als einen Beweis der Vorsehung betrachtet hat.

Das zentrale Anliegen dieser Sektion ist die Behandlung des wohl fundamentalsten Satzes der Wahrscheinlichkeitstheorie, des Gesetzes der großen Zahlen. Dieses begründet insbesondere den Zusammenhang zwischen Wahrscheinlichkeit und Frequenz, und erklärt die Bedeutung des Erwartungswertes als Mittel über wiederholte Zufallsexperimente. Im weiteren Sinne ist das Gesetz der großen Zahlen unsere erste Begegnung mit dem Prinzip, dass aus völlig zufälligen Ereignissen dennoch völlig deterministische Resultate folgen können.

6.1 Erwartungswert, Varianz, Momente

Sei X eine reelle Zufallsvariable auf $(\mathbb{R}, \mathfrak{B}, \mathbb{P})$ mit Verteilungsfunktion

$$F(x) \equiv \mathbb{P}\left(X \leq x\right). \tag{6.1}$$

Grundsätzlich haben wir ja gesehen, dass diese durch ihre Verteilungsfunktion die Zufallsvariable vollständig charakterisiert. Wir sind aber vielfach an alternativen, einfacheren Kenngrössen interessiert, und insbesondere für statistische Anwendungen möchten wir einige wenige bedeutungsvolle Parameter identifizieren, die die Eigenschaft einer Verteilung bestimmen.

Wir hatten bereits gesehen dass der Erwartungswert von X gegeben ist durch

$$\mathbb{E}[X] \equiv \int_\Omega X d\mathbb{P} = \int_{\mathbb{R}} x \, \mathrm{d}P_X(x). \tag{6.2}$$

wo $P_X \equiv \mathbb{P} \circ X^{-1}$ die Verteilung von X ist. Falls die Verteilung P_X absolut stetig bezüglich des Lebsguemaßes mit Dichte ρ_X ist, so gilt

$$\mathbb{E}[X] = \int_{\mathbb{R}} x \rho_X(x) dx. \tag{6.3}$$

Die Bedeutung der Erwartung ist ziemlich offensichtlich. Im weiteren möchte man natürlich wissen, wie sehr sich die Verteilung um diese Erwartung herum streut.

Die erste naheliegende Grösse ist die sogenannte *Varianz*,

$$\mathrm{var}(X) \equiv \mathbb{E}\left[(X - \mathbb{E}X)^2\right]. \tag{6.4}$$

Man bezeichnet im übrigen die Quadratwurzel der Varianz als *Standardabweichung*. Beachte, dass die Varianz einer Zufallsvariablen unendlich sein kann, auch wenn die Erwartung endlich ist.

Momente.

Eine naheliegende Verallgemeinerung der Varianz sind die sogenannten *Momente* eine Wahrscheinlichkeitsverteilung. Wir definieren

$$M_p \equiv \mathbb{E}\left[X^p\right] \tag{6.5}$$

Momente spielen auch deswegen eine äusserst wichtige Rolle, weil in vielen, *aber nicht allen* (!) Fällen die Kenntnis aller Momente einer Wahrscheinlichkeitsverteilung diese vollständig bestimmen. Ohne im Detail auf diese Fragen eingehen zu wollen, ist es nützlich folgendes Kriterium zu kennen:

Satz 6.1. *Sei $(M_p)_{p\in\mathbb{N}} \in \mathbb{R}$ eine Folge von reellen Zahlen mit der Eigenschaft, dass für alle $p \in \mathbb{N}$ $M_{2p} \geq 0$ und es $a > 0$ gibt, so dass*

$$\sum_{p=1}^{\infty} M_{2p} \frac{a^{2p}}{(2p)!} < \infty. \tag{6.6}$$

Dann existiert höchstens *ein Wahrscheinlichkeitsmaß auf $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$, so dass $M_p = \int_{\mathbb{R}} x^p dP$, für alle $p \in N$.*

Anmerkung. Die Aussage von Satz 6.1 impliziert, dass falls die Momente M_p einer Zufallsvariablen die Bedingung (6.6) erfüllen, dann legen diese die Verteilung der Zufallsvariablen eindeutig fest.

Beispiel 6.2. Für $X \sim \mathcal{N}(0,1)$, $M_p = 0$ für ungerade p und sonst $M_{2p} = (2p)!/(2^p p!)$, $p \in \mathbb{N}$. Deshalb gilt (6.6) für alle $a \in \mathbb{R}$.

Erzeugende Funktionen.

Eng mit den Momenten verknüpft, haüfig aber weit nützlicher, ist die sogenannte *Momenten erzeugende Funktion*, oder *Laplace Transformierte.* Diese ist definiert durch

$$\psi(z) \equiv \mathbb{E}\left[\mathrm{e}^{zX}\right]. \tag{6.7}$$

Natürlich muss $\psi(z)$ für $z \neq 0$ nicht notwendig endlich sein. Wenn es $h > 0$ gibt, so dass $\psi(\pm h) < \infty$, dann existiert $\psi(z)$ für alle $|z| \leq h$, ist unendlich oft differenzierbar für $z < |h|$ und es gilt, dass

$$M_p = \frac{d^p}{dz^p}\psi(z = 0), \tag{6.8}$$

d.h. aus ψ können alle Momente berechnet werden. Die Differenzierbarkeitseigenschaften folgen aus:

Satz 6.3. *Sei $(\Omega, \mathfrak{F}, \mu)$ ein Maßraum und $E \subset \mathbb{R}$ offen. Sei $f : \Omega \times E \to \mathbb{R}$ mit den Eigenschaften:*

(i) Die Funktion $\sup_{z\in E} |f(z, \cdot)| : \Omega \to \mathbb{R}$ absolut integrierbar bezüglich μ;
(ii) Für μ-fast alle $\omega \in \Omega$ ist $f(;\omega)$ in E stetig differenzierbar und
(iii) die Funktion $\sup_{z\in E} \left|\frac{\partial}{\partial z} f(z, \omega)\right|$ ist absolut integrierbar bezüglich μ.

Dann ist $F(z) \equiv \int f(z, \omega)d\mu(\omega)$ stetig differenzierbar in E und

$$\frac{d}{dz}F(z) = \int \frac{\partial}{\partial z} f(z, \omega)d\mu(\omega). \tag{6.9}$$

Der Beweis dieses Satzes folgt aus Lebesgue's Satz von der dominierten Konvergenz (Übung!).

Beispiel 6.4. Hier ist eine Liste von momentenerzeugende Funktionen wichtiger Verteilungen.

- Für $X \sim \mathcal{N}(m, \sigma^2)$, gilt $\psi(z) = \exp(\sigma^2 z^2/2 + zm)$.
- Für $X \sim \mathrm{Exp}(a)$, gilt $\psi(z) = 1/(1 - z/a)$ für $|z| < a$.
- Für $X \sim \mathrm{Poi}(\lambda)$, gilt $\psi(z) = \exp(-\lambda(\mathrm{e}^z - 1))$.
- Für $X \sim \mathrm{Geo}(q)$, gilt $\psi(z) = (1 - q)/(1 - q\mathrm{e}^z)$ für $|z| < \ln(1/q)$.
- Für $X \sim \mathrm{Bin}(n, p)$, gilt $\psi(z) = (1 - p + p\,\mathrm{e}^z)^n$.
- Für $X \sim \mathrm{Cauchy}(a)$ ist $\psi(z) = \infty$ für alle $z \neq 0$.

6.2 Die Chebyshev Ungleichung

Die Bedeutung von Varianz, Momenten und erzeugenden Funktionen erschliesst sich zum Teil aus der sogenannten *Chebyshev Ungleichung*.

Lemma 6.5. *Sei X eine reellwertige Zufallsvariable auf $(\Omega, \mathfrak{F}, \mathbb{P})$. Dann gilt, für alle $x > 0$,*

$$\mathbb{P}(|X - \mathbb{E}X| > x) \leq \frac{\mathrm{var}(X)}{x^2}. \tag{6.10}$$

Beweis. Wir können ohne Verlust der Allgemeinheit annehmen, dass $\mathbb{E}[X] = 0$. Dann ist, für alle $x > 0$,

$$\mathbb{P}(|X| > x) = \mathbb{E}\left[\mathbb{1}_{|X|>x}\right] \leq \mathbb{E}\left[\mathbb{1}_{|X|>x}\frac{X^2}{x^2}\right] \leq \mathbb{E}\left[\frac{X^2}{x^2}\right] = \frac{\mathrm{var}(X)}{x^2}, \tag{6.11}$$

was zu beweisen war. □

Die Herleitung dieser Ungleichung mag diese auf den ersten Blick völlig absurd wirken lassen. Allerdings steht der Nutzen der Ungleichung in keinem Verhältnis zu der Schwierigkeit ihres Beweises. Der Punkt ist die große Universalität der Aussage, die wesentliche Informationen aus nur einer relative leicht berechenbaren Kenngrösse einer Verteilung zu ziehen erlaubt.

Der singulär einfache Beweis läd natürlich dazu ein, eine allgemeinere Ungleichung herzuleiten:

Lemma 6.6. *Sei X eine rellwertige Zufallsvariable und sei, für ein $a \in \mathbb{R}$ $f : [a, \infty) \to \mathbb{R}_+$ eine monoton wachsende Funktion. Dann gilt für alle $y \geq a$,*

$$\mathbb{P}\left(X > y\right) \leq \frac{\mathbb{E}[f(X)]}{f(y)}. \tag{6.12}$$

Beweis. Für alle $y \geq a$,

$$\mathbb{P}(X > y) = \mathbb{E}\left[\mathbb{1}_{X>y}\right] \leq \mathbb{E}\left[\mathbb{1}_{X>y}\frac{f(X)}{f(y)}\right] \leq \frac{\mathbb{E}[f(X)]}{f(y)}, \tag{6.13}$$

was zu beweisen war. □

Die allgemeinere Ungleichung ist natürlich nur dann nützlich, wenn $\mathbb{E}f(X)$ nicht nur endlich, sondern auch berechenbar ist. Typischerweise wird die Markov-Ungleichung für die Fälle $f(x) = |x|^p$ und $f(x) = \exp(tx)$ gerne verwendet. Insbesondere der letzte Fall ist von großer Wichtigkeit, und bildet die Grundlage der sogenannten *Theorie der großen Abweichungen*.

Korollar 6.7. *Sei X eine reellwertige Zufallsvariable. Dann gilt*

$$\mathbb{P}(X \geq y) \leq \inf_{t\geq 0} \mathrm{e}^{-ty}\mathbb{E}(\mathrm{e}^{tX}). \tag{6.14}$$

Diese Abschätzung ist natürlich nur dann nützlich, wenn $\mathbb{E}\mathrm{e}^{tX}$ zumindest für kleine positive t endlich ist.

Die besondere Stärke dieser Ungleichung erweist sich wenn man Summen unabhängiger Zufallsvariablen betrachtet:

Korollar 6.8. *Sei X_i eine Familie unabhängiger Zufallsvariablen. Dann gilt*

$$\mathbb{P}\Big(\sum_{i=1}^{n} X_i \geq y\Big) \leq \inf_{t\geq 0} \mathrm{e}^{-ty}\prod_{i=1}^{n}\mathbb{E}(\mathrm{e}^{tX_i}). \tag{6.15}$$

Das Produkt ist dabei oft leicht zu berechnen. Insbesondere im Fall identisch verteilter Zufallsvariablen ergibt sich ein sehr einfacher Ausdruck. Betrachten wir

als Beispiel unabhängige Rademachervariablen mit Parameter $1/2$ (d.h. $\mathbb{P}(X = \pm) = 1/2$). Dann ist

$$\mathbb{P}\Big(n^{-1}\sum_{i=1}^{n} X_i \geq x\Big) \leq \inf_{t\geq 0} \mathrm{e}^{-txn}(\cosh t)^n$$
$$= \left[\exp\left(\inf_{t\geq 0}(-tx + \ln\cosh(t))\right)\right]^n = \mathrm{e}^{-nI(x)}$$

wo $I(x) = \frac{(1-x)}{2}\ln(1-x) + \frac{(1+x)}{2}\ln(1+x)$. Um dieses Ergebnis zu erhalten bemerkt man, dass das Minimum der Funktion $-tx + \ln\cosh t$ angenommen wird, wenn $\tanh(t) = x$. Da $\tanh^{-1}(x) = \frac{1}{2}\ln\frac{1+x}{1-x}$ ist, folgt dies nach einigen elementaren Rechnungen. Man vergleiche mit dem exakten Wert!!

6.3 Das Gesetz der großen Zahlen

In diesem Abschnitt werden wir den vielleicht wichtigsten Satz der Wahrscheinlichkeitstheorie beweisen, das sogenannte *starke Gesetz der großen Zahlen*. Das Gesetz der großen Zahlen macht für den Fall des Modells von unabhängigen Zufallsvariablen den Zusammenhang zwischen Wahrscheinlichkeit und Frequenz mathematisch rigoros.

Unser Ziel ist es den folgenden Satz zu beweisen.

Satz 6.9 (Starkes Gesetz der großen Zahlen). *Seien X_i, $i \in \mathbb{N}$, unabhängige, identisch verteilte, integrierbare Zufallsvariablen mit Mittelwert $\mu = \mathbb{E}X_i$. Sei $S_n \equiv \sum_{i=1}^n X_i$. Dann ist*

$$\lim_{n\to\infty} n^{-1} S_n = \mu, \quad \text{f.s.} \tag{6.16}$$

Diese Formulierung ist sehr befriedigend, da sie an die Zufallsvariablem ausser der Abhängigkeit nur die Integrierbarkeit verlangt, was ja eine Mindestanforderung is damit überhaupt die rechte Seite exitiert. Der Beweis dieses Satzes ist nicht so einfach, was genau daran liegt, dass wir nur diese minimale Forderung stellen. Wir werden daher zunächst zwei einfachere Fälle betrachten.

6.3.1 Das schwache Gesetz unter Momentenannahmen.

Die erste Naheliegende Idee um ein Gesetz der großen Zahlen zu erhalten ist die Verwendung der Chebyshev Ungleichung. Wir können zunächst ohne Beschränkung der Allgemeinheit $\mu = 0$ annehmen. Nun sieht man schnell, dass man mit einer Abschätzung

$$\mathbb{P}\left(\left|n^{-1}\sum_{i=1}^{n} X_i\right| > x\right) \leq \frac{\mathbb{E}\left|\sum_{i=1}^n X_i\right|}{nx} \leq \frac{\mathbb{E}|X_1|}{x} \tag{6.17}$$

nicht weiterkommt, da diese die Tatsache, dass $\mathbb{E}X_i = 0$ ist nicht auszunutzen vermage. Die nächste Idee wäre es mit der Chebyshev Ungleichung der Ordnung zwei zu versuchen, nämlich

$$\mathbb{P}\left(\left|n^{-1}\sum_{i=1}^{n} X_i\right| > x\right) \leq \frac{\mathbb{E}\left(\sum_{i=1}^{n} X_i\right)^2}{n^2 x^2}. \tag{6.18}$$

Wenn wir hier das Quadrat entwickeln, so sehen wir, das alle gemischten Terme $\mathbb{E}X_iX_j$, $i \neq j$ verschwinden, so dass wir die rechte Seite durch

$$\frac{\mathbb{E}X_1^2}{nx^2} \tag{6.19}$$

abschätzen können. Dies geht zumindest gegen Null, wenn $n \uparrow \infty$, falls denn $\mathbb{E}X_1^2 < \infty$. Wir brauchen also zwei Momente.

Diese Idee liefert schon ein Ergebnis, wenn auch nicht ganz das, was wir wollen.

Satz 6.10. *Seien X_i, $i \in \mathbb{N}$, identische verteilte und paarweise unkorrelierte Zufallsvariablen auf einem Wahrscheinlichkeitsraum $(\Omega, \mathfrak{F}, \mathbb{P})$ mit endlicher Varianz σ^2. Sei $S_n \equiv \sum_{i=1}^{n} X_i$. Dann gilt*

$$\frac{1}{n}\sum_{i=1}^{n} X_i \to \mathbb{E}[X_1] \quad \textit{in Wahrscheinlichkeit.} \tag{6.20}$$

Beweis. Der Beweis ist denkbar einfach. Wir haben wegen der Chebyshev Ungleichung (6.10), dass

$$\begin{aligned}\mathbb{P}\left(\left|\frac{1}{n}\sum_{i=1}^{n}(X_i - \mathbb{E}[X_1])\right| > \epsilon\right) &\leq \frac{\mathbb{E}\left[\left(\frac{1}{n}\sum_{i=1}^{n}(X_i - \mathbb{E}[X_1])\right)^2\right]}{\epsilon^2} \\ &= \frac{n^{-2}\sum_{i=1}^{n}\mathbb{E}\left[(X_i - \mathbb{E}[X_1])^2\right]}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2}.\end{aligned} \tag{6.21}$$

Da die rechte Seite für jedes $\epsilon > 0$ nach Null konvergieren, folgt die Konvergenz wie behauptet sofort. □

Anmerkung. Beachte, dass wir hier keine Unabhängigkeit, sondern nur die schwächere Annahme der Unkorreliertheit gefordert haben!

6.3.2 Das starke Gesetz unter Momentenbedingungen

Die Schranke in (6.21) ist nicht über n summierbar, daher lässt sich hieraus nicht die fast sichere Konvergenz via Borel-Cantelli Lemma ableiten. Die naheliegende Idee

ist nun diese Abschätzung zu verbessern, indem wir eine Chebyshev-Ungleichung höherer Ordnung verwenden. Dies liefert z.B. folgende Aussage:

Satz 6.11. *Seien X_i unabhängige, identisch verteilte Zufallsvariablen und $\mathbb{E}\left[X_i^4\right] < \infty$. Dann gilt, dass*

$$\frac{S_n}{n} \equiv \frac{1}{n}\sum_{i=1}^{n} X_i \to \mathbb{E}\left[X_1\right], \quad \text{f.s.} \tag{6.22}$$

Beweis. Wir können ohne Schaden annehmen, dass $\mathbb{E}\left[X_1\right] = 0$. Unter Verwendung unseres Kriteriums aus Korollar 5.13 müssen wir nur zeigen, dass

$$\sum_{n=1}^{\infty} \mathbb{P}(|S_n/n| > \epsilon) < \infty. \tag{6.23}$$

Dies folgt aus der Chebyshev Ungleichung wenn wir zeigen, dass

$$\mathbb{E}\left[(S_n/n)^4\right] \leq Cn^{-2}, \tag{6.24}$$

für $C < \infty$. Nun ist aber

$$\mathbb{E}\left[S_n^4\right] = \sum_{i_1,i_2,i_3,i_4=1}^{n} \mathbb{E}X_{i_1}X_{i_2}X_{i_3}X_{i_4}. \tag{6.25}$$

Wegen $\mathbb{E}[X_i] = 0$ tragen in dieser Summe nur Terme bei, in denen je zwei der Indizes gleich sind. Daher ist

$$\sum_{i_1,i_2,i_3,i_4=1}^{n} \mathbb{E}\left[X_{i_1}X_{i_2}X_{i_3}X_{i_4}\right] = 3(n^2-n)\left(\mathbb{E}\left[X_1^2\right]\right)^2 + n\mathbb{E}\left[X_1^4\right]. \tag{6.26}$$

Hieraus folgt aber (6.23) sofort. □

Wir haben also ein starkes Gesetz, aber nur unter recht starken Momentenannahmen. Damit sind wir noch nicht zufrieden. Was wir aus dem Beweisen aber sehen, ist, dass wir mit der Chebyshev Ungleichung nicht weiterkommen. Wir brauchen eine bessere Ungleichung.

6.3.3 Kolmogorov's Ungleichung

Die gesuchte Verbesserung ist die folgende sog. *Kolmogorov Ungleichung*. Sie sagt etwas über das Maximum einer ganzen Familie $S_k, k \leq n$ aus.

Lemma 6.12. *Seien X_i, $i \in \mathbb{N}$, unabhängige Zufallsvariablen mit Mittelwerten $\mathbb{E}\left[X_k\right] = \mu_k$ und Varianzen σ_k^2. Sei $S_n = \sum_{k=1}^n X_k$, $m_n = \sum_{k=1}^n \mu_k$ und $s_n^2 \equiv \sum_{k=1}^n \sigma_k^2$. Dann ist für alle $t > 0$,*

$$\mathbb{P}\left(\exists_{k\le n} \,:\, |S_k - m_k| \ge t s_n\right) \le t^{-2}. \tag{6.27}$$

Beweis. O.b.d.A. nehmen wir an, dass $\mu_k = 0$, $k \ge 1$, so dass auch $m_n = 0$, $n \ge 1$.

Wir definieren die Zufallsvariablen

$$Y_k = \mathbb{1}_{|S_k|\ge t s_n} \prod_{\ell<k} \mathbb{1}_{|S_\ell|<t s_n} = \mathbb{1}_{\{k=\min\{\ell : S_\ell \ge t s_n\}}. \tag{6.28}$$

Offenbar kann nur höchstens eine der Variablen Y_k den Wert eins annehmen, so dass $Z_n \equiv \sum_{k=1}^n Y_k$ nur die Werte null und eins annimmt. Offenbar ist Z_n genau dann eins wenn das Ereignis in (6.27) eintritt. Daher ist auch $\mathbb{P}(Z_n = 1) = \mathbb{E}[Z_n]$. Ferner ist

$$Z_n S_n^2 \le S_n^2, \tag{6.29}$$

und somit

$$\mathbb{E}\left[Z_n S_n^2\right] = \sum_{k=1}^n \mathbb{E}\left[Y_k S_n^2\right] \le s_n^2. \tag{6.30}$$

Nun setzen wir

$$U_k \equiv S_n - S_k = \sum_{\ell=k+1}^n X_\ell. \tag{6.31}$$

Die letzte Gleichung macht deutlich, dass U_k nur von den Variablen X_ℓ mit $\ell > k$ abhängt, weswegen U_k von S_k und von Y_k unabhängig sind. Nun schreiben wir

$$S_n^2 = (U_k + S_k)^2, \tag{6.32}$$

und erhalten so

$$\begin{aligned}\mathbb{E}\left[Y_k S_n^2\right] &= \mathbb{E}\left[Y_k (U_k + S_k)^2\right] \\ &= \mathbb{E}\left[Y_k S_k^2\right] + 2\mathbb{E}\left[U_k Y_k S_k\right] + \mathbb{E}\left[U_k^2 Y_k\right].\end{aligned}$$

Wegen der angesprochenen Unabhängigkeit ist der zweite Term im letzten Ausdruck gleich $2\,\mathbb{E}[U_k]\,\mathbb{E}[Y_k S_k] = 0$, da die Erwartung von U_k verschwindet. Da zudem der letzte Term nicht negativ ist, erhalten wir

$$\mathbb{E}\left[Y_k S_n^2\right] \ge \mathbb{E}\left[Y_k S_k^2\right]. \tag{6.33}$$

Da, wenn $Y_k \ne 0$ ist, $|S_k| \ge t s_n$, folgt weiter

$$\mathbb{E}\left[Y_k S_n^2\right] \ge \mathbb{E}[Y_k]\, t^2 s_n^2. \tag{6.34}$$

Setzen wir diese Ungleichung in (6.30) ein und benutzen (6.29), so erhalten wir

$$\mathbb{E}[Z_n]\, t^2 s_n^2 \le s_n^2, \tag{6.35}$$

was unmittelbar die Behauptung ergibt. □

Anmerkung. Wir sehen, dass die Aussage des Satzes die Chebyshev-Ungleichung der Ordnung zwei für den Endpunkt S_n impliziert. Die Kolmogorov Ungleichung ist aber strikt schärfer, da sie ja das Maximum der S_k mit $k \leq n$ kontrolliert. In der Tat ist die erzielte Verbesserung signifikant.

6.3.4 Beweis des starken Gesetzes der großen Zahlen

Die Stärke der Kolmogorov'schen Ungleichung zeigt sich im folgenden Kriterium für das starke Gesetz für unabhängige, aber nicht identisch verteilte Zufallsvariablen.

Lemma 6.13. *Seien X_k, $k \in \mathbb{N}$ unabhängige Zufallsvariablen mit Varianzen σ_k^2 und Mittelwerten μ_k. Wenn*

$$\sum_{k=1}^{\infty} \frac{\sigma_k^2}{k^2} < \infty, \tag{6.36}$$

dann gilt

$$\frac{1}{n} \sum_{k=1}^{n} (X_k - \mu_k) \to 0, \quad \text{f.s.} \tag{6.37}$$

Beweis. Wieder setzen wir o.B.d.A. $\mu_k \equiv 0$. Wir definieren die Ereignisse A_p durch

$$A_p = \bigcup_{2^{p-1} < n \leq 2^p} \{|S_n| \geq \epsilon n\}. \tag{6.38}$$

Wenn die Summe der Wahrscheinlichkeiten der A_p konvergiert, so folgt die fast sicher Konvergenz aus dem ersten Borel-Cantelli Lemma. Wir müssen also die Wahrscheinlichkeiten der A_p abschätzen. Nun impliziert das Ereignis A_p, dass für ein n zwischen $2^{p-1} + 1$ und 2^p, $|S_n| \geq \epsilon 2^{p-1}$. Dies ist aber ein Ereignis, dessen Wahrscheinlichkeit durch die Kolmogorov'sche Ungleichung abgeschätzt werden kann. Nämlich

$$\begin{aligned} \mathbb{P}(A_p) &\leq \mathbb{P}\left(\exists_{2^{p-1} < k \leq 2^p} \{|S_k| \geq \epsilon 2^{p-1}\}\right) \\ &\leq \mathbb{P}\left(\exists_{1 \leq k \leq 2^p} \{|S_k| \geq \epsilon 2^{p-1} s_{2^p}^{-1} s_{2^p}\}\right) \\ &\leq 4\epsilon^{-2} 2^{-2p} s_{2^p}^2. \end{aligned}$$

Nun müssen wir nur noch summieren:

$$\begin{aligned} \sum_{p=1}^{\infty} \mathbb{P}(A_p) &\leq \sum_{p=1}^{\infty} 4\epsilon^{-2} 2^{-2p} s_{2^p}^2 = 4\epsilon^{-2} \sum_{p=1}^{\infty} 2^{-2p} \sum_{k=1}^{2^p} \sigma_k^2 \\ &= 4\epsilon^{-2} \sum_{k=1}^{\infty} \sigma_k^2 \sum_{p: 2^p \geq k} 2^{-2p} \leq 8\epsilon^{-2} \sum_{k=1}^{\infty} \sigma_k^2 k^{-2} \end{aligned} \tag{6.39}$$

was nach Annahme endlich ist. Somit ist das Lemma bewiesen. □

Mit diesem Kriterium können wir nun den Beweis von Satz 6.9 führen.

Beweis. von Satz 6.9. Hier lernen wir noch eine wichtige Technik kennen, die der *Trunkation*. Im wesentlichen wollen wir unsere Variablen so aufspalten, dass wir einen Term erhalten, auf den wir das Lemma von oben anwenden können, während der Rest nach null konvergiert. Dazu setzen wir

$$U_k = X_k \mathbb{1}_{|X_k|<k}, \quad V_k = X_k \mathbb{1}_{|X_k|\geq k}. \tag{6.40}$$

Offenbar ist $X_k = U_k + V_k$. Nun erfüllen die U_k die Voraussetzungen von Lemma 6.13. Dazu berechnen wir

$$\sigma_k^2 \equiv \mathrm{var}(U_k) \leq \mathbb{E}[U_k^2] \leq \sum_{\ell=1}^{k} \ell\, \mathbb{E}\left(|X_k| \mathbb{1}_{\ell-1\leq|X_k|<\ell}\right) \equiv \sum_{\ell=1}^{k} \ell a_\ell. \tag{6.41}$$

beachte, dass a_ℓ nicht von k abhängt, da die X_k gleichverteilt sind.Daher gilt

$$\sum_{k=1}^{\infty} \frac{\sigma_k^2}{k^2} \leq \sum_{k=1}^{\infty} \frac{1}{k^2} \sum_{\ell=1}^{k} \ell a_\ell = \sum_{\ell=1}^{\infty} \ell a_\ell \sum_{k=\ell}^{\infty} \frac{1}{k^2} \leq C \sum_{\ell=1}^{\infty} a_\ell, \tag{6.42}$$

wobei wir benutzt haben, dass $\sum_{k=\ell}^{\infty} \frac{1}{k^2} \leq 2/\ell$ (für $\ell > 4$) ist; nun ist aber

$$\sum_{\ell=1}^{\infty} a_\ell = \mathbb{E}[|X_k|] < \infty, \tag{6.43}$$

nach Vorraussetzung. Somit sind in der Tat die Voraussetzungen von Lemma 6.13 erfüllt. Weiter ist

$$\mathbb{E}[U_k] = \mu - \mathbb{E}\left[X_k \mathbb{1}_{|X_k|\geq k}\right] = \mu - \mathbb{E}\left[X_1 \mathbb{1}_{|X_1|\geq k}\right]. \tag{6.44}$$

Da aber $\mathbb{E}[|X_1|] < \infty$, folgt

$$\lim_{k\uparrow\infty} \mathbb{E}[U_k] \leq \lim_{k\uparrow\infty} \left|\mathbb{E}\left[X_1 \mathbb{1}_{|X_1|\geq k}\right]\right| \leq \lim_{k\uparrow\infty} \mathbb{E}\left[|X_1| \mathbb{1}_{|X_1|\geq k}\right] = 0. \tag{6.45}$$

Insbesondere folgt daraus auch $\lim_{n\uparrow\infty} \frac{1}{n} \sum_{k=1}^{n} U_k = \mu$, Damit folgt aus Lemma 6.13, dass $n^{-1} \sum_{k=1}^{n} (U_k - \mathbb{E}[U_k]) \to 0$, fast sicher, und $n^{-1} \sum_{k=1}^{n} \mathbb{E}[U_k] \to \mu$, so dass $n^{-1} \sum_{k=1}^{n} U_k \to \mu$, fast sicher.

Wir müssen nur noch zeigen, dass V_k unwichtig ist. Die Gefahr an V_k ist ja, dass es sehr groß sein kann: dafür ist es aber auch meistens gleich Null. In der Tat wollen wir zeigen, dass es nur endlich oft von Null verschieden ist. Dazu schreiben wir

$$\mathbb{P}(V_n \neq 0) = \mathbb{E}\left[\mathbb{1}_{|X_n|\geq n}\right] \leq \sum_{\ell=n}^{\infty} \frac{a_{\ell+1}}{\ell}. \tag{6.46}$$

Dann ist

$$\sum_{n=1}^{\infty} \mathbb{P}(V_n \neq 0) \leq \sum_{n=1}^{\infty} \sum_{\ell=n}^{\infty} \frac{a_{\ell+1}}{\ell} = \sum_{\ell=1}^{\infty} \frac{a_{\ell+1}}{\ell} \sum_{n=1}^{\ell} 1 = \sum_{\ell=1}^{\infty} a_{\ell+1} < \infty \tag{6.47}$$

und das Ergebnis folgt aus dem ersten Borel-Cantelli Lemma. □

Kapitel 7
Der zentrale Grenzwertsatz

On peut facilement, au moyen de ces formules, déterminer les bénéfices des loteries[a].
Pierre Simon de Laplace, Théorie Analytique des Probabilités

[a] Man kann mittels dieser Formeln leicht den Gewinn von Lotterien berechnen.



Wir kommen nun zu dem zweiten wichtigen Satz der Wahrscheinlichkeitstheorie, dem nicht ohne Grund so genannten *zentralen Grenzwertsatz*. Seine Bedeutung liegt zum einen wieder in den Implikationen für die Statistik, denn er rechtfertigt in vielen Fällen die Annahme einer Gauß'schen Verteilung (bzw. derer Derivate) für Zufallsgrössen die auf komplizierte Art und Weise zustande kommen. Zum anderen ist er ein weiteres Beispiel dafür, wie spezifische Gesetzmässigkeiten aus zufälligem Geschehen folgen. Einen speziellen Fall des zentralen Grenzwertsatzes haben wir schon mit dem Satz von de Moivre-Laplace kennengelernt.

7.1 Grenzwertsätze

Der zentrale Grenzwertsatz kann als Verfeinerung des Gesetzes der großen Zahlen aufgefasst werden. Wir wissen, das für Summen, $S_n \equiv \sum_{i=1}^{n} X_i$, unabhängiger, identisch verteilter Zufallsvariablen, X_i, $n^{-1}S_n$ fast sicher gegen den Erwartungswert, $\mathbb{E}X_1$ konvergiert. Es liegt nun nahe, die Frage nach der Konvergenzgeschwindigkeit zu stellen. Dazu nehmen wir $n^{-1}S_n - \mathbb{E}X_1$ und blasen es mit einem n-abhängigen Faktor auf, der so gewählt ist, dass im Grenzwert etwa endliches übrig bleibt. Es liegt nahe, eine Potenz von n zu versuchen. Die Frage ist also: gibt es $\gamma > 0$, so dass

$$n^{\gamma}(n^{-1}S_n - \mathbb{E}X_1) \tag{7.1}$$

einen nicht-trivialen Limes hat. Dieser wird i.A. eine Zufallsvariable sein. Schon numerischen Simulationen zeigen dabei, dass die Konvergenz dabei bestenfalls in Verteilung zu erwarten ist. Unser Problem ist also die Berechnung der Verteilung des Limes von Summen unnabhängiger Zufallsvariablen nach geeigneter Reskalie-

rung. Unsere Erfahrung mit dem speziellen Fall der Bernoulliverteilung legt dabei nahe, dass wohl $\gamma = 1/2$ gewählt werden sollte, und das der Grenzwert gerade die Gaußverteilung sein sollte; jedoch ist von vorneherein nicht auszuschliessen, dass all dies von der speziellen Wahl der Verteilungen abhängen kann.

Allgemein gesprochen, stellt sich die Aufgabe also wie folgt:

- Unter welchen Annahmen an die Zufallsvariablen X_i gibt es ein γ, so dass der Ausdruck in (7.1) in Verteilung gegen eine Zufallsvariable konvergiert?
- Was sind die möglichen Verteilungen der Grenzwerte?
- Welche Bedingungen an die Verteilungen der X_i charakterisieren die Verteilung des Grenzwertes?

Wir werden uns im folgenden auf den Fall beschränken, dass die Zufallsvariablen X_i endliche Varianz haben. Es ist dann

$$\mathbb{E}\left[\left(n^{\lfloor g}\left(n^{-1}S_n - \mathbb{E}X_1\right)\right)^2\right] = n^{2\gamma-1}\mathrm{var}(X_1). \tag{7.2}$$

Für $\gamma < 1/2$ würde die Varianz also nach Null gehen, und also nur 0 als Grenzwert in Frage kommen. Für $\gamma > 1/2$ würde die Varianz immer grösser werden, was auch nicht erwarten liesse, dass ein Grenzwert existiert. Für $\gamma = 1/2$ dagegen bleibt schon einmal die Varianz konstant, was schon einmal ein gutes Zeichen ist. Es bleibt zu zeigen, dass für diese Wahl dann auch tatsächlich Konvergenz in Verteilung folgt.

7.2 Charakteristische Funktionen

Wir hatten gesehen, dass die Verteilungen als n-fache Faltungen der Verteilungen von X_i ausgedrückt werden können. Die entsprechenden Ausdrücke wirken allerdings im Allgemeinen unhandlich. Eine gute Methode, mit solchen Faltungen umzugehen ist die sogenannte Fouriertransformation.

Definition 7.1. Sei X eine reelle Zufallsvariable auf einem Wahrscheinlichkeitsraum $(\Omega, \mathfrak{F}, \mathbb{P})$, dann heißt

$$\phi(t) \equiv \phi_X(t) = \mathbb{E}[\mathrm{e}^{\mathbf{i}tX}] \equiv \mathbb{E}[\cos(Xt)] + \mathbf{i}\,\mathbb{E}[\sin(tX)], \tag{7.3}$$

wo $t \in \mathbb{R}$ und $\mathbf{i} = \sqrt{-1}$ ist, die *charakteristische Funktion* von X bzw. die charakteristische Funktion der Verteilung, $\mathbb{P}_X \equiv \mathbb{P} \circ X^{-1}$, von X.

Anmerkung. Natürlich ist, wenn P_X die Verteilung von X ist,

$$\phi_X(t) = \int_{\mathbb{R}} \mathrm{e}^{\mathbf{i}tx}\,\mathrm{d}P_X(x) \tag{7.4}$$

gerade die *Fouriertransformierte* des Masses P_X. Für ein Mass, μ, auf $\mathbb{R}$ schreiben wir auch ϕ_μ für $\int \mathrm{e}^{\mathbf{i}tx}\,\mathrm{d}\mu(x)$ und nennen ϕ_μ die charakteristische Funktion des Masses μ. In der Literatur wird häufig auch die Bezeichnung $\widehat{\mu} \equiv \phi_\mu$ benutzt.

Wir beobachten zuächst, dass $\phi_X(t)$ für alle $t \in \mathbb{R}$ existiert, da sowohl $\sin(xt)$ als auch $\cos(xt)$ beschränkt und messbar, also insbesondere integrierbar gegen jedes W-Maß sind. Weiterhin kann man zeigen, dass jede charakteristische Funktion stetig ist.

Lemma 7.2. *Jede charakteristische Funktion, ϕ, eines Wahrscheinlichkeitsmasses ist gleichmässig stetig auf $\mathbb{R}$.*

Beweis. Eine elementare Rechnung zeigt, dass

$$|\phi(t) - \phi(s)|^2 \leq 2\left(1 - \Re\left(\phi(t-s)\right)\right). \tag{7.5}$$

Es ist nämlich

$$\begin{aligned}
|\phi(t) - \phi(s)|^2 &= \left|\mathbb{E}\left[\mathrm{e}^{\mathbf{i}tX}\left(1 - \mathrm{e}^{\mathbf{i}(s-t)X}\right)\right]\right|^2 \\
&\leq \mathbb{E}\left[\left|1 - \mathrm{e}^{\mathbf{i}(s-t)X}\right|\right]^2 \leq \mathbb{E}\left[\left|1 - \mathrm{e}^{\mathbf{i}(s-t)X}\right|^2\right] \\
&= \mathbb{E}\left[2 - 2\cos((s-t)X)\right],
\end{aligned}$$

wo die zweite Ungleichung die Cauchy-Schwartz (oder die Jensen) Ungleichung benutzt. Damit ist $\phi(t)$ gleichmäßig stetig, wenn ϕ bei Null stetig ist. Dies folgt aber sofort: Für jedes $N < \infty$,

$$\mathbb{E}[1 - \cos(uX)] \leq \mathbb{E}\left[\mathbb{1}_{|X|\leq N}(1 - \cos(uX))\right] + 2\mathbb{P}\left(|X| > N\right).$$

Nun können wir für jedes $\epsilon > 0$ Zahlen $N \in \mathbb{N}$ und $u_0 > 0$ so finden, dass für alle $|u| \leq u_0$, sowohl der erste als auch der zweite Ausdruck kleiner als $\epsilon^2/2$ sind. Damit folgt aber die Stetigkeit, und sogar die gleichmässige Stetigkeit von ϕ. □

Wie schon die erzeugenden Funktionen sind die charakteristischen Funktionen mit den Momenten verknüpft.

Lemma 7.3. *Seien ϕ die charakteristische Funktion einer Zufallsvariablen X und sei ferner $\mathbb{E}\left[|X|^n\right] < \infty$. Dann ist ϕ n-mal differenzierbar und es gelten*

$$\phi(0) = 1, \tag{7.6}$$

$$\phi^{(n)}(0) \equiv \frac{d^n}{\mathrm{d}t^n}\phi(t=0) = \mathbf{i}^n\mathbb{E}\left[X^n\right]. \tag{7.7}$$

Beweis. Zunächst ist $\phi(0) = \mathbb{E}1 = 1$. Wir setzen $e(t;x) = \mathrm{e}^{\mathbf{i}xt}$ und $\mathrm{e}^{(n)}(t;x) \equiv \frac{\partial^n}{\partial t^n}e(t;x)$. Dann ist

$$e(t;X) = e(0;X) + \int_0^t \mathrm{e}^{(1)}(t_1;X)\,\mathrm{d}t_1, \tag{7.8}$$

und also

$$\phi(t) = \phi(0) + \mathbb{E}\left[\int_0^t \mathrm{e}^{(1)}(t_1;X)\,\mathrm{d}t_1\right]. \tag{7.9}$$

Nun ist $|\mathrm{e}^{(1)}(t_1; X)| \leq |X|$ und daher unter der Annahme, dass $\mathbb{E}|X| < \infty$, nach dem Satz von Fubini-Lebesgue,

$$\mathbb{E}\left[\int_0^t \mathrm{e}^{(1)}(t_1; X)\,\mathrm{d}t_1\right] = \int_0^t \mathbb{E}\left[\mathrm{e}^{(1)}(t_1; X)\right]\,\mathrm{d}t_1. \tag{7.10}$$

Die rechte Seite ist nun explizit differenzierbar bezüglich t und daher

$$\phi'(t) = \mathbb{E}\left[\mathrm{e}^{(1)}(t_1; X)\right] = i\mathbb{E}\left[X\mathrm{e}^{\mathbf{i}tX}\right], \tag{7.11}$$

und somit $\phi'(0) = \mathbf{i}\mathbb{E}X$.

Die Verallgemeinerung auf den Fall der n-ten Ableitung geht genauso, indem wir benutzen, dass

$$\mathrm{e}^{\mathbf{i}tX} - \sum_{j=0}^{n-1} \frac{(\mathbf{i}tX)^j}{j!} = \mathbf{i}^n X^n \int_0^t \int_0^{t_n} \cdots \int_0^{t_2} \mathrm{e}^{\mathbf{i}t_1 X}\,\mathrm{d}t_1 \ldots\,\mathrm{d}t_n. \tag{7.12}$$

Daher ist

$$\begin{aligned}\phi(t) - \sum_{j=0}^{n-1} \frac{(\mathbf{i}t)^j \mathbb{E}X^j}{j!} &= \mathbf{i}^n \mathbb{E}\left[X^n \int_0^t \int_0^{t_n} \cdots \int_0^{t_2} \mathrm{e}^{\mathbf{i}t_1 X}\,\mathrm{d}t_1 \ldots\,\mathrm{d}t_n\right] \\ &= \mathbf{i}^n \int_0^t \int_0^{t_n} \cdots \int_0^{t_2} \mathbb{E}\left[X^n \mathrm{e}^{\mathbf{i}t_1 X}\right]\,\mathrm{d}t_1 \ldots\,\mathrm{d}t_n. \end{aligned} \tag{7.13}$$

Hier haben wir wieder den Satz von Fubini-Lebesgue unter den Annahme dass $\mathbb{E}|X|^n < \infty$ ist benutzt um die Erwartung bez. X und die t-Integrale zu vertauschen. Jetzt können wir beide Seiten n-mal ableiten und t Null setzen um (7.6) zu erhalten. □

Die Nützlichkeit der charakteristischen Funktionen rührt unter anderem daher, dass sie eine sehr schöne Eigenschaft bezüglich der Faltung hat. Wir werden im folgenden stets Zufallsvariablen mit Mittelwert Null betrachten, da wir uns durch Subtraktion des Mittelwertes immer auf triviale Weise auf diesen Fall zurückziehen können.

Lemma 7.4. *Seien X_ℓ, $\ell \in \mathbb{N}$ unabhängige Zufallsvariablen mit Mittelwerten* 0 *und charakteristischen Funktionen ϕ_{X_ℓ}. Sei $S_n = \sum_{\ell=1}^n X_\ell$. Dann ist*

$$\phi_{S_n}(t) = \prod_{\ell=1}^n \phi_{X_\ell}(t). \tag{7.14}$$

Weiter gilt, wenn

$$Z_n \equiv n^{-1/2} S_n, \tag{7.15}$$

$$\phi_{Z_n}(t) = \prod_{\ell=1}^n \phi_{X_\ell}(t/\sqrt{n}). \tag{7.16}$$

Beweis. Die Aussagen folge sofort aus Lemma 3.9. □

Beispiel 7.5. Vergleiche mit Bemerkung 4.5 und Beispiel 6.4.

- Für $X \sim \mathcal{N}(\mu, \sigma^2)$, gilt $\phi(t) = \exp(-\sigma^2 t^2/2 + it\mu)$.
- Für $X \sim \mathrm{Bin}(n, p)$, gilt $\phi(t) = (1 - p + p\,\mathrm{e}^{it})^n$.
- Für $X \sim \mathrm{Poi}(\lambda)$, gilt $\phi(t) = \exp(-\lambda(\mathrm{e}^{it} - 1))$.
- Für $X \sim \mathrm{Exp}(a)$, gilt $\phi(t) = 1/(1 - it/a)$.
- Für $X \sim \mathrm{Geo}(q)$, gilt $\phi(t) = (1 - q)/(1 - q\mathrm{e}^{it})$.
- Für $X \sim \mathrm{Cauchy}(a)$, gilt $\phi(t) = \mathrm{e}^{-i|t|a}$.

In der Welt der charakteristischen Funktionen sind also die Summen unabhängier Zufallsvariablen einfach mit den Produkten verknüpft, was viel leichter zu handhaben ist als die Faltung. Was man also nur noch braucht, damit dies nützlich ist, ist ein Weg zurück aus der Welt der charakteristischen Funktionen in die der Verteilungen. Diesen liefert uns der folgende Satz von Lévy.

Satz 7.6. *Die charakteristische Funktion einer Zufallsvariablen legt deren Verteilung eindeutig fest.*

Beweis. Der Beweis benutzt den Gauss'schen Fall als Startpunkt. Wir beginnen daher mit folgendem Lemma.

Lemma 7.7. *Sei X eine Gauss'sche Zufallsvariable mit Mittelwert Null und Varianz σ^2. Dann ist für alle $t \in \mathbb{R}$*

$$\phi_X(t) = \exp\left(-\frac{\sigma^2 t^2}{2}\right). \tag{7.17}$$

Beweis. Man kann dieses Resultat auf verschiedene Arten zeigen. Wir gehen wie folgt vor. Aus dem Beweis von Satz 7.3 wissen wir schon, dass

$$\phi'_X(t) = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{\mathbb{R}} \mathrm{e}^{-\frac{x^2}{2\sigma^2}}\, \mathbf{i}x\mathrm{e}^{\mathbf{i}tx}\, \mathrm{d}x. \tag{7.18}$$

Nun ist

$$\mathrm{e}^{-\frac{x^2}{2\sigma^2}}\, \mathbf{i}x\mathrm{e}^{itx} = -\mathbf{i}\sigma^2 \left(\frac{\mathrm{d}}{\mathrm{d}x}\mathrm{e}^{-\frac{x^2}{2\sigma^2}}\right)\mathrm{e}^{\mathbf{i}tx}, \tag{7.19}$$

und daher erhalten wir durch partielle integration in (7.18) die Differentialgleichung

$$\phi'_X(t) = -t\sigma^2\phi_X(t). \tag{7.20}$$

Aus dem Eindeutigkeitsatz für Differentialgleichungen erster Ordnung folgt, dass diese Gleichung nur eine Lösung mit gegebenem Anfangswert $\phi_X(0)$ haben kann. In unserem Fall muss aber $\phi_X(0) = 1$ gelten. Nun ist die rechte Seite von (7.17) eine Lösung mit dieser Anfangsbedingung (wie man leicht nachrechnet), und mithin die einzige.die einzige. □

Anmerkung. Man kann diese Aussage auch mithilfe komplexer Kurvenintegrale beweisen.

Wir kommen nun zum Beweis des eigentlichen Satzes. Wir setzen

$$p_\sigma(x) \equiv \frac{1}{\sqrt{2\pi\sigma^2}} \mathrm{e}^{-\frac{x^2}{2\sigma^2}}. \tag{7.21}$$

Sei μ ein Wahrscheinlichkeitsmaß auf $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$. Wir definieren

$$f_\sigma(x) \equiv \int_{\mathbb{R}} p_\sigma(x-y)\,\mathrm{d}\mu(y) \equiv (p_\sigma \star \mu)(x), \tag{7.22}$$

und $d\mu_\sigma(x) \equiv f_\sigma(x)\,\mathrm{d}x$.

Wir zeigen zunächst, dass μ_σ eindeutig durch ϕ_μ bestimmt ist. Dazu beobachten wir, dass

$$\sqrt{2\pi\sigma^2}\, p_\sigma(x) = \mathrm{e}^{-\frac{x^2}{2\sigma^2}} = \int_{\mathbb{R}} \mathrm{e}^{-\mathbf{i}tx} p_{1/\sigma}(t)\,\mathrm{d}t. \tag{7.23}$$

Darum haben wir

$$\begin{aligned} f_\sigma(x) &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{\mathbb{R}}\int_{\mathbb{R}} \mathrm{e}^{-\mathbf{i}t(x-y)} p_{1/\sigma}(t)\,\mathrm{d}t\,\mathrm{d}\mu(y) \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{\mathbb{R}} \mathrm{e}^{-\mathbf{i}tx} p_{1/\sigma}(t) \left(\int_{\mathbb{R}} \mathrm{e}^{\mathbf{i}ty}\,\mathrm{d}\mu(y) \right) \mathrm{d}t \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{\mathbb{R}} \mathrm{e}^{-\mathbf{i}tx} p_{1/\sigma}(t)\phi_\mu(t)\,\mathrm{d}t. \end{aligned} \tag{7.24}$$

Hier haben wir den Satz von Fubini-Lebesgue in der ersten Gleichung verwendet und die Definition der charakteristischen Funktion in der zweiten. Im Ergebnis haben wir nun eine Formel für die Dichte des Maßes μ_σ in die nur die charakteristische Funktion von μ eingeht.

Schliesslich zeigen wir noch, dass für jede stetige und beschränkte Funktion, h,

$$\lim_{\sigma\downarrow 0} \int h(x)\,\mathrm{d}\mu_\sigma(x) = \int_{\mathbb{R}} h(x)\,\mathrm{d}\mu(x) \tag{7.25}$$

gilt. Zunächst sehen wir, dass, wieder unter Verwendung des Satzes von Fubini,

$$\begin{aligned} \int_{\mathbb{R}} h(x)\,\mathrm{d}\mu_\sigma(x) &= \int_{\mathbb{R}} \left(\int_{\mathbb{R}} h(x)\rho_\sigma(x-y)\mathrm{d}\mu(y) \right) \mathrm{d}x \\ &= \int_{\mathbb{R}} \left(\int_{\mathbb{R}} \rho_\sigma(x-y)h(x)\mathrm{d}x \right) \mathrm{d}\mu(y) = \int_{\mathbb{R}} (p_\sigma \star h)(y)\,\mathrm{d}\mu(y). \end{aligned} \tag{7.26}$$

Dabei haben wir die Faltung zweier Funktionen definiert als

$$(\rho_\sigma \star h)(y) = \int_{\mathbb{R}} \rho_\sigma(y-x)h(x)\mathrm{d}x \tag{7.27}$$

und benutzt, dass $\rho_\sigma(x) = \rho_\sigma(-x)$. Dann benutzen wir die elementaren Eigenschaften der Gauss'schen Dichte,

$$\int_{\mathbb{R}} p_\sigma(x)\,\mathrm{d}x = 1 \tag{7.28}$$

$$\lim_{\sigma\downarrow 0}\int_{|x|>\epsilon} p_\sigma(x)\,\mathrm{d}x = 0, \quad \forall \epsilon > 0. \tag{7.29}$$

Dies impliziert für stetige und beschränkte Funktionen h, dass

$$\lim_{\sigma\downarrow 0}(p_\sigma \star h)(x) \equiv \lim_{\sigma\downarrow 0}\int_{\mathbb{R}} p_\sigma(x-y)h(y)\mathrm{d}y = h(x). \tag{7.30}$$

Da weiter $p_\sigma \star h(x) \leq \sup h(x) < \infty$, können wir den Satz von Lebesgue benutzen um zu zeigen, dass (7.25) gilt. Damit ist aber das Maß μ eindeutig durch ϕ_μ festgelegt. □

Es ist also nicht verwunderlich, dass Konvergenz der charakteristischen Funktionen einer Folge von Zufallsvariablen deren Konvergenz in Verteilung impliziert. Auch dieser Satz geht auf Lévy zurück.

Satz 7.8. *Sei X_n, $n \in \mathbb{N}$, eine Folge von Zufallsvariablen und seien ϕ_n deren charakteristische Funktionen. Wenn die charakteristischen Funktionen ϕ_n punktweise gegen einen Grenzwert ϕ auf $\mathbb{R}$ konvergieren, der die charakteristische Funktion einer Zufallsvariablem X ist, dann konvergieren die Zufallsvariablen X_n in Verteilung gegen X.*

Beweis. Es sei ϕ_n eine Folge von charakteristischen Funktionen, die punktweise gegen eine charakteristische Funktion ϕ konvergiert. Es seien μ_n, μ, die zugehörigen Wahrscheinlichkeitsmaße. Wir wollen zeigen, daß μ_n schwach gegen μ konvergiert. Sei dazu f eine stetige Funktion mit kompaktem Träger. Wir zeigen zunächst, dass $\int f\,\mathrm{d}\mu_n \to \int f\,\mathrm{d}\mu$. Wir zeigen dazu, dass für alle $\sigma > 0$,

$$\int_{\mathbb{R}} p_\sigma \star f\,\mathrm{d}\mu_n \to \int_{\mathbb{R}} p_\sigma \star f\,\mathrm{d}\mu. \tag{7.31}$$

Dazu benutzen wir, dass, wie wir schon sahen,

$$\int_{\mathbb{R}} p_\sigma \star f\,\mathrm{d}\mu_n = \int_{\mathbb{R}} f(x)\left(\frac{1}{\sqrt{2\pi\sigma^2}}\int_{\mathbb{R}} \mathrm{e}^{-\mathbf{i}xt} p_{1/\sigma}(t)\phi_n(t)\,\mathrm{d}t\right)\mathrm{d}x. \tag{7.32}$$

Da ϕ_n punktweise konvergiert und die Integranden (bezüglich der t-Integration) $\mathrm{e}^{-\mathbf{i}tx} p_{1/\sigma}(t)\phi_n(t)$ im Betrag durch die integrierbare Funktion $p_{1/\sigma}(t)$ beschränkt sind, folgt aus dem Satz von Lebesgue, dass

$$\lim_{n\uparrow\infty}\frac{1}{\sqrt{2\pi\sigma^2}}\int_{\mathbb{R}} \mathrm{e}^{-\mathbf{i}xt} p_{1/\sigma}(t)\phi_n(t)\,\mathrm{d}t = \frac{1}{\sqrt{2\pi\sigma^2}}\int_{\mathbb{R}} \mathrm{e}^{-\mathbf{i}xt} p_{1/\sigma}(t)\phi(t)\,\mathrm{d}t, \tag{7.33}$$

und da diese im Betrag kleiner oder gleich 1 sind, können wir wieder den Satz von Lebesgue auf die x-Integration anwenden (da f beschränkt mit kompaktem Träger ist) und erhalten (7.31). Schliesslich bemerken wir, dass, für jedes $\sigma > 0$,

$$\begin{aligned}\left|\int f\,\mathrm{d}\mu_n - \int f\,\mathrm{d}\mu\right| &\le \int |f - (p_\sigma \star f)|\,\mathrm{d}\mu_n \\ &\quad + \left|\int (p_\sigma \star f)\,\mathrm{d}\mu_n - \int (p_\sigma \star f)\,\mathrm{d}\mu\right| \\ &\quad + \int |(p_\sigma \star f) - f|\,\mathrm{d}\mu.\end{aligned} \tag{7.34}$$

Sei $\epsilon > 0$ beliebig; dann wählen wir σ so, dass $\sup_x |(p_\sigma \star f)(x) - f(x)| \le \epsilon/3$ und danach n so, dass $\left|\int (p_\sigma \star f)\,\mathrm{d}\mu_n - \int (p_\sigma \star f)\,\mathrm{d}\mu\right| \le \epsilon/3$ (das ist wegen (7.31) möglich). Dann folgt mit (7.34), dass für solche n,

$$\left|\int f\,\mathrm{d}\mu_n - \int f\,\mathrm{d}\mu\right| \le \epsilon, \tag{7.35}$$

und mithin die Konvergenz von $\int f\,\mathrm{d}\mu_n$ nach $\int f\,\mathrm{d}\mu$.

Zum Schluss müssen wir noch zeigen, dass die Konvergenz für alle stetigen Funktionen mit kompaktem Träger ausreicht, um die Konvergenz von $\int f\,\mathrm{d}\mu_n$ für alle beschränkten stetigen Funktionen zu zeigen. Sei dazu h_k eine Folge von stetigen Funktionen mit kompaktem Träger und $0 \le h_k(x) \le 1$, so dass $h_k \uparrow 1$. Dann ist fh_k ebenfalls stetig mit kompaktem Träger, und somit

$$\int h_k f\,\mathrm{d}\mu_n \to \int h_k f\,\mathrm{d}\mu. \tag{7.36}$$

Weiter ist

$$\begin{aligned}\left|\int f\,\mathrm{d}\mu_n - \int f h_k\,\mathrm{d}\mu_n\right| &\le \sup_x |f(x)| \left(1 - \int h_k\,\mathrm{d}\mu_n\right), \\ \left|\int f\,\mathrm{d}\mu - \int f h_k\,\mathrm{d}\mu\right| &\le \sup_x |f(x)| \left(1 - \int h_k\,\mathrm{d}\mu\right).\end{aligned}$$

Somit haben wir

$$\begin{aligned}\left|\int f\,\mathrm{d}\mu_n - \int f\,\mathrm{d}\mu\right| &\le \left|\int f h_k\,\mathrm{d}\mu_n - \int f h_k\,\mathrm{d}\mu\right| \\ &\quad + M\left(1 - \int h_k\,\mathrm{d}\mu_n\right) + M\left(1 - \int h_k\,\mathrm{d}\mu\right) \\ &= \left|\int f h_k\,\mathrm{d}\mu_n - \int f h_k\,\mathrm{d}\mu\right| \\ &\quad + 2M\left(1 - \int h_k\,\mathrm{d}\mu\right) + M\left|\int h_k \mathrm{d}\mu_n - \int h_k\,\mathrm{d}\mu\right|\end{aligned} \tag{7.37}$$

wobei $M = \sup_x |f(x)|$. Der erste und der letzte Term streben für jedes $k \in \mathbb{N}$ mit n gegen Null, der zweite strebt mit k gegen Null. Für beliebiges $\epsilon > 0$ können wir daher k so wählen, dass $0 \le 1 - \int h_k \, \mathrm{d}\mu \le \epsilon/4M$. Danach wählen wir n_0, so dass für alle $n \ge n_0$, $M \left| \int h_k \, \mathrm{d}\mu_n - \int h_k \, \mathrm{d}\mu \right| \le \epsilon/4$ und $\left| \int f h_k \, \mathrm{d}\mu_n - \int f h_k \, \mathrm{d}\mu \right| \le \epsilon/4$. Dann ist für alle $n \ge n_0$

$$\left| \int f \, \mathrm{d}\mu_n - \int f \, \mathrm{d}\mu \right| \le \epsilon. \tag{7.38}$$

Dann folgt die schwache Konvergenz nach definition. □

7.3 Der zentrale Grenzwertsatz

Der Satz 7.8 von Lévy gibt uns ein einfach zu handhabendes Kriterium an die Hand, um einen zentralen Grenzwertsatz zu beweisen. Es genügt danach offenbar, die charakteristische Funktion der Zufallsvariablen Z_n zu berechnen und deren Konvergenz nachzuweisen und den Grenzwert als charakteristische Funktion einer bekannten Zufallsvariable zu identifizieren. In Hinblick darauf, dass wir stets statt X_i die Variablen $X_i - \mathbb{E}X_i$ betrachten können, genügt es im Folgenden die Annahme $\mathbb{E}X_i = 0$ zu machen.

Aus Lemma 7.4 folgt sofort als Korollar:

Korollar 7.9. *Seien X_i unabhängige identisch verteilte Zufallsvariablen mit Erwartungswert* 0 *und charakteristischer Funktion ϕ, und sei Z_n wie in (7.15).*

$$\phi_{Z_n}(t) = \left[\phi(n^{-1/2} t) \right]^n . \tag{7.39}$$

Bleibt also nur zu zeigen, wann und wohin $\left[\phi(n^{-1/2} t) \right]^n$ konvergiert. Hierzu benutzen wir das folgende elementare Lemma.

Lemma 7.10. *Sei $(a_n, n \in \mathbb{N})$ eine Folge von reellen Zahlen so dass $\lim_{n \uparrow \infty} a_n = a$. Dann gilt*

$$\lim_{n \uparrow \infty} (1 + a_n/n)^n = \mathrm{e}^a. \tag{7.40}$$

Beweis. Offenbar ist $1 + a_n/n = \exp(\ln(1 + a_n/n))$. Für hinreichend große n is dann auch $|a_n/n| \le 1/10$. Andererseits gibt es eine endliche Konstante C, so dass für alle $|x| \le 1/10$, $|\ln(1 + x) - x| \le Cx^2$. Mithin ist für hinreichend große n

$$(1 + a_n/n)^n \le \exp\left(a_n + C|a_n|^2/n \right) \tag{7.41}$$

$$(1 + a_n/n)^n \ge \exp\left(a_n - C|a_n|^2/n \right). \tag{7.42}$$

Hieraus folgt offensichtlich die Behauptung. □

Wir können nun unsere Kernaussage formulieren.

Lemma 7.11. *Sei ϕ eine zweimal differenzierbare Funktion auf $\mathbb{R}$ mit $\phi(0) = 1$ und $\phi'(0) = 0$. Dann gilt*

$$\lim_{n\to\infty} \left[\phi(n^{-1/2}t)\right]^n = \exp\left(+\frac{t^2}{2}\phi''(0)\right). \tag{7.43}$$

□

Beweis. Wir setzen

$$R_2(s) \equiv \phi(s) - 1 - \frac{s^2}{2}\phi''(0). \tag{7.44}$$

Wenn $\phi(t)$ zweimal differenzierbar ist, so bedeutet dies, da $\phi(0) = 1$ und $\phi'(0) = 0$ ist, dass

$$\lim_{|s|\downarrow 0} s^{-2} R_2(s) = 0, \tag{7.45}$$

also für jedes $t \in \mathbb{R}$,

$$\lim_{n\to\infty} \frac{n}{t^2} R_2\left(tn^{-1/2}\right) = 0. \tag{7.46}$$

Nun ist aber

$$\left[\phi\left(n^{-1/2}t\right)\right]^n = \left[1 + \frac{t^2}{2n}\phi''(0) + R_2\left(n^{-1/2}t\right)\right]^n \tag{7.47}$$

Damit erfüllt $a_n \equiv \frac{t^2}{2}\phi''(0) + nR_n(t/\sqrt{n})$ die Voraussetzung von Lemma 7.10 mit $a = \frac{t^2}{2}\phi''(0)$, und wir erhalten

$$\lim_{n\to\infty}\left[1 + \frac{t^2}{2n}\phi''(0) + R_2\left(tn^{-1/2}\right)\right]^n = \exp\left(+\frac{t^2}{2}\phi''(0)\right) \tag{7.48}$$

Damit ist das Lemma bewiesen. □

Damit können wir nun unser Hauptresultat sehr leicht herleiten.

Satz 7.12 (Zentraler Grenzwertsatz). *Seinen X_i, $i \in \mathbb{N}$ unabhängige identisch verteilte Zufallsvariable mit $\mathbb{E}X_i = \mu$ und $\mathrm{var}(X_i) = \sigma^2 < \infty$. Dann konvergiert*

$$Z_n \equiv \frac{\sum_{i=1}^n (X_i - \mu)}{\sqrt{n}} \tag{7.49}$$

in Verteilung gegen eine Gauß'sche Zufallsvariable mit Mittelwert 0 und Varianz σ^2.

Anmerkung. In dieser Allgemeinheit wurde der Zentrale Grenzwertsatz 1922 von Jarl Waldemar Lindeberg [10] bewiesen, nachdem Lyapunov eine Version unter stärkeren Bedingungen schon 1901 gezeigt hatte.

Beweis. Wir nehmen ohne Beschränkung der Allgemeinheit $\mu = 0$ an. Offenbar konvergiert nach dem Vorhergehenden die charakteristische Funktion von Z_n gegen $\exp(-t^2\sigma^2/2)$ weil $-\phi''_{X_k}(0) = \mathrm{var}(X_k) = \sigma^2$. Diese kennen wir schon als charakteristische Funktion der Gaußverteilung $\mathcal{N}(0, \sigma^2)$. □

7.4 Stabile Verteilungen

Die Tatsache, dass die Normalverteilung im zentralen Grenzwertsatz auftaucht kann man auch anders als über den oben gezeigten Beweis verstehen. Man kann sich nämlich die Frage stellen, welche Eigenschaften überhaupt Zufallsvariablen haben müssen, die als Limes von reskalierten Summen wie in (7.1) auftreten. Wir nehmen wieder an, dass $\mathbb{E}X_i = 0$.

Dazu schreiben $p < 1$, und $q = 1 - p$. Dann ist in Verteilung $S_n = S_{[pn]} + S'_{[qn]}$ wobei wir $S_{[pn]} = \sum_{i=1}^{[pn]} X_i$ und $S'_{[pn]} = \sum_{i=1}^{[qn]} X'_i$, wobei die $X'_i \equiv X_{[pn]+i}$. Offenbar ist dann

$$\begin{aligned} Z_n &= n^{-\gamma}\left(S_{[pn]} + S'_{[qn]}\right) \\ &= n^{-\gamma}[np]^{\gamma}[np]^{-\gamma}S_{[pn]} + n^{-\gamma}[nq]^{\gamma}[nq]^{-\gamma}S'_{[qn]} \\ &\sim p^{\gamma}Z_{[pn]} + q^{\gamma}Z'_{[qn]}, \end{aligned} \tag{7.50}$$

wo $Z_m \equiv m^{-\gamma}\sum_{k=1}^{m} X_k$, und Z'_m von Z_m unabhängig ist und die gleiche Verteilung hat. Wenn nun Z_n in Verteilung gegen eine Zufallsvariable Z konvergiert, so konvergieren natürlich die Verteilungen von $Z_{[pn]}$ und $Z'_{[qn]}$ gegen Zufallsvariablen mit derselben Verteilung. Dass, heißt, Z muss die Eigenschaft haben, dass

$$Z \stackrel{\mathcal{D}}{=} p^{\gamma}Z' + q^{\gamma}Z'', \tag{7.51}$$

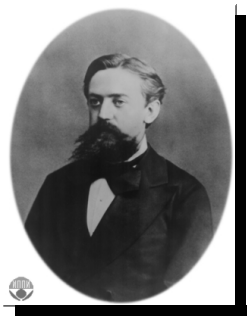
wo Z, Z' und Z'' unabhängig sind und die gleiche Verteilung haben. Für den Fall, dass die Varianz von Z endlich ist, folgt sofort, dass $p^{2\gamma} + (1-p)^{2\gamma} = 1$, was nur für $\gamma = 1/2$ erfüllt ist. Wir hatten schon gesehen, dass für $\gamma = \frac{1}{2}$ die Gaußverteilung gerade diese Eigenschaft hat. Man kann zeigen, dass die Gaußverteilung die einzige Verteilung mit Mittelwert 0 und endlicher Varianz ist, die diese Eigenschaft mit $\gamma = 1/2$ hat. Damit ist die Gaußverteilung in diesem Fall schon ein klarer Favorit.

Im Fall, dass die Varianz von X_i nicht endlich ist, schlägt das Argument für $\gamma = 1/2$ natürlich nicht mehr, und man kann sich dann die Frage nach einer Grenzverteilung mit allgemeineren γ stellen. Aus den obigen Betrachtungen sehen wir dann, dass im Ergebnis in jedem Fall nur eine Zufallsvariable herauskommen kann, die die Gleichung (7.51) erfüllt. Die Verteilungen solcher Zufallsvariablen nennt man auch *stabile* Verteilungen (im engeren Sinn). Mit Hilfe solcher Verteilungen kann man in der Tat Verallgemeinerungen des zentralen Grenzwertsatzes für Zufallsvariablen die keine endliche Varianz haben herleiten. Es würde hier allerdings zu weit gehen, dieses Thema auszuführen.

Kapitel 8
Markov Prozesse

Un des grands avantages du Calcul des Probabilités est d'apprendre à se défier des premiers aperçus. Comme on reconnaît qu'ils trompent souvent lorsqu'on peut les soumettre au calcul, on doit en conclure que sur d'autres objets il ne faut s'y livrer qu'avec une circonspection extrème[a].
Pierre Simon de Laplace, Théorie Analytique des Probabilités

[a] Ein großen Nutzen der Wahrscheinlichkeitsrechnung ist es uns zu lehren den ersten Eindrücken zu misstrauen. Da man feststellt, dass diese da, wo man sie mit mit Berechnungen konfrontieren kann, oft täuschen, so muss man schliessen, dass man sich ihnen in anderen Gegenständen nur mit der äusserster Umsicht ausliefern darf.



In den bisherigen 7 Kapiteln haben wir die grundlegenden Begriffe der Wahrscheinlichkeitstheorie kennengelernt und insbesondere die zwei wichtigsten Sätze, das Gesetz der großen Zahlen und den zentralen Grenzwertsatz hergeleitet. Dabei waren unabhängige Zufallsvariablen unser Grundbaustein, und alle unsere Resultate betrafen Objekte, die aus solchen konstruiert waren, insbesondere Summen und deren Grenzwerte.

In diesem Teil der Vorlesung wollen wir erstmals über unabhängige Zufallsvariablen hinausgehen und eine in vielen Anwendungen wichtige Klasse von *stochastischen Prozessen*, die sogenannten *Markov Prozesse* behandeln. Diese sind in vieler Hinsicht die wichtigsten stochastischen Prozesse überhaupt. Der Grund dafür ist, dass sie einerseits so vielseitig sind, dass sehr viele dynamischen Prozesse mit ihrer Hilfe modelliert werden können, andererseits aber mathematisch noch einigermaßen behandelbar sind. Wir werden in dieser Vorlesung natürlich nur einige wenige, einfache Beispiele dieser reichen Klasse betrachten. Markov Prozesse wurden von Andrey Andreyevich Markov (1856-1922) eingeführt.

8.1 Definitionen

Der Begriff des stochastischen Prozesses verallgemeinert den der Folgen unabhängiger Zufallsvariablen beziehungsweise der Summen solcher, wie wir sie in den vorherigen Kapiteln betrachtet haben. Bausteine sind Familien von Zufallsvariable X_t, die für gegebenes t Werte in einem Raum S, dem sogenannten *Zustandsraum*, annehmen. In der Regel wird S eine Teilmenge von $\mathbb{R}$, oder von $\mathbb{R}^d$, $d \geq 1$ sein, man

kann aber auch allgemeinere Räume zulassen. t nimmt Werte in einer sogenannten *Indexmenge*, I an. Die wichtigsten Beispiele sind $I = \mathbb{N}_0$ und $I = \mathbb{R}_+$, wobei wir uns hier auf den einfacheren Fall $I = \mathbb{N}_0$ einschränken wollen. Wir interpretieren den Index t als *Zeit*, und fassen X_t als Zustand eines Systems zur Zeit t auf. Der stochastische Prozess $\{X_t\}_{t\in I}$ ist als Familie von Zufallsvariablen definiert auf einem Wahrscheinlichkeitsraum $(\Omega, \mathfrak{F}, \mathbb{P})$ zu verstehen. Im Fall, dass $I = \mathbb{N}_0$ können wir natürlich $\Omega = S^{\mathbb{N}_0}$, und $\mathfrak{F} = \mathfrak{B}(S)^{\otimes\mathbb{N}_0}$, also den unendlichen Produktraum, wählen.

Alternativ zu der Definition 3.20 können wir einen stochastischen Prozess mit diskreter Zeit auch als eine messbare Abbildung mit Werten im Folgenraum $S^{\mathbb{N}_0}$ auffassen:

Definition 8.1. Sei $(\Omega, \mathfrak{F}, \mathbb{P})$ ein abstrakter Wahrscheinlichkeitsraum. Eine messbaren Abbildungen $X : (\Omega, \mathfrak{F}) \to (S^{\mathbb{N}_0}, \mathfrak{B}(S)^{\otimes\mathbb{N}_0})$ heißt ein *stochastischer Prozess* mit Zustandsraum S und Indexmenge $\mathbb{N}_0$.

Eine wichtige Größe ist selbstverständlich die Verteilung des Prozesses X, formal gegeben durch das Maß $P_X \equiv \mathbb{P} \circ X^{-1}$. P_X ist dann ein Wahrscheinlichkeitsmaß auf $(S^{\mathbb{N}_0}, \mathfrak{B}(S)^{\otimes\mathbb{N}_0})$.

Eine besonders wichtige Klasse von stochastischen Prozessen sind die sogenannten *Markovprozesse*. Sie stellen das stochastische Analogon zu dynamischen Systemen dar und spielen in der Modellierung des dynamischen Verhaltens vieler Systeme eine große Rolle. Wir werden in dieser Vorlesung nur eine spezielle Unterklasse von Markovprozessen, die sogenannten Markovketten mit diskreter Zeit, betrachten. Dabei ist der Zustandsraum zunächst eine endliche Menge.

Definition 8.2. Ein stochastischer Prozess mit diskreter Zeit und endlichem Zustandsraum S heißt eine *Markovkette*, genau dann, wenn, für alle $n \in \mathbb{N}_0$, und $t_0 < t_1 < t_2 < \cdots < t_n \in \mathbb{N}_0$, $x_0, x_1, \ldots, x_n \in S$, so dass

$$\mathbb{P}\left[X_{t_{n-1}} = x_{n-1}, X_{t_{n-2}} = x_{n-2}, \ldots, X_{t_0} = x_0\right] > 0, \tag{8.1}$$

gilt

$$\begin{aligned}&\mathbb{P}\left[X_{t_n} = x_n | X_{t_{n-1}} = x_{n-1}, X_{t_{n-2}} = x_{n-2}, \ldots, X_{t_0} = x_0\right] \\ &= \mathbb{P}\left[X_{t_n} = x_n | X_{t_{n-1}} = x_{n-1}\right].\end{aligned} \tag{8.2}$$

Anmerkung. Dieselbe Definition kann auch im Fall abzählbarer Zustandsräume verwandt werden. Im Fall überabzählbarer Zustandsräume tritt aber das Problem auf, dass alle betrachteten Ereignisse Wahrscheinlichkeit Null haben könnten. Um dieses Problem zu lösen werden wir den Begriff der bedingten Wahrscheinlichkeit so verallgemeinern müssen, dass auch auf Ereignisse mit Wahrscheinlichkeit Null bedingt werden kann. Dies wird aber erst Gegenstand der Vorlesung stochastische Prozesse sein.

Aufgrund der Diskretheit der Zeit können wir in (8.2) natürlich $t_i = i$ wählen und erhalten dann, dass

$$\begin{aligned}&\mathbb{P}\left[X_n = x_n | X_{n-1} = x_{n-1}, X_{n-2} = x_{n-2}, \ldots, X_0 = x_0\right] \\ &= \mathbb{P}\left[X_n = x_n | X_{n-1} = x_{n-1}\right] \equiv p_{n-1}(x_{n-1}, x_n).\end{aligned} \tag{8.3}$$

Satz 8.3. *Die Wahrscheinlichkeitsverteilung einer Markovkette mit diskreter Zeit ist eindeutig bestimmt durch die Angabe der Anfangsverteilung, $\pi_0(x)$, $x \in S$ und der Übergangswahrscheinlichkeiten $p_n(x, y)$, $n \in \mathbb{N}, x, y \in S$. Umgekehrt gibt es für jedes Wahrscheinlichkeitsmaß π_0 auf $(S, \mathfrak{B}(S))$ und einer Sammlung von Zahlen $p_n(x, y) \in [0, 1], n \in \mathbb{N}, x, y \in S$ mit der Eigenschaft, dass, für alle $n \in \mathbb{N}$ und alle $x \in S$,*

$$\sum_{y \in S} p_n(x, y) = 1, \tag{8.4}$$

eine Markovkette mir Übergangswahrscheinlichkeiten $p_n(x, y)$ und Anfangsverteilung π_0.

Anmerkung. Mann bezeichnet p_n auch als Übergangsmatrix. Eine Matrix mit der Eigenschaft (8.4) nennt man auch *stochastische Matrix*.

Beweis. Wir zeigen, dass die endlich dimensionalen Verteilungen festgelegt sind. Da wir auf einem endlichen Raum S arbeiten, genügt es offenbar für alle $n \in \mathbb{N}$, und alle $x_i \in S$, $i \leq n$, alle Wahrscheinlichkeiten der Form

$$\mathbb{P}[X_n = x_n, X_{n-1} = x_{n-1}, \ldots, X_1 = x_1, X_0 = x_0] \tag{8.5}$$

zu kennen. Nun ist aber wegen der Markoveigenschaft (6.6) und der Definition der bedingten Wahrscheinlichkeit

$$\begin{aligned}&\mathbb{P}[X_n = x_n, X_{n-1} = x_{n-1}, \ldots, X_1 = x_1, X_0 = x_0] \\ &= \mathbb{P}[X_n = x_n | X_{n-1} = x_{n-1}] \mathbb{P}[X_{n-1} = x_{n-1}, \ldots, X_1 = x_1, X_0 = x_0] \\ &= p_{n-1}(x_{n-1}, x_n) \mathbb{P}[X_{n-1} = x_{n-1}, \ldots, X_1 = x_1, X_0 = x_0] \\ &= p_{n-1}(x_{n-1}, x_n) p_{n-2}(x_{n-2}, x_{n-1}) \mathbb{P}[X_{n-2} = x_{n-2}, \ldots, X_1 = x_1, X_0 = x_0] \\ &= p_{n-1}(x_{n-1}, x_n) p_{n-2}(x_{n-2}, x_{n-1}) \ldots p_0(x_0, x_1) \mathbb{P}[X_0 = x_0] \\ &= p_{n-1}(x_{n-1}, x_n) p_{n-2}(x_{n-2}, x_{n-1}) \ldots p_0(x_0, x_1) \pi_0(x_0).\end{aligned} \tag{8.6}$$

Die Frage, ob es einen Prozesses gibt, die diese endlich dimensionalen Verteilungen besitzt, wollen wir hier noch nicht im Detail angehen. Dies wird in der Vorlesung "Stochastische Prozesse" getan werden. Wir bemerken lediglich, dass die so berechneten Verteilungen kompatibel sind in dem Sinne, dass

$$\begin{aligned}&\mathbb{P}[X_{n-1} = x_{n-1}, \ldots, X_1 = x_1, X_0 = x_0] \\ &= \sum_{x_n \in S} \mathbb{P}[X_n = x_n, X_{n-1} = x_{n-1}, \ldots, X_1 = x_1, X_0 = x_0]\end{aligned} \tag{8.7}$$

was aber aus der expliziten Formel (8.6) und der Eigenschaft (8.4) sogleich folgt. □

8.2 Markovketten mit stationären Überganswahrscheinlichkeiten

Nach diesem allgemeinen Bemerkungen wollen wir uns zunächst nur mit dem einfachsten, aber bereits interessanten Spezialfall befassen, in dem

(i) der Zustandsraum, S, eine endlich Menge ist, also $S = \{1, \dots, d\}$, $d \in \mathbb{N}$, und
(ii) die Übergangswahrscheinlichkeiten $p_{n-1}(x, y)$ nicht von n abhängen.

Man nennst solche Markovketten *zeitlich homogene* Markovketten oder Markovketten mit stationären Übergangswahrscheinlichkeiten.

Beispiel. Ein sehr einfaches Beispiel für eine Markovkette mit stationären Übergangswahrscheinlichkeiten ist folgendes (recht schlechtes) Klimamodell. Wir wollen dabei das Wetter auf die Grundfrage "Regen oder Sonnenschein" reduzieren. Das Wetter am Tag n soll also durch eine Zufallsvariable X_n die die Werte 0 (=Regen) und 1 (=Sonne) annimmt beschrieben werden. Versucht man diese durch unabhängige Zufallsvariablen zu beschreiben, stellt man fest, dass dies mit den Beobachtungen nicht kompatibel ist: längere Perioden mit konstantem Regen oder Sonnenschein treten in Wirklichkeit häufiger auf als das Modell vorhersagt. Man überlegt sich, dass es sinnvoll scheint, die Prognose des Wetters morgen davon abhängig zu machen, wie das Wetter heute ist (aber nicht davon wie es gestern und vorgestern war). Dies führt auf die Beschreibung durch eine Markovkette mit den Zuständen 0 und 1, und Übergangswahrscheinlichkeiten

$$\begin{aligned} p(0,1) &= p_{0,1}, \quad p(0,0) = p_{0,0} = 1 - p_{0,1}, \\ p(1,0) &= p_{1,0}, \quad p(1,1) = p_{1,1} = 1 - p_{1,0}. \end{aligned} \tag{8.8}$$

Zusammen mit der Anfangsverteilung $\pi(0) = p_0, \pi(1) = p_1 = 1 - p_0$ legt dies eine Markovkette fest. Wie sehen, dass wir nun 3 freie Parameter zur Verfügung haben, mit denen wir im Zweifel das Wetter besser fitten können.

Wir sehen, dass die Übergangswahrscheinlichkeiten einer stationären Markovkette eine $d \times d$ Matrix bilden, die wir mit P bezeichnen wollen. Diese Matrix nennt man die *Übergangsmatrix* der Markovkette. Zusammen mit dem *Vektor* π_0, der *Anfangsverteilung*, legt diese die Wahrscheinlichkeitsverteilung einer Markovkette vollständig fest, d.h. Wahrscheinlichkeiten beliebiger Ereignisse lassen sich durch diese Objekte ausdrücken. Durch diese Beobachtung begründet sich ein enger Zusammenhang zwischen Markovketten und der linearen Algebra.

Übergangsmatrizen sind keine beliebigen Matrizen, sondern sie haben eine Reihe von wichtigen Eigenschaften.

Lemma 8.4. *Sei P die Übergangsmatrix einer Markovkette mit Zustandsraum $S = \{1, \dots, d\}$ und stationären Übergangswahrscheinlichkeiten. Seien p_{ij} die Elemente von P. Dann gilt:*

(i) Für alle $i, j \in S$ gilt $1 \geq p_{ij} \geq 0$.
(ii) Für alle $i \in S$ gilt $\sum_{j \in S} p_{ij} = 1$.

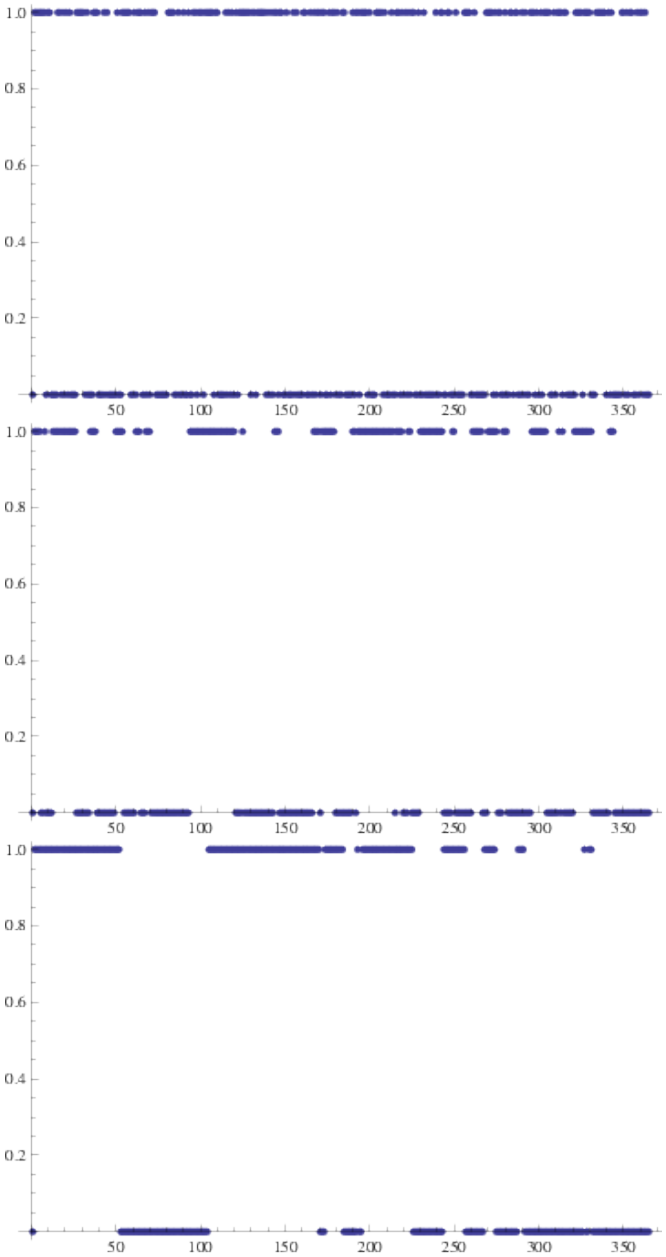


Abb. 8.1 Ein Jahresverlauf des "Wetters" in unserem Modell mit $p_{01} = p_{10} = 0.5$, 0.15, und 0.05.

Umgekehrt gilt: Jede Matrix die (i) und (ii) erfüllt, ist die Übergangsmatrix einer Markovkette.

Beweis. Die beiden ersten Eigenschaften sind offensichtlich, weil ja für jedes i, $p_{i,\cdot} = \mathbb{P}[X_{n+1} = \cdot | X_n = i]$ eine Wahrscheinlichkeitsverteilung auf S ist. Der Umkehrschluss folgt aus Satz 8.3. □

Matrizen die die Eigenschaften (i) und (ii) aus Lemma 8.4 erfüllen heißen *stochastische Matrizen*. Wir wollen uns die Übergangsmatrizen für einige Beispiele von Markovketten ansehen.

- **Unabhängige Zufallsvariablen.** Schon eine Folge unabhängiger, identisch verteilter Zufallsvariablen ist eine Markovkette. Hier ist

$$p_{ij} = \mathbb{P}[X_n = j | X_{n-1} = i] = \mathbb{P}[X_0 = j] = \pi_0(j), \tag{8.9}$$

  d.h. alle Zeilen der Matrix P sind identisch gleich dem Vektor der die Anfangsverteilung der Markovkette angibt.
- **Irrfahrt mit absorbierendem Rand.** Auch Summen unabhängiger Zufallsvariablen sind Markovketten. Wir betrachten den Fall, dass X_i unabhängige Rademachervariablen mit Parameter p sind, also eine Irrfahrt. In der Tat ist

$$\mathbb{P}[S_n = j | S_{n-i} = i] = \begin{cases} p, & \text{falls } j = i+1 \\ 1-p, & \text{falls } j = i-1 \\ 0, & \text{sonst} \end{cases} \tag{8.10}$$

  allerdings ist in diesem Fall der Zustandsraum abzählbar unendlich, nämlich $\mathbb{Z}$. Wir können eine Variante betrachten, in dem die Irrfahrt angehalten wird, wenn sie auf den Rand des endlichen Gebiets $[-L, L]$ trifft. Dazu modifizieren wir die Übergangswahrscheinlichkeiten aus (8.10) für den Fall $i = \pm L$, so dass

$$\mathbb{P}[S_n = j | S_{n-1} = \pm L] = \begin{cases} 1, & \text{falls } j = \pm L \\ 0, & \text{sonst} \end{cases} \tag{8.11}$$

  Die Übergangsmatrix hat dann folgende Gestalt:

$$P = \begin{pmatrix} 1 & 0 & 0 & \dots & \dots & \dots & 0 \\ 1-p & 0 & p & 0 & \dots & \dots & 0 \\ 0 & 1-p & 0 & p & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & \dots & 0 & 1-p & 0 & p & 0 \\ 0 & \dots & \dots & 0 & 1-p & 0 & p \\ 0 & \dots & \dots & \dots & 0 & 0 & 1 \end{pmatrix} \tag{8.12}$$

- **Unser Wettermodell (8.8)**. Hier ist

$$P = \begin{pmatrix} 1 - p_{0,1} & p_{0,1} \\ p_{1,0} & 1 - p_{1,0} \end{pmatrix} \tag{8.13}$$

Das der Zusammenhang zwischen Markovketten und Matrizen nicht nur oberflächlich ist, zeigt sich daran, dass in der Berechnung verschiedener Wahrscheinlichkeiten tatsächlich Matrixoperationen auftauchen. So ist

$$\mathbb{P}[X_n = j | X_0 = i] = \sum_{i_1, i_2, \ldots, i_{n-1}} p_{i i_1} p_{i_1 i_2} \ldots p_{i_{n-2} i_{n-1}} p_{i_{n-1} j} = (P^n)_{ij} \,.$$

Man schreibt für die bedingte Wahrscheinlichkeit $\mathbb{P}[X_n = j | X_0 = i] = P_n(i, j)$ und nennt diesen Ausdruck den *Propagator*. Eine weitere wichtige Größe ist die Verteilung der Markovkette zur Zeit n,

$$\pi_n(i) \equiv \mathbb{P}(X_n = i), \quad i \in S. \tag{8.14}$$

Es folgt, dass

$$\pi_n(j) \equiv \mathbb{P}[X_n = j] = \sum_{i \in S} \pi_0(i) P_n(i, j) = (\pi_0 P^n)_j \,. \tag{8.15}$$

Wir sehen also, dass die Verteilung der Markovkette zur Zeit n durch die Wirkung der Matrix P^n von links auf die Anfangsverteilung gegeben ist.

8.3 Invariante Verteilungen

Eine der ersten Fragen, die man sich stellen wird, ist, ob Verteilungen, π_0, gibt, die unter der Wirkung der Markovkette *invariant* sind.

Definition 8.5. Sei X eine Markovkette mit disketer Zeit, endlichem Zustandsraum S und stationären Übergangswahrscheinlichkeiten P. Dann heißt ein Wahrscheinlichkeitsmaß, π_0, *invariante Verteilung*, wenn für alle $n \in \mathbb{N}$ und alle $j \in S$,

$$\pi_n(j) = \pi_0(j), \tag{8.16}$$

gilt.

Offensichtlich ist wegen der Gleichung (8.15), die Frage nach invarianten Verteilungen äquivalent zur Frage nach links-Eigenwerten der Matrix P:

Lemma 8.6. *Sei P eine stochastische Matrix. Dann ist π_0 genau dann eine invariante Verteilung für eine Markovkette mit Übergangsmatrix P, wenn π_0 ein links-Eigenvektor von P zum Eigenwert 1 ist, mit $\pi_0(i) \geq 0$ und $\sum_{i \in S} \pi_0(i) = 1$.*

Beweis. Wir kombinieren (8.16) mit (8.15) und erhalten, dass π_0 invariant ist, wenn

$$\pi_0(i) = (\pi_0 P)_i \,. \tag{8.17}$$

Wenn andererseits ein Vektor mit positiven Komponenten deren Summe gleich eins ist die Gleichung (8.17) erfüllt, so liefert er eine invariante Anfangsverteilung. □

Satz 8.7. *Jede Markovkette mit stationären Übergangswahrscheinlichkeiten und endlichem Zustandsraum besitzt mindestens eine invariante Verteilung.*

Beweis. Der Beweis ist am einfachsten mit Hilfe eines tiefen Resultats der linearen Algebra, dem Satz von Perron-Frobenius, zu führen. Dieses lautet wie folgt.

Satz 8.8 (Perron-Frobenius 2). *Sei $A \neq 0$ eine $d \times d$ Matrix mit nicht-negativen Einträgen. Sei λ_0 definiert als Supremum über all $\lambda \in \mathbb{R}$, für die es einen Vektor x mit nicht-negativen reellen Elementen gibt, so dass*

$$\sum_{i=1}^{d} x_i = 1, \quad \text{und} \quad (Ax)_i \geq \lambda x_i, \forall i = 1, \ldots, d. \tag{8.18}$$

Dann gilt

(i) λ_0 ist ein Eigenwert mit Eigenvektor x mit nicht-negativen Elementen.
(ii) Alle anderen Eigenwerte, λ, von A erfüllen $|\lambda| \leq \lambda_0$.
(iii) Wenn λ Eigenwert von A ist und $|\lambda| = \lambda_0$, dann ist $\lambda/\lambda_0 \equiv \eta$ eine Wurzel der Eins (d.h. es gibt $k \in \mathbb{N}$, so dass $\eta^k = 1$) und $\eta^m \lambda_0$ ist für alle $m \in \mathbb{N}$ ein Eigenwert von A.

Wir wollen diesen Satz nun auf den Fall anwenden, wo $A = P$ die Übergangsmatrix einer Markovkette ist. Da P die Voraussetzungen des Satzes von Perron-Frobenius erfüllt, existiert ein maximaler positiver Eigenwert λ_0 und ein zugehöriger (Links-) Eigenvektor v der nichtnegative Einträge hat und die Normierung $\sum_i v_i = 1$ erfüllt. Wir müssen nur noch zeigen, dass $\lambda_0 = 1$ gilt. Dazu schreiben wir die Eigenwertgleichung $(vP)_i = \lambda_0 v_i$, für $i = 1, \ldots, d$ und summieren über i. Da P stochastisch ist, gilt dann

$$\lambda_0 \sum_{i=1}^{d} v_i = \sum_{j=1}^{d} \sum_{i=1}^{d} v_j p_{ji} = \sum_{j=1}^{d} v_j. \tag{8.19}$$

Da $\sum_{i=1}^{d} v_i = 1$, folgt $\lambda_0 = 1$. v liefert damit eine invariante Verteilung. □

Nach der Existenz sind die Fragen der Eindeutigkeit und der Konvergenz naheliegend. Diese gestalten sich etwas komplexer.

8.3.1 Markovketten und Graphen. Klassifizierung der Zustände

Es erweist sich als instruktiv mit einer Übergangsmatrix einen gerichteten Graphen auf dem Zustandsraum S zu verbinden. Wir fassen die Menge S als Knotenmenge eines (gerichteten) Graphen, $(S, \mathcal{E})$ auf. Wir sagen, dass $\mathcal{E}$ die *Kante*, (i, j), $i \in S$, $j \in S$ enthält, $(i, j) \in \mathcal{E}$, wenn $p_{ij} > 0$. Graphisch stellen wir dies durch einen Pfeil dar.

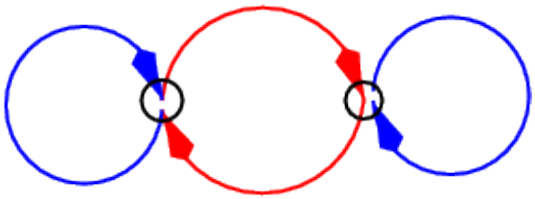


Abb. 8.2 Der Graph der Markovkette unseres Wettermodells

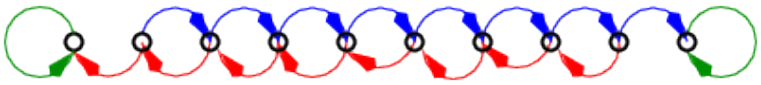


Abb. 8.3 Der Graph der am Rand gestoppten Irrfahrt

Definition 8.9. Ein *Pfad* γ in einem gerichteten Graphen $(S, \mathcal{E})$ ist eine Folge $\gamma = (e_1, e_2, \ldots, e_k)$ von Kanten $e_\ell \in \mathcal{E}$, so dass für jedes $\ell = 1, \ldots, k-1$ gilt, dass der Endpunkt von e_ℓ der Anfangspunkt von $e_{\ell+1}$ ist. γ verbindet i mit j falls der Anfangspunkt von e_1 i und der Endpunkt von e_k j ist.

Definition 8.10. Zwei Knoten, $i, j \in S$ einem gerichteten Graphen *kommunizieren*, wenn Pfade gibt, die i mit j verbinden und solche, die j mit i verbinden. Wir sagen auch, dass jeder Zustand mit sich selbst kommuniziert.

Man kann leicht nachprüfen, dass die Relation "kommunizieren" eine Äquivalenzrelation ist. Nun definiert eine Äquivalenzrelation eine Zerlegung der Menge S in Äquivalenzklassen. Wir bezeichnen die Äquivalenzklassen kommunizierender Zustände als *kommunizierende Klassen* oder einfach als *Klassen*.

Definition 8.11. Eine Markovkette heißt *irreduzibel* genau dann wenn der Zustandsraum aus einer einzigen Klasse besteht.

Anmerkung. Beachte, dass eine Markovkette deren Graph nicht zusammenhängend ist, auch nicht irreduzibel ist. Wenn der Graph einer Markovkette zusammenhängend ist, muss diese aber noch lange nicht irreduzibel sein.

Lemma 8.12. *Eine Markovkette ist genau dann irreduzibel, wenn es für jedes Paar,* $(i, j) \in S \times S$*, ein* $k \in \mathbb{N}_0$ *gibt, so dass* $\left(P^k\right)_{i,j} > 0$.

Beweis. Es gilt

$$\begin{aligned}\left(P^k\right)_{ij} &= \sum_{i_1, i_2, \ldots, i_{k-1}} p_{ii_1} p_{i_1 i_2} \cdots p_{i_{k-1} j} \\ &= \sum_{\substack{\gamma: i \to j \\ |\gamma| = k}} p_{e_1} p_{e_2} \cdots p_{e_k} \end{aligned} \tag{8.20}$$

Die rechte Seite ist offenbar genau dann positiv, wenn es einen solchen Weg gibt. Daraus folgt das Lemma direkt. □

Wenn wir die Annahme an P dahingehend verstärken, dass für alle i, j dasselbe k gewählt werden kann, erhalten wir eine erste Antwort auf unsere Fragen zur Konvergenz zur invarianten Verteilung.

Satz 8.13. *Sei P die Übergangsmatrix einer Markovkette mit endlichem Zustandsraum und es gebe $k \in \mathbb{N}$ so, dass die Matrix P^k nur strikt positive Einträge hat. Dann gibt es genau eine invariante Verteilung, μ, mit $\mu P = \mu$, und*

$$\lim_{n\to\infty} P^n = \Pi_0 \tag{8.21}$$

existiert und ist eine stochastische Matrix vom Rang 1 *deren Zeilen gerade durch den Vektor μ gegeben sind, d.h.*

$$\Pi_0 = \begin{pmatrix} \mu(1) & \mu(2) & \dots & \mu(d) \\ \mu(1) & \mu(2) & \dots & \mu(d) \\ \dots & \dots & \dots & \dots \\ \dots & \dots & \dots & \dots \\ \mu(1) & \mu(2) & \dots & \mu(d) \end{pmatrix}. \tag{8.22}$$

Insbesondere konvergiert für jede Anfangsverteilung π_0 die Verteilung $\pi_n = \pi_0 P^n$ gegen die einzige invariante Verteilung μ.

Anmerkung. Markovketten, für die die Aussage des Theorems 8.13 gilt, d.h. die eine einzige invariante Verteilung, μ, besitzen gegen welche die Verteilung π_t für jede Anfangsverteilung π_0 konvergiert, nennt man auch *ergodisch*.

Beweis. Wir benutzen im Beweis das sog. erste Perron-Frobenius Theorem.

Satz 8.14 (Perron-Frobenius 1). *Sei A eine $d \times d$ Matrix mit* strikt *positiven Einträgen. Dann gibt es einen Vektor, $\mathbf{x}$, mit* strikt *positiven Komponenten, so dass $A\mathbf{x} = \lambda_0 \mathbf{x}$. Der Eigenwert λ_0 ist einfach, und für alle anderen Eigenwerte, λ_i, von A, gilt $|\lambda_i| < \lambda_0$.*

Nach Voraussetzung erfüllt die Matrix $A = P^k$ die Voraussetzungen des ersten Perron-Frobenius Satzes (Satz 8.8). Insbesondere besitzt P^k einen einzigen maximalen Eigenwert 1 mit Eigenvektor μ, der strikt positive Einträge hat. Andererseits wissen wir, dass P mindestens einen maximalen Eigenwert 1 hat. Sei nun ν ein Eigenvektor von P mit Eigenwert λ und $|\lambda| = 1$. Dann gilt auch $\nu P^k = \lambda^k \nu$, und notwendig $\lambda^k = 1$. Somit muss $\nu = \mu$ sein. Damit gibt es aber nur einen Eigenwert von P der Betrag 1 hat, und daher folgt $\lambda = 1$. Alle anderen Eigenwerte sind im Betrag strikt kleiner als 1. Daher können wir P zerlegen als

$$P = \Pi_0 + Q, \tag{8.23}$$

wobei Π_0 der in (8.22) angegebene Projektor auf den eindimensionalen Eigenraum zum Eigenwert 1 (und zwar sowohl bezüglich der Wirkung nach rechts als nach links) ist, und Q bildet den dazu orthogonalen Unterraum auf sich ab. Nämlich:

(i) $\Pi_0^2 = \Pi_0$, und
(ii) $\Pi_0 Q = Q\Pi_0 = 0$.

Beide Aussagen folgen durch Nachrechnen.

Als nächstes zeigen wir, dass jeder Eigenwert der Matrix Q im Betrag strikt kleiner als eins ist. Gilt nämlich $\mathbf{v}Q = \lambda\mathbf{v}$, so haben wir

$$\lambda\mathbf{v}\Pi_0 = \mathbf{v}Q\Pi_0 = 0. \tag{8.24}$$

und daher ist, falls nicht $\lambda = 0$ ist, $\mathbf{v}\Pi_0 = 0$, und daher $\mathbf{v}P = \mathbf{v}(\Pi_0 + Q) = \mathbf{v}Q = \lambda\mathbf{v}$. Damit ist aber λ Eigenwert von P und somit wegen dem ersten Satz von Perron-Frobenius entweder $|\lambda| < 1$, oder $\lambda = 1$. Im letzteren Fall ist aber $\mathbf{v} = \mu$, und somit dann $\mathbf{v}Q = 0$, im Widerspruch zur Annahme $\lambda = 1$. Es bleibt also nur die Möglichkeit $|\lambda| < 1$.

Wir benötigen nun ein weiteres Resultat aus der linearen Analysis:

Lemma 8.15. *Sei B eine $d \times d$-Matrix und sei $\|\cdot\|$ eine Norm auf dem Raum der Matrizen (d.h. $\|B\| \equiv \sup_{\mathbf{v}\in\mathbb{R}^d} \frac{\|B\mathbf{v}\|}{\|\mathbf{v}\|}$, wo $\|\mathbf{v}\|$ eine beliebige Norm auf $\mathbb{R}^d$ ist). Dann besitzt B einen Eigenwert vom maximalen Betrag r und es gilt*

$$r = \limsup_{n\uparrow\infty} \|B^n\|^{1/n}. \tag{8.25}$$

Beweis. Jede Matrix B kann durch eine nicht-singuläre Transformation auf die Jordan-Normalform gebracht werden, d.h. es existiert eine invertierbare Matrix U, so dass $U^{-1}BU = J$, wo J blockdiagonal ist und jeder Block entweder diagonal ist oder die Form

$$\begin{pmatrix} \lambda_i & 1 & 0 & 0 & \dots & 0 \\ 0 & \lambda_i & 1 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots & & \\ \dots & \dots & \dots & \dots & & \\ 0 & \dots & 0 & 0 & \lambda_i & 1 \\ 0 & \dots & 0 & 0 & 0 & \lambda_i \end{pmatrix} \tag{8.26}$$

hat, wo λ_i die Eigenwerte von B sind. Insbesondere ist J von der Form $J = D + N$, wo D diagonal ist, D und N kommutieren, und N nilpotent ist, d.h. $N^d = 0$. Daraus folgt, dass (für $n \geq d$)

$$J^n = \sum_{k=0}^{d-1} \binom{n}{k} D^{n-k} N^k. \tag{8.27}$$

Nun ist $\|D\| = r$ und somit (mit der groben Abschätzung $\binom{n}{k} \leq n^k$)

$$\|J^n\| \leq \sum_{k=0}^{d-1} \|D\|^{n-k} \|N\|^k n^k = r^n \sum_{k=0}^{d-1} r^{-k} \|N\|^k n^k. \tag{8.28}$$

Wenn wir hier die n-te Wurzel ziehen und dann den Grenzwert $n \uparrow \infty$ betrachten, erhalten wir

$$\limsup_{n\uparrow\infty} \|J^n\|^{1/n} \le r \lim_{n\uparrow\infty} \left(\sum_{k=0}^{d-1} r^{-k} \|N\|^k n^k \right)^{1/n} = r. \tag{8.29}$$

Da U und U^{-1} beschränkt sind, folgt auch dass

$$\limsup_{n\uparrow\infty} \|B^n\|^{1/n} \le \lim_{n\uparrow\infty} \|J^n\|^{1/n} \|U\|^{1/n} \|U^{-1}\|^{1/n} = r, \tag{8.30}$$

also $r \le r$. Die Schranke in die umgekehrte Richtung ist einfacher. Wir benutzen nur, dass für jedes $n \ge 1$, und jeden Eigenwert λ mit Eigenvektor $\mathbf{v}$,

$$\|B^n\| \ge \frac{\|B^n \mathbf{v}\|}{\|\mathbf{v}\|} = |\lambda|^n, \tag{8.31}$$

also, da r größter Eigenwert von B ist, $\|B^n\|^{1/n} \ge r$. □Also gilt (8.25).

In unserem Fall ist aber $r < 1$. Dann folgt aus dem Lemma, dass für jedes $\epsilon > 0$ für alle hinreichend großen n gilt, dass $\|Q^n\| \le (r + \epsilon)^n$. Nun wählen wir ϵ so klein, dass dass $r + \epsilon < 1$. Dann folgt, dass

$$\lim_{n\uparrow\infty} \|Q^n\| = 0. \tag{8.32}$$

Da weiter $P^n = \Pi_0 + Q^n$, so folgt für alle Anfangsverteilungen π_0, dass

$$\lim_{n\uparrow\infty} \pi_0 P^n = \pi_0 \Pi_0 = \mu, \tag{8.33}$$

was der Behauptung entspricht. □

Anmerkung. Der Beweis von Satz 8.13 folgt dem Buch von Karlin und Taylor [7]. Man kann den Satz 8.13 auch ohne Verwendung der Sätze von Perron und Frobenius führen, siehe z.B. das Buch von Georgii [5]. Ich halte aber es aber für interessant und lehrreich, den Zusammenhang zwischen diesen Gebieten zu betonen. Insbesondere liefert der Beweis auch eine Kontrolle der Konvergenzgeschwindigkeit, nämlich $\|\pi_0 P^n - \mu\| \le C|\lambda_1|^n$, wo λ_1 der Eigenwert von P mit zweitgrößtem Betrag ist.

Wir wollen uns nun Fragen, für welche Markovketten die Voraussetzung des Satzes 8.13 gelten. Klar ist, dass Irreduzibilität eine *notwendige* Bedingung ist, die aber noch nicht ausreicht. Das relevante Konzept wird die *Periodizität* sein.

Definition 8.16. Wir sagen, dass ein Zustand i *periodisch* mit *Periode* $d(i)$ ist, wenn $d(i)$ der größte gemeinsame Teiler aller Zahlen $n \in \mathbb{N}$ ist, für die $(P^n)_{i,i} > 0$. Ein Zustand mit Periode 1 heißt *aperiodisch*.

Wir beobachten als Erstes, dass die Periode eine Klassenfunktion ist.

Lemma 8.17. *Wenn $i, j \in S$ kommunizieren, dann ist $d(i) = d(j)$.*

Beweis. Wir wissen, das es n und m gibt, so dass $P^n_{j,i} > 0$ und $P^m_{i,j} > 0$. Sei nun $P^\ell_{i,i} > 0$. Dann ist auch

$$P^{n+\ell+m}_{j,j} \geq P^{n}_{j,i} P^{\ell}_{i,i} P^{m}_{i,j} > 0. \tag{8.34}$$

Da auch $P^{2\ell}_{i,i} > 0$, ist auch $P^{n+2\ell+m}_{j,j} > 0$, so dass $d(j)$ sowohl $n + m + \ell$ als auch $n + m + 2\ell$ teilt. Mithin teilt es auch die Differenz dieser Zahlen, nämlich ℓ. Das gilt für alle ℓ für die $P^{\ell}_{i,i} > 0$, deshalb ist $d(j) \leq d(i)$. Da wir das Argument auch umdrehen können, folgt genauso gut, dass $d(i) \leq d(j)$, mithin die Behauptung. □

Lemma 8.18. *Wenn $i \in S$ periodisch mit Periode $d(i)$ ist, dann gibt es $M \in \mathbb{N}$, so dass für alle $n \geq M$, $\left(P^{n\,d(i)}\right)_{i,i} > 0$.*

Beweis. Die Behauptung folgt aus der zahlentheoretischen Tatsache, dass, wenn $n_1, \ldots, n_k, \ldots$ natürliche Zahlen mit größtem gemeinsamen Teiler d sind, es ein $M \in \mathbb{N}$ gibt, so dass für alle $m \geq M$, $d\,m$ als Linearkombination der n_i geschrieben werden kann,

$$d\,m = \sum_{\ell \geq 1} c_\ell n_\ell, \tag{8.35}$$

wo alle $c_\ell \in \mathbb{N}_0$ sind[1]. Damit kann also $nd(i)$ als Summe von ganzzahligen positiven Linearkombinationen von Zahlen n_ℓ geschrieben werden, für die $(P^{n_\ell})_{i,i} > 0$ ist. Daraus folgt die Behauptung. □

Lemma 8.19. *Eine irreduzible und aperiodische Markovkette mit endlichem Zustandsraum hat die Eigenschaft, dass es ein $k \in \mathbb{N}$ gibt, so dass für alle $i, j \in S$, $\left(P^{k}\right)_{i,j} > 0$. Insbesondere ist eine aperiodische irreduzible Markovkette ergodisch.*

Beweis. Wegen der vorhergehenden Sätze wissen wir, dass existiert $M \in \mathbb{N}$ so dass für alle $m \geq M$, $P^{m}_{j,j} > 0$. Man kann M unabhängig von j wählen, weil S endlich ist. Andererseits gibt es für jedes (i, j) ein $n_{i,j}$ so, dass

$$(P^{n_{i,j}})_{i,j} > 0. \tag{8.36}$$

Wenn $P^{m}_{j,j} > 0$, was für alle großen m der Fall ist, ist dann auch

$$(P^{n_{i,j}+m})_{i,j} > 0. \tag{8.37}$$

[1] Der Beweis dieser Tatsache ist nicht sonderlich schwer: Es seine zunächst A die Menge aller Zahlen die durch die rechte Seite von (8.35) dargestellt werden können, und sodann B die Menge aller ganzzahligen Linearkombinationen aus Zahlen von A. Es sei dann d' die kleinste positive Zahl in B. Wir wollen zeigen, dass d' gemeinsamer Teiler aller Zahlen in A ist. andernfalls gibt es eine Zahl $N > 0$ in A, die nicht durch d' teilbar ist. Dann sind $d' - N$ sowie $N - \ell d'$ für jedes $\ell \geq 1$ in B und ungleich Null. Aber eine dieser Zahlen muss dann positiv und kleiner als d' sein, im Widerspruch zur Annahme, dass d' diese kleinste Zahl ist. Deshalb ist d' gemeinsamer Teiler aller Zahlen aus A. Insbesondere teilt d' auch alle n_i. d ist aber auch der grösste gmeinsame Teiler. Falls es nämlich $d' > d$ gibt, die alle n_ℓ teilt, dann ist $\sum_{\ell \geq 1} c_\ell n_\ell = d' \sum_{\ell \geq 1} c_\ell n'_\ell$, wo $n'_\ell = n_\ell / d' \in \mathbb{N}$. Damit sind aber auch alle Zahlen in B von der Form d' mal eine Zahl aus einer Menge B'. Da in B' die kleinste positive Zahl mindestens 1 ist, ist die kleinste positive Zahl in B mindestens $d' > d$, was im Widerspruch zur Annahme steht. Also ist $d' = d$. Indem man die Gleichung (8.35) durch d teilt kann man sich auf den Fall $d = 1$ zurückziehen. Es folgt dann aus dem bisher Gesagten, dass es N_1, N_2 aus A gibt, so dass $N_1 - N_2 = 1$. Nun sei $m > N_2^2$, also $m = N_2^2 + \ell$, mit $\ell \in \mathbb{N}$. Dann ist $m = N_2^2 + bN_2 + j(N_1 - N_2)$ mit $0 \leq j < N_2$. Dies ist die gewünschte Darstellung von m.

Deshalb gilt für $k \geq M + \max_{i,j} n_{i,j}$, dass $(P^k)_{i,j} > 0$. □

Irreduzible und aperiodische Markovketten sind in der Praxis von großer Wichtigkeit. Darüber hinaus kann man auch Resultate für diese Ergebnisse für den allgemeinen Fall zusammen basteln.

Der Ergodensatz nutzt die Aperiodizität entscheidend aus. Er kann in dieser Form für periodische Markovketten auch nicht richtig sein. Es gilt aber für nur irreduzible Markovketten immer noch, dass sie eine einzige invariante Verteilung besitzen.

Satz 8.20. *Sei P die Übergangsmatrix einer irreduziblem Markovkette mit endlichem Zustandsraum. Dann besitzt P genau eine invariante Verteilung μ und es gilt, dass für alle $i \in S$, $\mu(i) > 0$.*

Beweis. Der Beweis ist denkbar einfach. Wir definieren für $1 > \epsilon > 0$ die Matrix $P_\epsilon \equiv \epsilon \mathbb{1} + (1-\epsilon)P$. P_ϵ hat folgende Eigenschaften:

(i) P_ϵ ist eine stochastische Matrix.
(ii) Die von P_ϵ erzeugte Markovkette ist irreduzibel und aperiodisch.
(iii) P und P_ϵ besitzen die gleichen Eigenvektoren.
(iv) $\mu P = \mu$ gilt genau dann wenn $\mu P_\epsilon = \mu$.

Nun wissen wir, dass P_ϵ einen einfachen Eigenwert 1 mit strikt positivem Eigenvektor besitzt. Damit folgt dasselbe auch für P, was zu beweisen war. □

Die einfachste periodische Kette hat die Übergangsmatrix

$$P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}. \tag{8.38}$$

Diese besitzt die Eigenwerte 1 und -1, und die invariante Verteilung $\mu = (1/2, 1/2)$. Es gibt es aber auch einen Eigenvektor, $\nu = (1, -1)$ mit Eigenwert -1. Man auch leicht, dass

$$P^n = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}^n = \begin{cases} \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, & \text{wenn } n \text{ ungerade ist,} \\ \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, & \text{wenn } n \text{ gerade ist.} \end{cases} \tag{8.39}$$

Hier konvergiert P^n also nicht. Klarerweise konvergiert dann auch $\pi_0 P^n$ für allgemeine Anfangsverteilungen aber nicht gegen die invariante Verteilung.

Wenn X eine ergodische Markovkette und μ ihre einzige invariante Verteilung ist, so bezeichnet man die Verteilung, $\mathbb{P}_\mu$, dieses Prozesses mit Anfangsverteilung $\pi_0 = \mu$ auch als stationäre Verteilung. Es gilt dann insbesondere, dass

$$\mathbb{P}_\mu[(X_1, X_2, \dots) \in A] = \mathbb{P}_\mu[(X_n, X_{n+1}, \dots) \in A], \tag{8.40}$$

für alle $n \in \mathbb{N}_0$ und alle $A \in \mathfrak{B}(S)^{\otimes \mathbb{N}_0}$. Es gilt in der Tat, dass die Verteilung einer ergodischen Markovkette gegen diese stationäre Verteilung konvergiert, in dem Sinne, dass für alle $A \in \mathfrak{B}(S)^{\otimes \mathbb{N}_0}$ und alle $x \in S$,

$$\lim_{n\to\infty} \left|\mathbb{P}_\mu[(X_1, X_2, \dots) \in A] - \mathbb{P}_x[(X_n, X_{n+1}, \dots) \in A]\right| = 0. \tag{8.41}$$

Der Beweis ist sehr einfach und nutzt die definierende Eigenschaft einer Markovkette:

$$\begin{aligned}
&\left|\mathbb{P}_\mu[(X_1, X_2, \dots) \in A] - \mathbb{P}_x[(X_n, X_{n+1}, \dots) \in A]\right| \\
&= \left|\sum_{y\in S} (\mathbb{P}_x[X_{n-1} = y] - \mu(y))\, \mathbb{P}_y[(X_1, X_2, \dots) \in A]\right| \\
&\leq \sum_{y\in S} |\mathbb{P}_x[X_n = y] - \mu(y)| \to 0, \qquad \text{wenn } n \uparrow \infty.
\end{aligned}$$

8.3.2 Die Sätze von Perron und Frobenius

Wie viele Dinge in der Theorie der Markov Ketten, sind die Sätze von Perron und Frobenius Gegenstand der linearen Algebra. Wegen ihrer Bedeutung geben wir hier trotzdem die Beweise an. Wir beginnen mit dem ersten Satz von Perron-Frobenius.

Beweis (von Satz 8.14). Es ist nun A eine $d \times d$ Matrix mit reellen, strikt positiven Einträgen. Es sei

$$E_d \equiv \left\{ \mathbf{x} \in \mathbb{R}^d, \sum_{i=1}^d x_i = 1,\ \forall_{i=1}^d x_i \geq 0 \right\}. \tag{8.42}$$

Wir betrachten die Menge

$$\Lambda \equiv \{\lambda \in \mathbb{R} : \exists\, \mathbf{x} \in E_d, A\mathbf{x} \geq \lambda \mathbf{x}\}. \tag{8.43}$$

Wir setzten $\lambda_0 = \sup\{\lambda \in \Lambda\}$. Es ist zunächst klar, dass $\lambda_0 > 0$ sein muss.

Des weitern existiert eine Folge γ_i die nach λ_0 konvergiert und Vektoren $\mathbf{x}^i$ mit nicht-negativen Einträgen (und mindestens einem strikt positiven Eintrag), so dass $A\mathbf{x}^i \geq \gamma_i \mathbf{x}^i$ und $\sum_j \mathbf{x}^i_j = 1$. Wegen der Kompaktheit der Menge E_d hat die Folge der Vektoren $\mathbf{x}^i$ konvergente Unterfolgen, d.h. es existieren Folgen $k_j \uparrow \infty$, so dass

$$\lim_{j\uparrow\infty} \mathbf{x}^{k_j} = \mathbf{x}^0. \tag{8.44}$$

Dabei hat $\mathbf{x}^0$ dieselben Eigenschaften wie die $\mathbf{x}^i$. Darüberhinaus gilt auch, dass

$$A\mathbf{x}^0 \geq \lambda_0 \mathbf{x}^0. \tag{8.45}$$

Betrachte nun $\mathbf{y} \equiv A\mathbf{x}^0$. Zunächst sind alle Komponenten $\mathbf{y}_\ell \equiv \sum_m A_{\ell m}\mathbf{x}^0_m > 0$ (da alle $A_{\ell m} > 0$). Weiter gilt auch, dass

$$(A\mathbf{y})_j = \sum_\ell A_{j\ell} \sum_m A_{\ell m}\mathbf{x}^0_m \geq \lambda_0 \sum_\ell A_{j\ell}\mathbf{x}^0_\ell = \lambda_0 \mathbf{y}_j \tag{8.46}$$

Angenommen, die Ungleichung (8.45) wäre strikt, d.h. zumindest für ein ℓ gelte $A\mathbf{x}^0_\ell > \lambda_0\mathbf{x}^0_\ell$. Dann ist aber die Ungleichung in (8.46) für jedes j strikt, und somit existiert ein Vektor mit strikt positiven Einträgen für den $A\mathbf{y}_\ell > \lambda_0\mathbf{y}_\ell$ für jede Komponente gilt. Durch Normierung folgt dann, dass es einen Vektor in E_d gibt, für den diese Ungleichung gilt. Das ist ein Widerspruch zur Definition von λ_0. Damit ist aber λ_0 Eigenwert und $\mathbf{x}^0$ der zugehörige Eigenvektor. Offenbar muss dieser Eigenvektor strikt positive Einträge haben.

Sei nun $\lambda \neq \lambda_0$ ein Eigenwert von A mit Eigenvektor $\mathbf{z}$. Dann gilt

$$|\lambda||\mathbf{z}_i| = \left|\sum_j A_{ij}\mathbf{z}_j\right| \leq \sum_j A_{ij}|\mathbf{z}_j| \leq \lambda_0|z_i|, \tag{8.47}$$

woraus folgt, dass $|\lambda| \leq \lambda_0$. Um zu zeigen, dass $|\lambda| < \lambda_0$, bemerken wir, dass wir stets ein $\delta > 0$ finden können, so dass $A_\delta \equiv A - \delta\mathbb{1}$ noch immer strikt positive Einträge hat. Der grösste Eigenwert von A_δ ist aber $\lambda_0 - \delta$. Nun folgt $|\lambda - \delta| \leq \lambda_0 - \delta$. Damit folgt aber, dass $|\lambda| \leq |\lambda - \delta| + \delta \leq \lambda_0$. Damit kann aber $|\lambda| = \lambda_0$ nur dann gelten, wenn λ reell und positive ist, und dann ist $\lambda = \lambda_0$.

Schliesslich zeigen wir, dass der Eigenraum von λ_0 eindimensional ist. Seine $\mathbf{x}, \mathbf{y}$ zwei nicht kolineare Eigenvektoren zu diesem Eigenwert. Dann gilt dasselbe auch für $\mathbf{z} = \mathbf{x} - c\mathbf{y}$. Dabei kann man aber stets c so wählen, dass die Einträge dieses Vektors unterschiedliches Vorzeichen haben. Aber dann gilt

$$\lambda_0|\mathbf{z}_i| = \left|\sum_j A_{ij}z_j\right| < \sum_j A_{ij}|z_j|, \tag{8.48}$$

for jedes j, weswegen ein Vektor in E_d existiert, der der Definition von λ_0 als Supremum von Λ widerspricht. □

Wir kommen nun zum Beweis des zweiten Satzes von Perron und Frobenius.

Beweis (von Satz 8.8). Es sei $\mathbf{E}$ die Matrix mit Einträgen $\mathbf{E}_{ij} \equiv 1$. Das A nichtnegative Einträge hat, hat für jedes $\delta > 0$ die Matrix $A + \delta\mathbf{E}$ strikt positive Einträge. Sei $\mathbf{x} \in E_d$ und $\delta_2 > \delta_1 > 0$. Wenn $(A + \delta_1\mathbf{E})\mathbf{x} \geq \lambda\mathbf{x}$, so haben wir

$$(A + \delta_2\mathbf{E})\mathbf{x}_\ell \geq \lambda\mathbf{x}_\ell + \delta_2 - \delta_1 \geq (\lambda + \delta_2 - \delta_1)\mathbf{x}_\ell. \tag{8.49}$$

Daraus folgt, dass dies auch für $\lambda_0(\delta)$, den größten Eigenwert von $(A+\delta\mathbf{E})$, gilt, also dass $\lambda_0(\delta)$ in δ monoton wächst. Nun wissen wir aber wegen dem ersten Perron-Frobenius Satz, dass es für jedes $\delta > 0$ genau einen normierten Vektor $\mathbf{x}(\delta)$ mit strikt positiven Einträgen gibt der Eigenvektor von $(A + \delta\mathbf{E})$ zum Eigenwert $\lambda_0(\delta)$ ist. Wegen Kompaktheit gibt es wieder eine Folge $\delta_k \downarrow 0$ so dass $\mathbf{x}(\delta_k) \to \mathbf{x}(0)$ konvergiert. Ausserdem konvergiert $\lambda_0(\delta_j)$ wegen Monotonie gegen eine Zahl $\lambda' \geq \lambda_0$. Andererseits ist leicht zu sehen, dass

$$A\mathbf{x}(0) = \lambda'\mathbf{x}(0). \tag{8.50}$$

Damit muss aber $\lambda' \leq \lambda_0$ gelten. Damit ist $\lambda' = \lambda_0$ und wir sehen, dass λ_0 Eigenwert mit Eigenvektor $\mathbf{x}_0$ der nur nicht-negative Einträge hat ist. Damit ist Teil (i) bewiesen. Der Beweis von (ii) folgt wieder, weil aus der Existenz eines Eigenwertes mit grösserem Betrag als λ_0 ein Widerspruch zur Definition von λ_0 folgt.

Den Beweis der Eigenschaft (iii) geben wir nicht, da diese nicht direkt genutzt wird. □

8.3.3 Wesentliche und unwesentliche Klassen.

Besitzt eine Markovkette mehrere Klassen, so kann man diese in zwei Gruppen einteilen: solche, aus denen man in eine andere Klasse austreten kann (aber nicht wieder zurück kann), und solche aus denen man nicht in eine andere Klasse eintreten kann (in die man aber ggf. aus anderen eintreten kann). Erstere heißen *unwesentlich*, letztere *wesentlich*.

Definition 8.21. Eine kommunizierende Klasse C einer Markovkette heisst *wesentlich* genau dann, wenn es keine Pfade im Graphen gibt, über die man aus C in eine anderen Klasse eintreten kann. Klassen, die nicht wesentlich sind, heissen *unwesentlich*.

Anmerkung. Im Fall endlichen Zustandsraums können wir wesentliche Klassen auch als *rekurrent*, unwesentliche als *transient* bezeichnen. Im Fall von Markovketten mit unendlichem Zustandsraum sind diese Begriffe aber zu unterscheiden.

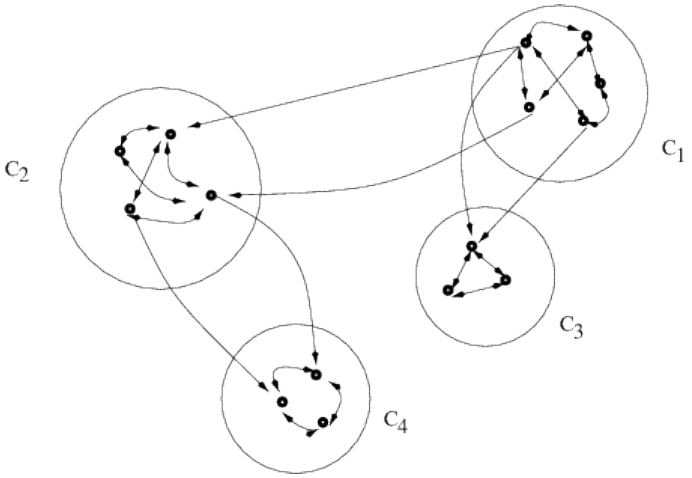


Abb. 8.4 Der Graph einer Markovkette mit vier Klassen C_1, C_2, C_3, C_4. Die Klassen C_1 und C_2 sind transient, C_3 und C_4 sind rekurrent.

Satz 8.22. *Sei X eine Markovkette mit Zustandsraum S. S zerfalle in die wesentlichen Klassen $C_1, \dots, C_\ell$ und die unwesentlichen Klassen $D_1, \dots, D_k$. Dann gibt es ℓ invariante Verteilungen $\mu_1, \dots, \mu_\ell$ mit Träger auf den wesentlichen Klassen $C_1, \dots, C_\ell$, und alle invarianten Verteilungen μ sind von der Form*

$$\mu = \sum_{i=1}^{\ell} \alpha_i \mu_i, \tag{8.51}$$

mit $\alpha_i \geq 0$ und $\sum_i \alpha_i = 1$.

Beweis. Es ist klar, dass es für jede wesentliche Klasse genau eine invariante Verteilung gibt. Sei nämlich C eine wesentliche Klasse. Wenn die Anfangsverteilung π_0 so gewählt ist, dass für alle $i \notin C$, $\pi_0(i) = 0$, dann ist für alle Zeiten für solche i, $\pi_t(i) = 0$. Die Matrix P eingeschränkt auf den von den Zuständen $j \in C$ aufgespannten Unterraum ist aber die Übergangsmatrix einer irreduziblen Markovkette mit Zustandsraum C. Also gibt es eine invariante Verteilung μ_C die C Maß eins gibt. Dies gilt für jede wesentliche Klasse separat.

Ebenso kann man sich leicht überzeugen, dass für jede invariante Verteilung μ auf den unwesentlichen Klassen verschwindet.

Sei dazu D die Vereinigung aller unwesentlichen Klassen D. Angenommen, $\mu(D) > 0$. Da μ invariant ist, muss $(\mu P)(D) = \mu(D)$ gelten. Nun ist aber für alle $j \in D$ und $i \notin D$, $p_{i,j} = 0$. Daher gilt

$$(\mu P)(D) = \sum_{j \in D} \sum_{i \in S} \mu(i) p_{i,j} = \sum_{j \in D} \sum_{i \in D} \mu(i) p_{i,j} + 0 \tag{8.52}$$

Weiter ist

$$(\mu P)(D) = \sum_{i \in D} \mu(i) \sum_{j \in D} p_{i,j} = \sum_{i \in D} \mu(i) - \sum_{i \in D} \mu(i) \sum_{j \notin D} p_{i,j} \leq \mu(D). \tag{8.53}$$

Dabei kann Gleichheit nur dann gelten, wenn für alle $i \in D$ für die es $j \in D^c$ gibt mit $p_{i,j} > 0$, $\mu(i) = 0$. Andererseits gilt für diese i dann

$$0 = \mu(i) = \sum_{j \in D} \mu(j) p_{j,i}, \tag{8.54}$$

weswegen $\mu(j) = 0$ auch für alle Zustände in D gilt die mit i verbunden sind; indem wir dieses Argument iterieren, folgt dass $\mu(j) = 0$ für alle $j \in D$ für die es einen Pfad gibt, der nach D^c führt. Dies ist aber ganz D, da sonst D eine wesentliche Klasse enthalten müsste.

Nutzt man nun diese Information, so verbleiben als Gleichungssystem für die invarianten Verteilungen nur noch entkoppelte Systeme für jede der verbleibenden wesentlichen irreduziblem Klassen. Daraus folgt die behauptete Struktur der invarianten Maße sofort. □

Beispiele. Wir schauen uns die Klassenzerlegung und invarianten Verteilungen für unsere drei Beispiele von vorher an.

- **Unabhängige Zufallsvariablen**. Hier ist die Markovkette irreduzibel und aperiodisch. Darüber hinaus ist die Übergangsmatrix bereits ein Projektor auf die einzige invariante Verteilung π_0.
- **Irrfahrt mit Rand**. Hier gibt es offenbar drei Klassen: $C_1 \equiv \{-L+1, \dots, L-1\}$, $C_2 = \{-L\}$ und $C_3 = \{L\}$. Dabei ist C_1 unwesentlich und C_2 und C_3 sind wesentlich. Daher haben wir zwei invariante Verteilungen, μ_2 und μ_3, wobei

$$\mu_2(j) = \delta_{j,-L}, \qquad \mu_3(j) = \delta_{j,L}. \tag{8.55}$$

  Natürlich sind auch alle konvexen Linearkombinationen dieser zwei Verteilungen invariante Verteilungen. Da für jede invariante Verteilung $\mu(C_1) = 0$ gilt, erschöpfen diese offenbar die invarianten Verteilungen dieser Markovkette.

- **Wettermodell**. Seien zunächst $p_{0,1}, p_{1,0} \in (0,1)$. Dann ist die Markovkette wieder irreduzibel und aperiodisch, und die einzige invariante Verteilung ist

$$\mu = \frac{1}{(p_{0,1} + p_{1,0})}(p_{1,0}, p_{0,1}). \tag{8.56}$$

  Dasselbe gilt wenn einer der beiden Parameter gleich eins ist, der andere aber in $(0,1)$ liegt.
  Wenn $p_{1,0}$ und $p_{0,1}$ gleich null sind, so gibt es zwei wesentliche Klassen mit den jeweils trivialen Verteilungen. Falls nur eine der beiden null ist, so gibt es eine wesentliche und eine unwesentliche Klasse.
  Wenn $p_{0,1} = p_{1,0} = 1$ ist, haben wir eine irreduzible, aber nicht aperiodische Klasse. Die Markovkette hat dann Periode zwei, wie schon oben beschrieben.

8.4 Stoppzeiten und der starke Ergodensatz

In der Folge werden wir mit Erwartungen von Funktionen von Markovprozessen beschäftigt sein. Wir schreiben dazu für messbare Funktionen F auf $(S^{\mathbb{N}_0}, \mathfrak{B}(S)^{\otimes \mathbb{N}_0})$ und für $x \in S$,

$$\mathbb{E}_x F = \mathbb{E}[F(X_0, X_1, \dots, X_n, \dots) | X_0 = x]. \tag{8.57}$$

Es ist in der Folge oft bequem, die Wahrscheinlichkeitsräume $(\Omega, \mathfrak{F}, \mathbb{P})$ und $(S_0^{\mathbb{N}}, \mathfrak{B}(S)^{\otimes \mathbb{N}_0}, P_X)$ zu identifizieren. Wir definieren die Zeittranslation θ_T durch

$$F \circ \theta_T(X_0, X_1, \dots, X_n, \dots) \equiv F(X_T, X_{T+1}, \dots, X_{T+n}, \dots). \tag{8.58}$$

8.4.1 Die starke Markoveigenschaft

Ein wesentliches Konzept in der Analyse von Markovprozessen ist das der *Stoppzeit*. Wir bezeichnen mit $\mathfrak{F}_n \equiv \sigma(X_0, \ldots, X_n)$ die σ-Algebra, die von den Zufallsvariablen $X_0, X_1, \ldots X_n$ erzeugt wird. Die Familie $\{\mathfrak{F}_n\}_{n\in\mathbb{N}_0}$ bezeichnet man auch als eine Filtrierung, bzw. die dem Markovprozess $\{X_n\}_{n\in\mathbb{N}_0}$ zugehörige Filtrierung der σ-Algebra $\mathfrak{F}$.

Definition 8.23. Eine Abbildung $T : \Omega \to \mathbb{N}_0$ heißt eine *Stoppzeit* genau dann, wenn für jedes $n \in \mathbb{N}_0$, das Ereignis $\{T = n\}$ in $\mathfrak{F}_n$ liegt.

Stoppzeiten sind also dadurch charakterisiert, dass man zu jedem Zeitpunkt, n, aus der Kenntnis des Verlaufs der Vergangenheit des Prozesses X entscheiden kann, ob diese Stoppzeit gerade erreicht ist.

Ein wichtiges Beispiel für Stoppzeiten sind die *ersten Eintrittszeiten* in Untermengen. Ist $D \subset S$, so definieren wir

$$\tau_D \equiv \inf\{n > 0 | X_n \in D\}. \tag{8.59}$$

Wir sehen, dass τ_D eine Stoppzeit ist:

$$\{\tau_D = n\} = \{\forall_{k<n}, X_k \notin D\} \cap \{X_n \in D\}. \tag{8.60}$$

Die rechte Seite ist manifest in $\mathfrak{F}_n$, weil sie nur von X_k mit $k \leq n$ abhängt.

Beispiel für eine interessante Größe, die keine Stoppzeit ist, ist die *letzten Austrittszeiten* aus Untermengen,

$$\sigma_D \equiv \sup\{n \geq 0 | X_n \in D\}. \tag{8.61}$$

Klarerweise können wir zu keinem Zeitpunkt wissen, ob der Prozess nicht nochmal nach D zurückkehrt, ohne in die Zukunft zu blicken.

Eine der wichtigsten Eigenschaften von Stoppzeiten ist die sogenannte *starke Markoveigenschaft*. Sie besagt, dass man die Erwartung bezüglich Verteilungen einer Markovkette an Stoppzeiten faktorisieren kann. Damit meinen wir das Folgende.

Wir definieren zunächst für eine Stoppzeit T die σ-Algebra $\mathfrak{F}_T$ als die Menge aller Ereignisse, die nur von X_n mit $n \leq T$ abhängen. Formal ist

$$\mathfrak{F}_T \equiv \bigcup_{n\in\mathbb{N}_0} \mathfrak{F}_n \cap \{n \leq T\}. \tag{8.62}$$

Satz 8.24 (Starke Markoveigenschaft). *Sei T eine Stoppzeit und seien F und G $\mathfrak{F}$-messbare Funktionen auf Ω. Sei darüber hinaus F messbar bezüglich $\mathfrak{F}_T$. Dann gilt für jedes $x \in S$, dass*

$$\mathbb{E}_x\left[\mathbb{1}_{T<\infty} F\, G \circ \theta_T\right] = \mathbb{E}_x\left[\mathbb{1}_{T<\infty} F\, \mathbb{E}_{X_T}[G]\right], \tag{8.63}$$

d.h.,

$$\mathbb{E}\left[\mathbb{1}_{T(X)<\infty}F(X)\,(G\circ\theta_T)(X)|X_0=x\right] \\ =\mathbb{E}\left[\mathbb{1}_{T(X)<\infty}F(X)\,\mathbb{E}[G(X')|X'_0=X_T]|X_0=x\right] \quad (8.64)$$

wo X' eine unabhängige Kopie von X ist.

Beweis. Man kann sich durch explizites Ausschreiben davon überzeugen, dass für jedes endliche n

$$\begin{aligned}&\mathbb{E}\left[\mathbb{1}_{T(X)=n}F(X)\,(G\circ\theta_T)(X)|X_0=x\right]\\ &=\sum_{y\in S}\mathbb{E}\left[\mathbb{1}_{T(X)=n}\mathbb{1}_{X_n=y}F(X)\,(G\circ\theta_n)(X)|X_0=x\right]\\ &=\sum_{y\in S}\mathbb{E}\left[\mathbb{1}_{T(X)=n}\mathbb{1}_{X_n=y}F(X)\,|X_0=x\right]\mathbb{E}[G(X')|X'_0=y]\\ &=\mathbb{E}\left[\mathbb{1}_{T(X)=n}F(X)\mathbb{E}[G(X')|X'_0=X_n]|X_0=x\right].\end{aligned}$$

Nun summieren wir einfach über n und erhalten die Behauptung. □

Eine Anwendung der starken Markoveigenschaft liefert eine neue Interpretation der invarianten Verteilung.

Lemma 8.25. *Sei X eine irreduzible Markovkette mit endlichem Zustandsraum S. Sei μ die zugehörige invariante Verteilung. Dann gilt, für $j,\ell\in S$,*

$$\mu(j)=\frac{\mathbb{E}_\ell\left[\sum_{t=1}^{\tau_\ell}\mathbb{1}_{X_t=j}\right]}{\mathbb{E}_\ell[\tau_\ell]} \quad (8.65)$$

wobei $\tau_\ell\equiv\inf\{n>0|X_n=\ell\}$.

Beweis. Wir zeigen zunächst, dass $\mathbb{E}_\ell[\tau_\ell]<\infty$, und somit der Ausdruck auf der rechten Seite von (8.65) Sinn macht.

Betrachten wir zunächst den Fall, dass unsere Markovkette aperiodisch ist. Dann wissen wir, dass es $k\in\mathbb{N}$ gibt, so dass für alle $i,j\in S$ $(P^k)_{i,j}\geq c>0$ ist. Dann ist aber

$$\mathbb{P}_\ell[\tau_\ell>t]\leq\mathbb{P}_\ell[X_{kn}\neq\ell,\forall kn\leq t]\leq\prod_{n:kn\leq t}(1-\min_{i\in S}(P^k)_{i,\ell})\lesssim(1-c)^{t/k}. \quad (8.66)$$

Damit ist dann natürlich $\mathbb{E}_\ell[\tau_\ell]=\sum_{t\geq0}\mathbb{P}_\ell[\tau_\ell>t]<\infty$.

Falls die Kette nur irreduzibel und nicht notwendig aperiodisch ist, so muss das das obige Argument leicht verändert werden. Es gilt nun immer noch, dass es für jedes $j\in S$ ein $k_j<\infty$ gibt, so dass $P^{k_j}_{j\ell}>0$. Daher gibt es $k^*\equiv\max_{j\in S}k_j$ mit der Eigenschaft, dass für alle $j\in S$, $\exists_{k_j\leq k^*}$ so dass $P^{k_j}_{j\ell}>0$ Damit aber ist

$$\min_{j\in S}\mathbb{P}_j\left(X_t=\ell,\exists_{t\leq k^*}\right)\geq\min_{j\in S}\mathbb{P}_j\left(X_{k_j}=\ell\right)>0. \quad (8.67)$$

Indem wir diese Abschätzung in (8.66) verwenden erhalten wir dieselbe Schlussfolgerung.

Wir definieren $\nu_\ell(j) = \mathbb{E}_\ell\left[\sum_{t=1}^{\tau_\ell} \mathbb{1}_{X_t=j}\right]$. Wenn wir zeigen, dass $\nu_\ell(j)$ die Invarianzeigenschaft erfüllt, so tut dies auch μ, und nach Konstruktion ist μ eine Wahrscheinlichkeitsverteilung. Wir schreiben zunächst $1 = \sum_{m\in S} \mathbb{1}_{X_{t-1}=m}$, und

$$\begin{aligned}\nu_\ell(j) = \mathbb{E}_\ell\left[\sum_{t=1}^{\infty} \mathbb{1}_{X_t=j}\mathbb{1}_{t\le\tau_\ell}\right] &= \sum_{t=1}^{\infty} \mathbb{P}_\ell\left(X_t = j, t \le \tau_\ell\right) \\ &= \sum_{m\in S}\sum_{t=1}^{\infty} \mathbb{P}_\ell\left(X_{t-1} = m, X_t = j, t \le \tau_\ell\right).\end{aligned}$$

Nun ist das Ereignis $\{t \le \tau_\ell\} = \{\tau_\ell \le t-1\}^c \in \mathfrak{F}_{t-1}$. Daher können wir die Markov-Eigenschaft zur Zeit $t-1$ anwenden und erhalten

$$\begin{aligned}\mathbb{P}_\ell\left(X_{t-1} = m, X_t = j, t \le \tau_\ell\right) &= \mathbb{P}_\ell\left(X_{t-1} = m, t \le \tau_\ell\right)\mathbb{P}_m\left(X_1 = j\right) \\ &= \mathbb{P}_\ell\left(X_{t-1} = m, t \le \tau_\ell\right) p_{m,j}. \end{aligned} \tag{8.68}$$

Damit ist aber

$$\nu_\ell(j) = \sum_{m\in S} \mathbb{E}_\ell\left[\sum_{t=1}^{\infty} \mathbb{1}_{X_{t-1}=m}\mathbb{1}_{t\le\tau_\ell}\right] p_{m,j} = \sum_{m\in S} \mathbb{E}_\ell\left[\sum_{t=1}^{\tau_\ell} \mathbb{1}_{X_{t-1}=m}\right] p_{m,j}. \tag{8.69}$$

Andererseits

$$\sum_{t=1}^{\tau_\ell} \mathbb{1}_{X_{t-1}=m} = \mathbb{1}_{X_0=m} + \sum_{t=1}^{\tau_\ell} \mathbb{1}_{X_t=m} - \mathbb{1}_{X_{\tau_\ell}=m} = \sum_{t=1}^{\tau_\ell} \mathbb{1}_{X_t=m}$$

weil $X_0 = X_{\tau_\ell}$. Somit ist aber

$$\nu_\ell(j) = \sum_{m\in S} \mathbb{E}_\ell\left[\sum_{t=1}^{\tau_\ell} \mathbb{1}_{X_t=m}\right] p_{m,j} = \sum_{m\in S} \nu_\ell(m) p_{m,j}. \tag{8.70}$$

Dies ist aber gerade die Gleichung für die invariante Verteilung. Daher ist $\nu_\ell(j)/\sum_{i\in S}\nu_\ell(i)$ eine invariante Wahrscheinlichkeitsverteilung. Nun ist aber

$$\sum_{i\in S} \nu_\ell(i) = \sum_{i\in S} \mathbb{E}_\ell\left[\sum_{t=1}^{\tau_\ell} \mathbb{1}_{X_t=i}\right] = \mathbb{E}_\ell\left[\sum_{t=1}^{\tau_\ell} \mathbb{1}_{X_t\in S}\right] = \mathbb{E}_\ell[\tau_\ell] \tag{8.71}$$

woraus die Behauptung des Lemmas folgt. Beachte, dass wegen der Eindeutigkeit, μ unabhängig von ℓ ist. □

Korollar 8.26. *Für eine irreduzible Markovkette mit endlichem Zustandsraum gilt*

$$\mu(j) = \frac{1}{\mathbb{E}_j[\tau_j]}. \tag{8.72}$$

Beweis. Formel (8.65) gilt für jede Wahl von ℓ. Indem wir $\ell = j$ wählen und benutzen, dass

$$\nu_j(j) = \mathbb{E}_j\left[\sum_{t=1}^{\tau_j} \mathbb{1}_{X_t=j}\right] = 1 \tag{8.73}$$

ist, weil aus der Definition von τ_j folgt $\mathbb{1}_{X_t=j} = \delta_{\tau_j,t}$ für $t = 1, \ldots, \tau_j$, erhalten wir (8.72). □

8.4.2 Der starke Ergodensatz

Wir sind nun in der Lage eine starke Form des Ergodensatzes für irreduzible Markovketten zu formulieren, die in gewisser Weise das Analogon des Gesetzes der großen Zahlen für Markovketten ist.

Satz 8.27 (Starker Ergodensatz). *Sei X eine irreduzible Markovkette mit endlichem Zustandsraum S und invarianter Verteilung μ. Sei $f : S \to \mathbb{R}$ eine beschränkte messbare Funktion. Dann gilt*

$$\lim_{n\to\infty} \frac{1}{n} \sum_{k=1}^{n} f(X_k) = \int_S f d\mu \quad \text{f.s.} \tag{8.74}$$

Anmerkung. Die Voraussetzungen an f sind angesichts der Endlichkeit des Zustandsraums natürlich trivial.

Beweis. Es genügt offenbar den Satz für Indikatorfunktionen $f = \mathbb{1}_i$, $i \in S$, zu beweisen. Sei nun τ_ℓ eine Folge von Stoppzeiten definiert durch

$$\begin{aligned} \tau_0 &\equiv \inf\{k > 0 : X_k = i\}, \\ \tau_\ell &\equiv \inf\{k > \tau_{\ell-1} : X_k = i\}. \end{aligned} \tag{8.75}$$

Mit anderen Worten, die Zeiten τ_ℓ sind genau die Zeiten, an denen X den Zustand i besucht. Offenbar ist dann

$$\sum_{k=1}^{n} f(X_k) = \sum_{k=1}^{n} \mathbb{1}_{X_k=i} = \max\{\ell : \tau_\ell \le n\}. \tag{8.76}$$

Nun machen wir folgende wichtige Beobachtung: Setze $\sigma_\ell = \tau_\ell - \tau_{\ell-1}$. Dann sind für $\ell \ge 1$ die σ_ℓ unabhängige, identisch verteilte Zufallsvariablen. Das folgt aus der starken Markoveigenschaft, indem wir nachweisen, dass für beliebige integrierbare Funktionen, $g_\ell : \mathbb{N} \to \mathbb{R}$, $\ell \in \mathbb{N}$ und für jedes $m \in \mathbb{N}$,

$$\mathbb{E}_i\left[\prod_{\ell=1}^{m} g_\ell(\sigma_\ell)\right] = \prod_{\ell=1}^{m} \mathbb{E}_i\left[g_\ell(\sigma_\ell)\right]. \tag{8.77}$$

(Übung!).

Wir wissen schon, dass $\mathbb{E}_i[\sigma_\ell] = \mathbb{E}_i[\tau_0] < \infty$. Daher gilt nach dem Gesetz der großen Zahlen,

$$\lim_{n\to\infty} \frac{\tau_n}{n} = \lim_{n\to\infty} \frac{\tau_0 + \sigma_1 + \cdots + \sigma_n}{n} = \mathbb{E}_i[\tau_0], \quad \text{f.s.}, \tag{8.78}$$

da ja

$$\lim_{n\to\infty} \frac{\tau_0}{n} = 0, \quad \text{f.s.} \tag{8.79}$$

Dann ist leicht einzusehen (Übung!), dass daraus folgt, dass

$$\lim_{n\to\infty} \frac{1}{n} \max\{\ell : \tau_\ell \le n\} = \frac{1}{\mathbb{E}_i[\tau_0]} = \mu(i), \quad \text{f.s.} \tag{8.80}$$

□

Anmerkung. Wir sehen, dass wir für den starken Ergodensatz die Aperiodizität nicht voraussetzen müssen. Es folgt daraus auch, dass für irreduzible Markovketten gilt, dass

$$\lim_{n\uparrow\infty} \frac{1}{n} \sum_{k=1}^{n} \pi_0 P^k = \mu, \tag{8.81}$$

das heißt, die Verteilung einer irreduziblem Markovkette konvergiert im Cesaro-Mittel stets gegen die invariante Verteilung konvergiert.

8.4.3 Markovketten Monte-Carlo Verfahren.

Eine in der Praxis wesentliche Anwendung des Ergodensatzes für Markovketten ist die Möglichkeit, mit seiner Hilfe Integrale bezüglich einer gewünschten Verteilung numerisch approximativ zu berechnen.

Bei der Berechnung von Erwartungswerten trifft man in der Praxis of auf zwei Probleme: (1) Der Zustandsraum ist sehr groß (und hochdimensional) (etwa etwa in der statistischen Mechanik, Maße nur "bis auf die Normierung" explizit gegeben, eta in der Form

$$\rho(x) = \frac{1}{Z} \exp(-\beta H(x)), \tag{8.82}$$

wo $H(x)$ eine einfach zu berechende Funktion ist, die Konstante Z aber nur als $\sum_{x\in S} \exp(-\beta H(x))$ gegeben ist, also etwa so schwer zu berechnen ist wie das Integral selbst.

Hier kommen nun die Markovketten und der Ergodensatz ins Spiel. Angenommen, wir fänden eine ergodische Markovkette mit Zustandraum S derart, das die invariante Verteilung der Kette gerade ρ ist. Da die Normierung für die Invarianzgleichung keine Rolle spielt, kann man eine solche konstruieren, ohne Z zu kennen. Dann wissen wir, dass

$$\lim_{n\to\infty} \frac{1}{n} \sum_{k=1}^{n} f(X_k) \equiv \int_S f d\rho \quad \text{f.s.} \tag{8.83}$$

Um eine systematische Approximation unseres Integrals zu bekommen, benötigen wir also nur eine Realisierungen der Zufallsvariablen $X_1, X_2, \ldots$. Dabei gewinnen wir natürlich nur dann etwas, wenn die entsprechenden bedingten Verteilungen, also die Übergangwahrscheinlichkeiten der Markovkette, finden können. Dazu muss man natürlich in der Lage sein, diese Zufallsvariablen in einfacher Weise numerisch zu konstruieren. Dazu ist es nützlich, die Markovkette so zu konstruieren, dass man von einem gegebenen Zustand aus nur sehr wenige Zustände erreichen kann; im obigen Beispiel $S = \{-1, 1\}^N$ wählt man die Markovkette etwa so, dass man in einem Schritt nur eine der Koordinaten des Vektors x ändern kann. Dann sind die Übergangswahrscheinlichkeiten effektiv Verteilungen auf nur N (statt 2^N) Zuständen, und somit viel leichter handhabbar. Im obigen Fall kann man z.B. die Übergangswahrscheinlichkeiten in der Form

$$p_{xy} = \frac{1}{N} \exp\left(-[H_N(y) - H_N(x)]_+\right), \text{wenn } |x - y| = 2, \tag{8.84}$$

$$p_{xx} = 1 - \sum_{y:|x-y|=2} p_{xy}, \tag{8.85}$$

und null sonst, wählen (Übung!).

Damit dieses Verfahren funktioniert, sollte natürlich die Konvergenz gegen die invariante Verteilung schnell genug erfolgen, so dass man tatsächlich rasch gute Approximationen erhält. Dies zu quantifizieren ist im Allgemeinen ein schwieriges Problem. In vielen Fällen liefert dieses *Markovketten Monte-Carlo Verfahren* aber sehr gute Resultate. Monte-Carlo Verfahren sind ein wichtiges Hilfsmittel der stochastischen Numerik und werden in verschiedener Form sehr verbreitet eingesetzt.

8.5 Vorwärtsgleichungen, Eintrittswahrscheinlichkeiten und Zeiten.

Ein typisches Vorgehen zur Berechnung verschiedener Wahrscheinlichkeiten in Markovketten besteht in der Herleitung von linearen Gleichungen für diese. Als Beispiel betrachten wir eine Markovkette mit Zustandsraum S, die zwei wesentliche Klassen C_1, C_2 sowie eine unwesentliche Klasse $C_3 = S \setminus (C_1 \cup C_2)$ habe. Wir interessieren uns dafür, mit welcher Wahrscheinlichkeit man, ausgehend von einem Zustand $x \in C_3$ in der wesentlichen Klasse C_1 endet. Diese können wir schreiben als

$$\mathbb{P}_x\left[\tau_{C_1} < \tau_{C_2}\right]. \tag{8.86}$$

Um eine Gleichung für diese Wahrscheinlichkeit zu erhalten, betrachten wir zunächst alle möglichen ersten Schritte der Kette und wenden dann die Markoveigenschaft

an. Wenn der erste Schritt bereits nach C_1 führt, so ist das Ereignis bereits realisiert und wir erhalten einen Beitrag 1; führt der erste Schritt nach C_2, so kann das Ereignis nicht eintreten, und wir erhalten einen Beitrag 0; wenn schliesslich der erste Schritt nach y in C_3 bleibt, ist der Beitrag gerade die Wahrscheinlichkeit, das Ereignis ausgehend von y zu realisieren. Dies liefert

$$\mathbb{P}_x\left[\tau_{C_1} < \tau_{C_2}\right] = \sum_{y\in C_1} p(x,y) + \sum_{y\in S\setminus(C_1\cup C_2)} p(x,y)\mathbb{P}_y\left[\tau_{C_1} < \tau_{C_2}\right]. \tag{8.87}$$

Wir können diese Gleichung in einer geschlossenen Form schreiben, wenn wir die Funktion $h_{C_1,C_2}(x)$ definieren als

$$h_{C_1,C_2}(x) \equiv \begin{cases} \mathbb{P}_x\left[\tau_{C_1} < \tau_{C_2}\right], & \text{wenn } x \in S\setminus(C_1\cup C_2), \\ 0, & \text{wenn } x \in C_2, \\ 1, & \text{wenn } x \in C_1. \end{cases} \tag{8.88}$$

Damit wird (8.87) in der Form

$$h_{C_1,C_2}(x) = \sum_{y\in S} p(x,y) h_{C_1,C_2}(y) = (Ph_{C_1,C_2})(x) \tag{8.89}$$

schreibbar. Eine solche Gleichung nennt man auch *Vorwärtsgleichung*. Eine Funktion, die in einem Gebiet die Gleichung $f = Pf$ löst, wo P Übergangsmatrix einer Markovkette ist, nennt man auch eine *harmonische Funktion*. Die Funktion h_{C_1,C_2} heißt speziell auch *Gleichgewichtspotential*. Man kan diese als Lösung des Gleichungssystems

$$\begin{aligned} &h_{C_1,C_2}(x) = (Ph_{C_1,C_2})(x), \quad x \in S\setminus(C_1\cup C_2), \\ &h_{C_1,C_2}(x) = 1, \quad x \in C_1, \\ &h_{C_1,C_2}(x) = 0, \quad x \in C_2, \end{aligned} \tag{8.90}$$

erhalten. Gleichungen wie (8.90) bilden die Grundlage für eine sehr weitgehende und tiefe Beziehung zwischen der Theorie der Markovprozesse und der *Potentialtheorie*, mithin zwischen Stochastik und Analysis. Wir werden diese Thematik in fortgeschrittenen Vorlesungen zur W-Theorie wieder aufgreifen.

Hier wollen wir einige grundlegenden Ergebnisse im Fall endlichen Zustandsraumes betrachten. Die erste Frage die wir uns stellen müssen, ist, ob Gleichungen des Typs (8.90) eindeutige Lösungen haben.

Definition 8.28. Sei P eine Übergangsmatrix einer Markovkette mit Zustandsraum S und sei $D \subset S$. Eine Funktion $f : S \to \mathbb{R}$ heißt *harmonisch* (bez. P) auf D, falls für alle $x \in D$, $f(x) = Pf(x)$.

Die Eindeutigkeit der Lösung folgt dann aus folgenden Satz (wobei man $D^c = C_1 \cup C_2$ und f die Differenz von zwei Lösungen von (8.90) einsetzt).

Satz 8.29. *Sei P die Übergangsmatrix einer Markovkette mit endlichem Zustandsraum S. Sei $D \subset S$ so dass von jedem $x \in D$ die Menge $D^c \equiv S \setminus D$ längs des Graphen der Markovkette erreicht werden kann. Dann hat das Gleichungssystem*

$$\begin{aligned} Pf(x) &= f, \text{ wenn } x \in D, \\ f(x) &= 0, \text{ wenn } x \in D^c, \end{aligned} \tag{8.91}$$

die eindeutige Lösung $f(x) \equiv 0$.

Beweis. Der Beweis dieses Satzes beruht auf dem sogenannten *Maximumsprinzip* für harmonische Funktionen.

Lemma 8.30. *Seien P und D wie im vorigen Satz und sei h eine harmonische Funktion of D. Es gebe fernen für jeden Punkt $x \in D$ einen Pfad in dem Graphen der Markovkette von x nach $S \setminus D$. Dann nimmt h ihr Maximum auf D^c an.*

Beweis. Sei $x \in D$ ein Maximum von h. Dann gilt

$$h(x) = \sum_y p_{xy} h(y). \tag{8.92}$$

Da $h(x) \geq h(y)$ für alle y in der Summe für die $p_{xy} > 0$, folgt dass $h(x) = h(y)$ für alle diese Punkte. Indem wir dieses argument iterieren, finden wir, dass es einen Weg längs Kanten des Graphen der Kette von x nach D^c gibt, längs dem h konstant den Wert $h(x)$ annimmt. □

Für unseren Fall ist f harmonisch auf D und $f = 0$ auf D^c. Daher ist $f(x) \leq 0$. Indem wir dasselbe Argument auf $-f$ anwenden, folgt auch, dass $f(x) \geq 0$. □

Übung. Sei eine Markovkette wie oben mit zwei wesentlichen und einer unwesentlichen Klasse gegeben. Seien die wesentlichen Klassen aperiodisch, und seien μ_1, μ_2 die invarianten Maße mit $\mu_i(C_i) = 1$. Dann gilt, für alle $x \in C_3$, wenn $\pi_0(y) = \delta_x(y)$,

$$\lim_{n\to\infty} \pi_n(z) = \mathbb{P}_x\left[\tau_{C_1} < \tau_{C_2}\right] \mu_1(z) + \mathbb{P}_x\left[\tau_{C_2} < \tau_{C_1}\right] \mu_2(z). \tag{8.93}$$

Neben den Eintreffwahrscheinlichkeiten in verschiedenen Klassen kann man auch nach der Verteilung der Eintrittszeiten fragen. So sei D eine beliebige Untermenge des Zustandsraums S. Was ist die Verteilung der Stoppzeit τ_D,

$$\mathbb{P}_x[\tau_D = t] \equiv f_D(x, t). \tag{8.94}$$

Wir können wieder eine Gleichung für $f_D(x, t)$ herleiten, indem wir uns zunächst den ersten Schritt der Kette ansehen. Falls $t = 1$, sehen wir dass (für $t = 1$ und $x \notin D$)

$$\mathbb{P}_x[\tau_D = 1] = \sum_{y \in D} p(x, y), \tag{8.95}$$

für $t > 1$ ist

$$\mathbb{P}_x[\tau_D = t] = \sum_{y \notin D} p(x,y)\mathbb{P}_y[\tau_D = t-1]. \tag{8.96}$$

Diese Gleichung kann man in einer schöneren Form schreiben, wenn die Definition der Funktion f_D wie folgt ausweitet:

$$f_D(x,t) \equiv \begin{cases} \mathbb{P}_x[\tau_D = t], & \text{wenn } x \in D^c, t \geq 1, \\ 0, & \text{wenn } x \in D, t \geq 1, \\ 0, & \text{wenn } x \in D^c, t = 0, \\ 1, & \text{wenn } x \in D, t = 0. \end{cases} \tag{8.97}$$

Dann erhalten wir nämlich für all $t \geq 1$, $x \in D^c$,

$$f_D(x,t) = \sum_{y \in S} p(x,y) f_D(y, t-1). \tag{8.98}$$

Damit sieht man, dass man die gesuchte Wahrscheinlichkeit durch Lösung eines diskreten Rand-Anfangswertproblems erhalten kann, dass wie folgt aussieht:

$$\begin{aligned} f_D(x,t) - f_D(x,t-1) &= \sum_{y \in S \setminus x} p(x,y) f_D(y,t-1),\ x \in D^c, t \geq 1, \\ f_D(x,t) &= 0, \quad x \in D, t \geq 1, \\ f_D(x,0) &= 0, \quad x \in D^c, \\ f_D(x,0) &= 1, \quad x \in D. \end{aligned} \tag{8.99}$$

Mit Hilfe der Matrix $L \equiv P - \mathbb{1}$ können wir die Gleichung (8.100) noch in der Form

$$f_D(x,t) - f_D(x,t-1) = (L f_D)(x,t-1) \tag{8.100}$$

schreiben. Die Lösung dieser linearen Gleichungen sind also geeignet um die Wahrscheinlichkeitsverteilung von τ_D zu berechnen.

Übung. Zeige, dass die Funktion

$$w_D(x) \equiv \begin{cases} \mathbb{E}_x \tau_D, & x \in D^c, \\ 0, & x \in D, \end{cases} \tag{8.101}$$

die Gleichung

$$\begin{aligned} w_D(x) &= \sum_{y \in S} p(x,y) w_D(y) + 1,\ x \in D^c, \\ w_D(x) &= 0, \quad x \in D, \end{aligned} \tag{8.102}$$

löst. Benutze dazu entweder die Gleichung (8.100) und die Beobachtung, dass $w_D(x) = \sum_{t=1}^{\infty} f_D(x,t)$, oder leite die Gleichung direkt analog zu der für f_D her.

8.6 Markovketten mit abzählbarem Zustandsraum

DerInhalt dieses Abschnitts ist optional und kann auch erst in der Vorlesung "Stochastische Prozesse" behandlet werden.

Wir wollen abschliessend unsere Betrachtung vom Markovketten noch auf den Fall von unendliche, aber abzählbare Zustandsräume ausdehnen. Ganz natürliche Prozesse, wie die Irrfahrt auf $\mathbb{Z}$ oder $\mathbb{Z}^d$, gehören dazu.

An den Definitionen einer Marlovkette ändert sich zunächst nicht. Ebenso können wir die Begriffe von kommunizierenden Klassen, Irreduzibilität, Periodizität ohne weiteres in diesem Kontext anwenden. Aus der Übergansmatrix wird nun eine unendlichdimensionale Übergansmatrix, P, mit Elementen p_{ij}, $i, j \in S$. Bei der Frage nach der Existenz und Eindeutigkeit einer invarianten Verteilung haben wir aber sehr stark auf der Theorie endlich dimensionaler Matrizen aufgebaut. Hier werden sich nun neue Fragen auftun.

Als erstes führen wir die Begriffe der *Rekurrenz* und *Transienz* ein.

Definition 8.31. Sei X eine irreduzible Markovkette mit abzählbarem Zustandsraum S.

(i) X heißt *transient*, wenn für jedes $i \in S$,

$$\mathbb{P}_i(\tau_i < \infty) < 1; \tag{8.103}$$

(ii)Andernfalls heißt X *rekurrent*.
(iii) X heißt *positiv rekurrent* falls für alle $i \in S$,

$$\mathbb{E}_i(\tau_i) < \infty. \tag{8.104}$$

Anmerkung. Man kann Transienz und Rekurrenz auch als Eigenschaft einzelner Zustände definieren. Diese Eigenschaften sind aber wieder Klasseneingenschaften, so dass sie für irreduzible Ketten Eigenschaften der Kette werden. Damit ist eine irreduzible Markovkette transient, rekurrent oder positiv rekurrent, wenn es einen Zustand gibt, für den die entprechenden Eigenschaften gelten.

Wir haben die folgenden alternative Charakterisierung von Transienz:

Lemma 8.32. *Sei X ein irreduzible Markovkette mit abzählbarem Zustandsraum. Dann ist X transient genau dann, wenn für jeden Zustand $\ell \in S$,*

$$\mathbb{P}_\ell\,(X_t = \ell, \text{i.o.}) = 0. \tag{8.105}$$

Beweis. Sei X transient, also $\mathbb{P}_\ell(\tau_\ell < \infty) \equiv c < 1$. Wegen der starken Markoveigenschaft sind die sukzessiven Versuche, von ℓ nach ℓ in endlicher Zeit zurückzukommen unabhängig. Daher gilt

$$\mathbb{P}_\ell\,(X_t = \ell,\ n\text{-mal}) = \mathbb{P}_\ell(\tau_\ell < \infty)^n \mathbb{P}_\ell(\tau_\ell = \infty) = c^n(1-c). \tag{8.106}$$

Nun ist wegen dem ersten Borel-Cantelli Lemma (8.105) wahr, falls

$$\sum_t \mathbb{P}_\ell(X_t = \ell) < \infty. \tag{8.107}$$

Aber

$$\sum_t \mathbb{P}_\ell(X_t = \ell) = \mathbb{E}_\ell\left(\sum_t \mathbb{1}_{X_t=\ell}\right) = \sum_{n=1}^{\infty} n\mathbb{P}_\ell(X_t = \ell,\ n\text{-mal}). \tag{8.108}$$

Da die Summanden wegen (8.106) kleiner sind als c^n mit $c < 1$, konvergiert die Summe. Sei umgekehrt (8.105) wahr. Nun ist

$$\begin{aligned} 1 - \mathbb{P}_\ell\left(X_t = \ell, \text{i.o.}\right) &= \sum_t \mathbb{P}_\ell(X_t = \ell)\mathbb{P}_\ell(\tau_\ell = \infty) \\ &= \sum_{n=1}^{\infty} n\mathbb{P}_\ell(X_t = \ell,\ n\text{-mal}))\mathbb{P}_\ell(\tau_\ell = \infty). \end{aligned} \tag{8.109}$$

Wenn nun die linke Seite der Gleichung gleich 1 ist, so muss $\mathbb{P}_\ell(\tau_\ell < \infty) < 1$ sein. □

Diese Eigenschaft erklärt den Begriff "transient': eine transiente Kette "verschwindet" fast sicher nach "unendlich" und kommt irgendwann einmal nie wieder zum Startpunkt zurück.

Positiv rekurrente Markovketten verhalten sich ähnlich wie irreduzible Markovketten mit endlichem Zustandsraum. Insbesondere besitzen sie eine einzige invariante Wahrsscheinlichkeitsverteilung. Dies ist der Inhalt des folgenden Satzes.

Satz 8.33. *Sei X eine positiv rekurrente Markovkette mit abzählbarem Zustandsraum S. Dann ist für jedes $j, \ell \in S$,*

$$\mu(j) \equiv \frac{\mathbb{E}_\ell\left(\sum_{t=1}^{\tau_\ell} \mathbb{1}_{X_t=j}\right)}{\mathbb{E}_\ell \tau_\ell}. \tag{8.110}$$

die eindeutige invariante (Wahrscheinlichkeits)Verteilung von X.

Beweis. Sei $\nu_\ell(j) = \mathbb{E}_\ell\left[\sum_{t=1}^{\tau_\ell} \mathbb{1}_{X_t=j}\right]$. Das ν_ℓ eine invariante Verteilung ist, haben wir schon in Lemma 8.25 gezeigt; die Tatsache, dass der Zustandsraum endlich ist wurde dort nur genutzt um zu zeigen, dass $\mathbb{E}_\ell\tau_\ell < \infty$; dies ist hier aber eine Annahme.

Wir müssen noch die Eindeutigkeit beweisen. Dazu zeigen wir zunächst folgendes:
Wenn X irreduzibel und μ ein invariantes Maß ist, und für irgendein $i \in S$ $\mu(i) = 0$ gilt, dann ist μ das Nullmaß.

Denn wenn für irgendein $j \in S$ $\mu(j) > 0$, dann gibt es ein endliches t so dass $p^t_{ji} > 0$, und somit wegen der Invarianzeigenschaft, dass

$$\mu(i) = \sum_k \mu(k)(t)_{ki} \geq \mu(j) p^t_{ji} > 0, \tag{8.111}$$

im Widerspruch zu der Annahme, dass $\mu(i) = 0$.

Wir werden zeigen, dass das oben definierte ν_ℓ das einzige invariante Mass ist, so dass $\nu(\ell) = 1$ gilt. Wegen der obigen Bemerkung folgt daraus die Eindeutigkeit. Gäbe es nämlich ein anderes invariantes Maß ν, dass nicht ein Vielfaches von ν_ℓ ist, so müsste ja $\nu(\ell) > 0$ sein, und daher $\nu' \equiv \nu/\nu(\ell)$ ein invariantes Maß mit $\nu'(\ell) = 1$!

Sei also ν ein invariantes Maß mit $\nu(\ell) = 1$. Wir werden zeigen, dass dann für alle Zustände $j \in S$, $\nu(j) \geq \nu_\ell(j)$. Dann aber wäre $\nu - \nu_\ell$ ein positives invariantes Maß, welches aber in ℓ verschwände, weswegen folgen würde, dass $\nu = \nu_\ell$.

Nun gilt, da nach Voraussetzung $\nu(\ell) = 1$,

$$\nu(i) = \sum_{j \neq \ell} \nu(j) p_{ji} + p_{\ell i}. \tag{8.112}$$

Wir schreiben $p_{\ell i}$ als

$$p_{\ell i} = \mathbb{E}_\ell \left(\mathbb{1}_{\tau_\ell \geq 1} \mathbb{1}_{X_1 = i} \right). \tag{8.113}$$

Nun können wir die Gleichung (8.112) für die Terme in der rechten Seite in sich selbst einsetzen. Es folgt

$$\begin{aligned} \nu(i) &= \sum_{j_1, j_2 \neq \ell} p_{j_2 j_1} p_{j_1 i} \nu(j_2) + \sum_{j_1 \neq \ell} p_{\ell j_1} p_{j_1 i} + \mathbb{E}_\ell \left(\mathbb{1}_{\tau_\ell \geq 1} \mathbb{1}_{X_1 = i} \right) \\ &= \sum_{j_1, j_2 \neq \ell} p_{j_2 j_1} p_{j_1 i} \nu(j_2) + \mathbb{E}_\ell \left(\sum_{s=1}^{2 \wedge \tau_\ell} \mathbb{1}_{X_s = i} \right). \end{aligned} \tag{8.114}$$

Weitere Iteration liefert für jedes $n \in \mathbb{N}$

$$\begin{aligned} \nu(i) &= \sum_{j_1, j_2, \ldots j_n \neq \ell} p_{j_n j_{n-1}} \cdots p_{j_2 j_1} p_{j_1 i} \nu(j_n) + \mathbb{E}_\ell \left(\sum_{s=1}^{n \wedge \tau_\ell} \mathbb{1}_{X_s = i} \right) \\ &\geq \mathbb{E}_\ell \left(\sum_{s=1}^{n \wedge \tau_\ell} \mathbb{1}_{X_s = i} \right). \end{aligned} \tag{8.115}$$

Da der letzte Ausdruck mit n gegen $\nu_\ell(i)$ konvergiert, folgt, wie angekündigt, $\nu(i) \geq \nu_\ell(i)$, und der Beweis ist abgeschlossen. □

Korollar 8.34. *Für positive rekurrente Markovketten gilt*

$$\mu(j) = \frac{1}{\mathbb{E}_j(\tau_j)}. \tag{8.116}$$

Beweis. Wähle $\ell = j$ in der Definition von $\mu(j)$, und beachte, dass

$$\nu_j(j) = \mathbb{E}_j(\sum_{t=1}^{\tau_j} \mathbb{1}_{X_t = x}) = 1. \tag{8.117}$$

□

Wir sehen, dass die positive Rekurrenz notwendig ist, um die Existenz eines normierbaren invarianten Maßes zu sichern. Wir wollen nun zeigen, dass unter der weiteren Annahme der Aperiodizität auch die Konvergenz gegen das invariante Wahrscheinlichkeitsmaß gegeben ist.

Zunächst zeigen wir, dass die Existenz eines strikt positiven invarianten Wahrscheinlichkeitsmasses positive Rekurrenz impliziert.

Lemma 8.35. *Sei X eine irreduzible Markovkette mit abzählbarem Zustandsraum. Wenn X ein invariantes Wahrscheinlichkeitsmaß μ besitzt, dann ist $\mu(i) = 1/\mathbb{E}_i\tau_i$, und X ist positiv rekurrent.*

Beweis. Da μ Wahrscheinlickeitsmaß ist, so muss wegen der Irreduzibilität für jeden Zustand ℓ für geeignetes n gelten, dass $\mu(\ell) = \sum_{i\in S}\mu(i)(p^n)_{i\ell} > 0$. Dann ist $\lambda(j) \equiv \mu(j)/\mu(\ell)$ invariantes Maß mit $\lambda(i) = 1$. Dann haben wir aber im vorigen Beweis gesehen, dass $\lambda(k) \geq \nu_\ell(k)$. Daher gilt

$$\mathbb{E}_\ell[\tau_\ell] = \sum_{i\in S}\nu_\ell(i) \leq \sum_{i\in S}\frac{\mu(i)}{\mu(\ell)} = \frac{1}{\mu(\ell)} < \infty. \tag{8.118}$$

Daher ist X positiv rekurrent. □

Satz 8.36. *Sei X eine irreduzible, aperiodische und positiv rekurrente Markovkette mit abzählbarem Zustandsraum S, Übergangsmatrix P und invarianter Wahrscheinlichkeitsverteilung μ. Dann gilt für jede Anfangsverteilung π_0, dass für alle $i \in S$,*

$$\lim_{n\uparrow\infty}(\pi_0 P^n)_i = \mu(i). \tag{8.119}$$

Beweis. Der Beweis benutzt die sogenannte "Kopplungsmethode". Sei π_0 die Anfangsverteilung unserer Kette X. Dann konstruieren wir eine zweite, von X unabhängige Markovkette mit derselben Übergangsmatrix aber mit Anfangsverteilung μ. Wir definieren eine Stoppzeit T bezüglich der Filtrierung $\mathfrak{F}_n \equiv \sigma(X_0, Y_0, X_1, Y_1, \ldots, X_n, Y_n)$ als

$$T \equiv \inf\{n : X_n = Y_n = i\}, \tag{8.120}$$

wo $i \in S$ ein beliebiger Zustand in S ist.

Wir zeigen zunächst, dass T fast sicher endlich ist. Dazu betrachten wir das Paar $W = (X, Y)$ als Markovkette mit Zustandsraum $S \times S$ und Übergangsmatrix $\widetilde{P}$ mit Elementen

$$\tilde{p}_{(ik)(jm)} \equiv p_{ij}p_{km}. \tag{8.121}$$

Die Anfangsverteilung dieser Kette ist $\tilde{\pi}_0((jk)) = \pi_0(j)\mu(k)$. Weil P irreduzibel und aperiodisch ist, so existiert für jedes i, j, k, ℓ ein n, so dass

$$\tilde{p}^n_{(ik)(jm)} = p^n_{ij}p^n_{km} > 0. \tag{8.122}$$

Daher ist W irreduzibel. Weiter ist offensichtlich, dass die invariante Verteilung $\tilde{\mu}$ der Kette W gegeben is durch

$$\tilde{\mu}((jk)) = \mu(j)\mu(k) > 0. \tag{8.123}$$

Daher ist W positiv rekurrent. Da $T = \inf\{n \geq 0 : W_n = (ii)\}$, ist $\mathbb{E}T < \infty$ und somit $\mathbb{P}(T < \infty) = 1$.

Nun konstruieren wir eine neue Markovkette Z mit Zustandsraum S, nämlich

$$Z_n = \begin{cases} X_n, & \text{wenn } n < T \\ Y_n, & \text{wenn } n \geq T. \end{cases} \tag{8.124}$$

Diese Markovkette hat aber dieselbe Verteilung wir X, was man formal mit der starken Markoveigenschaft beweist.

Daraus folgt nun aber

$$\begin{aligned} \mathbb{P}(X_n = i) &= \mathbb{P}(Z_n = i) \\ &= \mathbb{P}(Z_n = i \wedge \{n < T\}) + \mathbb{P}(Z_n = i \wedge \{n \geq T\}) \\ &= \mathbb{P}(X_n = i \wedge \{n < T\}) + \mathbb{P}(Y_n = i \wedge \{n \geq T\}) \\ &= \mathbb{P}(Y_n = i) + -\mathbb{P}(Y_n = i \wedge \{n < T\}) + \mathbb{P}(X_n = i | \{n < T\}) \\ &= \mu(i) + (\mathbb{P}(Y_n = i | n < T) - \mathbb{P}(X_n = i | n < T))\,\mathbb{P}(n < T). \end{aligned} \tag{8.125}$$

Nun ist aber der Ausdruck in der Klammer im Betrag kleiner als eins und der Koeffizient $\mathbb{P}(n < T)$ strebt nach Null, wenn $n \uparrow \infty$. Damit ist die Behauptung bewiesen. □

Anmerkung. Beachte, dass zum Beweis der Irreduzibilität der Kette W die Aperiodizität der Kette X notwendig war. So ist zum Beispiel im einfachsten Beispiel der deterministischen periodischen Kette mit Zustandsraum $\{1, 2\}$ der Zustand $(1, 2)$ nicht vom Zustand $(1, 1)$ erreichbar. Der Zustandsraum der Kette W zerfällt dann in die Klassen $C_1 = \{(12), (2, 1)\}$ und $C_2 = \{(11), (22)\}$.

Anmerkung. Die Chebeyshev Ungleichung liefert $\mathbb{P}(T > n) \leq \frac{\mathbb{E}T}{n}$. Damit liefert dieser Beweis für den Fall, dass der Zustandsraum endlich ist ein schwächeres Resultat. Allerdings könnte man dann auch zeigen, dass für $\lambda > 0$ klein genug, $\mathbb{E}\exp(\lambda T) < \infty$, woraus in dann exponentiell schnelle Konvergenz zum Gleichgewicht folgt.

Wir wollen noch anmerken, dass für transiente Zustände, i, einer Markovkette gilt, dass für alle j und für jedes invariante Maß μ,

$$\lim_{n \uparrow \infty} (p^n)_{ji} = 0 = \mu(i). \tag{8.126}$$

Es gilt nämlich, dass wegen Lemma 8.119

$$\sum_{n=0}^{\infty} (p^n)_{ji} \leq \mathbb{E}_i \left(\sum_{n=0}^{\infty} \mathbb{1}_{X_n = i} \right) < \infty. \tag{8.127}$$

Daraus folgt aber die Behauptung sofort.

Abschliessend bemerken wir noch, dass der starke Ergodensatz (Satz 8.27) auch für positive rekurrente Markovketten mit abzählbarem Zustandsraum gilt. Um dies zu sehen, dass im Beweis dieses Satzes die Annahme endlichen Zustandsraumes nur benutzt wird um die Existenz und Eindeutigkeit einer invarianten Verteilung sowie die Endlichkeit von $\mathbb{E}_\ell \tau_\ell$ sicherzustellen, was aber im positiv rekurrenten Fall auch gilt.

Literaturverzeichnis

1. P. Billingsley. *Probability and measure*. Wiley Series in Probability and Mathematical Statistics. John Wiley & Sons Inc., New York, 1995.
2. Yuan Shih Chow and Henry Teicher. *Probability theory*. Springer Texts in Statistics. Springer-Verlag, New York, third edition, 1997.
3. William Feller. *An introduction to probability theory and its applications. Vol. I*. Third edition. John Wiley & Sons Inc., New York, 1968.
4. William Feller. *An introduction to probability theory and its applications. Vol. II*. Second edition. John Wiley & Sons Inc., New York, 1971.
5. H.-O. Georgii. Spontaneous magnetization of randomly dilute ferromagnets. *J. Statist. Phys.*, 25(3):369–396, 1981.
6. Hans-Otto Georgii. *Stochastik*. de Gruyter Lehrbuch. Walter de Gruyter & Co., Berlin, 2002.
7. Samuel Karlin and Howard M. Taylor. *A first course in stochastic processes*. Academic Press [A subsidiary of Harcourt Brace Jovanovich, Publishers], New York-London, second edition, 1975.
8. G. Kersting and A. Wakolbinger. *Elementare Stochastik*. Birkhäuser, Basel, Boston, Berlin, 2008.
9. A. Klenke. *Wahrscheinlichkeitstheorie*. Springer-Verlag, New York, 2006.
10. J. W. Lindeberg. Eine neue Herleitung des Exponentialgesetzes in der Wahrscheinlichkeitsrechnung. *Math. Zeitschrift*, 15(4):211–225, 1922.

Glossary

$\mathfrak{A}$ Algebra

$\mathfrak{B}$ Borelsche σ-Algebra

$\mathfrak{F}$ σ-algebra

$\mathfrak{C}$ Mengen-System

$\mathcal{D}(\mathfrak{C})$ von $\mathfrak{C}$ erzeugtes Dynkinsystem

$\sigma(\mathfrak{C})$ von $\mathfrak{C}$ erzeugte σ-Algebra

Ω Menge

$\mathbb{P}$ Wahrscheinlichkeitsmaß, meist auf einen abstrakten W-Raum

μ Maß

P_f Bildmaß von $\mathbb{P}$ unter f

$\mathbb{E}$ Erwartung bezüglich $\mathbb{P}$

$\mathbb{P}(A|B)$ Bedingte Wahrscheinlichkeit von A gegeben B

$\mathcal{N}(m, \sigma^2)$ Gaußverteilung mit Mittelwert m und Varianz σ^2

F Verteilungsfunktion

$\mathbb{1}_A$ Indikatorfunktion der Menge A

δ_x Diracmaß auf x

X, Y, Z Zufallsvariablen

$\sigma(X)$ von X erzeugte σ-Algebra

τ Stoppzeit

τ_D Erste Treffzeit von D.

Sachverzeichnis

σ-Additivität, 13
σ-endlich, 14
Übergangsmatrix, 123, 124
σ-Algebra
  erzeugt von Funktionen, 43
  Produkt, 46

absolut stetig, 33
Algebra
  Mengen, 11
Anfangsverteilung, 124
aperiodisch, 132
Arcussinusgesetz, 63

Bayes'sche Formel, 41
Bayes, Th., 42
Bernoulli
  Verteilung, 34
Bildmaß, 31
Binomialverteilung, 34
Black-Sholes-Formel, 60
Borel-σ-Algebra, 14
Borel-Mengen, 14
Borell-Cantelli Lemmata, 79

Carathéodory
  Satz von, 20
Cauchyverteilung, 38
charakteristische Funktion, 98
Chebyshev Ungleichung, 87

Dirac-Maß, 33
Dynkin-System, 16

Eintrittszeiten, 140
empirische Verteilung, 8
Ereignisse, 1
  unabhängige, 41
Ergodensatz, 143, 152
  für positiv rekurrente Ketten, 152
ergodische Markovkette, 130
Erwartungswert, 26, 85
erzeugende Funktion, 86
Exponentialverteilung, 37

Faltung, 68
Fatou's Lemma, 29
Filtrierung, 139
Folgen unabhängiger Zufallsvariablen, 53
Fouriertransformation, 98
Frequenz, 7
Fubini
  Satz von, 51
Funktion
  charakteristische, 98
  einfache, 25
  integrierbare, 26
  messbare, 23

Gaußverteilung, 37, 68
geometrische Verteilung, 35
Gesetz der großen Zahlen, 89
  schwaches, 89
  starkes, 89, 91
Gleichverteilung, 37
Graph
  einer Markovkette, 128
Grenzwertsatz, 97
  zentraler, 105, 106
große Abweichungen, 89

harmonische Funktion, 146
hedging, 59

induziertes Maß, 31

Inhalt, 18
Integral, 24
integrierbare Funktion, 26
invariante Verteilung, 127
Inversionsformel
  von Lévy, 101
irreduzibel, 129
Irrfahrt, 56

Jordan Normalform, 131

Kolmogorov Axiome, 14
Kolmogorov Ungleichung, 91
kommunizierende Klassen, 129
Konsistenz, 110
Konvergenz, 71
  fast sichere, 78
  in Verteilung, 73
  in Wahrscheinlichkeit, 78
  monotone, 26
  schache, 71
  von Maßen, 72
  von Verteilungsfuktionen, 71
  von Zufallsvariablen, 73
Kopplung, 152

Lévy
  Satz von, 103
Lévy's Inversionsformel, 101
Lebesgue
  dominierter Konvergenzsatz, 29
Lebesgue Maß, 29
Lebesgue, H.L., 22
Lebesgue-Maß, 22
Leibniz Regel, 87
Lemma
  von Fatou, 29
likelihood Funktion, 115, 116

Maß, 14
  σ-endlich, 14
  absolut stetiges, 32
  Dirac, 33
  induziertes, 31
Markov Prozess, 121
Markovkette
  ergodische, 130
Markovketten Monte-Carlo, 144
Matrix
  stochastische, 123, 126
maximum-likelihood
  Prinzip, 116
  Schätzer, 116
Mengenalgebra, 11
Mengensystem, 11
  durchschnittstabiles, 16
  maßbestimmendes, 20
Messraum, 12
Modell
  statistisches, 115
Momente, 86
Monte-Carlo Verfahren, 144

Normalform
  Jordan, 131

Optionspreise, 58

paarweise unabhängig, 41
Parameterschätzung, 114
Periodizität, 132
Perron-Frobenius
  Satz von, 128, 130
Poissonverteilung, 35
positiv rekurrent, 149
Prämaß, 18
Produkt-σ-Algebra, 46, 53
Produktmaß, 46
Produktraum, 46
  unendlicher, 53
Prozess
  stochastischer, 53

Rademacher Variablen, 56
Regression
  lineare, 114
rekurrent, 137
  positiv, 149
Rekurrenz, 149
Riemann Integral, 29
Ruin-Problem, 61

Satz
  von Carathéodory, 20
  von der monotonen Konvergenz, 26
  von Fubini-Lebesgue, 51
  von Fubini-Tonnelli, 50
  von Lévy, 103
  von Lebesgue, 29
Satz von de Moivre-Laplaca, 74
Schätzer
  erwartungstreuer, 112
  für Mittelwert, 112
  für Varianz, 113
  konsistente, 110
Stirling formula, 74
stochastische Matrix, 123, 126
stochastischer Prozess, 53, 121

Stoppzeit, 139, 140
Strategie, 57

transient, 137
Transienz, 149
Trunkation, 94

unabhängig
  Ereignisse, 41
  Folgen von Zufallsvariablen, 53
  Zufallsvariablen, 44
Ungleichung
  Chebyshev, 87
  Kolmogorov, 91
  Markov, 88
Unkorreliertheit, 45
unwesentlich, 137

Varianz, 86
Verteilung
  invariante, 127
  einer Zufallsvariablen, 31
  empirische, 8
  invariante, 150
  stabile, 68
Verteilungsfunktion, 20
Vorwärtsgleichung, 146

Wahrscheinlichkeit
  bedingte, 40
Wahrscheinlichkeitsdichte, 33
Wahrscheinlichkeitsmaß, 13
Wahrscheinlichkeitsraum, 13
  abstrakter, 32
wesentlich, 137

Zentraler Grenzwertsatz, 74
zentraler Grenzwertsatz, 105, 106
Zufall, 1
Zufallsvariable, 23
  Summen von, 55
  unabhängige, 44
  unabhängige, identisch verteilte, 54
Zylindermengen, 53